

Regressão Linear com Enfoque Bayesiano

Combined Cycle Power Plant

Disciplina: Estatística Bayesiana

16 de junho de 2026

- **Objetivo Principal:** Modelar a relação entre covariáveis ambientais e a produção líquida horária de energia elétrica.
- **Unidade de Medida da Resposta:** Megawatts (MW).
- **Dataset:** *Combined Cycle Power Plant* (UCI Machine Learning Repository).
- **Conjunto de dados:**
 - Contém originalmente $n_{Total} = 9568$ observações compiladas ao longo de 6 anos (2006–2011).

Introdução

Estrutura e Descrição das Variáveis

Tabela: Preditores Ambientais e Variável Resposta

Variável	Descrição	Unidade de Medida
AT	Temperatura Ambiente	°C
V	Vácuo de Exaustão	cm Hg
AP	Pressão Atmosférica	mbar
RH	Umidade Relativa do Ar	%
PE	Potência Elétrica Líquida (Resposta)	MW

O Paradigma Bayesiano

Diferente da regressão frequentista tradicional, a inferência bayesiana trata os parâmetros do modelo (β e σ^2) como **variáveis aleatórias**, permitindo a incorporação de conhecimento prévio por meio de distribuições *a priori*.

- **Modelo Proposto:** Regressão linear com a priori conjugada **Normal–Gama Inversa** para o par de parâmetros (β, σ^2) .
- **Principais Vantagens:**
 - Possibilita a derivação analítica direta (exata) da distribuição posterior conjunta.
 - Fornece uma interpretação probabilística natural sobre os coeficientes de regressão e a variabilidade do erro.

1. Conceito Teórico

1.1 Modelo Generativo

Considere a formulação matricial clássica para o modelo de regressão linear:

$$\mathbf{Y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Onde $\mathbf{Y} \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$, $\boldsymbol{\beta} \in \mathbb{R}^p$ e o vetor de erros assume $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 I_n)$.

A distribuição condicional do vetor de respostas é expressa como:

$$\mathbf{Y} \mid \boldsymbol{\beta}, \sigma^2 \sim \mathcal{N}_n(X\boldsymbol{\beta}, \sigma^2 I_n)$$

Omitindo-se termos constantes, a função de **verossimilhança** do processo é dada por:

$$L(\boldsymbol{\beta}, \sigma^2) \propto (\sigma^2)^{-n/2} \exp \left(-\frac{(\mathbf{Y} - X\boldsymbol{\beta})^\top (\mathbf{Y} - X\boldsymbol{\beta})}{2\sigma^2} \right)$$

1. Conceito Teórico

1.2 Especificação da Distribuição a Priori Conjugada

Define-se a estrutura hierárquica da priori para o par de parâmetros (β, σ^2) :

- A variância residual σ^2 segue uma distribuição **Gama Inversa** (IG):

$$\sigma^2 \sim \text{IG}(a_0, b_0) \implies p(\sigma^2) = \frac{b_0^{a_0}}{\Gamma(a_0)} (\sigma^2)^{-a_0-1} \exp\left(-\frac{b_0}{\sigma^2}\right)$$

- Condicionalmente a σ^2 , o vetor de coeficientes β segue uma **Normal Multivariada**:

$$\beta \mid \sigma^2 \sim \mathcal{N}_p(\mu_0, \sigma^2 \Lambda_0^{-1})$$

A Priori Conjunta Normal–Gama Inversa (NIG)

A composição conjunta dos parâmetros resulta na especificação:

$$(\beta, \sigma^2) \sim \text{NIG}(\mu_0, \Lambda_0, a_0, b_0)$$

Onde $\Lambda_0 \in \mathbb{R}^{p \times p}$ é uma matriz de precisão *a priori* simétrica definida positiva.

1. Conceito Teórico

1.3 Aplicação do Teorema de Bayes

A distribuição a posteriori conjunta dos parâmetros é proporcional ao produto da densidade amostral (verossimilhança) pela densidade conjunta *a priori*:

$$p(\beta, \sigma^2 \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \beta, \sigma^2) p(\beta, \sigma^2)$$

Ao agrupar de forma ordenada as potências da variância σ^2 e os termos contidos na exponencial, a expressão conjunta torna-se:

$$p(\beta, \sigma^2 \mid \mathbf{Y}) \propto (\sigma^2)^{-a_0-1-\frac{n}{2}-\frac{p}{2}} \exp \left[-\frac{1}{\sigma^2} \left(b_0 + \frac{1}{2}(\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta) + \frac{1}{2}(\beta - \mu_0)^\top \Lambda_0 (\beta - \mu_0) \right) \right]$$

1. Conceito Teórico

1.4 Álgebra e Fechamento de Quadrados

Expandindo as formas quadráticas do expoente associadas a β , obtemos a seguinte relação linear-quadrática:

$$\beta^\top (X^\top X + \Lambda_0) \beta - 2\beta^\top (X^\top \mathbf{Y} + \Lambda_0 \mu_0) + \mathbf{Y}^\top \mathbf{Y} + \mu_0^\top \Lambda_0 \mu_0$$

Desta estrutura, isolamos os componentes definindo os novos **parâmetros posteriores**:

$$\boxed{\Lambda_n = X^\top X + \Lambda_0} \quad \text{e} \quad \boxed{\mu_n = \Lambda_n^{-1} (X^\top \mathbf{Y} + \Lambda_0 \mu_0)}$$

Ao completar o quadrado em relação ao vetor β , a expressão final reduz-se a:

$$(\beta - \mu_n)^\top \Lambda_n (\beta - \mu_n) + \mathbf{Y}^\top \mathbf{Y} + \mu_0^\top \Lambda_0 \mu_0 - \mu_n^\top \Lambda_n \mu_n$$

1. Conceito Teórico

1.5 e 1.6 Atualização dos Hiperparâmetros Posteriores

Os parâmetros posteriores do modelo são atualizados analiticamente por meio das expressões:

Parâmetros da Distribuição Posterior

$$a_n = a_0 + \frac{n}{2}$$

$$b_n = b_0 + \frac{1}{2} (\mathbf{Y}^\top \mathbf{Y} + \boldsymbol{\mu}_0^\top \Lambda_0 \boldsymbol{\mu}_0 - \boldsymbol{\mu}_n^\top \Lambda_n \boldsymbol{\mu}_n)$$

Dessa forma, conclui-se formalmente que a distribuição posterior conjunta é:

$$(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{Y}) \sim \text{NIG}(\boldsymbol{\mu}_n, \Lambda_n, a_n, b_n)$$

Que pode ser fatorada recursivamente nas distribuições condicionais e marginais:

$$\sigma^2 \mid \mathbf{Y} \sim \text{IG}(a_n, b_n) \quad \text{e} \quad \boldsymbol{\beta} \mid \sigma^2, \mathbf{Y} \sim \mathcal{N}_p(\boldsymbol{\mu}_n, \sigma^2 \Lambda_n^{-1})$$

1. Conceito Teórico

1.7 Interpretação Estatística do Modelo

Os parâmetros posteriores completos tornam-se:

- μ_0 : média *a priori* dos coeficientes
- Λ_0 : precisão *a priori* (quanto mais concentrada a prior, maior Λ_0)
- a_0, b_0 : informação prévia sobre a variância residual

A Média Posterior como Média Ponderada

$$\mu_n = (X^\top X + \Lambda_0)^{-1}(X^\top \mathbf{Y} + \Lambda_0 \mu_0)$$

A equação explicita que a estimativa posterior dos coeficientes configura uma média ponderada combinando a informação proveniente dos dados amostrais ($X^\top \mathbf{Y}$) com o conhecimento estabelecido *a priori* ($\Lambda_0 \mu_0$).

2. Dados

Inspeção e Amostragem Computacional

- **mostral Original:** $n = 9568$ linhas contendo 5 variáveis contínuas.
- Com a finalidade de construir uma análise prática mais prática, extraiu-se uma subamostra aleatória de **300 observações**.
- **Seleção aleatória:** Foi utilizada a semente `set.seed(20260610)`.
- **Avaliação do banco de dados:** Após uma análise detalhada via código `(colSums(is.na(dados)))` acusou a presença de ****zero**** valores faltantes ou inconsistências nulas em todas as colunas do dataset amostrado.

3. Análise Descritiva

Objetivos do Estudo Exploratório

Antes de ajustar o modelo, fazemos a análise exploratória dos dados. Isso é fundamental para:

- 1 **Avaliar a escala dimensional** de cada covariável do sistema, etapa indispensável para orientar a calibração adequada da matriz de hiperparâmetros de precisão *a priori* (Λ_0).
- 2 **Rastrear colinearidade** (associações lineares internas) entre os preditores ambientais para precaver redundâncias de variância.
- 3 **Verificar preliminarmente a hipótese de linearidade** univariada cruzando individualmente cada preditor com a resposta de interesse (PE).

3. Análise Descritiva

Resumo Estatístico das Variáveis (Amostra $n = 300$)

Tabela: Medidas de Posição, Distribuição e Quartis

Variável	Mínimo	1º Quartil	Mediana	Média	3º Quartil	Máximo
AT (°C)	2,34	12,49	19,09	19,23	26,02	32,95
V (cm Hg)	34,03	41,38	52,38	54,20	66,79	79,74
AP (mbar)	997,70	1009,20	1012,90	1013,54	1018,00	1031,70
RH (%)	32,25	63,87	74,91	74,01	85,74	100,07
PE (MW)	425,30	438,50	453,90	455,20	471,80	495,20

3. Análise Descritiva

Análise de Dispersão e Variabilidade

Tabela: Variabilidade Marginal das Variáveis

Variável	Média Amostral	Desvio-Padrão (DP)	Coeficiente de Variação (CV%)
AT	19,227	7,805	40,59%
V	54,205	12,891	23,78%
AP	1013,544	6,077	0,60%
RH	74,011	14,812	20,01%
PE	455,202	17,906	3,93%

- **Destaque de Escala:** A pressão barométrica (AP) manifesta extrema estabilidade relativa ($CV = 0,60\%$), contrastando com a temperatura ambiente (AT), que exhibe a dispersão proporcional mais acentuada ($CV = 40,59\%$).

3. Análise Descritiva

Matriz de Correlação Linear de Pearson

Tabela: Coeficientes de Correlação Inter-variáveis

	AT	V	AP	RH	PE
AT	1,0000	0,8595	-0,5830	-0,5227	-0,9524
V	0,8595	1,0000	-0,5026	-0,2846	-0,8929
AP	-0,5830	-0,5026	1,0000	0,0939	0,5947
RH	-0,5227	-0,2846	0,0939	1,0000	0,3630
PE	-0,9524	-0,8929	0,5947	0,3630	1,0000


- **Associação com a Resposta:** As covariáveis AT ($r = -0,9524$) e V ($r = -0,8929$) exibem forte acoplamento linear negativo com a potência gerada (PE).
- **Alerta de Colinearidade:** A forte correlação mútua observada entre a temperatura e o vácuo (AT e V com $r = 0,8595$) indica um expressivo compartilhamento de informação explicativa.

3. Análise Descritiva

Distribuições Marginais (Histogramas)

- **AT e V (Bimodais):** Apresentam comportamento com dois picos nítidos.
- **AP (Simétrica):** Exibe distribuição aproximadamente Normal (em forma de sino).
- **RH (Assimétrica):** Assimetria à esquerda, indicando maior frequência de dias com umidade relativa elevada.
- **PE (Resposta):** Percebe-se um padrão bimodal, concentrando a produção em dois patamares de potência.

Análise de Frequência e Densidade




3. Análise Descritiva

Relação dos Preditores com a Resposta (PE)

- **AT vs. PE** ($r = -0,95$): Fortíssima associação linear negativa. Configura-se como o preditor mais influente no rendimento energético.
- **V vs. PE** ($r = -0,89$): Relação negativa acentuada, embora exiba maior dispersão nos valores intermediários.
- **AP vs. PE** ($r = 0,59$): Correlação positiva moderada; elevações na pressão atmosférica tendem a aumentar a potência líquida.
- **RH vs. PE** ($r = 0,36$): Associação positiva fraca e comportamento ruidoso, sugerindo menor peso explicativo direto.

Comportamento Linear das Variáveis



4. Modelo de Regressão Linear

Formalizando: Notação e Definições

Anteriormente dizemos que a formulação matricial para o modelo é:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Ou seja:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i, \quad i = 1, \dots, n$$

Onde $i = 1, 2, \dots, n$ é o índice da observação. Definimos as seguintes quantidades para a i -ésima observação:

Onde $i = 1, 2, \dots, n$ é o índice da observação. Definimos:

- Y_i : produção líquida de energia (MW)
- x_{i1} : temperatura ambiente AT_i ($^{\circ}\text{C}$)
- x_{i2} : vácuo de exaustão V_i (cm Hg)
- x_{i3} : pressão ambiente AP_i (mbar)
- x_{i4} : umidade relativa RH_i (%)

Interpretação dos parâmetros:

- β_1 : variação esperada em PE para cada aumento de 1°C em temperatura
- β_2 : ... para cada aumento de 1 cm Hg no vácuo
- β_3 : ... para cada aumento de 1 mbar na pressão
- β_4 : ... para cada aumento de 1 pp na umidade relativa
- ε_i : erro aleatório da i -ésima observação

4. Modelo de Regressão Linear

Formalizando: Especificação Matricial

Para usar a forma compacta (matricial),

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

precisamos definir o seguinte:

$$\mathbf{Y}_{n \times 1} = (Y_1, \dots, Y_n)^\top, \quad \boldsymbol{\beta}_{p \times 1} = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4)^\top$$

$$\mathbf{X}_{n \times p} = \begin{pmatrix} 1 & x_{11} & x_{12} & x_{13} & x_{14} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & x_{n4} \end{pmatrix}$$

com $p = 5$ (intercepto + 4 covariáveis)

5. Especificação Bayesiana

Escolha dos Hiperparâmetros a priori

Escolhemos a distribuição a priori conjugada Normal–Gama Inversa, conforme apresentado na Seção 1:

$$\sigma^2 \sim \text{IG}(a_0, b_0), \quad \beta \mid \sigma^2 \sim \mathcal{N}_p(\mu_0, \sigma^2 \Lambda_0^{-1})$$

de forma que $(\beta, \sigma^2) \sim \mathcal{NIG}(\mu_0, \Lambda_0, a_0, b_0)$.

Hiperparâmetros Escolhidos (Priori Fraca/Não-Informativa)

$$\mu_0 = \mathbf{0}_5, \quad \Lambda_0 = 10^{-4} \cdot I_5, \quad a_0 = b_0 = 0,01$$

- Valores pequenos de Λ_0 refletem grande incerteza *a priori* sobre os coeficientes β (difusa).
- Com $a_0 = b_0 = 0,01$, a distribuição IG *a priori* da variância σ^2 também é pouco informativa.
- Esta escolha permite verificar a convergência da posterior bayesiana para o estimador clássico de Mínimos Quadrados Ordinários (MQO).

6. Atualização Bayesiana

Cálculo Computacional da Posteriori

Com base nas expressões analíticas derivadas na Seção 1, calculamos (com software R) diretamente os hiperparâmetros posteriores Λ_n , μ_n , a_n e b_n : Resultado: $a_n = 150,01$ e $b_n = 2850,664$.

Tabela: Vetor de Médias a Posterioris μ_n

Parâmetro	Estimativa Pontual (perda quadrática)
Intercepto (β_0)	464,220183
AT (β_1)	-1,928991
V (β_2)	-0,276881
AP (β_3)	0,054413
RH (β_4)	-0,163096

- A média a posteriori μ_n fornece a estimativa pontual de Bayes para cada coeficiente, sob perda quadrática.
- Sinais e magnitudes são consistentes com as correlações observadas na análise descritiva (Seção 3).

6. Atualização Bayesiana

Variância a Posteriori de σ^2 e Desvio dos Coeficientes

A esperança posterior da variância residual é dada por:

$$E[\sigma^2 \mid \mathbf{Y}] = \frac{b_n}{a_n - 1} = 19,1307 \implies \text{DP residual} \approx 4,3739 \text{ MW}$$

A matriz de covariância posterior dos coeficientes (condicional a $\sigma^2 = E[\sigma^2 \mid \mathbf{Y}]$) é:

$$\text{Cov}(\beta \mid \mathbf{Y}) = E[\sigma^2 \mid \mathbf{Y}] \cdot \Lambda_n^{-1}$$

Tabela: Desvios-Padrão Posteriores Marginais dos Coeficientes

	Intercepto	AT	V	AP	RH
DP	55,563262	0,086409	0,041789	0,053779	0,022872

6. Atualização Bayesiana

Resumo da Posterior e Intervalos de Credibilidade 95%

A distribuição marginal de cada coeficiente é $\beta_j | \mathbf{Y} \sim t_{2a_n} \left(\mu_{n,j}, \frac{b_n}{a_n} [\Lambda_n^{-1}]_{jj} \right)$, com $2a_n$ graus de liberdade.

Tabela: Resumo da Distribuição Posterior dos Coeficientes

Parâmetro	Média Posterior	DP Posterior	IC95% (Inf.)	IC95% (Sup.)
Intercepto (β_0)	464,22018	55,56326	355,24216	573,19820
AT (β_1)	-1,92899	0,08641	-2,09847	-1,75951
V (β_2)	-0,27688	0,04179	-0,35884	-0,19492
AP (β_3)	0,05441	0,05378	-0,05107	0,15989
RH (β_4)	-0,16310	0,02287	-0,20796	-0,11824

- Note:** O IC (95%) de AP contém o zero, sugerindo incerteza relevante sobre o sinal de seu efeito sobre PE nesta amostra.

6. Atualização Bayesiana

Interpretação dos Coeficientes a Posteriori estimados

- β_1 (**AT**): coeficiente negativo – temperaturas mais altas reduzem a eficiência das turbinas a gás, diminuindo a potência produzida.
- β_2 (**V**): coeficiente negativo – maior vácuo de exaustão (pressão mais baixa no condensador) reduz a eficiência da turbina a vapor.
- β_3 (**AP**): coeficiente positivo – maior pressão atmosférica favorece a densidade do ar nas turbinas a gás.
- β_4 (**RH**): coeficiente ligeiramente negativo – umidade mais alta pode reduzir levemente o desempenho.

7 Comparação com Método de Mínimos Quadrados (Frequentista)

Bayesiano (Priori Fraco) vs. Mínimos Quadrados Ordinários

Com prior não-informativo ($\Lambda_0 \rightarrow 0$), espera-se que a média posterior μ_n convirja para o estimador clássico $\hat{\beta} = (X^\top X)^{-1} X^\top Y$.

Tabela: Comparação: MQO vs. Bayesiano (Prior Fraco)

Parâmetro	MQO	Bayesiano
Intercepto	471,834587	464,220183
AT	-1,934442	-1,928991
V	-0,276200	-0,276881
AP	0,047048	0,054413
RH	-0,164198	-0,163096


- As estimativas bayesianas são praticamente idênticas às do MQO, como esperado sob prior difuso.
- **Diferença fundamental:** na abordagem bayesiana, μ_n é a média de uma distribuição de probabilidade sobre β , e os intervalos de credibilidade possuem interpretação probabilística direta – diferentemente dos intervalos de confiança frequentistas.

8. Análise de Resíduos

Gráficos de Diagnóstico

- **Resíduos vs. Ajustados:** dispersão sem padrão sistemático aparente em torno de zero, indicando homocedasticidade razoável.
- **QQ-plot:** pontos próximos da reta de referência, sugerindo aproximação adequada à normalidade nos resíduos.
- **Histograma:** forma aproximadamente simétrica e unimodal, compatível com a suposição gaussiana do modelo.
- **Resíduos por Ordem:** ausência de tendência ou autocorrelação visível ao longo do índice das observações.

Diagnóstico Gráfico dos Resíduos



8. Análise de Resíduos

Métricas de Validação

- O R^2 foi de 0,94075 isso indica que 94% da variabilidade total da Potência Elétrica é explicada pelas quatro variáveis ambientais;
- O MAE foi de 3,59 isso indica que em média as previsões do modelo erram em cerca de 3,59 MegaWatts;
- O RMSE foi de 4,35 isso indica que em média as previsões do modelo erram em cerca de 4,35 MegaWatts;

Como o RMSE mede o quadrado dos desvios e o MAE mede o valor absoluto dos desvios o primeiro dá peso maior a grandes desvios, a diferença entre os dois é pequena, indicando que há poucos outliers ou que eles pouco desviam.

9. Distribuições Posteriores Marginais dos Coeficientes

A distribuição posteriori dos coeficientes quando marginalizada segue uma t-Student não central de $2a_n$ graus de liberdade:

$$\beta_j \mid \mathbf{Y} \sim t_{2a_n} \left(\mu_{n,j}, \frac{b_n}{a_n} [\Lambda_n^{-1}]_{jj} \right)$$

Como $n = 9568$ é um valor muito grande a t-Student converge para uma distribuição normal


9. Distribuições Posteriores Marginais dos Coeficientes

A distribuição posteriori dos coeficientes quando marginalizada segue uma t-Student não central de $2a_n$ graus de liberdade:

$$\beta_j \mid \mathbf{Y} \sim t_{2a_n} \left(\mu_{n,j}, \frac{b_n}{a_n} [\Lambda_n^{-1}]_{jj} \right)$$

Como $n = 9568$ é um valor muito grande a t-Student converge para uma distribuição normal

Gráficos das Densidades




10. Predição

Para uma nova observação $\mathbf{x}_\star$ a distribuição preditiva posterior marginaliza sobre β e σ^2 resulta em:

$$Y_\star | \mathbf{Y} \sim t_{2a_n} \left(\mathbf{x}_\star^\top \boldsymbol{\mu}_n, \frac{b_n}{a_n} (1 + \mathbf{x}_\star^\top \boldsymbol{\Lambda}_n^{-1} \mathbf{x}_\star) \right)$$

Para uma estimativa de $\mathbf{x}_\star = [20 \ 55 \ 1010 \ 70]^\top$ uma única predição é de $\mathbf{Y}_\star = 453,952 \text{ MW}$ e $\text{IC}(95\%) = [445.349, 462.554]$

Observado vs. Predito



11. Conclusões

O modelo de regressão bayesiano se ajusta bem aos dados analisados, fornecendo bons resultados e conclusões a cerca da variável resposta. Apenas uma única covariável (AP-pressão atmosférica) não é estatisticamente significativa.

Os resultados pouco diferem do modelo clássico por primeiramente a função de perda ser a quadrática, segundo assumirmos normalidade (apesar das covariáveis não apresentarem esse comportamento) e gamma inversa para as prioris e principalmente pela grande quantidade de dados.