

Regressão Linear com Enfoque Bayesiano

Combined Cycle Power Plant
Disciplina: Estatística Bayesiana

Gabriela Lins de Albuquerque Marcelo Xinhong Huang Paulo Roberto Salles Neto

Universidade Federal de São Carlos
Departamento de Estatística

Junho, 2026

Introdução

O Problema e o Conjunto de Dados

- **Objetivo Principal:** Modelar a relação entre covariáveis ambientais e a produção líquida horária de energia elétrica.
- **Unidade de Medida da Resposta:** Megawatts (MW).
- **Dataset:** *Combined Cycle Power Plant* ([UCI Machine Learning Repository](#)).
- **Conjunto de dados:**
 - Contém originalmente $n_{Total} = 9568$ observações compiladas ao longo de 6 anos (2006–2011).

Introdução

Estrutura e Descrição das Variáveis

Tabela: Preditores Ambientais e Variável Resposta

Variável	Descrição	Unidade de Medida
AT	Temperatura Ambiente	°C
V	Vácuo de Exaustão	cm Hg
AP	Pressão Atmosférica	mbar
RH	Umidade Relativa do Ar	%
PE	Potência Elétrica Líquida (Resposta)	MW

O Paradigma Bayesiano

Diferente da regressão frequentista tradicional, a inferência bayesiana trata os parâmetros do modelo (β e σ^2) como **variáveis aleatórias**, permitindo a incorporação de conhecimento prévio por meio de distribuições *a priori*.

- **Modelo Proposto:** Regressão linear com a priori conjugada **Normal–Gama Inversa** para o par de parâmetros (β, σ^2) .
- **Principais Vantagens:**
 - Possibilita a derivação analítica direta (exata) da distribuição a posteriori conjunta.
 - Fornece uma interpretação probabilística natural sobre os coeficientes de regressão e a variabilidade do erro.

1. Conceito Teórico

1.1 Modelo Generativo

Considere a formulação matricial clássica para o modelo de regressão linear:

$$\mathbf{Y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Onde $\mathbf{Y} \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$, $\boldsymbol{\beta} \in \mathbb{R}^p$ e o vetor de erros assume $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 I_n)$.

A distribuição condicional do vetor de respostas é expressa como:

$$\mathbf{Y} \mid \boldsymbol{\beta}, \sigma^2 \sim \mathcal{N}_n(X\boldsymbol{\beta}, \sigma^2 I_n)$$

Omitindo-se termos constantes, a função de **verossimilhança** do processo é dada por:

$$L(\boldsymbol{\beta}, \sigma^2) \propto (\sigma^2)^{-n/2} \exp \left(-\frac{(\mathbf{Y} - X\boldsymbol{\beta})^\top (\mathbf{Y} - X\boldsymbol{\beta})}{2\sigma^2} \right)$$

1. Conceito Teórico

1.2 Especificação da Distribuição a Priori Conjugada

Define-se a estrutura hierárquica da priori para o par de parâmetros (β, σ^2) :

- A variância residual σ^2 segue uma distribuição **Gama Inversa** (IG):

$$\sigma^2 \sim \text{IG}(a_0, b_0) \implies p(\sigma^2) = \frac{b_0^{a_0}}{\Gamma(a_0)} (\sigma^2)^{-a_0-1} \exp\left(-\frac{b_0}{\sigma^2}\right)$$

- Condicionalmente a σ^2 , o vetor de coeficientes β segue uma **Normal Multivariada**:

$$\beta \mid \sigma^2 \sim \mathcal{N}_p(\mu_0, \sigma^2 \Lambda_0^{-1})$$

A Priori Conjunta Normal–Gama Inversa (NIG)

A composição conjunta dos parâmetros resulta na especificação:

$$(\beta, \sigma^2) \sim \text{NIG}(\mu_0, \Lambda_0, a_0, b_0)$$

Onde $\Lambda_0 \in \mathbb{R}^{p \times p}$ é uma matriz de precisão *a priori* simétrica definida positiva.

1. Conceito Teórico

1.3 Aplicação do Teorema de Bayes

A distribuição a posteriori conjunta dos parâmetros é proporcional ao produto da densidade amostral (verossimilhança) pela densidade conjunta *a priori*:

$$p(\beta, \sigma^2 \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \beta, \sigma^2) p(\beta, \sigma^2)$$

Ao agrupar de forma ordenada as potências da variância σ^2 e os termos contidos na exponencial, a expressão conjunta torna-se:

$$p(\beta, \sigma^2 \mid \mathbf{Y}) \propto (\sigma^2)^{-a_0-1-\frac{n}{2}-\frac{p}{2}} \exp \left[-\frac{1}{\sigma^2} \left(b_0 + \frac{1}{2}(\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta) + \frac{1}{2}(\beta - \mu_0)^\top \Lambda_0 (\beta - \mu_0) \right) \right]$$

1. Conceito Teórico

1.4 Álgebra e Fechamento de Quadrados

Expandindo as formas quadráticas do expoente associadas a β , obtemos a seguinte relação linear-quadrática:

$$\beta^\top (X^\top X + \Lambda_0) \beta - 2\beta^\top (X^\top \mathbf{Y} + \Lambda_0 \mu_0) + \mathbf{Y}^\top \mathbf{Y} + \mu_0^\top \Lambda_0 \mu_0$$

Desta estrutura, isolamos os componentes definindo os novos **parâmetros a posteriori**:

$$\boxed{\Lambda_n = X^\top X + \Lambda_0} \quad \text{e} \quad \boxed{\mu_n = \Lambda_n^{-1} (X^\top \mathbf{Y} + \Lambda_0 \mu_0)}$$

Ao completar o quadrado em relação ao vetor β , a expressão final reduz-se a:

$$(\beta - \mu_n)^\top \Lambda_n (\beta - \mu_n) + \mathbf{Y}^\top \mathbf{Y} + \mu_0^\top \Lambda_0 \mu_0 - \mu_n^\top \Lambda_n \mu_n$$

1. Conceito Teórico

1.5 e 1.6 Atualização dos Hiperparâmetros a posteriori

Os parâmetros a posteriori do modelo são atualizados analiticamente por meio das expressões:

Parâmetros da Distribuição a Posteriori

$$a_n = a_0 + \frac{n}{2}$$

$$b_n = b_0 + \frac{1}{2} (\mathbf{Y}^\top \mathbf{Y} + \boldsymbol{\mu}_0^\top \boldsymbol{\Lambda}_0 \boldsymbol{\mu}_0 - \boldsymbol{\mu}_n^\top \boldsymbol{\Lambda}_n \boldsymbol{\mu}_n)$$

Dessa forma, conclui-se formalmente que a distribuição a posteriori conjunta é:

$$(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{Y}) \sim \text{NIG}(\boldsymbol{\mu}_n, \boldsymbol{\Lambda}_n, a_n, b_n)$$

Que pode ser fatorada recursivamente nas distribuições condicionais e marginais:

$$\sigma^2 \mid \mathbf{Y} \sim \text{IG}(a_n, b_n) \quad \text{e} \quad \boldsymbol{\beta} \mid \sigma^2, \mathbf{Y} \sim \mathcal{N}_p(\boldsymbol{\mu}_n, \sigma^2 \boldsymbol{\Lambda}_n^{-1})$$

1. Conceito Teórico

1.7 Interpretação Estatística do Modelo

Os parâmetros a posteriori completos tornam-se:

- μ_0 : média *a priori* dos coeficientes
- Λ_0 : precisão *a priori* (quanto mais concentrada a priori, maior Λ_0)
- a_0, b_0 : informação prévia sobre a variância residual

A Média a Posteriori como Média Ponderada

$$\mu_n = (X^T X + \Lambda_0)^{-1} (X^T \mathbf{Y} + \Lambda_0 \mu_0)$$

A equação explicita que a estimativa a posteriori dos coeficientes configura uma média ponderada combinando a informação proveniente dos dados amostrais ($X^T \mathbf{Y}$) com o conhecimento estabelecido *a priori* ($\Lambda_0 \mu_0$).

2. Dados

Inspeção e Amostragem Computacional

- **Amostra Original:** $n = 9568$ linhas contendo 5 variáveis contínuas.
- Com a finalidade de construir uma análise prática mais prática, extraiu-se uma subamostra aleatória de **300 observações**.
- **Seleção aleatória:** Foi utilizada a semente `set.seed(20260610)`.
- **Avaliação do banco de dados:** Após uma análise detalhada via código `(colSums(is.na(dados)))` acusou a presença de ****zero**** valores faltantes ou inconsistências nulas em todas as colunas do dataset amostrado.

3. Análise Descritiva

Objetivos do Estudo Exploratório

Antes de ajustar o modelo, fazemos a análise exploratória dos dados. Isso é fundamental para:

- ➊ **Avaliar a escala dimensional** de cada covariável do sistema, etapa indispensável para orientar a calibração adequada da matriz de hiperparâmetros de precisão *a priori* (Λ_0).
- ➋ **Rastrear colinearidade** (associações lineares internas) entre os preditores ambientais para precaver redundâncias de variância.
- ➌ **Verificar preliminarmente a hipótese de linearidade** univariada cruzando individualmente cada preditor com a resposta de interesse (PE).

3. Análise Descritiva

Resumo Estatístico das Variáveis (Amostra $n = 300$)

Tabela: Medidas de Posição, Distribuição e Quartis

Variável	Mínimo	1º Quartil	Mediana	Média	3º Quartil	Máximo
AT (°C)	2,34	12,49	19,09	19,23	26,02	32,95
V (cm Hg)	34,03	41,38	52,38	54,20	66,79	79,74
AP (mbar)	997,70	1009,20	1012,90	1013,54	1018,00	1031,70
RH (%)	32,25	63,87	74,91	74,01	85,74	100,07
PE (MW)	425,30	438,50	453,90	455,20	471,80	495,20

3. Análise Descritiva

Análise de Dispersão e Variabilidade

Tabela: Variabilidade Marginal das Variáveis

Variável	Média Amostral	Desvio-Padrão (DP)	Coeficiente de Variação (CV%)
AT	19,227	7,805	40,59%
V	54,205	12,891	23,78%
AP	1013,544	6,077	0,60%
RH	74,011	14,812	20,01%
PE	455,202	17,906	3,93%

- **Destaque de Escala:** A pressão barométrica (AP) manifesta extrema estabilidade relativa ($CV = 0,60\%$), contrastando com a temperatura ambiente (AT), que exhibe a dispersão proporcional mais acentuada ($CV = 40,59\%$).

3. Análise Descritiva

Matriz de Correlação Linear de Pearson

Tabela: Coeficientes de Correlação Inter-variáveis

	AT	V	AP	RH	PE
AT	1,0000	0,8595	-0,5830	-0,5227	-0,9524
V	0,8595	1,0000	-0,5026	-0,2846	-0,8929
AP	-0,5830	-0,5026	1,0000	0,0939	0,5947
RH	-0,5227	-0,2846	0,0939	1,0000	0,3630
PE	-0,9524	-0,8929	0,5947	0,3630	1,0000


- **Associação com a Resposta:** As covariáveis AT ($r = -0,9524$) e V ($r = -0,8929$) exibem forte acoplamento linear negativo com a potência gerada (PE).
- **Alerta de Colinearidade:** A forte correlação mútua observada entre a temperatura e o vácuo (AT e V com $r = 0,8595$) indica um expressivo compartilhamento de informação explicativa.

3. Análise Descritiva

Distribuições Marginais (Histogramas)

- **AT e V (Bimodais):** Apresentam comportamento com dois picos nítidos.
- **AP (Simétrica):** Exibe distribuição aproximadamente Normal (em forma de sino).
- **RH (Assimétrica):** Assimetria à esquerda, indicando maior frequência de dias com umidade relativa elevada.
- **PE (Resposta):** Percebe-se um padrão bimodal, concentrando a produção em dois patamares de potência.

Análise de Frequência e Densidade




3. Análise Descritiva

Relação dos Preditores com a Resposta (PE)

- **AT vs. PE** ($r = -0,95$): Fortíssima associação linear negativa. Configura-se como o preditor mais influente no rendimento energético.
- **V vs. PE** ($r = -0,89$): Relação negativa acentuada, embora exiba maior dispersão nos valores intermediários.
- **AP vs. PE** ($r = 0,59$): Correlação positiva moderada; elevações na pressão atmosférica tendem a aumentar a potência líquida.
- **RH vs. PE** ($r = 0,36$): Associação positiva fraca e comportamento ruidoso, sugerindo menor peso explicativo direto.

Comportamento Linear das Variáveis



4. Modelo de Regressão Linear

Formalizando: Notação e Definições

Anteriormente dizemos que a formulação matricial para o modelo é:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Ou seja:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i, \quad i = 1, \dots, n$$

Onde $i = 1, 2, \dots, n$ é o índice da observação. Definimos as seguintes quantidades para a i -ésima observação:

Onde $i = 1, 2, \dots, n$ é o índice da observação. Definimos:

- Y_i : produção líquida de energia (MW)
- x_{i1} : temperatura ambiente AT_i ($^{\circ}\text{C}$)
- x_{i2} : vácuo de exaustão V_i (cm Hg)
- x_{i3} : pressão ambiente AP_i (mbar)
- x_{i4} : umidade relativa RH_i (%)

Interpretação dos parâmetros:

- β_1 : variação esperada em PE para cada aumento de 1°C em temperatura
- β_2 : ... para cada aumento de 1 cm Hg no vácuo
- β_3 : ... para cada aumento de 1 mbar na pressão
- β_4 : ... para cada aumento de 1 pp na umidade relativa
- ε_i : erro aleatório da i -ésima observação

4. Modelo de Regressão Linear

Formalizando: Especificação Matricial

Para usar a forma compacta (matricial),

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

precisamos definir o seguinte:

$$\mathbf{Y}_{n \times 1} = (Y_1, \dots, Y_n)^\top, \quad \boldsymbol{\beta}_{p \times 1} = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4)^\top$$

$$\mathbf{X}_{n \times p} = \begin{pmatrix} 1 & x_{11} & x_{12} & x_{13} & x_{14} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & x_{n4} \end{pmatrix}$$

com $p = 5$ (intercepto + 4 covariáveis)

5. Especificação Bayesiana

Escolha dos Hiperparâmetros a priori

Escolhemos a distribuição a priori conjugada Normal–Gama Inversa, conforme apresentado na Seção 1:

$$\sigma^2 \sim \text{IG}(a_0, b_0), \quad \beta \mid \sigma^2 \sim \mathcal{N}_p(\mu_0, \sigma^2 \Lambda_0^{-1})$$

de forma que $(\beta, \sigma^2) \sim \mathcal{NIG}(\mu_0, \Lambda_0, a_0, b_0)$.

Hiperparâmetros Escolhidos (Priori Fraca/Não-Informativa)

$$\mu_0 = \mathbf{0}_5, \quad \Lambda_0 = 10^{-4} \cdot I_5, \quad a_0 = b_0 = 0,01$$

- Valores pequenos de Λ_0 refletem grande incerteza *a priori* sobre os coeficientes β (difusa).
- Com $a_0 = b_0 = 0,01$, a distribuição IG *a priori* da variância σ^2 também é pouco informativa.
- Esta escolha permite verificar a convergência da a posteriori bayesiana para o estimador clássico de Mínimos Quadrados Ordinários (MQO).

6. Atualização Bayesiana

Cálculo Computacional da Posteriori

Com base nas expressões analíticas derivadas na Seção 1, calculamos (com software R) diretamente os hiperparâmetros a posteriori Λ_n , μ_n , a_n e b_n : Resultado: $a_n = 150,01$ e $b_n = 2850,664$.

Tabela: Vetor de Médias a Posterioris μ_n

Parâmetro	Estimativa Pontual (perda quadrática)
Intercepto (β_0)	464,220183
AT (β_1)	-1,928991
V (β_2)	-0,276881
AP (β_3)	0,054413
RH (β_4)	-0,163096

- A média a posteriori μ_n fornece a estimativa pontual de Bayes para cada coeficiente, sob perda quadrática.
- Sinais e magnitudes são consistentes com as correlações observadas na análise descritiva (Seção 3).

6. Atualização Bayesiana

Variância a Posteriori de σ^2 e Desvio dos Coeficientes

A esperança a posteriori da variância residual é dada por:

$$E[\sigma^2 | \mathbf{Y}] = \frac{b_n}{a_n - 1} = 19,1307 \implies \text{DP residual} \approx 4,3739 \text{ MW}$$

A matriz de covariância a posteriori (marginal) dos coeficientes é dada por:

$$\text{Cov}(\beta | \mathbf{Y}) = E[\sigma^2 | \mathbf{Y}] \cdot \Lambda_n^{-1}$$

Tabela: Desvios-Padrão a Posteriori Marginais dos Coeficientes

	Intercepto	AT	V	AP	RH	σ^2
DP	55,563262	0,086409	0,041789	0,053779	0,022872	1,5725

6. Atualização Bayesiana

Resumo da Posteriori e Intervalos de Credibilidade 95%

A distribuição marginal de cada coeficiente é $\beta_j | \mathbf{Y} \sim t_{2a_n} \left(\mu_{n,j}, \frac{b_n}{a_n} [\Lambda_n^{-1}]_{jj} \right)$, com $2a_n$ graus de liberdade.

Tabela: Resumo da Distribuição a Posteriori dos Coeficientes

Parâmetro	Média a Posteriori	DP a Posteriori	IC95% (Inf.)	IC95% (Sup.)
Intercepto (β_0)	464,22018	55,56326	355,24216	573,19820
AT (β_1)	-1,92899	0,08641	-2,09847	-1,75951
V (β_2)	-0,27688	0,04179	-0,35884	-0,19492
AP (β_3)	0,05441	0,05378	-0,05107	0,15989
RH (β_4)	-0,16310	0,02287	-0,20796	-0,11824
σ^2	19,1307	1,5725	16,2943	22,4523

- Note:** O IC (95%) de AP contém o zero, sugerindo incerteza relevante sobre o sinal de seu efeito sobre PE nesta amostra.

6. Atualização Bayesiana

Interpretação dos Coeficientes a Posteriori estimados

- β_1 (**AT**): coeficiente negativo – temperaturas mais altas reduzem a eficiência das turbinas a gás, diminuindo a potência produzida.
- β_2 (**V**): coeficiente negativo – maior vácuo de exaustão (pressão mais baixa no condensador) reduz a eficiência da turbina a vapor.
- β_3 (**AP**): coeficiente positivo – maior pressão atmosférica favorece a densidade do ar nas turbinas a gás.
- β_4 (**RH**): coeficiente ligeiramente negativo – umidade mais alta pode reduzir levemente o desempenho.

7 Comparação com Método de Mínimos Quadrados (Frequentista)

Bayesiano (Priori Fraco) vs. Mínimos Quadrados Ordinários

Com prior não-informativo ($\Lambda_0 \rightarrow 0$), espera-se que a média a posteriori μ_n convirja para o estimador clássico $\hat{\beta} = (X^\top X)^{-1} X^\top Y$.

Tabela: Comparação: MQ vs. Bayesiano (Prior Fraco)

Parâmetro	MQ	Bayesiano
Intercepto	471,834587	464,220183
AT	-1,934442	-1,928991
V	-0,276200	-0,276881
AP	0,047048	0,054413
RH	-0,164198	-0,163096
σ^2	MSE=19,25221	19,1307


- As estimativas bayesianas são praticamente idênticas às do frequentista (MQ), como esperado sob a priori difusa.
- **Diferença fundamental:** na abordagem bayesiana, μ_n é a média de uma distribuição de probabilidade sobre β , e os intervalos de credibilidade possuem interpretação probabilística direta – diferentemente dos intervalos de confiança frequentistas.

8. Análise de Resíduos

Gráficos de Diagnóstico

- **Resíduos vs. Ajustados:** dispersão sem padrão sistemático aparente em torno de zero, indicando homocedasticidade razoável.
- **QQ-plot:** pontos próximos da reta de referência, sugerindo aproximação adequada à normalidade nos resíduos.
- **Histograma:** forma aproximadamente simétrica e unimodal, compatível com a suposição gaussiana do modelo.
- **Resíduos por Ordem:** ausência de tendência ou autocorrelação visível ao longo do índice das observações.

Diagnóstico Gráfico dos Resíduos



8. Análise de Resíduos

Métricas de Validação

- O R^2 foi de 0,94075 isso indica que 94% da variabilidade total da Potência Elétrica é explicada pelas quatro variáveis ambientais;
- O MAE foi de 3,59 isso indica que em média as previsões do modelo erram em cerca de 3,59 MegaWatts;
- O RMSE foi de 4,35 isso indica que em média as previsões do modelo erram em cerca de 4,35 MegaWatts;
- O MAPE foi de 0,7925%, isso indica que em média as previsões do modelo erram em cerca de 0,7925% da produção real, que é menos que 1%, indicando que as previsões estão precisas;

Como o RMSE mede o quadrado dos desvios e o MAE mede o valor absoluto dos desvios o primeiro dá peso maior a grandes desvios, a diferença entre os dois é pequena, indicando que há poucos outliers ou que eles pouco desviam.


9. Distribuições a Posteriori Marginais dos Coeficientes

A distribuição a posteriori dos coeficientes quando marginalizada segue uma t-Student não central de $2a_n$ graus de liberdade:

$$\beta_j \mid \mathbf{Y} \sim t_{2a_n} \left(\mu_{n,j}, \frac{b_n}{a_n} [\Lambda_n^{-1}]_{jj} \right)$$

Como $n = 300$ é um valor grande a t-Student converge para uma distribuição normal

Gráficos das Densidades




10. Predição

Para uma nova observação $\mathbf{x}_\star$ a distribuição preditiva a posteriori marginaliza sobre β e σ^2 resulta em:

$$Y_\star | \mathbf{Y} \sim t_{2a_n} \left(\mathbf{x}_\star^\top \boldsymbol{\mu}_n, \frac{b_n}{a_n} (1 + \mathbf{x}_\star^\top \boldsymbol{\Lambda}_n^{-1} \mathbf{x}_\star) \right)$$

Para uma estimativa de $\mathbf{x}_\star = [20 \ 55 \ 1010 \ 70]^T$ uma única predição é de $\mathbf{Y}_\star = 453,952 \text{ MW}$ e $\text{IC}(95\%) = [445.349, 462.554]$

Observado vs. Predito



11. Conclusões

O modelo de regressão bayesiano se ajusta bem aos dados analisados, fornecendo bons resultados e conclusões a cerca da variável resposta. Apenas uma única covariável (AP-pressão atmosférica) não é estatisticamente significativa.

Os resultados pouco diferem do modelo clássico por primeiramente a função de perda ser a quadrática, segundo assumirmos distribuição normal-gama inversa para as prioris (apesar das covariáveis não apresentarem esse comportamento) e principalmente pela grande quantidade de dados.

Combined Cycle Power Plant (UCI Machine Learning Repository) -
<https://archive.ics.uci.edu/dataset/294/combined+cycle+power+plant>

Obrigado!

Gabriela Lins de Albuquerque – Marcelo Xinhong Huang – Paulo Roberto Salles Neto
Departamento de Estatística – UFSCar