Atividade 2 --- Análise de Regressão

Contexto

Nesta atividade, será realizada a simulação de um conjunto de dados a partir de um modelo de regressão linear simples com parâmetros conhecidos. A partir desses dados, serão conduzidos procedimentos de inferência estatística, incluindo o teste de hipóteses para o coeficiente angular e a construção de intervalos de confiança, além da análise do efeito da centralização da variável explicativa sobre os parâmetros do modelo.

1.a) Simule um conjunto de dados com n pares (Y_i, X_i), e ajuste o modelo de regressão linear simples.

O modelo considerado é: $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$

In [5]:
```
# modelo: Y_i = beta_0 + beta_1*X_i + erro_i

set.seed(260329)
n <- 20    # número de observações / tamanho da amostra
beta_0 <- 2.9    # os parâmetros
beta_1 <- 5

X <- runif(n,min = 10, max = 20)
Erros <- rnorm(n, mean = 0, sd = 5)
Y <- beta_0 + beta_1 * X + Erros
```

Foi gerado um conjunto de dados com n=20 observações, considerando o modelo $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, onde $\varepsilon_i \sim N(0, \sigma^2)$, independentes e identicamente distribuídos.

A covariável X_i foi simulada a partir de uma distribuição uniforme no intervalo [10, 20], enquanto o erro aleatório ε_i foi gerado a partir de uma distribuição normal com média zero e desvio padrão igual a 5.

A variável resposta Y_i foi então construída de acordo com o modelo especificado.

---

b) Teste as hipóteses: $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$

In [6]:
```
modelo <- lm(Y ~ X)
summary(modelo)$coef
```

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	0.065660	5.6440789	0.01163343	9.908460e-01
X	5.190601	0.3790429	13.69396656	5.858565e-11

Foi ajustado um modelo de regressão linear simples para avaliar a relação entre X e Y.

As estimações foram: $\hat{\beta}_0 = 0.6$ $\hat{\beta}_1 = 5.19$

A estatística usada para fazer o teste é $t = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{MSE/\sum(X_i - \bar{X})^2}}$, e essa estatística sob H_0 segue uma distribuição t de student com n-2 graus de liberdade

A partir dos resultados do teste feito acima, observa-se que o coeficiente associado a X é estatisticamente significativo, com valor-p (5.86e-11) próximo de zero, .

Dessa forma, rejeitamos H_0, há evidência de que $\beta_1 \neq 0$, indicando uma relação linear entre X e Y no range de [10; 20].

---

c) Determine um intervalo de confiança para β_1 Interprete o intervalo

Intervalo de confiança para β_1:

In [7]:
```
confint(modelo)
```

	2.5 %	97.5 %
(Intercept)	-11.792110	11.923430
X	4.394262	5.986941

O intervalo de confiança de 95% para β_1, dado por [4.4; 5.9] não contém o valor zero, o que reforça a evidência de que o coeficiente de inclinação é diferente de zero e isso indica que, em média, um aumento unitário em X está associado a um aumento entre 4.4 e 5.9 unidades em Y.

Além disso, o intervalo está próximo do valor verdadeiro utilizado na simulação ($\beta_1 = 5$), indicando que o estimador $\hat{\beta}_1$ é adequado neste contexto.

---

d) Centralize o modelo. Ajuste o modelo centralizado. Interprete β_0^* e β_1. Compare os modelos

X centralizado é dado por:

$X^* = X - \bar{X}$

Assim, $Y_i^* = \beta_0^* + \beta_1 X_i^* + \varepsilon_i$

onde $\beta_0^* = \beta_0 + \beta_1 \bar{X}$

Em seguida, ajustou-se um novo modelo de regressão utilizando X^*.

In [15]:
```
X_centralizado <- X - mean(X)

modelo_centralizado <- lm(Y ~ X_centralizado)
```

```
summary(modelo_centralizado)$coef

confint(modelo_centralizado)
```

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	75.816091	1.1208535	67.64140	4.048758e-23
X_centralizado	5.190601	0.3790429	13.69397	5.858565e-11

	2.5 %	97.5 %
(Intercept)	73.461266	78.170917
X_centralizado	4.394262	5.986941

As estimações foram: $\hat{\beta}_0^* = 75.82$ e $\hat{\beta}_1 = 5.19$

O intervalo de confiança de 95% para β_1 não mudou, continua sendo [4.4; 5.9]. E sobre a hipótese $H_0 : \beta_1 = 0$, é rejeitada por valor p pequeno. Isso é esperado já que o modelo centralizado preserva a inferência a β_1

Comparando os coeficientes dos dois modelos, observa-se que:

- O estimador $\hat{\beta}_1$ para β_1 e o seu intervalo de confiança permanecem inalterados nos dois modelos.
- O intercepto é modificado ($\beta_0 \neq \beta_0^*$).

No modelo original, o intercepto representa o valor esperado de Y quando $X = 0$, o que pode não ter interpretação prática, especialmente quando esse valor está fora do intervalo observado.

Enquanto no modelo centralizado, o intercepto ${\beta_0}^*$ passa a representar o valor esperado de Y quando $X = \bar{X}$.

Assim, a centralização não altera a inclinação da reta, pois a inclinação continua sendo β_1 (que representa a variação esperada em Y associado a um aumento unitário em X), mas modifica a interpretação do intercepto, tornando-o mais informativo quando o valor médio de X é relevante.

Gráfico de dispersão para comparação :

In [13]:
```
plot(X, Y,
     col = "red",
     pch = 16,
     xlab = "X / X centralizado",
     ylab = "Y",
     main = "Comparação: dados originais vs centralizados",
     xlim = range(c(X, X_centralizado))
)

#pontos do modelo centralizado
points(X_centralizado, Y,
       col = "blue",
```
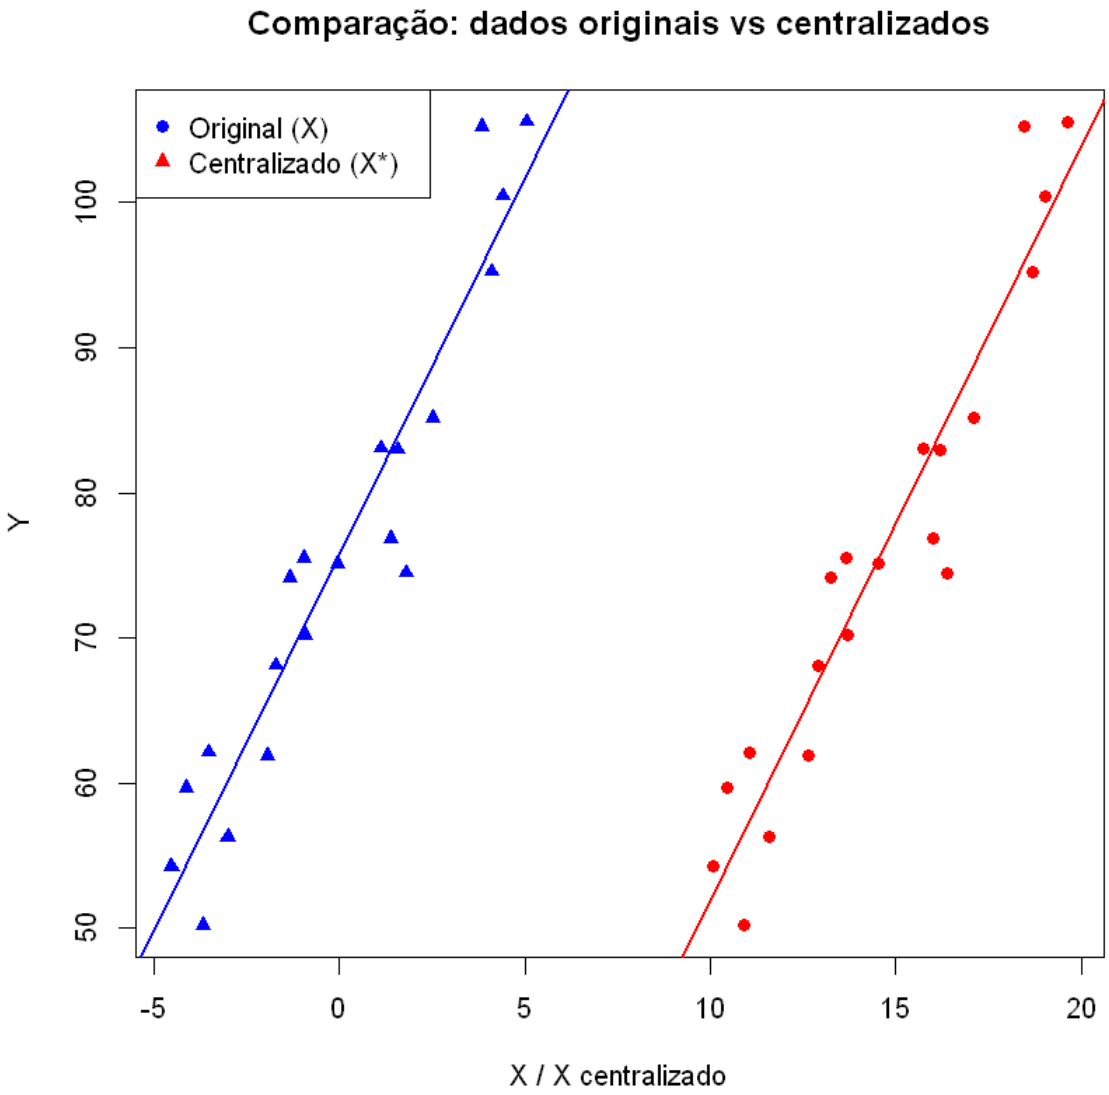
```
       pch = 17)

#retas
abline(modelo, col = "red", lwd = 2)
abline(modelo_centralizado, col = "blue", lwd = 2)


# legenda
legend("topleft",
       legend = c("Original (X)", "Centralizado (X*)"),
       col = c("blue", "red"),
       pch = c(16, 17))
```