Atividade 2 – Regressão

Aluno: Marcelo Huang

Enunciado:

Descrição

Nesta atividade, será realizada a simulação de um conjunto de dados a partir de um modelo de regressão linear simples com parâmetros conhecidos. A partir desses dados, serão conduzidos procedimentos de inferência estatística, incluindo o teste de hipóteses para o coeficiente angular e a construção de intervalos de confiança, além da análise do efeito da centralização da variável explicativa sobre os parâmetros do modelo. E alguns itens extras adcionados posteriormente.

Itens:

1.a) Simule um conjunto de dados com n pares (Y_i, X_i), e ajuste o modelo de regressão linear simples.
O modelo considerado é:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

onde $\varepsilon_i \sim N(0, \sigma^2)$, independentes e identicamente distribuídos.
Foi gerado um conjunto de dados com $n = 25$ observações.

A covariável X_i foi simulada a partir de uma distribuição uniforme no intervalo [10, 20] (usando a função "runif"do R), enquanto o erro aleatório ε_i foi gerado a partir de uma distribuição normal com média zero e desvio padrão igual a 5 ("rnorm(n, mean = 0, sd = 5)").
Atribuindo valores dos parâmetros: $\beta_0 = 16$ e $\beta_1 = 5$
A variável resposta Y_i foi então construída de acordo com o modelo especificado.

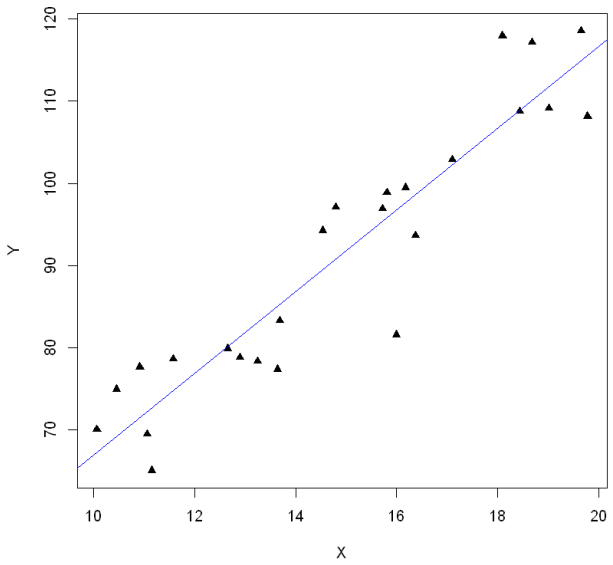

Figura 1: Gráfico de dispersão

Foi ajustado um modelo de regressão linear simples para avaliar a relação entre X e Y.
As estimações foram: $\hat{\beta}_0 = 17.15$ $\hat{\beta}_1 = 4,97$
— **1.b) Teste as hipóteses:**

Os β's	Valor estimado	t	$Pr(>\|t\|)$
$\hat{\beta}_0$	17,15	2,83	9.4e-03
$\hat{\beta}_1$	4.97	12,47	1.02e-11

Tabela 1: Resultados sobre estimadores

$$H_0 : \beta_1 = 0$$
$$H_1 : \beta_1 \neq 0$$

Sobre o β_1, a estatística usada para fazer o teste é $t = \frac{\hat{\beta}_1 - \beta_1}{EP(\hat{\beta}_1)} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{MSE/\sum(X_i - \bar{X})^2}}$, e essa estatística sob H_0 segue uma distribuição t de student com n-2 graus de liberdade.
A partir dos resultados do teste feito acima, observa-se que o coeficiente associado a X é estatisticamente significativo, com valor-p (1.02e-11) próximo de zero, .

Dessa forma, rejeitamos H_0, há evidência de que $\beta_1 \neq 0$, indicando uma relação linear entre X e Y no range de [10; 20].

c) Determine um intervalo de confiança para β_1 Interprete o intervalo

Intervalo de confiança para Os β's	2.5%	97.5%
β_0	4.63	29.67
β_1	4.15	5.80

Tabela 2: Intervalos de Confiança

Pela tabela 2, intervalo de confiança de 95% para β_1, dado por [4.15; 5.8] não contém o valor zero, o que evidencia que o coeficiente de inclinação β_1 é diferente de zero e isso indica que, em média, um aumento unitário em X está associado a um aumento entre 4.15 e 5.8 unidades em Y.

Além disso, note que o intervalo contém o valor verdadeiro utilizado na simulação ($\beta_1 = 5$).

d) Centralize o modelo. Ajuste o modelo centralizado. Interprete β_0^* e β_1. Compare os modelos

X centralizado é dado por:
$X^* = X - \bar{X}$
Assim, $Y_i^* = \beta_0^* + \beta_1 X_i^* + \varepsilon_i$ onde $\beta_0^* = \beta_0 + \beta_1 \bar{X}$
Em seguida, ajustou-se um novo modelo de regressão utilizando X^*.

Os β's	Valor estimado	t	$Pr(>\|t\|)$
$\hat{\beta}_0^*$	91.11	75.99	3.97e-29
$\hat{\beta}_1$	4.97	12,47	1.02e-11

Tabela 3: Resultados sobre estimadores no modelo centralizado

As estimações foram: $\hat{\beta}_0^* = 91.11$ e $\hat{\beta}_1 = 4.97$

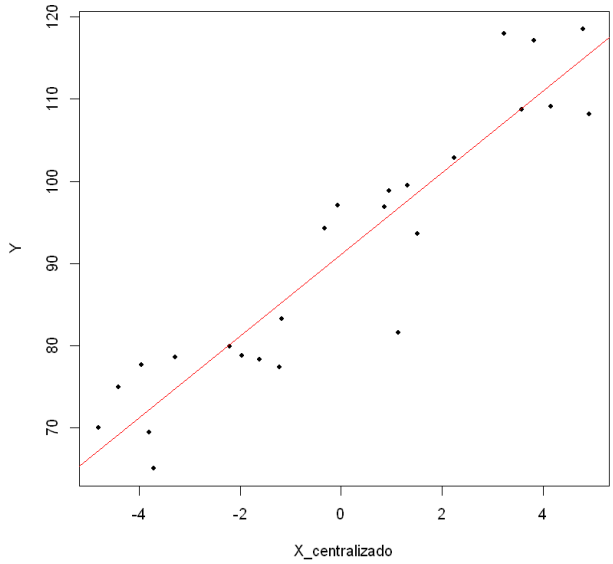

Figura 2: Gráfico de dispersão (modelo Centralizado)

O intervalo de confiança de 95% para β_1 não mudou, continua sendo [4.15; 5.8]. E sobre a hipótese $H_0 : \beta_1 = 0$, é rejeitada por valor p pequeno. Isso é esperado já que o modelo centralizado preserva a inferência a β_1

Comparando os coeficientes dos dois modelos, observa-se que:

- O estimador $\hat{\beta}_1$ para β_1 e o seu intervalo de confiança permanecem inalterados nos dois modelos.

- O intercepto é modificado ($\beta_0 \neq \beta_0^*$).

No modelo original, o intercepto representa o valor esperado de Y quando $X = 0$, o que pode não ter interpretação prática, especialmente quando esse valor está fora do intervalo observado.

Enquanto no modelo centralizado, o intercepto ${\beta_0}^*$ passa a representar o valor esperado de Y quando $X = \bar{X}$.

$\hat{\beta}_0^* = 91.11$: É o valor esperado de Y_i quando é dado que X_i é $\bar{X}$

$\hat{\beta}_1 = 4.97$: É epresenta a variação média. esperada em Y quando X aumenta em uma unidade.

Assim, a centralização não altera a inclinação da reta, pois a inclinação continua sendo β_1 (que representa a variação esperada em Y associado a um aumento unitário em X), mas modifica a interpretação do intercepto, tornando-o mais informativo quando o valor médio de X é relevante.

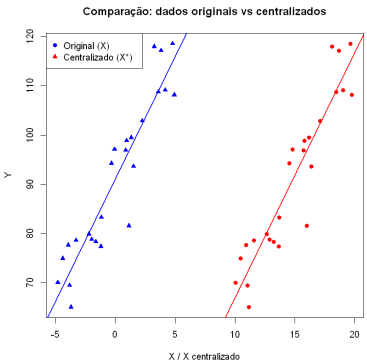

Figura 3: Comparação: dados originais vs centralizados

e) Escolha um X_0 dentro da amplitude de X. Encontre um IC 95% de Y_0 esperado desse X_0. Interprete

Sabemos que $E(\hat{Y_0}) = \hat{Y_0}$, e pelos resultados conhecidos, temos uma quantidade pivotal $\frac{\hat{Y_0} - E(Y_0)}{\sqrt{MSE/n + (MSE*(X_0-\bar{X})^2)/\sum(X_i-\bar{X})^2}}$ e que segue uma distribuição t de student com n-2 graus de liberdade. Logo, o intervalo de confiança para $E(Y_0)$ é dado por

$$\hat{Y_0} \pm t_{n-2,0.025}\sqrt{MSE\left(\frac{1}{n} + \frac{(X_0-\bar{X})^2}{\sum_{i=1}^{n}(X_i-\bar{X})^2}\right)}.$$

É escolhido um $X_0 = 17.82$, assim o valo de $\hat{Y_0}|X_0 = 17.82$ é 105.836. e o intervalo de 95 % de confiança para $E(Y_0)$ é [102.355 , 109.328].
Interpretação: Com 95% de confiança, o valor esperado de Y_0 quando $X_0 = 17.82$ está entre 102.355 e 109.318 .

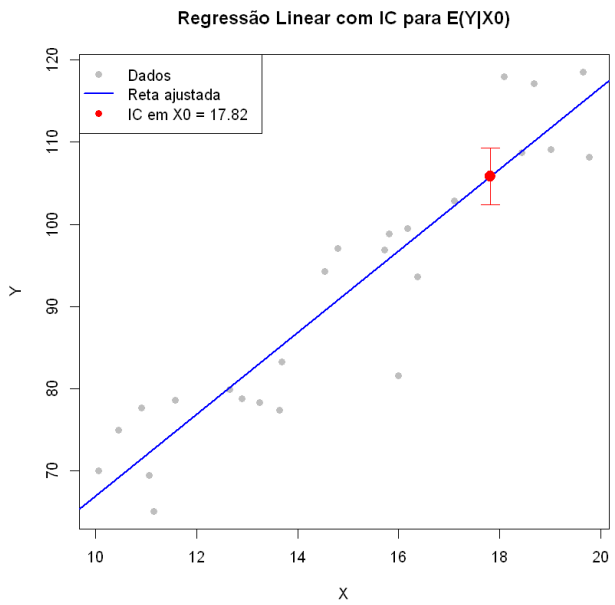

Figura 4

f) Encontre um intervalo de PREDIÇÃO 95% da variável resposta Y_0 desse mesmo X_0. Compare.

Pelos resultados conhecidos, o intervalo de predição para Y_0 é dado por:

$$\hat{Y_0} \pm t_{n-2,0.025}\sqrt{MSE\left(\frac{1}{m} + \frac{1}{n} + \frac{(X_0-\bar{X})^2}{\sum_{i=1}^{n}(X_i-\bar{X})^2}\right)}.$$

(nesse caso $m = 1$ pois só é tirada uma observação de $X_0 = 17.82$)
Com o mesmo $X_0 = 17.82$, o intervalo de predição 95 % para Y_0 é [92.96, 118.71] (espera-se que 95% das predições futuras estejam dentro desse intervalo).
Comparação: Para o mesmo X_0, o intervalo de predição é sempre mais amplo que o intervalo de confiança para a média.
O IC quantifica a incerteza sobre onde está a média da população; o IP quantifica a incerteza sobre onde cairá um novo valor individual, incluindo a variabilidade aleatória dos erros.

g) Construa uma banda de confiança Usando o resultado conhecido sobre Fronteira de Working-Hotelling:

$$\hat{Y_0} \pm \sqrt{2F_{2,n-2}^{(0.05)}} \cdot \sqrt{\hat{Var}(\hat{Y_0})}$$

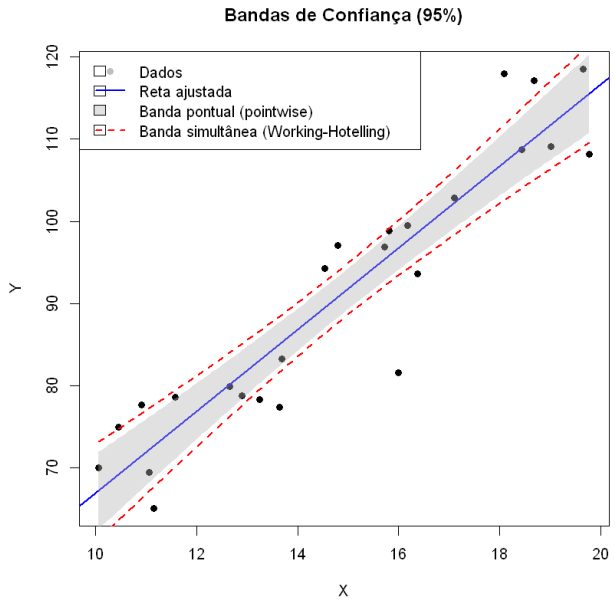

Figura 5: Banda de Confiança

A banda vermelha tracejada (figura 5) resultante de Working-Hotelling garante, com $(1-\alpha)\%$ de confiança (no caso do gráfico $\alpha = 0.05$), que toda a reta verdadeira está dentro da região para qualquer X no intervalo considerado ([10,20]).

Apêndice

Códigos usados nessa atividade podem ser acessados via link:
`https://github.com/Marcehlin/Atividades-2026_1`.