

Atividade 3

Análise de Regressão

Modelagem e Validação

Aluno: Marcelo Huang

20 de maio de 2026

Ajustar um modelo de regressão considerando:

- Ano de Experiência;
- Ano de Escolaridade;
- Setor de Trabalho;
- Idade;
- Resposta: $\log(\text{Salário})$.

Além disso:

- realizar as 4 etapas discutidas em sala;
- executar testes t;
- construir testes F parciais (Type III).

Foi realizado um estudo utilizando regressão linear múltipla para modelar:

$$Y = \log(\text{Salário})$$

Covariáveis utilizadas:

- X_1 : Experiência profissional;
- X_2 : Escolaridade;
- X_3 : Setor (dummy);
- X_4 : Idade.

Objetivos

- Diagnóstico de resíduos;
- Identificação de outliers;
- Testes estatísticos;
- Validação preditiva.

- Total de observações: 24
- Treino: 17 observações
- Teste: 7 observações

Grupo teste:

1, 5, 8, 13, 14, 18, 19

As análises foram realizadas no software **R**.

Etapa 1 – Verificação Inicial

Objetivos:

- verificar inconsistências;
- detectar problemas nos dados;
- avaliar plausibilidade;
- investigar linearidade.

Possíveis ações:

- corrigir;
- transformar;
- remover observações.

Consistência dos Dados

Foi utilizada a seguinte aproximação:


$$\text{Início} = \text{Idade} - (\text{Experiência} + \text{Escolaridade} + 6)$$

Obs	Idade	Exp	Escol.	Início
9	22	17	17	-6
10	28	18	18	-2
11	28	16	16	2
3	22	9	13	6


Conclusão

Existem observações pouco plausíveis, mas nenhuma foi removida.

log(Salário) vs Experiência



log(Salário) vs Escolaridade



log(Salário) vs Idade

Salário por Setor

Tabela: Estatísticas descritivas das variáveis

Variável	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
Experiencia	2.000	4.000	7.000	7.941	11.000	18.000
Escolaridade	8.000	10.000	13.000	12.650	14.000	18.000
Setor	0.0000	0.0000	1.0000	0.5294	1.0000	1.0000
Idade	21.000	23.000	31.000	30.820	38.000	42.000
LogSalario	7.392	8.033	8.470	8.496	8.970	9.330

Conclusão da Etapa 1

- Nenhuma observação foi removida;
- Dados sem erros óbvios;
- Relações aproximadamente lineares;
- Nenhum outlier importante detectado;
- Idade apresentou efeito aparentemente fraco.

Etapa 2 – Preparação das Covariáveis

Objetivos:

- investigar multicolinearidade;
- analisar correlações;
- reduzir dimensionalidade;
- selecionar variáveis.



Matriz de Correlação

	Exp	Escol.	Idade	LogSal
Experiência	1.000	0.636	-0.250	0.711
Escolaridade	0.636	1.000	-0.285	0.698
Idade	-0.250	-0.285	1.000	-0.071
LogSalário	0.711	0.698	-0.071	1.000

Conclusão

Não há correlações excessivamente altas entre preditoras.

Análise Gráfica das Correlações



	Exp	Escol.	Setor	Idade
VIF	1.71	1.85	1.21	1.75

Conclusão

Todos os VIFs ficaram abaixo de 2.

Não há evidência de multicolinearidade problemática.

Métodos utilizados:

- Stepwise (AIC);
- Cp de Mallows;
- LASSO.

Resultado

Todos os métodos selecionaram:

Experiência + Escolaridade

As variáveis Setor e Idade foram removidas.

Conclusão da Etapa 2

- Ausência de multicolinearidade;
- Correlações moderadas;
- Métodos de seleção concordaram;
- Modelo reduzido escolhido:

$$\log(\text{Salário}) = \beta_0 + \beta_1 \text{Experiência} + \beta_2 \text{Escolaridade}$$

$$Y = \beta_0 + \beta_1 \text{Experiência} + \beta_2 \text{Escolaridade} + \varepsilon$$


Coeficientes estimados:

$$\hat{\beta}_0 = 7.07$$

$$\hat{\beta}_1 = 0.05$$

$$\hat{\beta}_2 = 0.08$$

- Cada ano adicional de experiência aumenta o log-salário em aproximadamente 4%;
- Cada ano adicional de escolaridade aumenta o log-salário em aproximadamente 8%;
- O intercepto não possui interpretação prática.




Teste de Breusch-Pagan:

$$p\text{-valor} = 0.1378$$

Conclusão

Não há evidência contra homocedasticidade.



Teste Shapiro-Wilk:


$$p = 0.6652$$

Conclusão


Os resíduos podem ser considerados aproximadamente normais.

Outliers e Alavancagem


Resíduos studentizados vs Ajustados






Alavancagem (os Hii)



Distância de Cook



DFFITS e DFBETAS



As observações 4 e 10 merecem investigação adicional.

Comparações entre modelos com e sem pontos influentes (4 e 10)

Tabela: Estimativas dos coeficientes sob remoção de observações influentes

Estimativa dos β	Ambos	Sem4	Sem10	Sem ambos
(Intercept)	7.07122157	6.9309315	6.72441238	6.6445531
Experiencia	0.04919066	0.0641627	0.03147366	0.0476804
Escolaridade	0.08179765	0.0876268	0.11694960	0.1173557

- $R^2 = 0.6071$
- $R^2_{ajustado} = 0.551$
- Estatística F = 10.82
- Valor-p global = 0.0014

Conclusão

O modelo global é significativo.

Variável	Estatística F	Valor-p
Experiência	4.257	0.058
Escolaridade	3.632	0.077

- Ambas as variáveis apresentaram contribuição moderada;
- Exclusão de Setor e Idade não comprometeu o ajuste.

Conclusão da Etapa 3

- Pressupostos razoavelmente atendidos;
- Possível necessidade de termo quadrático;
- Influência moderada das observações 4 e 10;
- Modelo significativo globalmente;
- Experiência e Escolaridade são relevantes.

Pergunta principal:

O modelo é útil para prever novos dados?

Métodos utilizados:

- Hold-out (treino/teste);
- Validação cruzada 5-fold.

Predições no Conjunto de Teste

Obs	LogSalário	Predição	Erro
1	8.874	8.625	0.249
5	7.472	7.873	-0.401
8	8.599	8.348	0.251
13	8.632	8.445	0.187
14	8.149	8.200	-0.051
18	9.060	8.750	0.310
19	8.156	8.167	-0.011

Métrica	Treino	Teste	CV 5-fold
RMSE	0.3426	0.2434	0.3629
MAE	0.2763	0.2075	0.2950
MAPE		0.0248	
R^2	0.6071	0.9676	0.7317

Interpretação

O hold-out foi otimista devido ao tamanho reduzido da amostra.

- O modelo apresenta capacidade preditiva razoável;
- A validação cruzada forneceu estimativas mais confiáveis;
- Ainda existe espaço para melhoria;
- A inclusão de termos quadráticos pode melhorar o ajuste.

Modelo com Termo Quadrático


Modelo adicional testado:

$$\log(\text{Salário}) = \beta_0 + \beta_1 \text{Experiência} + \beta_2 \text{Experiência}^2 + \beta_3 \text{Escolaridade}$$

Resultados:

- RMSE teste = 0.117
- MAE teste = 0.099
- MAPE = 0.0118
- Estimativas: $\hat{\beta}_0 = 5.83$, $\hat{\beta}_1 = 0.25$, $\hat{\beta}_2 = -0.01$, $\hat{\beta}_3 = 0.12$
- Não apresenta outliers nem pontos influentes
- Melhor ajuste residual

Diagnóstico do Modelo Quadrático



Conclusões Finais

- Experiência e Escolaridade foram as variáveis mais relevantes;
- Não houve multicolinearidade significativa;
- O modelo linear apresentou desempenho moderado;
- O modelo quadrático apresentou melhoria no ajuste;
- A validação cruzada indicou utilidade prática do modelo.

Conclusão Principal

O modelo é útil para previsão, mas ainda pode ser refinado.

Bom dia pra vocês

Relatório completo disponível em PDF.