

Atividade 3 -- Análise de Regressão:

Aluno: Marcelo Huang

Enunciado: "O conjunto acima envolve as covariáveis Ano de Experiência, Ano de Escolaridade, Setor do Trabalho, Idade do Funcionario e a resposta Log(Salário). Ajuste um modelo de regressão considerando as 4 etapas discutidas em sala.

E a partir dos teste t's de construções, faça teste F parcial. Use type III.

Etapa 0: Contextualizando

Nesta atividade, será realizada uma análise de um conjunto de dados dito na sala de aula, usando um modelo de regressão linear. A partir desses dados, serão conduzidos: Diagnóstico/Análise de resíduos; Detecção de outliers e pontos influentes; Testes estatísticas; e validação do modelo.

O conjunto de dados é composto por 3 covariáveis e 1 variável resposta:

- X_1 : Anos de Experiência profissional
- X_2 : Anos de Escolaridade
- X_3 : Variável dummy, é 1 ou 0. 1 significa **Privado**, 0 significa **Público**
- X_4 : Idade da pessoa
- Y : log(Salário).

O conjunto de dados (total de 24 observações) foi dividido em duas partes: teste (7 observações: 1;5;8;13;14;18;19), treino (17 observações: o resto que sobrou)

Nessa atividade, as análises serão realizadas no software **R**, utilizando funções da linguagem, nativas e/ou de pacotes externas

Etapa 1:

Pegar os dados brutos e começa a verificar inconveniências.

Nesse contexto seria verificar a consistência entre idade, experiência e escolaridade.

- Corrigir
- Transformar
- Remover

Todas ações feitas devem ser documentadas e justificadas.

1.1 Carregando os dados:

Dados do Experimento

Indice	Ano_Exper	Ano_Escol	Setor	Idade	Log(Salario)
21	3	11	0	33	7.997
6	3	14	1	42	8.388
...	...	...	...	...	...
10	18	18	0	28	9.174
24	6	10	1	23	8.033

1.2 Verificando inconsistências:

Para um indivíduo, a idade deve ser compatível com anos de experiência e escolaridade. Geralmente a idade de início da vida profissional pode ser aproximada por:

$$\text{Início} = \text{Idade} - (\text{Experiencia} + \text{Escolaridade} + 6)$$

Supondo que a escolaridade **formal** comece aos 6 anos. Além disso o início da vida profissional deve ser maior ou igual a 16 anos para ser razoável (podendo ter uma margem de erro).

Índice da Observação	Idade	Anos de Experiencia	Anos de Escolaridade	Início do trabalho
9	22	17	17	-6
10	28	18	18	-2
11	28	16	16	2
3	22	9	13	6
...	...	...	...	...

Tabela acima é ordenada de maneira crescente pelo "Início do trabalho". Fazendo a conta usando a aproximação dada acima, pode-se perceber que existe algumas observações estranhas, por exemplo:

- Observação **9**:

-> Idade=22, Experiencia=17, Escolaridade=17. Início = $22 - 17 - (17 - 6) = 22 - 17 - 11 = -6$.

-> Para ter 17 anos de experiência e 17 de escolaridade, seriam necessários pelo menos $17 + 11 = 28$ anos de vida. Com 22 anos, é praticamente impossível, a não ser que a pessoa começou a trabalhar e estudar aos 5 anos, tal probabilidade não é nula. Manter.

- Observação **10**:

-> Idade=28, Experiencia=18, Escolaridade=18. Início = $28 - 18 - 12 = -2$.

-> Mesmo problema da observação 10: seriam necessários no mínimo 30 anos de vida. a não ser que a pessoa começou a trabalhar e estudar aos 5 anos, tal probabilidade não é nula. Manter.

- Observação **11**:

-> Idade=28, Experiencia=16, Escolaridade=16. Início = $28 - 16 - 10 = 2$.


-> Aqui a idade de início seria 2 anos. O total de anos "ocupados" (experiência + escolaridade pós-6) é $16+10=26$, contra 28 de idade, sobriariam apenas 2 anos antes dos 6, ou seja, a pessoa teria começado a trabalhar aos 2 anos. Não provável, mas pode trabalhar e estudar ao mesmo tempo. Manter.

- Observação 3: Idade=22, Experiencia=9, Escolaridade=13. Início = $22 - 9 - 7 = 6$.

-> Mais ou menos possível. A anomalia é menos grave. Manter.

****Logo nenhuma observação é removida, o conjunto de treino ainda contém 17 observações**


1.3 Análise gráfica para linearidade:



As variáveis Experiência, Escolaridade, e Idade apresentam comportamento linear com a resposta log(Salário). Não tem indícios da necessidade de uma transformação.

1.4 Verificando outliers univariados

Pois outliers na resposta ou nas preditoras podem distorcer a análise:



Não parece ter outliers na covariáveis.

1.5 Concluindo etapa 1

- A base de treino tem 17 observações.
- As variáveis estão nos intervalos esperados, sem erros de digitação óbvios.
- A verificação de idade de início de trabalho mostrou valores entre X e Y, a maior parte dos dados é plausível, tem algumas observações pouco inconveniente mas foram mantidas.

- Os gráficos de dispersão sugerem relação aproximadamente linear entre log-salário e as preditoras, exceto talvez a Idade, que apresentou pouco efeito no log-salário. O boxplot de Setor mostra diferença de medianas, indicando possível efeito.
 - Nenhum outlier foi detectado nos boxplots; os valores estão dentro do esperado.
-

Etapa 2:


Para a base da nossa análise, deve se verificar as seguintes coisas:


- Redução de dimensão das covariáveis (Parcimonia)
- Matriz de correlação
- Matriz de dispersão
- Multicolinearidade, usando critério de VIF (Variance Inflation Factor) como medida
- Seleção de variáveis

*Qual o ponto dessa etapa? Preparar as covariáveis para o ajuste. *

Covariáveis IMPORTANTES/RELEVANTES

	Experiencia	Escolaridade	Idade	LogSalario
Experiencia	1.000	0.636	-0.250	0.711
Escolaridade	0.636	1.000	-0.285	0.698
Idade	-0.250	-0.285	1.000	-0.071
LogSalario	0.711	0.698	-0.071	1.000





A matriz de correlação não revela correlações muito fortes entre as variáveis preditoras (todas as correlações entre pares de preditores são menores que 0,7 em valor absoluto). Isso sugere **ausência de multicolinearidade** problemática, indicando que as covariáveis são aproximadamente linearmente independentes entre si.

2.2 Diagnóstico de multicolinearidade usando VIF (Variance Inflation Factor) como medida

	Experiencia	Escolaridade	Setor	Idade
VIF	1.71	1.85	1.21	1.75

Os Valores do Fator de Inflação da Variância (VIF) são todos inferiores a 2. Esse resultado confirma a **ausência de multicolinearidade**; não há evidência de que alguma preditora seja combinação linear das demais.

2.3 Seleção de variáveis

- Stepwise: a saída em R fica do jeito abaixo

```
Call:
lm(formula = LogSalario ~ Experiencia + Escolaridade, data = dados)

Coefficients:
(Intercept)    Experiencia    Escolaridade
      7.07122         0.04919         0.08180
```

O método stepwise both com critério AIC partiu do modelo nulo e adicionou/removeu termos até encontrar o modelo com menor AIC. O modelo selecionado contém ****Escolaridade, Experiencia****. As variável Setor e Idade foram excluídas.

- Cp de Mallows:

```
Selection Algorithm: exhaustive
      Experiencia  Escolaridade  Setor1  Idade
1 ( 1 ) "*"          " "          " "    " "
2 ( 1 ) "*"          "*"          " "    " "
3 ( 1 ) "*"          "*"          " "    "*"
4 ( 1 ) "*"          "*"          "*"    "*"
.....
```

	1 variável	2 variável	3 variável	4 variável
Cp de Mallows	5.44	3.64	4.61	5.000000

os Cp de Mallows são:

1 variável: 5.44 (Escolaridade); **2 variável: 3.64 (Experiencia + Escolaridade)**; 3 variável: 4.61 (Experiencia + Escolaridade + Idade); 4 variável: 5.00 (Experiencia + Escolaridade + Idade + Setor)

O modelo com menor Cp é o de 2 variáveis (Experiencia + Escolaridade).

- LASSO:

```
5 x 1 sparse Matrix of class "dgCMatrix"
      lambda.min
(Intercept) 7.40210261
Experiencia 0.03842477
Escolaridade 0.06239494
Setor       .
Idade       .
```


O LASSO reteve Experiencia, Escolaridade, e atribui valores baixos de λ para Setor e Idade.

2.4 Conclusão da Etapa 2

- A Matriz de Correlação não mostrou correlações elevadas entre preditoras, e os VIFs (todos próximos abaixo de 2) confirmaram ausência de multicolinearidade.
- Na seleção de variáveis, o método Stepwise com AIC reteve Experiencia, Escolaridade, assim como o Cp de Mallows, e assim como LASSO.
- Em respeito aos métodos usados (Stepwise, Cp e LASSO), selecionamos para a etapa seguinte **o modelo com Experiencia e Escolaridade.**

Etapa 3:

1. Ajustar o modelo
2. Fazer Diagnóstico/ análise de resíduo para verificar os pressupostos:
 - Linearidade (gráfico de resíduos vs. valores ajustados)
 - Homocedasticidade (o mesmo gráfico + teste de Breusch-Pagan ou outros testes)
 - Normalidade dos erros (QQ-plot + teste de Shapiro-Wilk ou outros)
 - Independência (gráfico de resíduos vs. ordem de coleta, nesse caso não temos a ordem)
3. Se passar pelo crivo da análise de resíduo --> prossiga
4. Inclua a parte de detecção de outliers e pontos influentes. Opções: H_{ii} ; DF-Betas; DF-Fits; D-Cook
5. Após análise de resíduo faça testes: F-Global; t; F-Parcial

3.1 Ajuste do modelo

Pela etapa 2, o modelo é da forma

$$Y = \log(\text{salário}) = \beta_0 + \beta_1 \text{Experiencia} + \beta_2 \text{Escolaridade} + \varepsilon_{ij}$$

```
Call:
lm(formula = LogSalario ~ Experiencia + Escolaridade, data = dados)
... ..
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   7.07122     0.45630   15.497 3.3e-10 ***
Experiencia    0.04919     0.02384    2.063  0.0581 .
Escolaridade   0.08180     0.04292    1.906  0.0774 .
... ..
```

- Coeficientes estimados: $\hat{\beta}_0 = 7.07$, $\hat{\beta}_1 = 0.05$, $\hat{\beta}_2 = 0.08$

Interpretação:

Para cada ano adicional de Experiência, o log-Salário aumenta em média 4%, mantendo a Escolaridade fixa;


Para cada ano adicional de Escolaridade, o log-salário aumenta em média 8%, mantendo a escolaridade fixa”;

Não tem interpretação para β_0 pois aparentemente 0 não está no range das covariáveis Experiência e Escolaridade.

3.2 Diagnóstico/ Análise de resíduos

3.2.1 Linearidade

O gráfico de resíduos vs valores ajustados.



Aparenta ter alguma estrutura de um U invertido, isso pode indicar que um termo quadrático é necessário no modelo (supostamente Experiência^2), mas faço isso se sobrar tempo. Por enquanto vou prosseguir como o

mesmo modelo para ver o que acontece.

3.2.2 Homocedasticidade

O gráfico seria o mesmo de antes.

Mas formalmente, pode-se fazer um teste de Breusch-Pagan.


```
studentized Breusch-Pagan test  
  
data:  modelo  
BP = 3.9642, df = 2, p-value = 0.1378
```

Valor-p de 0.1378 não é pequeno, a hipótese da homocedasticidade não é violada, podemos prosseguir.

3.2.3 Normalidade dos Erros

QQ-Plot e teste de Shapiro-Wilk:

QQ-plot dos Resíduos



Shapiro-Wilk normality test

```
data:  residuos  
W = 0.96178, p-value = 0.6652
```

- No QQ-plot, a maioria dos pontos estão perto da reta. Pequenos desvios nas caudas são toleráveis com $n = 21$.
- O teste Shapiro-Wilk: H_0 = os dados vêm de uma distribuição normal.

Valor-p = 0.66, não rejeita H_0 (que afirma os dados são normalmente distribuídos)


(Claro, mesmo se valor-p fosse razoavelmente pequeno, Note que a regressão linear é robusta a desvios de normalidade especialmente para amostras não muito pequenas.)

3.2.4 Independência

Como não temos a ordem de coleta, assumimos que são independentes.

3.3 Análise de outliers e pontos influentes

3.3.1 Resíduos studentized e alavancagem (os H_{ii})




Possíveis outliers (resíduo studentizado > |2|):

Experiencia	Escolaridade	Setor	Idade	LogSalario
11	16	16	0	28
				8.47

Note que a observação 11 foi classificada como outlier pelo resíduo studentizado.


Calculuando os valores de alavancagem (h_{ii}):



Não tem valores (h_{ii}) maiores que o limiar = 0.35, ou seja ninguém é considerado de alta alavancagem e merece atenção.

3.3.2 Distância de Cook


Distância de Cook




Tem dois valores (observação 4 e 10 do treino) que são maiores que o limiar ($4/17 = 0.235$) sinalizando que são pontos influentes.

3.3.3 DFFITS e DFBETAS


DFFITS



DFBETAS - Experiencia



DFBETAS - Escolaridade



As observações 4 e 10 do treino possuem a distância de Cook que ultrapassa o limiar, além disso elas apresentam alta alavancagem/leverage e destacam-se em DFFits e em DFBETAS para Experiencia. Devem ser investigados.

3.4 Testes de significância formais

Fazendo um sumário do modelo com comando "summary" do R, tem-se:

```
Call:
lm(formula = LogSalario ~ Experiencia + Escolaridade, data = dados)

Residuals:
    Min       1Q   Median       3Q      Max
-0.69703 -0.15158  0.02404  0.22629  0.53970
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.07122	0.45630	15.497	3.3e-10 ***
Experiencia	0.04919	0.02384	2.063	0.0581 .
Escolaridade	0.08180	0.04292	1.906	0.0774 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3776 on 14 degrees of freedom

Multiple R-squared: 0.6071, Adjusted R-squared: 0.551

F-statistic: 10.82 on 2 and 14 DF, p-value: 0.001446

Note que o R^2 ajustado é 0.551

Após confirmar que os pressupostos são aceitáveis, realiza-se os testes:

- Teste F global: já obtido no summary. Conclusão: Rejeita $H_0: \beta_1 = \beta_2 = 0$, valor-p = 0.0014
- Testes t individuais: obtido no summary. Tanto para β_1 quanto para β_2 , todos os valores-p não foram inferiores a 0.05, não rejeita a hipótese de que são nulas.

Teste F parcial: serve para comparar o modelo reduzido com o modelo completo (incluindo Setor e Idade). Isso avalia se as variáveis excluídas são conjuntamente significativas.

Usando **R** e o type III do teste parcial (comando é `Anova(modelo, type = "III")`), a saída fica:

```
A anova: 4 x 4
Sum Sq Df F value Pr(>F)
<dbl> <dbl> <dbl> <dbl>
(Intercept) 34.2369378 1 240.151437 3.304527e-10
Experiencia 0.6069104 1 4.257110 5.814262e-02
Escolaridade 0.5178092 1 3.632119 7.741689e-02
Residuals 1.9958953 14 NA NA
```

Assim, pode-se dizer que:

- Para Experiência: valor-p = 0.058 não é muito pequeno, isso significa que remover "Experiência" piora (moderadamente) o ajuste do modelo, mesmo mantendo "Escolaridade".
- Para Escolaridade: valor-p = 0.074 não é muito pequeno, isso significa que remover Escolaridade piora (moderadamente) o ajuste do modelo, mesmo mantendo "Experiência".

Resumindo: tanto experiência quanto escolaridade apresentaram contribuição mais ou menos significativa para explicar a variável resposta LogSalário.

E fazendo anova comparando o modelo reduzido e o modelo full, tem-se um valor-p = 0.30, confirmando que a exclusão de Setor e Idade não compromete o ajuste.

3.5 Conclusão da Etapa3

O diagnóstico de resíduos não revelou violações muito graves dos pressupostos:

- A linearidade não parece fortemente adequada, talvez precise de um termo quadrático
- A homoscedasticidade é garantida (teste de Breusch-Pagan valor-p = 0.13),
- A normalidade dos resíduos é sustentável (Shapiro-Wilk p = 0.66)
- Não há indícios de dependência.

A análise de influência detectou pontos com leverage ligeiramente alto (obs. 4 e 10), e D de Cook > limite.

Os testes de significância indicam que o modelo como um todo não é muito significativo (coeficiente de Determinação ajustado $R^2 = 0.551$) (F-global valor-p = 0.001) e que ambos os preditores (Experiência e Escolaridade) são moderadamente relevantes (os valores-p pequenos).

O teste F-parcial (type III) retornou valores-p são pequenos, ou seja as covariáveis Experiência e Escolaridade são moderadamente significativos.

E fazendo anova comparando o modelo reduzido e o modelo full, tem-se um valor-p = 0.30, confirmando que a exclusão de Setor e Idade não compromete o ajuste.

Portanto, o modelo reduzido não parece muito apropriado, mas isso vai ser investigado na etapa 4.

Etapa 4:

Validação

Procurar a resposta da seguinte questão: **O modelo é útil para uma nova Base de dados??**

O que pode ser feito é antes de ajustar o modelo, separar um conjunto pequeno para validar depois.

1. Divisão aleatória antes de ajustar. exemplo: 70% treino e 30% teste.
2. Opções de validar o modelo:
 - Reportar medidas preditivas como RMSE
 - Validação cruzada (k-fold)

Note que $n = 24 - 7 = 17$, a amostra é pequena

4.1 Divisão em treino e teste

O modelo foi ajustado com as 17 observações separadas, pois já no início com o `set.seed(20260513)` para reprodutividade, o grupo teste é formado por 7 observações (1;5;8;13;14;18;19), e o grupo treino é o que sobrou.

4.2 Predição no conjunto de teste.

Indice	Experiencia	Escolaridade	Setor	Idade	LogSalario	Pred_LogSal
1	5	16	1	38	8.874	8.625
5	3	8	1	23	7.472	7.873
8	11	9	0	28	8.599	8.348
13	3	15	0	42	8.632	8.445
14	3	12	0	32	8.149	8.200
18	6	11	0	34	9.060	8.75
19	4	11	1	39	8.156	8.167

4.3 Métricas de erro de predição

São usadas as seguintes métricas:

- RMSE (raiz do erro quadrático médio)
- MAE (erro absoluto médio)
- R^2 (Coeficiente de determinação preditivo)

```
RMSE_teste: 0.2434
MAE_teste: 0.2075
R² preditivo: 0.9676
```

```
RMSE_treino: 0.3426
MAE_treino: 0.2763
```

4.4 O que dizer sobre essas métricas

Para avaliar a capacidade preditiva do modelo, a base (24 obs.) é dividida aleatoriamente em treino (17 obs.) e teste (7 obs.), com semente 20260512.

É feito um ajuste do modelo no treino e obtivemos no teste um $RMSE_{teste}$ de 0.2434, MAE_{teste} de 0.2075 e R^2 preditivo de 0.9676, enquanto $RMSE_{treino}$ é 0.3426 e MAE_{treino} é 0.2763.

Apesar do tamanho diminuto do conjunto de teste, o resultado acima obtido por divisão treino-teste sugere que o modelo é moderadamente útil para novas observações.

4.5 Conclusão da Validação Cruzada (5-fold)

A validação cruzada com 5 partições foi aplicada ao modelo **LogSalario ~ Experiencia + Escolaridade** utilizando **todos os 24 dados brutos** (sem separação prévia treino/teste). Os resultados médios foram:

- **RMSE = 0,3629**
- **$R^2 = 0,7317$**
- **MAE = 0,2950**

Comparação com as métricas anteriores (hold-out):

Métrica	Hold-out (treino)	Hold-out (teste)	Validação Cruzada (5-fold)
RMSE	0,3426	0,2434	0,3629
R^2	0,6071 (ajust=0,551)	0,9676 (preditivo)	0,7317
MAE	0,2763	0,2075	0,2950

Interpretação:

1. **O RMSE da validação cruzada (0,3629) é ligeiramente superior ao RMSE de treino (0,3426)**, o que era esperado – a CV avalia o erro em dados não vistos durante o treinamento de cada fold.
 - Porém, o RMSE da CV é **maior do que o RMSE obtido no conjunto de teste hold-out (0,2434)**. Isso indica que a estimativa pontual baseada em uma única divisão treino-teste (com apenas 7 observações) foi **otimista** (subestimou o erro real). A CV fornece uma métrica mais estável e confiável para uma amostra pequena ($n=24$).
2. **O R^2 médio da CV (0,7317) é muito menor do que o R^2 preditivo do hold-out (0,9676)**, confirmando que o hold-out superestimou a capacidade preditiva devido ao tamanho reduzido do conjunto de teste.
 - O valor 0,7317 está mais próximo do R^2 ajustado do treino (0,551) e do R^2 múltiplo (0,6071), sugerindo que o modelo explica cerca de **73% da variabilidade de novos dados**, em média.
3. **O MAE da CV (0,2950) indica que, em média, a previsão do log-salário erra por aproximadamente 0,30 unidades**. Na escala original do salário (exponencial), isso representa um erro multiplicativo de cerca de $\exp(0,295) \approx 1,34$ (34% de erro percentual médio) – um valor moderado, mas que pode ser aprimorado.

Conclusão final sobre a utilidade do modelo:

- O modelo com **Experiência e Escolaridade** apresenta **capacidade preditiva razoável**, porém não excelente.
- A validação cruzada corrige o viés otimista do hold-out e mostra que o erro esperado em novas observações é **RMSE $\approx 0,36$** , ainda assim inferior ao desvio padrão da resposta (**$\text{sd}(\text{dados_brutos}\$LogSalario) \approx 0,54$**), indicando que o modelo agrega valor em relação a uma previsão ingênua (apenas a média).
- Recomenda-se, em trabalhos futuros, testar a inclusão de termos quadráticos (especialmente para **Experiencia**) ou investigar a interação entre escolaridade e setor, pois o R^2 da CV de 0,73 deixa margem para melhoria.

Portanto, o modelo é útil, mas deve ser usado com cautela – especialmente porque a amostra é pequena (24 observações) e os pontos influentes (obs. 4 e 10) podem distorcer as estimativas em novas bases.

Adicional:

Problema no Teste de linearidade:

incluir quadrático de Experiencia -----> $\text{LogSalario} \sim \text{Experiencia} + I(\text{Experiencia}^2) + \text{Escolaridade}$

```
RMSE_teste: 0.117
MAE_teste: 0.0993
R² preditivo: 0.9586
RMSE_treino: 0.253
MAE_treino: 0.2112
```

Resíduos vs Ajustados (Linearidade)

