

Atividade 3 -- Análise de Regressão:

Aluno: Marcelo Huang

Enunciado: "O conjunto acima envolve as covariáveis Ano de Experiência, Ano de Escolaridade, Setor do Trabalho, Idade do Funcionario e a resposta Log(Salário). Ajuste um modelo de regressão considerando as 4 etapas discutidas em sala."

Contexto

Nesta atividade, será realizada uma análise de um conjunto de dados dito na sala de aula, usando um modelo de regressão linear. A partir desses dados, serão conduzidos: Diagnóstico/Análise de resíduos; Detecção de outliers e pontos influentes; Testes estatísticas; e validação do modelo.

O conjunto de dados é composto por 3 covariáveis e 1 variável resposta:

- X_1 : Anos de Experiência profissional
- X_2 : Anos de Escolaridade
- X_3 : Variável dummy, é 1 ou 0. 1 significa **Privado**, 0 significa **Público**
- X_4 : Idade da pessoa
- Y : log(Salário).

Nessa atividade, as análises serão realizadas no software **R**, utilizando funções da linguagem, nativas e/ou de pacotes externas

Etapa 1:

Pegar os dados brutos e começa a verificar inconveniências.

Nesse contexto seria verificar a consistência entre idade, experiência e escolaridade.

- Corrigir
- Transformar
- Remover

Todas ações feitas devem ser documentadas e justificadas.

1.1 Carregando os dados (disponibilizado no classroom):

Dados do Experimento

Ano_Exper	Ano_Escol	Setor	Idade	Log(Salario)
5	16	1	38	8.874
11	10	1	39	8.970

Ano_Exper	Ano_Escol	Setor	Idade	Log(Salario)
9	13	1	22	8.901
...	...	...	...	...
5	13	1	21	8.416
6	10	1	23	8.033

1.2 Verificando inconsistências:

Para um indivíduo, a idade deve ser compatível com anos de experiência e escolaridade. Geralmente a idade de início da vida profissional pode ser aproximada por:

$$\text{Início} = \text{Idade} - (\text{Experiencia} + \text{Escolaridade} + 6)$$

Supondo que a escolaridade **formal** comece aos 6 anos. Além disso o início da vida profissional deve ser maior ou igual a 16 anos para ser razoável (podendo ter uma margem de erro).

Índice da Observação	Idade	Anos de Experiencia	Anos de Escolaridade	Início do trabalho
9	22	17	17	-6
10	28	18	18	-2
11	28	16	16	2
3	22	9	13	6
...	...	...	...	...

Tabela acima é ordenada de maneira crescente pelo "Início do trabalho".

Fazendo a conta usando a aproximação dada acima, pode-se perceber que existe algumas observações estranhas, por exemplo:

- Observação 9:

-> Idade=22, Experiencia=17, Escolaridade=17. Início = $22 - 17 - (17 - 6) = 22 - 17 - 11 = -6$.

-> Para ter 17 anos de experiência e 17 de escolaridade, seriam necessários pelo menos $17 + 11 = 28$ anos de vida. Com 22 anos, é matematicamente impossível, nem trabalho infantil nem estudo concomitante explicam. Remover.

- Observação 10:

-> Idade=28, Experiencia=18, Escolaridade=18. Início = $28 - 18 - 12 = -2$.

-> Mesmo problema: seriam necessários no mínimo 30 anos de vida. Impossível. Remover.

- Observação 11:

-> Idade=28, Experiencia=16, Escolaridade=16. Início = $28 - 16 - 10 = 2$.

-> Aqui a idade de início seria 2 anos, o que ainda é absurdo. O total de anos "ocupados" (experiência + escolaridade pós-6) é $16+10=26$, contra 28 de idade, sobriam apenas 2 anos antes dos 6, ou seja, a pessoa teria começado a trabalhar aos 2 anos. Não provável. Remover.



- Observação 3: Idade=22, Experiencia=9, Escolaridade=13. Início = $22 - 9 - 7 = 6$.

-> Mais ou menos possível (se a pessoa vive na era vitoriana na Inglaterra), mas num contexto profissional contemporâneo, 6 anos soa como erro de registro. A anomalia é menos grave, porém digna de nota. Manter.

Logo as observações 9 e 10 e 11 violam a consistência lógica, vão ser removidas já que não sabemos se foi um erro de registro ou outra coisa.

Assim a base resultante contém agora 21 observações depois de remover 9 e 10 e 11.


1.3 Análise gráfica para linearidade:



As variáveis Experiência, Escolaridade, e Idade apresentam comportamento linear com a resposta $\log(\text{Salário})$. Não tem indícios da necessidade de uma transformação.

1.4 Verificando outliers univariados

Outliers na resposta ou nas preditoras podem distorcer a análise. Faça boxplots individuais:



Não parece ter outliers na covariáveis

1.5 Concluindo etapa 1

- A base tem 24 observações completas, sem dados ausentes, mas duas observações (**9, 10 e 11**) foram removidas por violar a lógica.

- As variáveis estão nos intervalos esperados, sem erros de digitação óbvios.
- A verificação de idade de início de trabalho mostrou valores entre X e Y, todos plausíveis (ou, se encontrou algo, a ação tomada).
- Os gráficos de dispersão sugerem relação aproximadamente linear entre log-salário e as preditoras, exceto talvez a Idade, que apresentou pouco efeito no log-salário. O boxplot de Setor mostra diferença de medianas, indicando possível efeito.

Etapa 2:

Para a base da nossa análise, deve se verificar as seguintes coisas:


- Redução de dimensão das covariáveis (Parcimonia)
- Matriz de correlação
- Matriz de dispersão
- Multicolinearidade, usando critério de VIF (Variance Inflation Factor) como medida
- Seleção de variáveis


*Qual o ponto dessa etapa? Preparar as covariáveis para o ajuste. *

Covariáveis IMPORTANTES/RELEVANTES

2.1 Matriz de correlação

	Experiencia	Escolaridade	Idade	LogSalario
Experiencia	1.000	-0.071	-0.060	0.635
Escolaridade	-0.071	1.000	0.252	0.682
Idade	-0.060	0.252	1.000	0.255
LogSalario	0.635	0.682	0.255	1.000





A matriz de correlação não revela correlações elevadas entre as variáveis predictoras (todas as correlações entre pares de preditores são menores que 0,3 em valor absoluto). Isso sugere **ausência de multicolinearidade** problemática, indicando que as covariáveis são aproximadamente linearmente independentes entre si.

2.2 Diagnóstico de multicolinearidade usando VIF (Variance Inflation Factor) como medida

	Experiencia	Escolaridade	Idade	LogSalario
VIF	1.021	1.07	1.10	0.635

Os Valores do Fator de Inflação da Variância (VIF) são todos inferiores a 2, próximos de 1. Esse resultado confirma a **ausência de multicolinearidade**; não há evidência de que alguma preditora seja combinação linear das demais.

2.3 Seleção de variáveis

- Stepwise: a saída em R fica do jeito abaixo

```
Call:
lm(formula = LogSalario ~ Escolaridade + Experiencia + Idade,
    data = dados)

Coefficients:
(Intercept)  Escolaridade  Experiencia      Idade
   5.714365    0.141135    0.122842    0.009121
```

O método stepwise both com critério AIC partiu do modelo nulo e adicionou/removeu termos até encontrar o modelo com menor AIC. O modelo selecionado contém **Escolaridade, Experiencia e Idade**. A variável Setor foi excluída.

- Cp de Mallows:

```
      Experiencia  Escolaridade  Setor1  Idade
1 ( 1 ) " "      "*"          " "    " "
2 ( 1 ) "*"      "*"          " "    " "
3 ( 1 ) "*"      "*"          " "    "*"
4 ( 1 ) "*"      "*"          "*"    "*"

```

	1 variável	2 variável	3 variável	4 variável
Cp de Mallows	156.214020	6.107709	3.706976	5.000000

os Cp de Mallows são:

1 variável: 11.26 (Escolaridade); **2 variável: 6.1 (Experiencia + Escolaridade)**; **3 variável: 3.7 (Experiencia + Escolaridade + Idade)**; 4 variável: 5.00 (Experiencia + Escolaridade + Idade + Setor)

O modelo com menor Cp é o de 3 variáveis (Experiencia + Escolaridade + Idade). Mas o Cp de 2 variáveis também é pequeno, próximo com o Cp de 3.

- LASSO:

```
5 x 1 sparse Matrix of class "dgCMatrix"
      lambda.min
(Intercept)  5.831765894
Experiencia  0.120882575
Escolaridade 0.138458408
Setor1      -0.038042853
Idade        0.007505697
```

O LASSO reteve Experiencia, Escolaridade, e atribui valores baixos de λ para Setor e Idade.

2.4 Conclusão da Etapa 2

- A Matriz de Correlação não mostrou correlações elevadas entre preditoras, e os VIFs (todos próximos de 1) confirmaram ausência de multicolinearidade.
- Na seleção de variáveis, o método Stepwise com AIC reteve Experiencia, Escolaridade e Idade, assim como o Cp de Mallows.
- Entretanto, o Cp de Mallows com duas variáveis (Experiencia e Escolaridade) possui Cp pequeno também, com desempenho similar ao modelo de três variáveis.
- Além disso, O LASSO excluiu Setor, atribuiu à Idade um coeficiente desprezível (0,003), corroborando a ideia de que nem o setor nem a Idade contribuem de forma expressiva. Adicionalmente, a correlação entre Idade e LogSalario é baixa (0,26).
- Em respeito ao princípio da parcimônia e apoiado pelo Cp e LASSO, selecionamos para a etapa seguinte **o modelo com Experiencia e Escolaridade.**

Etapa 3:

1. Ajustar o modelo
2. Fazer Diagnóstico/ análise de resíduo para verificar os pressupostos:
 - Linearidade (gráfico de resíduos vs. valores ajustados)
 - Homocedasticidade (o mesmo gráfico + teste de Breusch-Pagan ou outros testes)
 - Normalidade dos erros (QQ-plot + teste de Shapiro-Wilk ou outros)
 - Independência (gráfico de resíduos vs. ordem de coleta, nesse caso não temos a ordem)
3. Se passar pelo crivo da análise de resíduo --> prossiga
4. Inclua a parte de detecção de outliers e pontos influentes. Opções: H_{ii} ; DF-Betas; DF-Fits; D-Cook
5. Após análise de resíduo faça testes: F-Global; t; F-Parcial

3.1 Ajuste do modelo

Pela etapa 2, o modelo é da forma

$$Y = \log(\text{salário}) = \beta_0 + \beta_1 \text{Experiencia} + \beta_2 \text{Escolaridade} + \varepsilon_{ij}$$

```
Call:
lm(formula = LogSalario ~ Experiencia + Escolaridade, data = dados)
... ..
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   5.94336    0.16459   36.11 < 2e-16 ***
Experiencia    0.12193    0.01071   11.39 1.16e-09 ***
Escolaridade   0.14716    0.01213   12.13 4.25e-10 ***
... ..
```

- Coeficientes estimados: $\hat{\beta}_0 = 5.94$, $\hat{\beta}_1 = 0.12$, $\hat{\beta}_2 = 0.14$

Interpretação:

Para cada ano adicional de Experiência, o log-Salário aumenta em média 12%, mantendo a Escolaridade fixa;


Para cada ano adicional de Escolaridade, o log-salário aumenta em média 14%, mantendo a escolaridade fixa”;

Não tem interpretação para β_0 pois aparentemente 0 não está no range das covariáveis Experiência e Escolaridade.

3.2 Diagnóstico/ Análise de resíduos

3.2.1 Linearidade

O gráfico de resíduos vs valores ajustados. A hipótese é que a relação é linear se os resíduos se distribuem aleatoriamente em torno de zero, sem curvatura.



Não parenta ter alguma estrutura, podemos prosseguir.

3.2.2 Homocedasticidade

O gráfico seria o mesmo de antes.

Mas formalmente, pode-se fazer um teste de Breusch-Pagan.

```
studentized Breusch-Pagan test
```


```
data: modelo
```

```
BP = 0.66704, df = 2, p-value = 0.7164
```

Valor-p de 0.71 não é pequeno, a hipótese da homocedasticidade não é violada, podemos prosseguir.

3.2.3 Normalidade dos Erros

QQ-Plot e teste de Shapiro-Wilk:



Shapiro-Wilk normality test

data: residuos

W = 0.96513, p-value = 0.6248

- No QQ-plot, a maioria dos pontos estão perto da reta. Pequenos desvios nas caudas são toleráveis com $n = 21$.

- O teste Shapiro-Wilk: H_0 = os dados vêm de uma distribuição normal.

Valor-p = 0.62, não rejeita H_0 (que afirma os dados são normalmente distribuídos)

(Claro, mesmo se valor-p fosse razoavelmente pequeno, Note que a regressão linear é robusta a desvios de normalidade especialmente para amostras não muito pequenas.)


3.2.4 Independência

Como não temos a ordem de coleta, assumimos que são independentes.

3.3 Análise de outliers e pontos influentes

3.3.1 Alavanacagem (leverage)


Calculando os valores de alavancagem (h_{ii}):



Não tem valores (h_{ii}) maiores que o limiar = 0.28, ou seja ninguém é considerado de alta alavancagem e merece atenção.


3.3.2 Distância de Cook

Distância de Cook




Tem dois valores (observação com índices 2 e 15, pois 9,10 e 11 foram removidos) que são maiores que o limiar ($4/21 = 0.19$) sinalizando que são pontos influentes.


3.3.3 DFFITS e DFBETAS



DFBETAS - Experiencia



DFBETAS - Escolaridade



As observações 2 e 15 possuem a distância de Cook que ultrapassa o limiar, além disso elas apresentam alta alavancagem/leverage e destacam-se em DFFits e em DFBETAS para Experiencia. Devem ser investigados.

3.4 Testes de significância formais

Fazendo um sumário do modelo com comando "summary" do R, tem-se:

```
Call:
lm(formula = LogSalario ~ Experiencia + Escolaridade, data = dados)

Residuals:
    Min       1Q   Median       3Q      Max
-0.24164 -0.11360 -0.01011  0.10610  0.21373
```

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   5.94336    0.16459   36.11 < 2e-16 ***
Experiencia    0.12193    0.01071   11.39 1.16e-09 ***
Escolaridade   0.14716    0.01213   12.13 4.25e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1411 on 18 degrees of freedom
Multiple R-squared:  0.9349,    Adjusted R-squared:  0.9276
F-statistic: 129.2 on 2 and 18 DF,  p-value: 2.105e-11

```

Note que o R^2 ajustado é 0.9276

Após confirmar que os pressupostos são aceitáveis, realiza-se os testes:

- Teste F global: já obtido no summary. Conclusão: Rejeita $H_0: \beta_1 = \beta_2 = 0$, valor-p = 2.1e-11
- Testes t individuais: já no summary. todos valores-p foram bem pequenas, rejeita a hipótese de que são nulas.

Teste F parcial: serve para comparar o modelo reduzido com o modelo completo (incluindo Setor e Idade). Isso avalia se as variáveis excluídas são conjuntamente significativas.

Usando **R** e o type III do teste parcial (comando é `Anova(modelo, type = "III")`), a saída fica:

```

A anova: 4 x 4
Sum |    Sq |    Df |    F value |    Pr(>F)
<dbl> <dbl> <dbl> <dbl>
(Intercept) 25.9742132  1  1304.0053  3.001280e-18
Experiencia  2.5836976  1  129.7115  1.164790e-09
Escolaridade  2.9303732  1  147.1160  4.246866e-10
Residuals    0.3585383 18  NA  NA

```

Assim, pode-se dizer que:

- Para Experiência: valor-p = 1.16e-09 é muito pequeno, isso significa que remover "Experiência" piora fortemente o ajuste do modelo, mesmo mantendo "Escolaridade".
- Para Escolaridade: valor-p = 4.24e-10 é muito pequeno, isso significa que remover Escolaridade piora fortemente o ajuste do modelo, mesmo mantendo Experiência.

Resumindo: tanto experiência quanto escolaridade apresentaram contribuição significativa para explicar a variável resposta LogSalário, controlando-se mutuamente.

3.5 Conclusão da Etapa3

O diagnóstico de resíduos não revelou violações graves dos pressupostos:

- A linearidade parece adequada (resíduos sem padrão)
- A homoscedasticidade é garantida (teste de Breusch-Pagan valor-p = 0.71),
- A normalidade dos resíduos é sustentável (Shapiro-Wilk p = 0.62)
- Não há indícios de dependência.

A análise de influência detectou pontos com leverage ligeiramente alto (obs. 2 e 15), mas D de Cook < limite.

Os testes de significância indicam que o modelo como um todo é significativo, pois:

1. coeficiente de Determinação ajustado $R^2 = 0.927$
2. F-global valor-p = 2.1e-11
3. e que ambos os preditores (Experiência e Escolaridade) são individualmente relevantes (os valores-p pequenos em F-parcial).

Etapa 4:

Validação

Procurar a resposta da seguinte questão: **O modelo é útil para uma nova Base de dados??**

O que pode ser feito é antes de ajustar o modelo, separar um conjunto pequeno para validar depois.

1. Divisão aleatória antes de ajustar. exemplo: 70% treino e 30% teste.
2. Opções de validar o modelo:
 - Reportar medidas preditivas como RMSE
 - Validação cruzada (k-fold) (é uma possibilidade mas não será abordada nessa atividade)

Note que $n=24 - 3 = 21$, a amostra é pequena

4.1 Divisão em treino e teste

A amostra tinha 24 observações, removeu-se 3 observações absurdas sobrou 21 observações. Para validar é feita uma divisão de dados: 70% são usados para ajustar o modelo, e 30% são usados para validar.

Usando `set.seed(20260512)` para reprodutividade, o grupo teste é formado por 6 observações (1,5,8,10,14,18), e o grupo para ajustar é o que sobrou.

4.2 Reajuste do modelo para a base de treino

```
Call:
lm(formula = LogSalario ~ Experiencia + Escolaridade, data = dados_treino)
...
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	6.09257	0.24459	24.909	1.06e-11	***
Experiencia	0.12863	0.01404	9.161	9.16e-07	***
Escolaridade	0.13220	0.01893	6.982	1.47e-05	***

$$\hat{Y} = \log(\text{salário}) = \beta_0 + \beta_1 \text{Experiencia} + \beta_2 \text{Escolaridade} + \epsilon_{ij}$$

- Coeficientes estimados nesse reajuste: $\hat{\beta}_0 = 6.09$, $\hat{\beta}_1 = 0.1286$, $\hat{\beta}_2 = 0.132$

4.3 Predição no conjunto de teste

Experiencia	Escolaridade	Setor	Idade	LogSalario	Pred_LogSal
5	16	1	38	8.874	8.850
3	8	1	23	7.472	7.536
11	9	0	28	8.599	8.697
3	15	0	42	8.632	8.461
7	8	1	39	7.796	8.050
3	11	0	33	7.997	7.932

4.4 Métricas de erro de predição

São usadas as seguintes métricas:

- RMSE (raiz do erro quadrático médio)
- MAE (erro absoluto médio)
- R^2 (Coeficiente de determinação preditivo)

RMSE: 0.1368
 MAE: 0.1125
 R^2 preditivo: 0.9329

4.6 Conclusão da etapa 4

Para avaliar a capacidade preditiva do modelo, a base (21 obs.) é dividida aleatoriamente em treino (15 obs.) e teste (6 obs.), com semente 20260512.

É feito um ajuste do modelo no treino e obtivemos no teste um RMSE de 0.1368, MAE de 0.1125 e R^2 preditivo de 0.9329.

Esses valores indicam que o modelo captura parte substancial da variação do log-salário.

Apesar do tamanho diminuto do conjunto de teste, o resultado sugere que o modelo é útil para novas observações.