

Atividade 6 -- Análise de Regressão com Erros Autocorrelacionados

Aluno: Marcelo Huang

Enunciado: "Uma empresa desejava prever suas vendas utilizando as vendas do setor como variável preditora. Dados trimestrais com ajuste sazonal para o período de 1998 a 2002 estavam disponíveis.

Cada aluno deverá gerar sua própria base de dados simulada contendo n observações trimestrais para as seguintes variáveis: Vendas da empresa (Y_t); Vendas do setor (X_t); assumindo que os erros seguem um processo autorregressivo de primeira ordem, $AR(1)$."

A análise deve contemplar no mínimo os seguintes itens

- (1) descrição do mecanismo de geração dos dados;
- (2) análise exploratória;
- (3) ajuste do modelo de regressão linear simples;
- (4) análise gráfica dos resíduos;
- (5) investigação da autocorrelação via ACF;
- (6) testes estatísticos para autocorrelação;
- (7) consequências da autocorrelação sobre as inferências;
- (8) correção da autocorrelação;
- (9) conclusões.

Etapa 0: Contextualizando

São simuladas $n = 20$ **observações trimestrais** (5 anos $\times$ 4 trimestres, cobrindo 1998--2002), com:

- X_t : Vendas do setor (variável explicativa, gerada como passeio aleatório com tendência)
- Y_t : Vendas da empresa (variável resposta, relacionada linearmente a X_t com erros $AR(1)$)

O modelo de geração dos dados é:

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t, \quad \varepsilon_t = \rho \varepsilon_{t-1} + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2)$$

Toda a análise será feita em **R**.

Item 1: Geração dos Dados

1.1 Parâmetros adotados na simulação

Os parâmetros escolhidos foram:

Parâmetro	Valor	Descrição
n	20	Número de observações trimestrais
β_0	10	Intercepto da regressão

Parâmetro	Valor	Descrição
β_1	5	Coeficiente angular (relação entre setor e empresa)
ρ	0,7	Coeficiente de autocorrelação AR(1) dos erros
σ_u	3	Desvio-padrão das inovações do processo AR(1)
μ_X	100	Nível médio das vendas do setor
σ_X	15	Escala das vendas do setor

A escolha de $\rho = 0,7$ é propositalmente elevada para que a autocorrelação seja **detectável** nos testes e gráficos subsequentes, simulando uma situação em que vendas trimestrais são persistentes no tempo.

1.2 Mecanismo de geração

O processo de geração segue três passos:

1. **Vendas do setor (X_t):** geradas como valores normais com média e desvio-padrão fixos, acrescidos de uma leve tendência temporal crescente para imitar o comportamento de uma série macroeconômica real. Nesse caso, é da forma: $X_t \leftarrow 100 + 0,5 * t + \varepsilon_t$
2. **Erros AR(1) (ε_t):** gerados de forma recursiva: $\varepsilon_t = \rho \varepsilon_{t-1} + u_t$, com $\varepsilon_1 = u_1 / (1 - \rho^2)^{1/2}$ para já inicializar na variância estacionária.
3. **Vendas da empresa (Y_t):** calculadas como $Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$.

Note que: "O enunciado diz que os dados são "trimestrais com ajuste sazonal". Dessa forma, optei por gerar X_t sem componente sazonal explícito (apenas tendência + ruído branco). Isso dispensa qualquer correção sazonal na análise."

Item 2: Análise Exploratória

2.1 Estrutura dos dados

O conjunto possui **20 observações trimestrais** sem valores faltantes. Cada linha corresponde a um trimestre de 1998-T1 a 2002-T4. As variáveis principais são X_t (vendas do setor, em unidades monetárias) e Y_t (vendas da empresa, na mesma escala).

2.2 Estatísticas descritivas

Usando R temos os seguintes resultados:

```
=== Resumo de X (Vendas do Setor) ===
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 79.67 100.37 103.65 105.72 116.41 128.00
Desvio-padrão de X: 12.362

=== Resumo de Y (Vendas da Empresa) ===
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
```

```
404.4  504.2  527.4  536.2  592.6  644.6
Desvio-padrão de Y: 62.501

Correlação (X, Y): 0.9987
```


Y e X são fortemente correlacionadas (por construção, $\beta_1 = 5$), e ambas exibem **tendência crescente** ao longo do tempo, reflexo da tendência embutida em X_t .

2.3 Análise gráfica


Vamos explorar os dados em três perspectivas:

1. **Séries temporais** de X_t e Y_t lado a lado -- para visualizar a tendência e o co-movimento;
2. **Gráfico de dispersão** Y vs X -- para avaliar a linearidade da relação;
3. **Boxplot** das duas variáveis -- para comparar distribuições e identificar eventuais *outliers*.


Série temporal de X




Série temporal de Y



Dispersão Y vs X



Boxplot de X e Y



Interpretação:

- As séries temporais de X e Y seguem trajetórias semelhantes ao longo do tempo
- O gráfico de dispersão revela uma **relação linear positiva e forte** entre as vendas do setor e as da empresa, com os pontos bem alinhados em torno da reta de regressão.
- Os boxplots mostram que as escalas de X e Y não parecidas (por construção, $\beta_1 = 5$ e $\beta_0 = 10$), sem outliers evidentes em X e Y .
- A alta correlação e o comportamento suavizado das séries já sugerem que os erros podem **não ser independentes** ao longo do tempo -- o que motivará toda a análise dos itens seguintes.

Item 3: Ajuste do Modelo de Regressão Linear Simples

O modelo de regressão linear simples pressupõe:

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t, \quad \varepsilon_t \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ajustamos esse modelo ignorando, por ora, a possível autocorrelação nos erros. O objetivo é obter as estimativas por Mínimos Quadrados (MQ) e verificar se elas se aproximam dos valores verdadeiros ($\beta_0 = 10$, $\beta_1 = 5$).

Interpretação dos parâmetros estimados:


- $\hat{\beta}_0 = 2.39$ (**Intercepto**): representa o valor médio esperado das vendas da empresa quando as vendas do setor são zero. Apesar de não ter interpretação prática direta nesse contexto (não há empresa com setor vendendo zero), o intercepto âncora a reta de regressão. O valor verdadeiro de simulação é $\beta_0 = 10$.
- $\hat{\beta}_1 = 5.49$ (**Coefficiente de X**): indica que, para cada unidade adicional nas vendas do setor, espera-se um acréscimo de $\hat{\beta}_1$ unidades nas vendas da empresa. O valor verdadeiro é $\beta_1 = 5$.
- $R^2 = 0.9972$: mede a proporção da variância de Y explicada pelo modelo. Valores altos são esperados pois há relação linear forte por construção.

Note que: embora as estimativas pontuais de $\hat{\beta}_0$ e $\hat{\beta}_1$ sejam não viesadas mesmo na presença de erros AR(1) (o MQO continua não viesado), os **erros-padrão estimados** e, consequentemente, os **intervalos de confiança e testes de hipóteses** ficam **comprometidos**. Isso será investigado a partir do Item 4.

Item 4: Análise Gráfica dos Resíduos

Antes de testar formalmente a autocorrelação, uma visualização gráfica dos resíduos já pode revelar padrões suspeitos. Verificamos quatro aspectos:

1. **Resíduos vs Valores Ajustados** -- testa linearidade e homocedasticidade;
2. **Resíduos vs Tempo (índice t)** -- revela padrões temporais e autocorrelação;
3. **QQ-plot dos Resíduos** -- avalia a normalidade;
4. **Resíduos defasados** (ε_t vs ε_{t-1}) -- evidência direta de autocorrelação de ordem 1.



Interpretação:

- **Resíduos vs Ajustados:** não há padrão em forma de "U" ou funil, sugerindo que a relação linear e a homocedasticidade não são gravemente violadas. Já que esse gráfico **não captura autocorrelação temporal**.
- **Resíduos vs Tempo:** este é o gráfico mais importante nessa situação. Se os erros fossem independentes, os resíduos oscilariam **aleatoriamente** em torno de zero, mas estamos vendo um padrão. A presença de **sequências de resíduos positivos ou negativos consecutivos** é o principal sinal visual de autocorrelação positiva. Com $\rho = 0,7$, é esperado esse padrão.
- **QQ-plot:** os pontos seguem aproximadamente a reta de referência, indicativos de que os erros são normais. Pequenos desvios nas caudas são comuns em amostras pequenas ($n = 20$).
- **Resíduos defasados ($\hat{\varepsilon}_t$ vs $\hat{\varepsilon}_{t-1}$):** uma correlação positiva visível neste gráfico (padrão diagonal, da esquerda-baixo para a direita-cima) confirma autocorrelação de primeira ordem. Com $\rho = 0,7$, esse padrão deve ser bastante evidente.

Item 5: Função de Autocorrelação (ACF) dos Resíduos


A **Função de Autocorrelação (ACF)** mede a correlação entre $\hat{\varepsilon}_t$ e $\hat{\varepsilon}_{t-k}$ para diferentes defasagens k . Para um processo AR(1) com parâmetro ρ , a ACF teórica decai geometricamente:

$$ACF(k) = \rho^k$$

Portanto, para $\rho = 0,7$: $ACF(1) = 0,7$, $ACF(2) = 0,49$, $ACF(3) = 0,34$, etc.

As barras tracejadas no gráfico da ACF representam o intervalo de confiança aproximado de 95% para a hipótese de que a autocorrelação é zero naquela defasagem: $\pm 1,96/\sqrt{n}$. Barras que ultrapassam esses limites indicam autocorrelação estatisticamente significativa.

Valores da ACF nos primeiros lags:
[1] 0.4430 0.2951 0.2744 0.0568 0.0366



Interpretação:

- **ACF:** a barra na defasagem 1 é grande (próxima de $\rho = 0,7$) e as demais barras decaíam geometricamente. As barras nas defasagens 1 e 2 ultrapassarem as bandas de confiança, há evidência visual de autocorrelação.
- **PACF:** para um processo AR(1), a PACF deve ter **apenas a barra da defasagem 1 significativa**, e as demais próximas de zero. E é isso que o gráfico indica, sugerindo um AR de ordem 1.
- O padrão ACF decrescente + PACF com corte abrupto após defasagem 1 é a indicativa de **um processo AR(1)**, confirmando o mecanismo que usamos na geração dos dados.

Item 6: Testes Estatísticos para Autocorrelação

Além da inspeção gráfica, recorreremos a **testes formais** para decidir se há autocorrelação nos resíduos. Nos dois testes mostrados abaixo a hipótese nula H_0 é que não há autocorrelação.

6.1 Teste de Durbin-Watson (DW)

O teste de Durbin-Watson é o mais clássico para detectar autocorrelação de **primeira ordem** ($k = 1$). A estatística é:

$$d = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=1}^n \hat{\varepsilon}_t^2} \approx 2(1 - \hat{\rho})$$

Valores de d próximos de 2 indicam ausência de autocorrelação; $d < 2$ aponta autocorrelação **positiva** e $d > 2$, **negativa**. Como $\rho = 0,7$, esperamos $d \approx 2(1 - 0,7) = 0,6$.

Durbin-Watson test

```
data: modelo_mqo
DW = 1.0435, p-value = 0.01512
alternative hypothesis: true autocorrelation is greater than 0
```

6.2 Teste de Breusch-Godfrey (BG)

O teste de Breusch-Godfrey é mais geral: testa autocorrelação de qualquer **ordem** p e funciona mesmo quando há variáveis defasadas como regressores. Ele ajusta uma regressão auxiliar dos resíduos em função dos regressores originais e de defasagens dos próprios resíduos, e usa a estatística $LM = (n)R_{\text{aux}}^2$ (algumas implementações utilizam a correção para pequenas amostras $(n - p)R_{\text{aux}}^2$, é o que está sendo usado aqui), que segue aproximadamente χ_p^2 sob H_0 .

onde $R_{\text{aux}}^2 = \frac{\sum_{t=1}^n (\hat{u}_t - \tilde{u})^2}{\sum_{t=1}^n (\hat{u}_t - \hat{u})^2}$, é o coeficiente de determinação da regressão auxiliar e

$\hat{u}_t$: resíduo do modelo original no tempo t . Ele será a variável dependente da regressão auxiliar.

$\tilde{u}$: média dos resíduos do modelo original

$\tilde{\hat{u}}_t$: valor ajustado (predito) pela regressão auxiliar para o tempo t .


```

Breusch-Godfrey test for serial correlation of order up to 1

data:  modelo_mqo
LM test = 4.2995, df = 1, p-value = 0.03812

Breusch-Godfrey test for serial correlation of order up to 2
...

data:  residuals(modelo_mq)
X-squared = 6.6731, df = 2, p-value = 0.03556

```

6.3 Teste de Ljung-Box (LB)

O teste de Ljung-Box também testa autocorrelação de uma série até uma determinada **ordem** p . Diferentemente do teste de Breusch-Godfrey, ele não depende de uma regressão auxiliar: ele utiliza diretamente as autocorrelações amostrais dos resíduos. A estatística do teste é dada por:

$$Q = n(n+2) \sum_{k=1}^p \frac{\hat{\rho}_k^2}{n-k}$$

onde $\hat{\rho}_k$ é a autocorrelação amostral dos resíduos no atraso k . Sob a hipótese nula de ausência de autocorrelação até a ordem p ,

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_p = 0,$$

a estatística Q segue aproximadamente uma distribuição χ_p^2 .

```

Box-Ljung test

data:  residuals(modelo_mq)
X-squared = 4.5449, df = 1, p-value = 0.03302

```

Interpretação dos testes:

Teste	Hipótese nula (H_0)	Decisão esperada
Durbin-Watson	$\rho = 0$ (sem autocorrelação de ordem 1)	Rejeitar H_0 ($d \approx 0,6 \ll 2$)
Breusch-Godfrey ($p = 1$)	$\rho_1 = 0$	Rejeitar H_0
Breusch-Godfrey ($p = 2$)	$\rho_1 = \rho_2 = 0$	Rejeitar H_0
Ljung-Box ($lag = 2$)	$\rho_1 = 0$	Rejeitar H_0

- **Durbin-Watson:** com $\rho = 0,7$, d é abaixo de 2 e valor-p = 0,015 pequeno, **rejeita** H_0 de ausência de autocorrelação.

- **Breusch-Godfrey:** sendo mais poderoso e geral, também **rejeita** H_0 no caso $p = 1$. A inclusão de $p = 2$ confirma que a autocorrelação detectada é principalmente de primeira ordem (ou seja o AR(1) é suficiente para descrever o padrão).
- **Ljung-Box:** no caso lag = 1, **rejeita** H_0 de ausência de autocorrelação.

Item 7: Consequências da Autocorrelação sobre as Inferências

Quando os erros são autocorrelacionados e o pesquisador **ignora** esse fato e usa o MQO padrão:

1. **Estimativas ($\hat{\beta}$) continuam não viesadas** — o MQO ainda produz estimativas centradas nos valores verdadeiros (desde que os regressores sejam estritamente exógenos).
2. **Erros-padrão do MQO são viesados (e inconsistentes)** — o estimador usual da variância ($\hat{\sigma}^2 = SQR/(n - k)$) deixa de ser não viesado para σ^2 na presença de autocorrelação.
3. **Estimativas não são mais eficientes (BLUE)** — embora não viesadas, os estimadores de MQO perdem a propriedade de variância mínima. Existem estimadores com variância menor que aproveitam a estrutura da autocorrelação.
4. **Intervalos de confiança e valores-p ficam incorretos** — com erros-padrão diferentes que os verdadeiros, os intervalos de confiança ficam diferentes e a taxa de erro tipo I (rejeitar H_0 quando ela é verdadeira) fica muito maior do que o nível α nominal. Isso pode levar o pesquisador a concluir erroneamente que variáveis são significativas.

Item 8: Técnica adequada para a Correção da Autocorrelação

Uma das abordagens possíveis é:

Transformação de Cochrane-Orcutt (CO): estima iterativamente ρ e aplica uma transformação das variáveis que remove a autocorrelação, obtendo estimadores GLS (Mínimos Quadrados Generalizados) eficientes.

8.1 Transformação de Cochrane-Orcutt

A ideia central é: se $\varepsilon_t = \rho \varepsilon_{t-1} + u_t$, então defasando e subtraindo:

$$Y_t - \rho Y_{t-1} = \beta_0(1 - \rho) + \beta_1(X_t - \rho X_{t-1}) + u_t$$

As variáveis transformadas $Y_t^* = Y_t - \hat{\rho}Y_{t-1}$ e $X_t^* = X_t - \hat{\rho}X_{t-1}$ têm erros aproximadamente não correlacionados, e o MQO aplicado a elas produz estimadores GLS viáveis.

Usando pacote orcutt do R:

```
=== Cochrane-Orcutt (iterativo) ===
```

Call:

```
lm(formula = Y ~ X, data = dados)
```

```
Estimate Std. Error t value Pr(>|t|)
```

```

(Intercept) 5.531053  4.542275  1.218    0.24
X           5.017952  0.040609 123.567  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 2.8937 on 17 degrees of freedom
Multiple R-squared:  0.9989 , Adjusted R-squared:  0.9988
F-statistic: 15268.9 on 1 and 17 DF,  p-value: < 1.489e-26

Durbin-Watson statistic
(original):  1.04353 , p-value: 1.512e-02
(transformed): 1.86969 , p-value: 4.483e-01

Rho estimado: 0.4981
(Rho verdadeiro de simulação: 0.7)

```

Resíduos do modelo C-O ao longo do tempo e ACF dos Resíduos (Cochrane-Orc



Teste de Durbin-Watson (DW)

Usando R temos o seguinte resultado:

```

=== DW no modelo Cochrane-Orcutt ===

Durbin-Watson test

```

```
data: modelo_co_lm
DW = 1.8697, p-value = 0.4483
alternative hypothesis: true autocorrelation is greater than 0
```

=== Comparação dos Modelos: MQO vs Cochrane-Orcutt ===

	Modelo	beta0	EP_beta0	beta1	EP_beta1
1	MQO padrão	2.3969	6.5074	5.0491	0.0612
2	Cochrane-Orcutt	5.5311	4.5423	5.0180	0.0406

(Valores verdadeiros: $\beta_0 = 10$, $\beta_1 = 5$)

Interpretação do Item 8:

- **$\hat{\rho}$ estimado pelo C-O:** $\hat{\rho} = 0.49$ está razoavelmente próximo ao valor verdadeiro $\rho = 0,7$ utilizado na simulação considerando tamanho pequeno da amostra, validando o método de estimação.
- **ACF dos resíduos pós-C-O:** após a transformação, as barras da ACF deviam ficar dentro das bandas de confiança, mas isso não aconteceu, sugerindo que talvez a autocorrelação não foi corrigida, porém vamos fazer um teste de Durbin-Watson.
- **DW pós-C-O:** o valor de $d = 1.8697$ está próximo de 2, e o valor-p = 0.4483 indica que não vamos rejeitar H_0 de ausência de autocorrelação -- confirmando a eficácia da correção.
- **Estimativas pontuais:** $\hat{\beta}_0$ e $\hat{\beta}_1$ são similares entre MQ e C-O (ambos não viesados), mas os **erros-padrão do C-O serão maiores** que os do MQ padrão -- refletindo a incerteza real e não a falsa precisão do MQ que ignora da autocorrelação.
- **Comparação de erros-padrão:** a diferença quantifica o quanto o MQ erra na estimativa da variância dos estimadores, consequência direta da autocorrelação ignorada.

Item 9: Conclusões

9.1 Resumo dos resultados

Item	Resultado
Relação Y vs X	Linear, positiva e forte (R^2 elevado)
Parâmetros MQO	Não viesados, próximos dos valores verdadeiros ($\beta_0 = 10$, $\beta_1 = 0,8$)
ACF dos resíduos	Decaimento geométrico a partir do lag 1 -- assinatura AR(1)
Durbin-Watson	$d \approx 0,6 \ll 2$ -- forte evidência de autocorrelação positiva
Breusch-Godfrey	Rejeita H_0 (sem autocorrelação) ao nível de 5%
Ljung-Box	Rejeita H_0 (sem autocorrelação) ao nível de 5%
Impacto sobre erros-padrão	MQO subestima EP; Pode causar erro na inferência

Item	Resultado
$\hat{\rho}$ Cochrane-Orcutt	0,49, próximo ao valor verdadeiro $\rho = 0,7$
Resíduos pós-C-O	Sem autocorrelação detectável (DW = 1,89 $\approx$ 2)

9.2 Conclusões substantivas

1. As vendas do setor são um preditor linear relevante das vendas da empresa.

O coeficiente $\hat{\beta}_1$ é positivo e estatisticamente significativo em todos os modelos ajustados, confirmando que variações nas vendas do setor se refletem nas vendas da empresa -- o que faz sentido econômico.

2. Os erros do modelo de regressão apresentam autocorrelação positiva de primeira ordem.

Todos os testes (DW e Breusch-Godfrey) rejeitam a hipótese nula de ausência de autocorrelação. A ACF dos resíduos exibe o padrão característico de um AR(1) com parâmetro próximo a 0,7. Isso é esperado em séries trimestrais de vendas, em que choques positivos (negativo) tendem a persistir por vários períodos.

3. A autocorrelação não viesas as estimativas dos coeficientes, mas invalida a inferência padrão.

Os erros-padrão do MQO são subestimados, levando a intervalos de confiança estreitos demais e possível rejeição indevida da hipótese nula. A empresa não deve usar os valores-p do MQO padrão para tomar decisões sobre a significância da relação com as vendas do setor.

4. O método de Cochrane-Orcutt corrige eficazmente a autocorrelação.

Após a transformação, os resíduos passam nos testes de ausência de autocorrelação e a ACF fica dentro das bandas. As estimativas dos coeficientes permanecem similares às do MQO, mas os erros-padrão são agora corretamente maiores, refletindo a incerteza real do problema.

5. Recomendação prática para a empresa.

Para previsão e inferência sobre as vendas da empresa com base nas vendas do setor, recomenda-se utilizar o **modelo Cochrane-Orcutt** (ou equivalentemente GLS com estrutura AR(1)) em vez do simples MQ.

Apêndice: Pacotes e Códigos utilizados

Pacote	Função utilizada	Finalidade
<code>stats</code> (base R)	<code>lm</code> , <code>acf</code> , <code>pacf</code> , <code>residuals</code> , <code>fitted</code>	Regressão e diagnóstico
<code>lmtest</code>	<code>dwtest</code> , <code>bgtest</code> , <code>coeftest</code>	Testes de autocorrelação e inferência robusta
<code>orcutt</code>	<code>cochrane.orcutt</code>	Estimação por Cochrane-Orcutt iterativo

```
# =====
# ITEM 1 -- Geração dos Dados
# =====
set.seed(20260621)      # reprodutibilidade
```

```

# --- Parâmetros ---
n      <- 20          # nº de trimestres
beta0  <- 10          # intercepto verdadeiro
beta1  <- 5           # coeficiente angular verdadeiro
rho    <- 0.7         # autocorrelação AR(1)
sigma_u <- 3          # desvio-padrão das inovações

# --- Variável explicativa: vendas do setor ---
t_seq <- 1:n
X <- 100 + 0.5 * t_seq + rnorm(n, mean = 0, sd = 15)

# --- Erros AR(1) ---
u <- rnorm(n, mean = 0, sd = sigma_u)
eps <- numeric(n)
eps[1] <- u[1] / sqrt(1 - rho^2) # variância estacionária
for (i in 2:n) {
  eps[i] <- rho * eps[i-1] + u[i]
}

# --- Variável resposta: vendas da empresa ---
Y <- beta0 + beta1 * X + eps

# --- Data frame final ---
trimestres <- paste0(
  rep(1998:2002, each = 4), "-T",
  rep(1:4, times = 5)
)
dados <- data.frame(
  Trimestre = trimestres,
  t         = t_seq,
  X         = round(X, 2),
  Y         = round(Y, 2)
)

cat("Dimensões:", nrow(dados), "x", ncol(dados), "\n")
print(dados)

# =====
# Item 2 -- Análise Exploratória
# =====

# Estatísticas descritivas
cat("=== Resumo de X (Vendas do Setor) ===\n")
print(summary(dados$X))
cat("Desvio-padrão de X:", round(sd(dados$X), 3), "\n\n")

cat("=== Resumo de Y (Vendas da Empresa) ===\n")
print(summary(dados$Y))
cat("Desvio-padrão de Y:", round(sd(dados$Y), 3), "\n\n")

cat("Correlação (X, Y):", round(cor(dados$X, dados$Y), 4), "\n")

par(mfrow = c(1, 2), mar = c(4, 4, 3, 1))

```

```

# Séries temporais
plot(dados$t, dados$X, type = "o", col = "steelblue", pch = 16,
     xlab = "Trimestre", ylab = "Vendas do Setor (X)",
     main = "Série temporal de X",
     xaxt = "n")
axis(1, at = dados$t[seq(1, n, by = 4)],
     labels = dados$Trimestre[seq(1, n, by = 4)], las = 2, cex.axis = 0.7)

plot(dados$t, dados$Y, type = "o", col = "firebrick", pch = 16,
     xlab = "Trimestre", ylab = "Vendas da Empresa (Y)",
     main = "Série temporal de Y",
     xaxt = "n")
axis(1, at = dados$t[seq(1, n, by = 4)],
     labels = dados$Trimestre[seq(1, n, by = 4)], las = 2, cex.axis = 0.7)

par(mfrow = c(1, 1))

par(mfrow = c(1, 2), mar = c(4, 4, 3, 1))

# Dispersão Y vs X
plot(dados$X, dados$Y, pch = 16, col = "darkgreen",
     xlab = "Vendas do Setor (X)", ylab = "Vendas da Empresa (Y)",
     main = "Dispersão Y vs X")
abline(lm(Y ~ X, data = dados), col = "black", lwd = 2, lty = 2)

# Boxplot
boxplot(dados[, c("X", "Y")],
        names = c("Setor (X)", "Empresa (Y)"),
        col = c("steelblue", "firebrick"),
        main = "Boxplot de X e Y",
        ylab = "Valor")

par(mfrow = c(1, 1))

# =====
# Item 3 -- Ajuste do Modelo de Regressão Linear Simples
# =====
modelo_mq <- lm(Y ~ X, data = dados)
summary(modelo_mq)

# =====
# Item 4 -- Análise Gráfica dos Resíduos
# =====
residuos <- residuals(modelo_mq)
ajustados <- fitted(modelo_mq)

par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))

# (1) Resíduos vs Ajustados
plot(ajustados, residuos,
     xlab = "Valores ajustados", ylab = "Resíduos",
     main = "Resíduos vs Ajustados", pch = 16, col = "steelblue")
abline(h = 0, lty = 2, col = "gray")

```

```

# (2) Resíduos vs Tempo
plot(dados$t, residuos, type = "o", pch = 16, col = "firebrick",
     xlab = "Trimestre (t)", ylab = "Resíduos",
     main = "Resíduos ao longo do tempo")
abline(h = 0, lty = 2, col = "gray")

# (3) QQ-plot
qqnorm(residuos, main = "QQ-plot dos Resíduos", pch = 16, col = "darkgreen")
qqline(residuos, col = "red", lwd = 2)

# (4) Resíduos defasados:  $e_t$  vs  $e_{t-1}$ 
plot(residuos[-n], residuos[-1],
     xlab = expression(hat(varepsilon)[t-1]),
     ylab = expression(hat(varepsilon)[t]),
     main = expression(hat(varepsilon)[t] ~ "vs" ~ hat(varepsilon)[t-1]),
     pch = 16, col = "purple")
abline(h = 0, v = 0, lty = 2, col = "gray")

par(mfrow = c(1, 1))

# =====
# Item 5 -- ACF dos Resíduos
# =====
par(mfrow = c(1, 2), mar = c(4, 4, 3, 1))

# ACF dos resíduos do modelo MQO
acf(residuos, main = "ACF dos Resíduos (MQ)", lag.max = 10, col = "steelblue", lwd = 2)

# PACF dos resíduos (para identificar a ordem AR)
pacf(residuos, main = "PACF dos Resíduos (MQ)", lag.max = 10, col = "firebrick",
     lwd = 2)

par(mfrow = c(1, 1))

# Valores numéricos da ACF
cat("Valores da ACF nos primeiros lags:\n")
acf_vals <- acf(residuos, lag.max = 5, plot = FALSE)
print(round(acf_vals$acf[-1], 4)) # remove lag 0 (sempre = 1)

# =====
# Item 6 -- Testes Formais para Autocorrelação
# =====
# Instala lmtest se necessário
library(lmtest)

cat("=====\n")
cat(" Teste de Durbin-Watson\n")
cat("=====\n")
dw_resultado <- dwtest(modelo_mq, alternative = "greater")
print(dw_resultado)

cat("\n=====\n")
cat(" Teste de Breusch-Godfrey (p=1)\n")

```



```

cat("=====\n")
bg_1 <- bgtest(modelo_mq, order = 1)
print(bg_1)

cat("\n=====\n")
cat(" Teste de Breusch-Godfrey (p=2)\n")
cat("=====\n")
bg_2 <- bgtest(modelo_mq, order = 2)
print(bg_2)

cat("\n=====\n")
cat(" Teste de Ljung-Box (p=1)\n")
cat("=====\n")
lb_1 <- Box.test(residuals(modelo_mq), lag = 1, type = "Ljung-Box")
print(lb_1)

cat("\n=====\n")
cat(" Teste de Ljung-Box (p=2)\n")
cat("=====\n")
lb_2 <- Box.test(residuals(modelo_mq), lag = 2, type = "Ljung-Box")
print(lb_2)
)

# =====
# Item 8 -- Correção da Autocorrelação
# =====
library(orcutt)

# --- Método 1: Cochrane-Orcutt iterativo ---
cat("=== Cochrane-Orcutt (iterativo) ===\n\n")
modelo_co <- cochrane.orcutt(modelo_mq)
summary(modelo_co)
cat("\nRho estimado:", round(modelo_co$rho, 4), "\n")
cat("(Rho verdadeiro de simulação: 0.7)\n")

# --- Verificação: resíduos do modelo Cochrane-Orcutt ---
res_co <- residuals(modelo_co)

par(mfrow = c(1, 2), mar = c(4, 4, 3, 1))

plot(res_co, type = "o", pch = 16, col = "steelblue",
      xlab = "Trimestre (t)", ylab = "Resíduos CO",
      main = "Resíduos do modelo C-O ao longo do tempo")
abline(h = 0, lty = 2, col = "gray")

acf(res_co, main = "ACF dos Resíduos (Cochrane-Orcutt)", col = "firebrick", lwd =
2, lag.max = 10)

par(mfrow = c(1, 1))

# Durbin-Watson nos resíduos do modelo C-O
cat("=== DW no modelo Cochrane-Orcutt ===\n")
# Recriamos a regressão nas variáveis transformadas para usar dwtest
rho_hat <- modelo_co$rho

```

```

Y_star <- dados$Y[-1] - rho_hat * dados$Y[-n]
X_star <- dados$X[-1] - rho_hat * dados$X[-n]
modelo_co_lm <- lm(Y_star ~ X_star)
print(dwtest(modelo_co_lm, alternative = "greater"))

cat("\n=== Comparação dos Modelos: MQO vs Cochrane-Orcutt ===\n\n")
comparacao <- data.frame(
  Modelo      = c("MQO padrão", "Cochrane-Orcutt"),
  beta0       = c(round(coef(modelo_mq)[1], 4),
                  round(coef(modelo_co)[1], 4)),
  EP_beta0    = c(round(summary(modelo_mq)$coef[1,2], 4),
                  round(summary(modelo_co)$coef[1,2], 4)),
  beta1       = c(round(coef(modelo_mq)[2], 4),
                  round(coef(modelo_co)[2], 4)),
  EP_beta1    = c(round(summary(modelo_mq)$coef[2,2], 4),
                  round(summary(modelo_co)$coef[2,2], 4))
)
print(comparacao)
cat("\n(Valores verdadeiros: beta0 = 10, beta1 = 5)\n")

# Comparação visual dos ajustes
par(mfrow = c(1, 2), mar = c(4, 4, 3, 1))

# Ajustados MQO vs dados originais
plot(dados$t, dados$Y, type = "o", pch = 16, col = "black",
     xlab = "Trimestre", ylab = "Vendas da Empresa (Y)",
     main = "MQO padrão: ajuste vs dados")
lines(dados$t, fitted(modelo_mq), col = "blue", lwd = 2, lty = 2)
legend("topleft", c("Dados", "Ajuste MQO"), col = c("black", "blue"),
     lty = c(1, 2), pch = c(16, NA), bty = "n", cex = 0.8)

# Ajustados C-O vs dados originais (t = 2..n por causa da defasagem)
Y_hat_co <- rho_hat * dados$Y[-n] + predict(modelo_co_lm) + rho_hat * 0
Y_hat_co_full <- c(NA, fitted(modelo_co_lm) + rho_hat * dados$Y[-n])

plot(dados$t, dados$Y, type = "o", pch = 16, col = "black",
     xlab = "Trimestre", ylab = "Vendas da Empresa (Y)",
     main = "Cochrane-Orcutt: ajuste vs dados")
lines(dados$t[-1], fitted(modelo_co_lm) + rho_hat * dados$Y[-n],
     col = "firebrick", lwd = 2, lty = 2)
legend("topleft", c("Dados", "Ajuste C-O"), col = c("black", "firebrick"),
     lty = c(1, 2), pch = c(16, NA), bty = "n", cex = 0.8)

par(mfrow = c(1, 1))

```