

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Estatística

*Relatório - Atividade 7 - Regressão
Logística*

Marcelo Huang 832111
Marcela Cobra Moraes 813147
Matheus Brito 812048

Julho, 2026

1 Introdução

O cancelamento de clientes, conhecido no meio empresarial como *churn*, é um dos problemas enfrentados por empresas que possuem serviços de assinatura, como é o caso de operadoras de telecomunicações. Reter um cliente já existente geralmente é mais barato do que conquistar um novo, então entender quais fatores levam um cliente a cancelar o serviço tem valor direto para a tomada de decisão da empresa.

Este trabalho utiliza o conjunto de dados *Telco Customer Churn*, disponibilizado publicamente no Kaggle, composto por 7043 clientes de uma empresa de telecomunicações. Para cada cliente, o banco registra informações cadastrais, os serviços contratados, a forma de pagamento e se o cliente cancelou ou não o serviço.

2 Objetivo

O objetivo deste trabalho é ajustar um modelo de regressão logística para estimar a probabilidade de um cliente cancelar o serviço (*churn*), a partir de suas características cadastrais, dos serviços contratados e das condições do contrato. Além do ajuste do modelo, pretende-se avaliar quais covariáveis são significativas para explicar o cancelamento, interpretar o efeito dessas covariáveis por meio das razões de chances, e medir a capacidade preditiva do modelo em dados que não foram usados na sua construção.

3 Descrição do Conjunto de Dados

O banco de dados original possui 7043 linhas e 21 colunas. A Figura 1 mostra as primeiras linhas do banco, com algumas das colunas disponíveis.

customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	...
7590-VHVEG	Female	0	Yes	No	1	No	No phone servic	DSL	...
5575-GNVDE	Male	0	No	No	34	Yes	No	DSL	...
3668-QPYBK	Male	0	No	No	2	Yes	No	DSL	...
7795-CFOCW	Male	0	No	No	45	No	No phone servic	DSL	...
9237-HQITU	Female	0	No	No	2	Yes	No	Fiber optic	...
9305-CDSKC	Female	0	No	No	8	Yes	Yes	Fiber optic	...
1452-KIOVK	Male	0	No	Yes	22	Yes	Yes	Fiber optic	...
6713-OKOMC	Female	0	No	No	10	No	No phone servic	DSL	...
7892-POOKP	Female	0	Yes	No	28	Yes	Yes	Fiber optic	...
...	...	...	...	...	...	...	...	...	...

Figura 1: Primeiras linhas do conjunto de dados

3.1 Variável resposta

A variável resposta é *Churn*, que indica se o cliente cancelou o serviço (*Yes*) ou permaneceu com a empresa (*No*). Para o ajuste do modelo de regressão logística, essa

variável foi recodificada como binária numérica, assumindo o valor 1 quando o cliente cancelou e 0 caso contrário.

Do total de 7043 clientes, 5174 (73,5%) não cancelaram o serviço e 1869 (26,5%) cancelaram. Trata-se, portanto, de uma base moderadamente desbalanceada, o que foi levado em conta na divisão da amostra (Seção 5) e será retomado mais adiante na escolha do ponto de corte do modelo.

3.2 Covariáveis

As covariáveis utilizadas na análise são as seguintes:

- **gender**: sexo do cliente (Male/Female);
- **SeniorCitizen**: indica se o cliente é idoso;
- **Partner**: se o cliente possui cônjuge;
- **Dependents**: se o cliente possui dependentes;
- **tenure**: número de meses que o cliente permanece na empresa;
- **PhoneService, MultipleLines**: relacionadas ao serviço de telefonia;
- **InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies**: relacionadas ao serviço de internet e seus complementos;
- **Contract**: tipo de contrato firmado (mensal, um ano ou dois anos);
- **PaperlessBilling**: se a fatura é enviada de forma digital;
- **PaymentMethod**: forma de pagamento utilizada pelo cliente;
- **MonthlyCharges**: valor cobrado mensalmente, em dólares;
- **TotalCharges**: valor total já cobrado do cliente desde o início do contrato.

A coluna **customerID**, presente no banco original, foi removida por se tratar apenas de um identificador do cliente, sem relação alguma com a chance de cancelamento.

3.3 Tratamento dos dados

Ao importar o banco no R, a coluna **TotalCharges** apresentou 11 valores faltantes. A investigação dessas linhas mostrou que todas elas correspondiam a clientes com **tenure** igual a zero, ou seja, clientes que haviam acabado de contratar o serviço e ainda não haviam completado um mês de cobrança. Como o valor faltante não é, nesse caso, desconhecido, mas sim implicado pela própria variável **tenure**, optou-se por imputar o valor 0 nessas 11 observações em vez de removê-las do banco, preservando assim a base completa de 7043 clientes.

As demais variáveis de texto foram convertidas para o formato de fator, adequado para representar variáveis categóricas no R, e a variável **SeniorCitizen**, originalmente codificada como 0 e 1, também foi tratada como fator.

4 Análise Exploratória

A Figura 2 mostra a distribuição da variável resposta, confirmando o desbalanceamento já mencionado na Seção anterior.




Figura 2: Distribuição da variável resposta (Churn)

Em relação às covariáveis numéricas, a Tabela 1 apresenta um resumo estatístico do tempo de contrato, da mensalidade e do total cobrado.

Tabela 1: Estatísticas descritivas das covariáveis numéricas

Variável	Mín.	1º Quart.	Mediana	Média	3º Quart.	Máx.
tenure (meses)	0	9	29	32,37	55	72
MonthlyCharges (US\$)	18,25	35,50	70,35	64,76	89,85	118,75
TotalCharges (US\$)	0	398,60	1394,50	2279,70	3786,60	8684,80

As Figuras 3 e 4 comparam a distribuição do tempo de contrato e da mensalidade entre clientes que cancelaram e clientes que permaneceram com a empresa. Nota-se que clientes que cancelaram tendem a ter um tempo de contrato menor, o que é esperado, já que clientes mais antigos já demonstraram algum nível de fidelidade ao serviço. Também é possível notar que os clientes que cancelaram tendem a pagar mensalidades mais altas.




Figura 3: Tempo de contrato (meses) por status de churn




Figura 4: Mensalidade por status de churn

Para as covariáveis categóricas, foi analisada a proporção de cancelamento dentro de cada categoria. A Figura 5 mostra essa relação para o tipo de contrato: clientes com contrato mensal (*Month-to-month*) cancelam em uma proporção bem maior (42,7%) do que clientes com contrato de um ano (11,3%) ou de dois anos (2,8%), o que sugere que essa covariável deve ter um papel importante no modelo.




Figura 5: Proporção de churn por tipo de contrato

A Figura 6 apresenta a mesma análise para o método de pagamento. Chama atenção que clientes que pagam por cheque eletrônico (*Electronic check*) apresentam uma proporção de cancelamento consideravelmente maior do que os demais métodos, próxima de 45%.




Figura 6: Proporção de churn por método de pagamento

5 Divisão da Amostra

Como a variável resposta é desbalanceada (73,5% de clientes que não cancelaram contra 26,5% de clientes que cancelaram), a divisão entre treino e teste foi feita de forma estratificada, e não por amostragem aleatória simples. A estratificação garante que essa mesma proporção de cancelamento seja preservada tanto na amostra de treino quanto na amostra de teste, evitando que uma divisão aleatória concentre, por acaso, mais casos de churn em um dos dois conjuntos.

Foi adotada a proporção de 70% dos dados para treino e 30% para teste, resultando em 4931 observações na amostra de treino e 2112 observações na amostra de teste.

6 Ajuste do Modelo

O modelo é ajustado exclusivamente na amostra de treino, e primeiramente nós utilizamos todas as covariáveis disponíveis como ponto de partida (modelo completo).

*Note que a covariável 'TotalCharges' é, por definição, aproximadamente 'tenure' × 'MonthlyCharges' (ignorando pequenas variações de reajuste). Isso gera multicolinearidade severa (alta correlação entre os preditores). Removemos 'TotalCharges' para ajustar o modelo.

Com a função "glm", os resultados foram:

Call:

```
glm(formula = Churn ~ gender + SeniorCitizen + Partner + Dependents +
     tenure + PhoneService + MultipleLines + InternetService +
     OnlineSecurity + OnlineBackup + DeviceProtection + TechSupport +
     StreamingTV + StreamingMovies + Contract + PaperlessBilling +
     PaymentMethod + MonthlyCharges, family = binomial(link = "logit"),
     data = treino)
```

Coefficients: (7 not defined because of singularities)

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.056273	0.959267	1.101	0.27084	
genderMale	-0.061292	0.076973	-0.796	0.42587	
SeniorCitizenYes	0.273139	0.100931	2.706	0.00681	**
PartnerYes	-0.030620	0.091444	-0.335	0.73774	
DependentsYes	-0.135889	0.105529	-1.288	0.19785	
tenure	-0.031893	0.002782	-11.462	< 2e-16	***
PhoneServiceYes	0.526417	0.771309	0.682	0.49492	
MultipleLinesNo phone service	NA	NA	NA	NA	
MultipleLinesYes	0.514457	0.210996	2.438	0.01476	*
InternetServiceFiber optic	2.063687	0.948765	2.175	0.02962	*
InternetServiceNo	-2.103937	0.959321	-2.193	0.02830	*
OnlineSecurityNo internet service	NA	NA	NA	NA	
OnlineSecurityYes	-0.205073	0.212406	-0.965	0.33431	
OnlineBackupNo internet service	NA	NA	NA	NA	

...

Residual deviance: 4153.9 on 4908 degrees of freedom

AIC: 4199.9

Number of Fisher Scoring iterations: 6

E a partir do modelo completo, aplicamos uma seleção de variáveis por critério de informação (AIC, método stepwise em ambas as direções) para obter um modelo mais parcimonioso, eliminando covariáveis que não contribuem para o ajuste.

Resultado:

Call:

```
glm(formula = Churn ~ SeniorCitizen + Dependents + tenure + MultipleLines +
    InternetService + OnlineSecurity + DeviceProtection + StreamingTV +
    StreamingMovies + Contract + PaperlessBilling + PaymentMethod +
    MonthlyCharges, family = binomial(link = "logit"), data = treino)
```

Coefficients: (4 not defined because of singularities)

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.793296	0.601593	2.981	0.002874	**
SeniorCitizenYes	0.279563	0.099923	2.798	0.005145	**
DependentsYes	-0.149319	0.096075	-1.554	0.120138	
tenure	-0.031767	0.002699	-11.769	< 2e-16	***
MultipleLinesNo phone service	-0.631549	0.295070	-2.140	0.032328	*
MultipleLinesYes	0.546584	0.112447	4.861	1.17e-06	***
InternetServiceFiber optic	2.221735	0.325678	6.822	8.99e-12	***
InternetServiceNo	-2.233533	0.381692	-5.852	4.87e-09	***
OnlineSecurityNo internet service	NA	NA	NA	NA	
OnlineSecurityYes	-0.176339	0.119601	-1.474	0.140374	
DeviceProtectionNo internet service	NA	NA	NA	NA	
DeviceProtectionYes	0.226074	0.115478	1.958	0.050263	.
StreamingTVNo internet service	NA	NA	NA	NA	
StreamingTVYes	0.849547	0.161511	5.260	1.44e-07	***
StreamingMoviesNo internet service	NA	NA	NA	NA	
StreamingMoviesYes	0.900656	0.159136	5.660	1.52e-08	***
...					

Residual deviance: 4156.3 on 4912 degrees of freedom

AIC: 4194.3

Number of Fisher Scoring iterations: 6

Note que: temos um aviso sobre singularidades "Coefficients: N not defined because of singularities". Isso ocorre porque algumas categorias das variáveis de complementos de internet ('OnlineSecurity', 'OnlineBackup', 'DeviceProtection', 'TechSupport', 'StreamingTV', 'StreamingMovies') possuem o nível "No internet service", que é perfeitamente coincidente com os clientes que já têm 'InternetService' = "No".

Ou seja, saber que um cliente não tem ‘OnlineSecurity’ por "não ter serviço de internet" já é informação totalmente contida na variável ‘InternetService’. Isso gera colinearidade perfeita entre essas colunas dummy, e o R, ao não conseguir estimar um coeficiente único para elas, atribui ‘NA’ e simplesmente as remove do ajuste (a informação não se perde: ela é absorvida pelo coeficiente de ‘InternetServiceNo’). O mesmo ocorre com ‘MultipleLinesNo phone service’, redundante com ‘PhoneServiceNo’.

Comparando o modelo completo com o modelo final (stepwise)

Tabela 2: Comparação entre modelo completo e modelo final (stepwise)

	Modelo completo	Modelo final (stepAIC)
Desvio Residual	4153,9 (4908 gl)	4156,3 (4912 gl)
AIC	4199,9	4194,3

O modelo final tem **menos variáveis** (removeu `gender`, `Partner`, `PhoneService`, `OnlineBackup` e `TechSupport`, que não eram significativas no modelo completo), um aumento muito pequeno no desvio residual ($4153,9 \rightarrow 4156,3$, praticamente desprezível) e, ainda assim, um **AIC menor** ($4194,3 < 4199,9$). Isso indica que essas variáveis removidas não contribuíam de forma relevante para explicar o churn, e o modelo mais parcimonioso é preferível: perde-se pouquíssima capacidade explicativa e ganha-se um modelo mais simples e mais generalizável.

Interpretação **preliminar** dos coeficientes significativos (log-odds)

No modelo final, destacam-se como estatisticamente significativas ($p < 0,05$):

- **SeniorCitizenYes** ($\beta \approx 0,28$, $p \approx 0,005$): ser idoso está associado a **maior** chance de churn.
- **tenure** ($\beta \approx -0,032$, $p < 0,001$): cada mês adicional de permanência está associado a **menor** chance de churn – é a variável mais fortemente significativa do modelo.
- **MultipleLinesYes** ($\beta \approx 0,546$, $p < 0,001$) e **MultipleLinesNo phone service** ($\beta \approx -0,632$, $p \approx 0,023$): ter múltiplas linhas aumenta a chance de churn em relação a não ter múltiplas linhas.
- **InternetServiceFiber optic** ($\beta \approx 2,22$, $p < 0,001$): clientes com internet fibra têm chance **bem maior** de churn do que os com DSL (categoria de referência).
- **InternetServiceNo** ($\beta \approx -2,234$, $p < 0,001$): clientes sem serviço de internet têm chance **bem menor** de churn.
- **DeviceProtectionYes** ($\beta \approx 0,227$, $p \approx 0,049$) e **StreamingTVYes** ($\beta \approx 0,850$, $p < 0,001$): associados a **maior** chance de churn (efeito a ser confirmado ao

observar as demais variáveis do modelo, como `Contract` e `PaymentMethod`, que não aparecem no trecho mostrado mas certamente estão no modelo final).

Esses sinais ainda estão na escala do log-odds (coeficientes da regressão logística). Na próxima parte (Razões de Chance), vamos exponenciar esses coeficientes ($\exp(\text{coef})$) para obter os *odds ratios*, que facilitam bastante a interpretação – por exemplo, dizer que "cada mês adicional de permanência reduz a chance de churn em X%" em vez de falar em log-odds.

Diagnóstico do modelo

Para avaliar a qualidade do ajuste e identificar possíveis pontos influentes ou anomalias, foram gerados os gráficos de diagnóstico baseados nos resíduos do modelo final (Figura 7).




Figura 7: Diagnóstico do modelo

Ao analisar os gráficos, devemos levar em consideração que estamos trabalhando com uma **regressão logística** (resposta binária). Por essa razão, os diagnósticos visuais tradicionais interpretam-se de forma diferente da regressão linear clássica:

- **Residuals vs Fitted e Scale-Location:** Observa-se a formação clara de duas bandas ou curvas de pontos que se cruzam de forma assintótica. Esse padrão em formato de “X” não indica uma falha de especificação ou heterocedasticidade; trata-se de um comportamento esperado e característico de dados binários, onde os resíduos observados ficam restritos a duas trajetórias possíveis dependendo se o valor real de Churn é 0 ou 1. A linha vermelha suavizada próxima de zero no

primeiro gráfico sugere que, na média, as probabilidades estimadas estão bem calibradas.

- **Q-Q Residuals:** O gráfico de probabilidade normal compara os quantis dos resíduos padronizados de desvio com os quantis teóricos de uma distribuição normal. Embora a regressão logística não assuma normalidade dos resíduos, este gráfico é útil para detectar desvios severos ou *outliers* nas caudas. Nota-se um comportamento linear bem definido na maior parte da distribuição, com um leve descolamento nas caudas superiores (identificando observações como as de índices 4514, 269 e 5442), sugerindo casos em que o modelo falhou em prever um evento com alta ou baixa probabilidade estimada.
- **Residuals vs Leverage:** Este gráfico permite identificar pontos de alta alavancagem (*leverage*) e observações influentes por meio da Distância de Cook. No modelo ajustado, a grande maioria dos dados possui alavancagem muito baixa (inferior a 0,012). Embora algumas observações (como 4514, 6725 e 6814) apresentem resíduos padronizados elevados, nenhuma delas ultrapassa ou chega perto das linhas de corte da Distância de Cook (representadas pelas linhas pontilhadas vermelhas que sequer aparecem na região visível do gráfico). Isso indica que **não existem pontos influentes** capazes de distorcer ou comprometer isoladamente as estimativas dos coeficientes obtidos.

Em suma, o diagnóstico visual indica que o modelo se comporta conforme o esperado para a estrutura de dados de regressão logística, livre de pontos aberrantes com influência desproporcional sobre o ajuste.

7 Interpretação dos Coeficientes

Os coeficientes do modelo logístico são interpretados na escala do log-odds. Para facilitar a interpretação, calculamos as razões de chance (**odds ratios**), obtidas por $e^{\hat{\beta}}$, junto com os respectivos intervalos de confiança de 95%.

- $OR > 1$: a covariável **aumenta** a chance de cancelamento;
- $OR < 1$: a covariável **diminui** a chance de cancelamento;
- $OR = 1$: a covariável não tem efeito sobre a chance de cancelamento.

Nós temos os seguintes resultados:

Tabela 3: Odds Ratios e intervalos de confiança de 95%

Variável	OR	2,5%	97,5%
(Intercept)	6,009	1,851	19,586
SeniorCitizenYes	1,323	1,087	1,609
DependentsYes	0,861	0,713	1,039
tenure	0,969	0,964	0,974
MultipleLinesNo phone service	0,532	0,298	0,947
MultipleLinesYes	1,727	1,386	2,154
InternetServiceFiber optic	9,223	4,884	17,514
InternetServiceNo	0,107	0,051	0,226
OnlineSecurityNo internet service	NA	NA	NA
OnlineSecurityYes	0,838	0,663	1,059
DeviceProtectionNo internet service	NA	NA	NA
DeviceProtectionYes	1,254	1,000	1,573
StreamingTVNo internet service	NA	NA	NA
StreamingTVYes	2,339	1,706	3,213
StreamingMoviesNo internet service	NA	NA	NA
StreamingMoviesYes	2,461	1,804	3,366
ContractOne year	0,486	0,379	0,621
ContractTwo year	0,249	0,166	0,364
PaperlessBillingYes	1,379	1,160	1,639
PaymentMethodCredit card (automatic)	0,908	0,698	1,182
PaymentMethodElectronic check	1,308	1,052	1,628
PaymentMethodMailed check	1,014	0,778	1,322
MonthlyCharges	0,948	0,925	0,971

Interpretação das Razões de Chance (Odds Ratios)

Uma covariável é considerada relevante quando o intervalo de confiança de 95% do OR **não contém o valor 1**. Quando o IC inclui 1, não há evidência de que a variável altere a chance de churn, mesmo que o OR pontual seja diferente de 1.

Variáveis associadas a maior chance de churn (OR > 1, IC não contém 1)

SeniorCitizenYes (OR = 1,323; IC 1,087–1,609): ser idoso aumenta em cerca de **32%** a chance de cancelamento, mantidas as demais variáveis constantes.

MultipleLinesYes (OR = 1,727; IC 1,386–2,154): ter múltiplas linhas telefônicas aumenta em aproximadamente **73%** a chance de churn em relação a não ter múltiplas linhas.

InternetServiceFiber optic (OR = 9,223; IC 4,884–17,514): possuir internet por fibra óptica multiplica por aproximadamente **9 vezes** a chance de churn em

relação ao serviço DSL (categoria de referência). Continua sendo o efeito mais forte observado no modelo.

DeviceProtectionYes (OR = 1,254; IC 1,000–1,573): apresenta efeito positivo, porém o limite inferior do intervalo de confiança é praticamente igual a 1, indicando evidência estatística bastante limítrofe.

StreamingTVYes (OR = 2,339; IC 1,706–3,213) e **StreamingMoviesYes** (OR = 2,461; IC 1,804–3,366): clientes que possuem esses serviços apresentam mais que o **dobro** da chance de churn. Esse resultado provavelmente está relacionado ao fato de esses serviços estarem concentrados entre clientes com internet, especialmente fibra óptica, refletindo o perfil dos planos mais caros.

PaperlessBillingYes (OR = 1,379; IC 1,160–1,639): utilizar fatura digital está associado a um aumento de aproximadamente **38%** na chance de churn.

PaymentMethodElectronic check (OR = 1,308; IC 1,052–1,628): clientes que utilizam cheque eletrônico apresentam cerca de **31%** mais chance de cancelar o serviço em relação ao método de pagamento de referência.

Variáveis associadas a menor chance de churn (OR < 1, IC não contém 1)

tenure (OR = 0,969; IC 0,964–0,974): cada mês adicional de permanência reduz em aproximadamente **3%** a chance de churn, sendo um dos efeitos mais consistentes do modelo.

MultipleLinesNo phone service (OR = 0,532; IC 0,298–0,947): clientes sem serviço telefônico apresentam aproximadamente **47%** menor chance de churn em comparação com a categoria de referência.

InternetServiceNo (OR = 0,107; IC 0,051–0,226): não possuir serviço de internet reduz a chance de churn em aproximadamente **89%** quando comparado aos clientes com internet DSL.

ContractOne year (OR = 0,486; IC 0,379–0,621) e **ContractTwo year** (OR = 0,249; IC 0,166–0,364): contratos mais longos reduzem substancialmente a probabilidade de churn. Contratos de um ano apresentam redução de aproximadamente **51%** e contratos de dois anos cerca de **75%** em relação aos contratos mensais.

MonthlyCharges (OR = 0,948; IC 0,925–0,971): após o ajuste pelas demais variáveis do modelo, mensalidades mais elevadas aparecem associadas a uma **redução** na

chance de churn. Esse resultado difere da análise exploratória devido ao efeito de confundimento entre valor da mensalidade, tipo de internet e serviços adicionais.

Variáveis sem evidência de efeito (IC contém 1)

- `DependentsYes`, `OnlineSecurityYes`, `PaymentMethodCredit card (automatic)` e `PaymentMethodMailed check`. Como seus intervalos de confiança incluem o valor 1, não há evidência estatística de associação com a chance de churn após o ajuste pelas demais covariáveis.
- Embora `DeviceProtectionYes` apresente um intervalo cujo limite inferior é igual a 1,000 após arredondamento, o resultado deve ser interpretado com cautela, pois representa uma evidência limítrofe.

Sobre as linhas NA

As linhas `OnlineSecurityNo internet service`, `DeviceProtectionNo internet service`, `StreamingTVNo internet service` e `StreamingMoviesNo internet service` aparecem como NA porque esses níveis são perfeitamente redundantes com a variável `InternetServiceNo`. Assim, seus coeficientes não podem ser estimados separadamente, caracterizando um caso de colinearidade perfeita. Esse comportamento é esperado e não representa erro na estimação do modelo.

Resumo

Os principais determinantes da ocorrência de churn continuam sendo o **tipo de contrato**, o **tempo de permanência do cliente** e o **tipo de serviço de internet**. Contratos de maior duração reduzem fortemente a probabilidade de cancelamento, enquanto clientes com internet por fibra óptica apresentam risco substancialmente maior de churn. Além disso, serviços de streaming e o pagamento por cheque eletrônico permanecem associados a maior probabilidade de cancelamento, mesmo após o ajuste pelas demais variáveis do modelo.

8 Avaliação da significância

Comparamos o modelo completo e o modelo reduzido por meio do teste da razão de verossimilhanças (Likelihood Ratio Test).

Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1 4912	4156.341	NA	NA	NA

2	4908	4153.921	4	2.42072	0.6588862
---	------	----------	---	---------	-----------

O teste da razão de verossimilhanças comparando o modelo completo e o modelo final (reduzido) resultou em uma diferença de deviance de 2,42 (4 graus de liberdade) e $p\text{-valor} = 0,659$. Como o $p\text{-valor}$ é alto, não há evidência de que o modelo completo se ajuste significativamente melhor aos dados do que o modelo reduzido.

Vale notar que, embora o ‘stepAIC’ tenha removido 5 variáveis do modelo completo (‘gender’, ‘Partner’, ‘PhoneService’, ‘OnlineBackup’ e ‘TechSupport’), a diferença de graus de liberdade entre os dois modelos é de apenas 4, e não 5. Isso ocorre porque, no modelo completo, o nível "No phone service" da variável ‘MultipleLines’ era perfeitamente colinear com ‘PhoneService = "No"' (um cliente sem telefone nunca pode ter múltiplas linhas), o que fazia seu coeficiente ser ‘NA’ por singularidade. Ao remover ‘PhoneService’ do modelo, essa colinearidade deixa de existir, e o coeficiente de ‘MultipleLinesNo phone service’ passa a ser estimável no modelo final, recuperando 1 grau de liberdade que se perde ao remover as outras 5 variáveis. Assim temos 4 parâmetros a menos (24 no modelo completo contra 20 no modelo final), consistente com o resultado do teste.

E como vimos anteriormente, o modelo final apresenta AIC menor (4194,3) do que o modelo completo (4199,9). Como o modelo mais simples explica os dados praticamente tão bem quanto o modelo completo, mas com menos parâmetros, ambos os critérios, o teste da razão de verossimilhanças e o AIC, apontam na mesma direção.

Por esses motivos, adotamos o modelo final (reduzido) como modelo de referência para as próximas etapas da análise (curva ROC e matriz de confusão).

Apêndice - Código em R

```
1 library(dplyr)
2 library(ggplot2)
3 library(caret)
4
5 set.seed(123) #para o treino e teste
6
7 dados <- read.csv("WA_Fn-UseC_-Telco-Customer-Churn.csv",
8   stringsAsFactors = FALSE)
9 head(dados)
10
11 dim(dados)#linha/coluna
12 str(dados)#tipos de variaveis
13
14 dados$Churn <- ifelse(dados$Churn == "Yes", 1, 0)
15
16 table(dados$Churn)
17 prop.table(table(dados$Churn))
18
19 dados$customerID <- NULL
20
21 sum(is.na(dados$TotalCharges))
22
23 dados[is.na(dados$TotalCharges), c("tenure", "MonthlyCharges", "
24   TotalCharges")]
25
26 dados$TotalCharges[is.na(dados$TotalCharges)] <- 0
27
28 sum(is.na(dados))
29
30 dados <- dados %>% mutate(across(where(is.character), as.factor)
31   )
32
33 dados$SeniorCitizen <- factor(dados$SeniorCitizen, labels = c("
34   No", "Yes"))
35
36 str(dados)
```



```
36 ggplot(dados, aes(x = factor(Churn, labels = c("Nao cancelou", "
    Cancelou")))) +
37   geom_bar(fill = "steelblue") +
38   labs(title = "Distribuicao da variavel resposta (Churn)",
39         x = "", y = "Numero de clientes")
40
41 summary(dados[, c("tenure", "MonthlyCharges", "TotalCharges")])
42
43
44 ggplot(dados, aes(x = factor(Churn, labels = c("Nao cancelou", "
    Cancelou"))),
45         y = tenure)) +
46   geom_boxplot(fill = "lightblue") +
47   labs(title = "Tempo de contrato (meses) por status de churn",
48         x = "", y = "Tenure (meses)")
49
50
51 ggplot(dados, aes(x = factor(Churn, labels = c("Nao cancelou", "
    Cancelou"))),
52         y = MonthlyCharges)) +
53   geom_boxplot(fill = "lightgreen") +
54   labs(title = "Mensalidade por status de churn",
55         x = "", y = "Mensalidade (MonthlyCharges)")
56
57
58
59 prop.table(table(dados$Contract, dados$Churn), margin = 1)
60
61 ggplot(dados, aes(x = Contract, fill = factor(Churn, labels = c(
    "Nao cancelou", "Cancelou")))) +
62   geom_bar(position = "fill") +
63   labs(title = "Proporcao de churn por tipo de contrato",
64         x = "Tipo de contrato", y = "Proporcao", fill = "Churn")
65
66
67 ggplot(dados, aes(x = PaymentMethod, fill = factor(Churn, labels
    = c("Nao cancelou", "Cancelou")))) +
68   geom_bar(position = "fill") +
69   labs(title = "Proporcao de churn por metodo de pagamento",
70         x = "Metodo de pagamento", y = "Proporcao", fill = "Churn
    ") +
```

```
71 theme(axis.text.x = element_text(angle = 30, hjust = 1))
72
73
74
75
76 indices_treino <- createDataPartition(dados$Churn, p = 0.7, list
    = FALSE)
77
78 treino <- dados[indices_treino, ]
79 teste <- dados[-indices_treino, ]
80
81 nrow(treino)
82 nrow(teste)
83
84 modelo_completo <- glm(Churn ~ ., data = treino, family =
    binomial(link = "logit"))
85 modelo_completo <- update(modelo_completo, . ~ . - TotalCharges)
86
87 summary(modelo_completo)
88
89 library(MASS)
90
91 modelo_final <- stepAIC(modelo_completo, direction = "both",
    trace = FALSE)
92
93 summary(modelo_final)
94
95 par(mfrow = c(2, 2))
96 plot(modelo_final)
97 par(mfrow = c(1, 1))
98
99 # Razoes de chance (odds ratios) e intervalos de confianca de
    95%
100 odds_ratios <- exp(cbind(OR = coef(modelo_final), confint(modelo
    _final)))
101
102 round(odds_ratios, 3)
103
104 # Teste da razao de verossimilhanças entre o modelo completo e o
    modelo final (reduzido)
105 anova(modelo_final, modelo_completo, test = "Chisq")
```

```
106  
107 # Comparacao do AIC dos dois modelos  
108 AIC(modelo_completo, modelo_final)
```

Referências

- [1] BlastChar. *Telco Customer Churn*. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>.