

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Estatística

Relatório - Atividade 7 - Regressão Logística

Marcelo Huang 832111

Marcela Cobra Moraes 813147

Matheus Brito 812048

Julho, 2026

1 Introdução

O cancelamento de clientes, conhecido no meio empresarial como *churn*, é um dos problemas enfrentados por empresas que possuem serviços de assinatura, como é o caso de operadoras de telecomunicações. Reter um cliente já existente geralmente é mais barato do que conquistar um novo, então entender quais fatores levam um cliente a cancelar o serviço tem valor direto para a tomada de decisão da empresa.

Este trabalho utiliza o conjunto de dados *Telco Customer Churn*, disponibilizado publicamente no Kaggle, composto por 7043 clientes de uma empresa de telecomunicações. Para cada cliente, o banco registra informações cadastrais, os serviços contratados, a forma de pagamento e se o cliente cancelou ou não o serviço.

2 Objetivo

O objetivo deste trabalho é ajustar um modelo de regressão logística para estimar a probabilidade de um cliente cancelar o serviço (*churn*), a partir de suas características cadastrais, dos serviços contratados e das condições do contrato. Além do ajuste do modelo, pretende-se avaliar quais covariáveis são significativas para explicar o cancelamento, interpretar o efeito dessas covariáveis por meio das razões de chances, e medir a capacidade preditiva do modelo em dados que não foram usados na sua construção.

3 Descrição do Conjunto de Dados

O banco de dados original possui 7043 linhas e 21 colunas. A Figura 1 mostra as primeiras linhas do banco, com algumas das colunas disponíveis.

customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	...
7590-VHVEG	Female	0	Yes	No	1	No	No phone servic	DSL	...
5575-GNVDE	Male	0	No	No	34	Yes	No	DSL	...
3668-QPYBK	Male	0	No	No	2	Yes	No	DSL	...
7795-CFOCW	Male	0	No	No	45	No	No phone servic	DSL	...
9237-HQITU	Female	0	No	No	2	Yes	No	Fiber optic	...
9305-CDSKC	Female	0	No	No	8	Yes	Yes	Fiber optic	...
1452-KIOVK	Male	0	No	Yes	22	Yes	Yes	Fiber optic	...
6713-OKOMC	Female	0	No	No	10	No	No phone servic	DSL	...
7892-POOKP	Female	0	Yes	No	28	Yes	Yes	Fiber optic	...
...	...	...	...	...	...	...	...	...	...

Figura 1: Primeiras linhas do conjunto de dados

3.1 Variável resposta

A variável resposta é *Churn*, que indica se o cliente cancelou o serviço (*Yes*) ou permaneceu com a empresa (*No*). Para o ajuste do modelo de regressão logística, essa

variável foi recodificada como binária numérica, assumindo o valor 1 quando o cliente cancelou e 0 caso contrário.

Do total de 7043 clientes, 5174 (73,5%) não cancelaram o serviço e 1869 (26,5%) cancelaram. Trata-se, portanto, de uma base moderadamente desbalanceada, o que foi levado em conta na divisão da amostra (Seção 5) e será retomado mais adiante na escolha do ponto de corte do modelo.

3.2 Covariáveis

As covariáveis utilizadas na análise são as seguintes:

- **gender**: sexo do cliente (Male/Female);
- **SeniorCitizen**: indica se o cliente é idoso;
- **Partner**: se o cliente possui cônjuge;
- **Dependents**: se o cliente possui dependentes;
- **tenure**: número de meses que o cliente permanece na empresa;
- **PhoneService, MultipleLines**: relacionadas ao serviço de telefonia;
- **InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies**: relacionadas ao serviço de internet e seus complementos;
- **Contract**: tipo de contrato firmado (mensal, um ano ou dois anos);
- **PaperlessBilling**: se a fatura é enviada de forma digital;
- **PaymentMethod**: forma de pagamento utilizada pelo cliente;
- **MonthlyCharges**: valor cobrado mensalmente, em dólares;
- **TotalCharges**: valor total já cobrado do cliente desde o início do contrato.

A coluna **customerID**, presente no banco original, foi removida por se tratar apenas de um identificador do cliente, sem relação alguma com a chance de cancelamento.

3.3 Tratamento dos dados

Ao importar o banco no R, a coluna **TotalCharges** apresentou 11 valores faltantes. A investigação dessas linhas mostrou que todas elas correspondiam a clientes com **tenure** igual a zero, ou seja, clientes que haviam acabado de contratar o serviço e ainda não haviam completado um mês de cobrança. Como o valor faltante não é, nesse caso, desconhecido, mas sim implicado pela própria variável **tenure**, optou-se por imputar o valor 0 nessas 11 observações em vez de removê-las do banco, preservando assim a base completa de 7043 clientes.

As demais variáveis de texto foram convertidas para o formato de fator, adequado para representar variáveis categóricas no R, e a variável **SeniorCitizen**, originalmente codificada como 0 e 1, também foi tratada como fator.

4 Análise Exploratória

A Figura 2 mostra a distribuição da variável resposta, confirmando o desbalanceamento já mencionado na Seção anterior.




Figura 2: Distribuição da variável resposta (Churn)

Em relação às covariáveis numéricas, a Tabela 1 apresenta um resumo estatístico do tempo de contrato, da mensalidade e do total cobrado.

Tabela 1: Estatísticas descritivas das covariáveis numéricas

Variável	Mín.	1º Quart.	Mediana	Média	3º Quart.	Máx.
tenure (meses)	0	9	29	32,37	55	72
MonthlyCharges (US\$)	18,25	35,50	70,35	64,76	89,85	118,75
TotalCharges (US\$)	0	398,60	1394,50	2279,70	3786,60	8684,80

As Figuras 3 e 4 comparam a distribuição do tempo de contrato e da mensalidade entre clientes que cancelaram e clientes que permaneceram com a empresa. Nota-se que clientes que cancelaram tendem a ter um tempo de contrato menor, o que é esperado, já que clientes mais antigos já demonstraram algum nível de fidelidade ao serviço. Também é possível notar que os clientes que cancelaram tendem a pagar mensalidades mais altas.




Figura 3: Tempo de contrato (meses) por status de churn




Figura 4: Mensalidade por status de churn

Para as covariáveis categóricas, foi analisada a proporção de cancelamento dentro de cada categoria. A Figura 5 mostra essa relação para o tipo de contrato: clientes com contrato mensal (*Month-to-month*) cancelam em uma proporção bem maior (42,7%) do que clientes com contrato de um ano (11,3%) ou de dois anos (2,8%), o que sugere que essa covariável deve ter um papel importante no modelo.




Figura 5: Proporção de churn por tipo de contrato

A Figura 6 apresenta a mesma análise para o método de pagamento. Chama atenção que clientes que pagam por cheque eletrônico (*Electronic check*) apresentam uma proporção de cancelamento consideravelmente maior do que os demais métodos, próxima de 45%.




Figura 6: Proporção de churn por método de pagamento

5 Divisão da Amostra

Como a variável resposta é desbalanceada (73,5% de clientes que não cancelaram contra 26,5% de clientes que cancelaram), a divisão entre treino e teste foi feita de forma estratificada, e não por amostragem aleatória simples. A estratificação garante que essa mesma proporção de cancelamento seja preservada tanto na amostra de treino quanto na amostra de teste, evitando que uma divisão aleatória concentre, por acaso, mais casos de churn em um dos dois conjuntos.

Foi adotada a proporção de 70% dos dados para treino e 30% para teste, resultando em 4931 observações na amostra de treino e 2112 observações na amostra de teste.

6 Ajuste do Modelo

O modelo é ajustado exclusivamente na amostra de treino, e primeiramente nós utilizamos todas as covariáveis disponíveis como ponto de partida (modelo completo).

*Note que a covariável 'TotalCharges' é, por definição, aproximadamente 'tenure' × 'MonthlyCharges' (ignorando pequenas variações de reajuste). Isso gera multicolinearidade severa (alta correlação entre os preditores). Removemos 'TotalCharges' para ajustar o modelo.

Com a função "glm", os resultados foram:

Call:

```
glm(formula = Churn ~ gender + SeniorCitizen + Partner + Dependents +
    tenure + PhoneService + MultipleLines + InternetService +
    OnlineSecurity + OnlineBackup + DeviceProtection + TechSupport +
    StreamingTV + StreamingMovies + Contract + PaperlessBilling +
    PaymentMethod + MonthlyCharges, family = binomial(link = "logit"),
    data = treino)
```

Coefficients: (7 not defined because of singularities)

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.056273	0.959267	1.101	0.27084	
genderMale	-0.061292	0.076973	-0.796	0.42587	
SeniorCitizenYes	0.273139	0.100931	2.706	0.00681	**
PartnerYes	-0.030620	0.091444	-0.335	0.73774	
DependentsYes	-0.135889	0.105529	-1.288	0.19785	
tenure	-0.031893	0.002782	-11.462	< 2e-16	***
PhoneServiceYes	0.526417	0.771309	0.682	0.49492	
MultipleLinesNo phone service	NA	NA	NA	NA	
MultipleLinesYes	0.514457	0.210996	2.438	0.01476	*
InternetServiceFiber optic	2.063687	0.948765	2.175	0.02962	*
InternetServiceNo	-2.103937	0.959321	-2.193	0.02830	*
OnlineSecurityNo internet service	NA	NA	NA	NA	
OnlineSecurityYes	-0.205073	0.212406	-0.965	0.33431	
OnlineBackupNo internet service	NA	NA	NA	NA	

...

Residual deviance: 4153.9 on 4908 degrees of freedom

AIC: 4199.9

Number of Fisher Scoring iterations: 6

E a partir do modelo completo, aplicamos uma seleção de variáveis por critério de informação (AIC, método stepwise em ambas as direções) para obter um modelo mais parcimonioso, eliminando covariáveis que não contribuem para o ajuste.

Resultado:

Call:

```
glm(formula = Churn ~ SeniorCitizen + Dependents + tenure + MultipleLines +
     InternetService + OnlineSecurity + DeviceProtection + StreamingTV +
     StreamingMovies + Contract + PaperlessBilling + PaymentMethod +
     MonthlyCharges, family = binomial(link = "logit"), data = treino)
```

Coefficients: (4 not defined because of singularities)

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.793296	0.601593	2.981	0.002874	**
SeniorCitizenYes	0.279563	0.099923	2.798	0.005145	**
DependentsYes	-0.149319	0.096075	-1.554	0.120138	
tenure	-0.031767	0.002699	-11.769	< 2e-16	***
MultipleLinesNo phone service	-0.631549	0.295070	-2.140	0.032328	*
MultipleLinesYes	0.546584	0.112447	4.861	1.17e-06	***
InternetServiceFiber optic	2.221735	0.325678	6.822	8.99e-12	***
InternetServiceNo	-2.233533	0.381692	-5.852	4.87e-09	***
OnlineSecurityNo internet service	NA	NA	NA	NA	
OnlineSecurityYes	-0.176339	0.119601	-1.474	0.140374	
DeviceProtectionNo internet service	NA	NA	NA	NA	
DeviceProtectionYes	0.226074	0.115478	1.958	0.050263	.
StreamingTVNo internet service	NA	NA	NA	NA	
StreamingTVYes	0.849547	0.161511	5.260	1.44e-07	***
StreamingMoviesNo internet service	NA	NA	NA	NA	
StreamingMoviesYes	0.900656	0.159136	5.660	1.52e-08	***
...					

Residual deviance: 4156.3 on 4912 degrees of freedom

AIC: 4194.3

Number of Fisher Scoring iterations: 6

Note que: temos um aviso sobre singularidades "Coefficients: N not defined because of singularities". Isso ocorre porque algumas categorias das variáveis de complementos de internet ('OnlineSecurity', 'OnlineBackup', 'DeviceProtection', 'TechSupport', 'StreamingTV', 'StreamingMovies') possuem o nível "No internet service", que é perfeitamente coincidente com os clientes que já têm 'InternetService' = "No".

Ou seja, saber que um cliente não tem ‘OnlineSecurity’ por "não ter serviço de internet" já é informação totalmente contida na variável ‘InternetService’. Isso gera colinearidade perfeita entre essas colunas dummy, e o R, ao não conseguir estimar um coeficiente único para elas, atribui ‘NA’ e simplesmente as remove do ajuste (a informação não se perde: ela é absorvida pelo coeficiente de ‘InternetServiceNo’). O mesmo ocorre com ‘MultipleLinesNo phone service’, redundante com ‘PhoneServiceNo’.

Comparando o modelo completo com o modelo final (stepwise)

Tabela 2: Comparação entre modelo completo e modelo final (stepwise)

	Modelo completo	Modelo final (stepAIC)
Desvio Residual	4153,9 (4908 gl)	4156,3 (4912 gl)
AIC	4199,9	4194,3

O modelo final tem **menos variáveis** (removeu `gender`, `Partner`, `PhoneService`, `OnlineBackup` e `TechSupport`, que não eram significativas no modelo completo), um aumento muito pequeno no desvio residual ($4153,9 \rightarrow 4156,3$, praticamente desprezível) e, ainda assim, um **AIC menor** ($4194,3 < 4199,9$). Isso indica que essas variáveis removidas não contribuíam de forma relevante para explicar o churn, e o modelo mais parcimonioso é preferível: perde-se pouquíssima capacidade explicativa e ganha-se um modelo mais simples e mais generalizável.

Interpretação **preliminar** dos coeficientes significativos (log-odds)

No modelo final, destacam-se como estatisticamente significativas ($p < 0,05$):

- **SeniorCitizenYes** ($\beta \approx 0,28$, $p \approx 0,005$): ser idoso está associado a **maior** chance de churn.
- **tenure** ($\beta \approx -0,032$, $p < 0,001$): cada mês adicional de permanência está associado a **menor** chance de churn – é a variável mais fortemente significativa do modelo.
- **MultipleLinesYes** ($\beta \approx 0,546$, $p < 0,001$) e **MultipleLinesNo phone service** ($\beta \approx -0,632$, $p \approx 0,023$): ter múltiplas linhas aumenta a chance de churn em relação a não ter múltiplas linhas.
- **InternetServiceFiber optic** ($\beta \approx 2,22$, $p < 0,001$): clientes com internet fibra têm chance **bem maior** de churn do que os com DSL (categoria de referência).
- **InternetServiceNo** ($\beta \approx -2,234$, $p < 0,001$): clientes sem serviço de internet têm chance **bem menor** de churn.
- **DeviceProtectionYes** ($\beta \approx 0,227$, $p \approx 0,049$) e **StreamingTVYes** ($\beta \approx 0,850$, $p < 0,001$): associados a **maior** chance de churn (efeito a ser confirmado ao

observar as demais variáveis do modelo, como `Contract` e `PaymentMethod`, que não aparecem no trecho mostrado mas certamente estão no modelo final).

Esses sinais ainda estão na escala do log-odds (coeficientes da regressão logística). Na próxima parte (Razões de Chance), vamos exponenciar esses coeficientes ($\exp(\text{coef})$) para obter os *odds ratios*, que facilitam bastante a interpretação – por exemplo, dizer que "cada mês adicional de permanência reduz a chance de churn em X%" em vez de falar em log-odds.

Diagnóstico do modelo

Para avaliar a qualidade do ajuste e identificar possíveis pontos influentes ou anomalias, foram gerados os gráficos de diagnóstico baseados nos resíduos do modelo final (Figura 7).




Figura 7: Diagnóstico do modelo

Ao analisar os gráficos, devemos levar em consideração que estamos trabalhando com uma **regressão logística** (resposta binária). Por essa razão, os diagnósticos visuais tradicionais interpretam-se de forma diferente da regressão linear clássica:

- **Residuals vs Fitted e Scale-Location:** Observa-se a formação clara de duas bandas ou curvas de pontos que se cruzam de forma assintótica. Esse padrão em formato de “X” não indica uma falha de especificação ou heterocedasticidade; trata-se de um comportamento esperado e característico de dados binários, onde os resíduos observados ficam restritos a duas trajetórias possíveis dependendo se o valor real de Churn é 0 ou 1. A linha vermelha suavizada próxima de zero no

primeiro gráfico sugere que, na média, as probabilidades estimadas estão bem calibradas.

- **Q-Q Residuals:** O gráfico de probabilidade normal compara os quantis dos resíduos padronizados de desvio com os quantis teóricos de uma distribuição normal. Embora a regressão logística não assuma normalidade dos resíduos, este gráfico é útil para detectar desvios severos ou *outliers* nas caudas. Nota-se um comportamento linear bem definido na maior parte da distribuição, com um leve descolamento nas caudas superiores (identificando observações como as de índices 4514, 269 e 5442), sugerindo casos em que o modelo falhou em prever um evento com alta ou baixa probabilidade estimada.
- **Residuals vs Leverage:** Este gráfico permite identificar pontos de alta alavancagem (*leverage*) e observações influentes por meio da Distância de Cook. No modelo ajustado, a grande maioria dos dados possui alavancagem muito baixa (inferior a 0,012). Embora algumas observações (como 4514, 6725 e 6814) apresentem resíduos padronizados elevados, nenhuma delas ultrapassa ou chega perto das linhas de corte da Distância de Cook (representadas pelas linhas pontilhadas vermelhas que sequer aparecem na região visível do gráfico). Isso indica que **não existem pontos influentes** capazes de distorcer ou comprometer isoladamente as estimativas dos coeficientes obtidos.

Em suma, o diagnóstico visual indica que o modelo se comporta conforme o esperado para a estrutura de dados de regressão logística, livre de pontos aberrantes com influência desproporcional sobre o ajuste.

7 Interpretação dos Coeficientes

Os coeficientes do modelo logístico são interpretados na escala do log-odds. Para facilitar a interpretação, calculamos as razões de chance (**odds ratios**), obtidas por $e^{\hat{\beta}}$, junto com os respectivos intervalos de confiança de 95%.

- $OR > 1$: a covariável **aumenta** a chance de cancelamento;
- $OR < 1$: a covariável **diminui** a chance de cancelamento;
- $OR = 1$: a covariável não tem efeito sobre a chance de cancelamento.

Nós temos os seguintes resultados:

Tabela 3: Odds Ratios e intervalos de confiança de 95%

Variável	OR	2,5%	97,5%
(Intercept)	6,009	1,851	19,586
SeniorCitizenYes	1,323	1,087	1,609
DependentsYes	0,861	0,713	1,039
tenure	0,969	0,964	0,974
MultipleLinesNo phone service	0,532	0,298	0,947
MultipleLinesYes	1,727	1,386	2,154
InternetServiceFiber optic	9,223	4,884	17,514
InternetServiceNo	0,107	0,051	0,226
OnlineSecurityNo internet service	NA	NA	NA
OnlineSecurityYes	0,838	0,663	1,059
DeviceProtectionNo internet service	NA	NA	NA
DeviceProtectionYes	1,254	1,000	1,573
StreamingTVNo internet service	NA	NA	NA
StreamingTVYes	2,339	1,706	3,213
StreamingMoviesNo internet service	NA	NA	NA
StreamingMoviesYes	2,461	1,804	3,366
ContractOne year	0,486	0,379	0,621
ContractTwo year	0,249	0,166	0,364
PaperlessBillingYes	1,379	1,160	1,639
PaymentMethodCredit card (automatic)	0,908	0,698	1,182
PaymentMethodElectronic check	1,308	1,052	1,628
PaymentMethodMailed check	1,014	0,778	1,322
MonthlyCharges	0,948	0,925	0,971

Interpretação das Razões de Chance (Odds Ratios)

Uma covariável é considerada relevante quando o intervalo de confiança de 95% do OR **não contém o valor 1**. Quando o IC inclui 1, não há evidência de que a variável altere a chance de churn, mesmo que o OR pontual seja diferente de 1.

Variáveis associadas a maior chance de churn (OR > 1, IC não contém 1)

SeniorCitizenYes (OR = 1,323; IC 1,087–1,609): ser idoso aumenta em cerca de **32%** a chance de cancelamento, mantidas as demais variáveis constantes.

MultipleLinesYes (OR = 1,727; IC 1,386–2,154): ter múltiplas linhas telefônicas aumenta em aproximadamente **73%** a chance de churn em relação a não ter múltiplas linhas.

InternetServiceFiber optic (OR = 9,223; IC 4,884–17,514): possuir internet por fibra óptica multiplica por aproximadamente **9 vezes** a chance de churn em

relação ao serviço DSL (categoria de referência). Continua sendo o efeito mais forte observado no modelo.

DeviceProtectionYes (OR = 1,254; IC 1,000–1,573): apresenta efeito positivo, porém o limite inferior do intervalo de confiança é praticamente igual a 1, indicando evidência estatística bastante limítrofe.

StreamingTVYes (OR = 2,339; IC 1,706–3,213) e **StreamingMoviesYes** (OR = 2,461; IC 1,804–3,366): clientes que possuem esses serviços apresentam mais que o **dobro** da chance de churn. Esse resultado provavelmente está relacionado ao fato de esses serviços estarem concentrados entre clientes com internet, especialmente fibra óptica, refletindo o perfil dos planos mais caros.

PaperlessBillingYes (OR = 1,379; IC 1,160–1,639): utilizar fatura digital está associado a um aumento de aproximadamente **38%** na chance de churn.

PaymentMethodElectronic check (OR = 1,308; IC 1,052–1,628): clientes que utilizam cheque eletrônico apresentam cerca de **31%** mais chance de cancelar o serviço em relação ao método de pagamento de referência.

Variáveis associadas a menor chance de churn (OR < 1, IC não contém 1)

tenure (OR = 0,969; IC 0,964–0,974): cada mês adicional de permanência reduz em aproximadamente **3%** a chance de churn, sendo um dos efeitos mais consistentes do modelo.

MultipleLinesNo phone service (OR = 0,532; IC 0,298–0,947): clientes sem serviço telefônico apresentam aproximadamente **47%** menor chance de churn em comparação com a categoria de referência.

InternetServiceNo (OR = 0,107; IC 0,051–0,226): não possuir serviço de internet reduz a chance de churn em aproximadamente **89%** quando comparado aos clientes com internet DSL.

ContractOne year (OR = 0,486; IC 0,379–0,621) e **ContractTwo year** (OR = 0,249; IC 0,166–0,364): contratos mais longos reduzem substancialmente a probabilidade de churn. Contratos de um ano apresentam redução de aproximadamente **51%** e contratos de dois anos cerca de **75%** em relação aos contratos mensais.

MonthlyCharges (OR = 0,948; IC 0,925–0,971): após o ajuste pelas demais variáveis do modelo, mensalidades mais elevadas aparecem associadas a uma **redução** na

chance de churn. Esse resultado difere da análise exploratória devido ao efeito de confundimento entre valor da mensalidade, tipo de internet e serviços adicionais.

Variáveis sem evidência de efeito (IC contém 1)

- `DependentsYes`, `OnlineSecurityYes`, `PaymentMethodCredit card (automatic)` e `PaymentMethodMailed check`. Como seus intervalos de confiança incluem o valor 1, não há evidência estatística de associação com a chance de churn após o ajuste pelas demais covariáveis.
- Embora `DeviceProtectionYes` apresente um intervalo cujo limite inferior é igual a 1,000 após arredondamento, o resultado deve ser interpretado com cautela, pois representa uma evidência limítrofe.

Sobre as linhas NA

As linhas `OnlineSecurityNo internet service`, `DeviceProtectionNo internet service`, `StreamingTVNo internet service` e `StreamingMoviesNo internet service` aparecem como NA porque esses níveis são perfeitamente redundantes com a variável `InternetServiceNo`. Assim, seus coeficientes não podem ser estimados separadamente, caracterizando um caso de colinearidade perfeita. Esse comportamento é esperado e não representa erro na estimação do modelo.

Resumo

Os principais determinantes da ocorrência de churn continuam sendo o **tipo de contrato**, o **tempo de permanência do cliente** e o **tipo de serviço de internet**. Contratos de maior duração reduzem fortemente a probabilidade de cancelamento, enquanto clientes com internet por fibra óptica apresentam risco substancialmente maior de churn. Além disso, serviços de streaming e o pagamento por cheque eletrônico permanecem associados a maior probabilidade de cancelamento, mesmo após o ajuste pelas demais variáveis do modelo.

8 Avaliação da significância

Comparamos o modelo completo e o modelo reduzido por meio do teste da razão de verossimilhanças (Likelihood Ratio Test).

Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1 4912	4156.341	NA	NA	NA

2 4908 4153.921 4 2.42072 0.6588862

O teste da razão de verossimilhanças comparando o modelo completo e o modelo final (reduzido) resultou em uma diferença de deviance de 2,42 (4 graus de liberdade) e $p\text{-valor} = 0,659$. Como o $p\text{-valor}$ é alto, não há evidência de que o modelo completo se ajuste significativamente melhor aos dados do que o modelo reduzido.

Vale notar que, embora o ‘stepAIC’ tenha removido 5 variáveis do modelo completo (‘gender’, ‘Partner’, ‘PhoneService’, ‘OnlineBackup’ e ‘TechSupport’), a diferença de graus de liberdade entre os dois modelos é de apenas 4, e não 5. Isso ocorre porque, no modelo completo, o nível "No phone service" da variável ‘MultipleLines’ era perfeitamente colinear com ‘PhoneService = "No"' (um cliente sem telefone nunca pode ter múltiplas linhas), o que fazia seu coeficiente ser ‘NA’ por singularidade. Ao remover ‘PhoneService’ do modelo, essa colinearidade deixa de existir, e o coeficiente de ‘MultipleLinesNo phone service’ passa a ser estimável no modelo final, recuperando 1 grau de liberdade que se perde ao remover as outras 5 variáveis. Assim temos 4 parâmetros a menos (24 no modelo completo contra 20 no modelo final), consistente com o resultado do teste.

E como vimos anteriormente, o modelo final apresenta AIC menor (4194,3) do que o modelo completo (4199,9). Como o modelo mais simples explica os dados praticamente tão bem quanto o modelo completo, mas com menos parâmetros, ambos os critérios, o teste da razão de verossimilhanças e o AIC, apontam na mesma direção.

Por esses motivos, adotamos o modelo final (reduzido) como modelo de referência para as próximas etapas da análise (curva ROC e matriz de confusão).

9 Curva ROC e Área Sob a Curva (AUC)

A capacidade preditiva do modelo final foi avaliada exclusivamente na amostra de teste (2112 observações), que não participou do ajuste. Para cada cliente do teste, o modelo fornece uma probabilidade estimada de cancelamento, $\hat{p}_i = \hat{P}(\text{Churn} = 1 \mid \mathbf{x}_i)$. A classificação de um cliente como “churn” ou “não churn” depende, então, da escolha de um ponto de corte c : classifica-se como churn todo cliente com $\hat{p}_i \geq c$.

A curva ROC (*Receiver Operating Characteristic*) resume o desempenho do modelo para todos os pontos de corte possíveis, representando, para cada valor de c , o par (1 – especificidade, sensibilidade). Um classificador sem poder discriminatório corresponde à diagonal do gráfico, enquanto curvas mais próximas do canto superior esquerdo indicam melhor capacidade de separar as duas classes. A Figura 8 apresenta a curva ROC obtida na amostra de teste.




Figura 8: Curva ROC do modelo final na amostra de teste

A área sob a curva (AUC) foi de **0,8468**, com intervalo de confiança de 95% de $[0,8290; 0,8646]$ (método de DeLong). A AUC pode ser interpretada como a probabilidade de que, ao sortear aleatoriamente um cliente que cancelou e um que não cancelou, o modelo atribua probabilidade estimada de churn maior ao cliente que de fato cancelou. Um valor de 0,5 equivale a um classificador aleatório e 1 a um classificador perfeito; valores entre 0,8 e 0,9 são usualmente considerados indicativos de discriminação boa hosmer2013. Assim, o modelo apresenta boa capacidade de ordenar os clientes segundo o risco de cancelamento, e o intervalo de confiança, inteiramente acima de 0,8, reforça essa conclusão.

Escolha do ponto de corte

O ponto de corte usual de $c = 0,5$ não é adequado neste problema, por dois motivos. Primeiro, a base é desbalanceada (aproximadamente 27% de churn), de modo que as probabilidades estimadas se concentram abaixo de 0,5 e um corte nesse valor classificaria a grande maioria dos clientes como “não churn”, resultando em sensibilidade baixa. Segundo, do ponto de vista do negócio, os erros têm custos assimétricos: deixar de identificar um cliente que vai cancelar (falso negativo) implica a perda integral da receita desse cliente, enquanto direcionar uma ação de retenção a um cliente que não iria cancelar (falso positivo) tem custo comparativamente menor.

Por isso, o ponto de corte foi determinado a partir da própria curva ROC, pelo **índice de Youden**, que seleciona o corte c que maximiza

$$J(c) = \text{sensibilidade}(c) + \text{especificidade}(c) - 1,$$

isto é, o ponto da curva ROC mais distante da diagonal do classificador aleatório, equilibrando a detecção dos dois grupos sem privilegiar a classe majoritária. O corte

obtido foi

$$c^* = 0,2310,$$

associado, na amostra de teste, a sensibilidade de 0,8430 e especificidade de 0,6930. Note que c^* é próximo da prevalência de churn na base ($\approx 0,24$ no teste), comportamento esperado para cortes ótimos em bases desbalanceadas. Esse valor foi adotado na construção da matriz de confusão da seção seguinte.

10 Matriz de Confusão e Medidas de Desempenho

Aplicando o ponto de corte $c^* = 0,2310$ às probabilidades estimadas na amostra de teste, cada cliente foi classificado como churn ($\hat{p}_i \geq c^*$) ou não churn ($\hat{p}_i < c^*$). A Tabela 4 apresenta a matriz de confusão resultante.

Tabela 4: Matriz de confusão na amostra de teste (corte $c^* = 0,2310$)

		Observado		Total
		Não churn (0)	Churn (1)	
2* Predito	Não churn (0)	1106	81	1187
	Churn (1)	490	435	925
Total		1596	516	2112

Dos 516 clientes da amostra de teste que de fato cancelaram, o modelo identificou corretamente 435 (verdadeiros positivos) e deixou de identificar apenas 81 (falsos negativos). Em contrapartida, 490 clientes que não cancelaram foram classificados como churn (falsos positivos). As principais medidas de desempenho derivadas dessa matriz estão resumidas na Tabela 5.

Tabela 5: Medidas de desempenho na amostra de teste

Medida	Valor
Acurácia	0,7296
Sensibilidade (recall)	0,8430
Especificidade	0,6930
Valor preditivo positivo (precisão)	0,4703
Valor preditivo negativo	0,9318
F1-score	0,6037
Acurácia balanceada	0,7680
Kappa de Cohen	0,4227

Interpretação das medidas

Sensibilidade (0,8430): entre os clientes que efetivamente cancelaram, o modelo identificou corretamente 84,3%. Esta é a medida mais relevante no contexto do problema, pois mede diretamente a capacidade do modelo de “capturar” os clientes em risco, que são o alvo das ações de retenção.

Especificidade (0,6930): entre os clientes que permaneceram, 69,3% foram corretamente classificados como não churn. O valor mais moderado reflete a escolha deliberada de um corte baixo, que aceita mais falsos positivos em troca de maior sensibilidade.

Valor preditivo positivo (0,4703): entre os clientes apontados pelo modelo como risco de churn, 47,0% de fato cancelaram. Em termos práticos, se a empresa direcionar ações de retenção a todos os clientes sinalizados, aproximadamente metade dessas ações atingirá clientes que realmente iriam cancelar, proporção bastante superior à prevalência de churn na base (24,4%), o que evidencia o ganho de focalização proporcionado pelo modelo.

Valor preditivo negativo (0,9318): entre os clientes classificados como não churn, 93,2% de fato permaneceram. Ou seja, quando o modelo indica que um cliente não está em risco, essa indicação é altamente confiável, o que permite à empresa excluir com segurança esses clientes das campanhas de retenção.

F1-score (0,6037): média harmônica entre precisão e sensibilidade, adequada para bases desbalanceadas por não ser inflada pela classe majoritária. O valor reflete o compromisso adotado: sensibilidade alta com precisão moderada.

Acurácia (0,7296) e acurácia balanceada (0,7680): a acurácia global indica que 73,0% dos clientes do teste foram corretamente classificados. É importante observar que esse valor é ligeiramente **inferior** à taxa de não informação (*No Information Rate*) de 0,7557, que corresponde à acurácia de um classificador trivial que previsse “não churn” para todos os clientes. Esse resultado não indica falha do modelo, e sim uma consequência direta e intencional da escolha do ponto de corte: o classificador trivial teria sensibilidade igual a zero, sendo inútil para o propósito da análise, enquanto o modelo com corte de Youden detecta 84,3% dos cancelamentos. Em bases desbalanceadas, a acurácia global é uma medida enganosa de qualidade, e por isso privilegiam-se a acurácia balanceada (0,7680, média entre sensibilidade e especificidade) e as demais medidas discutidas acima.

Kappa de Cohen (0,4227): mede a concordância entre predito e observado descontando a concordância esperada ao acaso; o valor obtido indica concordância mo-

derada, coerente com o perfil das demais medidas.

Em resumo, com o ponto de corte definido pela curva ROC, o modelo prioriza a detecção dos clientes em risco (sensibilidade de 84,3% e valor preditivo negativo de 93,2%), ao custo de acionar também uma parcela de clientes que não cancelariam. No contexto de retenção de clientes, esse é o perfil de erro desejável.

11 Conclusões

Este trabalho ajustou um modelo de regressão logística para estimar a probabilidade de cancelamento (churn) de clientes de uma empresa de telecomunicações, a partir de características cadastrais, dos serviços contratados e das condições contratuais, utilizando 70% da base para ajuste e 30% para avaliação.

Quanto aos fatores associados ao churn, os principais resultados foram:

- O **tipo de contrato** é o fator de proteção mais importante: em relação ao contrato mensal, contratos de um ano reduzem a chance de cancelamento em aproximadamente 51% ($OR = 0,486$) e contratos de dois anos em cerca de 75% ($OR = 0,249$).
- O **tempo de permanência (tenure)** também reduz o risco: cada mês adicional de relacionamento está associado a uma redução de cerca de 3% na chance de churn ($OR = 0,969$), indicando que os clientes recentes são os mais vulneráveis.
- O **serviço de internet por fibra óptica** apresentou a maior associação positiva com o churn ($OR = 9,223$ em relação ao DSL), enquanto não possuir internet reduz fortemente a chance de cancelamento ($OR = 0,107$). Serviços de streaming ($OR \approx 2,3$ a $2,5$), fatura digital ($OR = 1,379$) e pagamento por cheque eletrônico ($OR = 1,308$) também se mostraram associados a maior risco.

Do ponto de vista preditivo, o modelo final apresentou AUC de 0,8468 (IC 95%: 0,8290 a 0,8646) na amostra de teste, indicando boa capacidade de discriminação entre clientes que cancelam e que permanecem. Com o ponto de corte de 0,2310, definido pelo índice de Youden sobre a curva ROC, obteve-se sensibilidade de 84,3%, especificidade de 69,3% e valor preditivo negativo de 93,2%, perfil adequado ao objetivo prático de identificar os clientes em risco para ações de retenção.

Limitações

- Os dados são **observacionais**, de modo que as associações estimadas não permitem interpretação causal. O efeito da fibra óptica, por exemplo, pode estar confundido com preço, região ou perfil dos clientes que contratam esse serviço.

- Há **colinearidade estrutural** entre `InternetService` e os níveis “No internet service” das variáveis de serviços complementares (e entre `PhoneService` e `MultipleLines`), o que gerou coeficientes não estimáveis (NA), tratados pelo R via remoção automática dos termos redundantes. A covariável `TotalCharges` foi removida por ser função aproximada de `tenure` $\times$ `MonthlyCharges`.
- O ponto de corte foi escolhido por um critério estatístico (índice de Youden), que atribui pesos iguais a sensibilidade e especificidade. Na prática, o corte ideal dependeria dos custos reais das ações de retenção e do valor de cada cliente.
- O modelo assume efeitos aditivos e lineares na escala do log-odds; não foram investigadas interações entre covariáveis nem formas não lineares (por exemplo, splines para `tenure`).
- A avaliação baseou-se em uma única divisão treino/teste; os resultados podem variar ligeiramente com outras partições.

Apêndice - Código em R

```
1 library(dplyr)
2 library(ggplot2)
3 library(caret)
4 aveis...
5
6 dados <- read.csv("C:/Users/Marcella Cobra/Documents/WA_Fn-UseC_
  -Telco-Customer-Churn.csv", stringsAsFactors = FALSE)
7
8 head(dados)
9
10 dim(dados)
11 str(dados)
12
13
14 dados$Churn <- ifelse(dados$Churn == "Yes", 1, 0)
15
16
17 table(dados$Churn)
18 prop.table(table(dados$Churn))
19
20 dados$customerID <- NULL
21
22
23
24 sum(is.na(dados$TotalCharges))
25
26 dados[is.na(dados$TotalCharges), c("tenure", "MonthlyCharges", "
  TotalCharges")]
27 dados$TotalCharges[is.na(dados$TotalCharges)] <- 0
28
29 sum(is.na(dados))
30
31 dados <- dados %>% mutate(across(where(is.character), as.factor)
  )
32
33 dados$SeniorCitizen <- factor(dados$SeniorCitizen, labels = c("
  No", "Yes"))
34
35 str(dados)
```

```
36
37
38 ggplot(dados, aes(x = factor(Churn, labels = c("Nao cancelou", "
    Cancelou")))) +
39   geom_bar(fill = "steelblue") +
40   labs(title = "Distribuicao da variavel resposta (Churn)",
41         x = "", y = "Numero de clientes")
42
43
44 summary(dados[, c("tenure", "MonthlyCharges", "TotalCharges")])
45
46 ggplot(dados, aes(x = factor(Churn, labels = c("Nao cancelou", "
    Cancelou"))),
47         y = tenure)) +
48   geom_boxplot(fill = "lightblue") +
49   labs(title = "Tempo de contrato (meses) por status de churn",
50         x = "", y = "Tenure (meses)")
51
52 ggplot(dados, aes(x = factor(Churn, labels = c("Nao cancelou", "
    Cancelou"))),
53         y = MonthlyCharges)) +
54   geom_boxplot(fill = "lightgreen") +
55   labs(title = "Mensalidade por status de churn",
56         x = "", y = "Mensalidade (MonthlyCharges)")
57
58
59 prop.table(table(dados$Contract, dados$Churn), margin = 1)
60
61 ggplot(dados, aes(x = Contract, fill = factor(Churn, labels = c(
    "Nao cancelou", "Cancelou")))) +
62   geom_bar(position = "fill") +
63   labs(title = "Proporcao de churn por tipo de contrato",
64         x = "Tipo de contrato", y = "Proporcao", fill = "Churn")
65
66 ggplot(dados, aes(x = PaymentMethod, fill = factor(Churn, labels
    = c("Nao cancelou", "Cancelou")))) +
67   geom_bar(position = "fill") +
68   labs(title = "Proporcao de churn por metodo de pagamento",
69         x = "Metodo de pagamento", y = "Proporcao", fill = "Churn
    ") +
70   theme(axis.text.x = element_text(angle = 30, hjust = 1))
```

```
71
72 indices_treino <- createDataPartition(dados$Churn, p = 0.7, list
    = FALSE)
73
74 treino <- dados[indices_treino, ]
75 teste  <- dados[-indices_treino, ]
76
77 nrow(treino)
78 nrow(teste)
79
80
81 modelo_completo <- glm(Churn ~ ., data = treino, family =
    binomial(link = "logit"))
82 modelo_completo <- update(modelo_completo, . ~ . - TotalCharges)
83
84 summary(modelo_completo)
85
86 library(MASS)
87
88 modelo_final <- stepAIC(modelo_completo, direction = "both",
    trace = FALSE)
89
90 summary(modelo_final)
91
92 par(mfrow = c(2, 2))
93 plot(modelo_final)
94 par(mfrow = c(1, 1))
95
96 odds_ratios <- exp(cbind(OR = coef(modelo_final), confint(modelo
    _final)))
97
98 round(odds_ratios, 3)
99
100 anova(modelo_final, modelo_completo, test = "Chisq")
101
102 AIC(modelo_completo, modelo_final)
103 library(pROC)
104
105
106 probab_teste <- predict(modelo_final, newdata = teste, type = "
    response")
```



```
147  
148 matriz$overall["Accuracy"]  
149 matriz$byClass[c("Sensitivity", "Specificity",  
150                  "Pos Pred Value", "Neg Pred Value",  
151                  "F1", "Balanced Accuracy")]
```

Referências

- [1] BlastChar. *Telco Customer Churn*. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>.