

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Estatística

Relatório - Atividade 4- Análise de Regressão

Matheus Brito 812048
Marcela Cobra Moraes 813147
Marcelo Huang 832111

Maio, 2026

1 Introdução

O concreto é um dos materiais de construção mais utilizados no mundo, e sua resistência à compressão é uma propriedade fundamental para o dimensionamento estrutural. Essa resistência depende de múltiplos fatores, como a proporção dos componentes da mistura e o tempo de cura (idade). Compreender quantitativamente essas relações é essencial tanto para a engenharia prática quanto para o controle de qualidade.

Este trabalho utiliza o conjunto de dados de resistência à compressão do concreto disponibilizado no repositório UCI Machine Learning [1], composto por 1030 observações experimentais. O banco de dados registra a resistência à compressão (em MPa) em função de oito variáveis relacionadas à composição da mistura e à idade do concreto.

2 Objetivo

O objetivo deste trabalho é ajustar um modelo de regressão linear múltipla para explicar e prever a resistência à compressão do concreto a partir das variáveis disponíveis, avaliando a adequação do modelo, a significância dos preditores e sua capacidade preditiva em dados novos.

3 Análise Descritiva

3.1 Dados e variáveis

Temos: Y é a resistência à compressão (MPa) e as covariáveis são:

- X_1 : Cimento (kg/m^3)
- X_2 : Escória (kg/m^3)
- X_3 : Cinza Volante (kg/m^3)
- X_4 : Água (kg/m^3)
- X_5 : Superplastificante (kg/m^3)
- X_6 : Agregado Graúdo (kg/m^3)
- X_7 : Agregado Miúdo (kg/m^3)
- X_8 : Idade (dias)

Para validação, realizou-se uma divisão aleatória (semente 42) em conjunto de treino (721 observações, 70%) e teste (309 observações, 30%). Todas as análises foram executadas no software R.

3.2 Estatísticas descritivas

A Tabela 1 resume as principais estatísticas das variáveis no conjunto de treino.

Tabela 1: Estatísticas descritivas das variáveis (treino)

Variável	Mín.	1º Quart.	Mediana	Média	3º Quart.	Máx.
Cimento	102.0	192.0	266.0	280.4	350.0	540.0
Escória	0.00	0.00	42.08	78.34	145.00	359.40
Cinza Volante	0.00	0.00	0.00	52.71	118.27	200.00
Água	121.8	164.9	185.7	181.8	193.0	246.9
Superplastificante	0.000	0.000	6.470	6.298	10.160	32.200
Agr. Graúdo	801.0	932.0	968.0	972.4	1028.4	1134.3
Agr. Miúdo	594.0	724.3	778.5	771.0	821.0	992.6
Idade	1.00	7.00	28.00	45.83	56.00	365.00
Resistência	2.332	24.065	34.770	36.090	45.940	82.599

Note que os dados não apresentam inconsistência. Todo concreto testado era feito com presença de ingredientes principais: Cimento, Água, e Agregados (Graúdo e Miúdo)

3.3 Transformações e interações das Covariáveis

E considerando a natureza das covariáveis, é conveniente considerar as seguintes transformações e interações das covariáveis:

- X_9^* : $\log(\text{Idade})$
- X_{10}^* : produto do Cimento e Idade = Cimento*Idade

Além disso, foi feita uma transformação (usando Box-Cox, $\lambda \approx 0.5$) em Y para garantir que o modelo seja válido posteriormente. Assim o modelo completo considerado é da forma:

$$\sqrt{Y} = X\beta + \varepsilon,$$

3.4 Gráfico de dispersão

A Figura 1 mostra a relação entre cada covariável e a variável resposta. Não há evidências graves de não linearidade.




Figura 1: Gráfico de dispersão das covariáveis versus resistência à compressão

Devido a estrutura dos dados (alguns concretos não tem determinado componente) não há estrutura visual evidente nos gráficos de dispersão

4 Seleção de variáveis

4.1 Matriz de correlação e multicolinearidade

A Figura 2 apresenta o *corrplot* das variáveis. As correlações entre preditoras são baixas ($|\rho| < 0,7$), sugerindo ausência de multicolinearidade severa, exceto para os pares (Idade x log Idade) e (Idade x CimXIdade).




Figura 2: Corrplot das variáveis numéricas

Os valores do Fator de Inflação da Variância (VIF) para o modelo completo são apresentados na Tabela 2. A maioria são inferiores a 10, indicando ausência de multicolinearidade problemática, mas tem alguns que são superiores a 10 (AgregadoGraúdo e CimXIdade). Nenhuma dessas duas covariáveis são removidas por ter VIF alto, pois isso não reduz a apreciação preditiva global do modelo.

Tabela 2: VIF do modelo completo — parte 1 (preditores originais)

Cimento	Escória	CinzaVol.	Água	Superplast.	Agr.Graúdo	Agr.Miúdo	Idade
8.08	7.58	6.51	6.98	3.05	14.39	5.24	7.49

Tabela 3: VIF do modelo completo — parte 2

log(Idade)	CimXIdade
2.59	13.34

Foi aplicado um método de seleção de variáveis:

- **Stepwise (AIC):** selecionou o modelo com $\text{sqrt}(\text{Resistencia}) \sim \text{Cimento} + \text{Escoria} + \text{CinzaVolante} + \text{Agua} + \text{AgregadoGraudo} + \text{AgregadoMiudo} + \text{Idade} + \text{logIdade} + \text{CimXIdade}$.

Com esse critério, optou-se pelo modelo com 9 covariáveis (Superflastificante = X_5 não foi retido).

5 Modelo

5.1 Ajuste do modelo

O modelo foi ajustado (por mínimos quadrados) conforme a seleção realizada na Etapa 2:

$$\sqrt{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_6 X_6 + \beta_7 X_7 + \beta_8 X_8 + \beta_9 X_9^* + \beta_{10} X_{10}^* + \varepsilon.$$

Resumo do modelo ajustado será apresentado posteriormente.

5.2 Diagnóstico de resíduos

5.2.1 Independência

Como não temos a ordem da coleta, assume-se a independência.

5.2.2 Normalidade

O teste de Shapiro-Wilk ($p = 0,2675$) não rejeita a hipótese de normalidade dos resíduos.

5.2.3 Homocedasticidade

O teste de Breusch-Pagan(studentize = FALSE) ($p = 0,2295$) não rejeita a homocedasticidade. A Figura 3 mostra o QQ-plot e o gráfico de resíduos versus valores ajustados.




Figura 3: QQ-plot e resíduos vs valores ajustados

5.3 Detecção de Outliers e Pontos influentes

- **Resíduo studentizado:** houve observações com $|r_i| > 3$ (4 observações: 5 165 289 534).
- **Alavancagem (h_{ii}):** 38 pontos acima de $2p/n$, mas nenhum acima do critério alternativo $(1/2)$. Note: $p = \#$ de parâmetros, e $n = \#$ de observações

Como há presença de outliers, abaixo é feita uma investigação sobre pontos influentes:

- **Distância de Cook:** nenhum ponto acima do limiar $F_{p, n-p, 0.5}$.
- **DFFITS:** nenhum ponto acima do limite.
- **DFBETAS:** com critério $2/\sqrt{n}$ detectaram-se 128 pontos; com critério $|\text{DFBETAS}| > 1$ nenhum ponto influente. Devido à estrutura dos dados, isso era esperado.

Sobre pontos influentes, conclui-se que não há presença de pontos influentes. As Figuras 4–7 ilustram essas medidas (Resíduos studentizado, h_{ii} , DCook e DFFITS).




Figura 4: Resíduos studentizados




Figura 5: Alavancagem (h_{ii}) ordenada




Figura 6: Distância de Cook




Figura 7: DFFITS

5.4 Estimativas dos parâmetros e Testes de significância formais

Sumário do modelo

A seguir, o resumo do modelo ajustado no R:

Call:

```
lm(formula = sqrtResist ~ Cimento + Escoria + CinzaVolante +
    Agua + Idade + AgregadoGraudo + AgregadoMiudo + logIdade +
    CimXIdade, data = treino)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.80721	-0.34670	-0.01011	0.36603	1.77594

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-4.772e+00	1.712e+00	-2.787	0.00546	**
Cimento	1.291e-02	5.902e-04	21.868	< 2e-16	***
Escoria	9.906e-03	6.780e-04	14.610	< 2e-16	***
CinzaVolante	8.940e-03	8.469e-04	10.556	< 2e-16	***
Agua	-1.026e-02	2.333e-03	-4.395	1.27e-05	***
Idade	2.548e-03	1.310e-03	1.945	0.05214	.
AgregadoGraudo	2.572e-03	5.908e-04	4.353	1.54e-05	***
AgregadoMiudo	2.941e-03	7.281e-04	4.039	5.94e-05	***
logIdade	9.325e-01	2.932e-02	31.805	< 2e-16	***
CimXIdade	-1.968e-05	3.661e-06	-5.376	1.03e-07	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5734 on 711 degrees of freedom

Multiple R-squared: 0.8478, Adjusted R-squared: 0.8459

F-statistic: 440.2 on 9 and 711 DF, p-value: < 2.2e-16

Note que as hipóteses nulas do teste F-Global e dos testes t (menos paara a co-variavel "Idade") foram rejeitadas com valores-p baixos mostrado na saída de código acima.

Interpretação:

- **Cimento** ($\hat{\beta}_1 = 0,0129$): a cada kg/m^3 adicional de cimento, a raiz quadrada da resistência aumenta em média 0,0129 unidades, mantendo as demais variáveis fixas.
- **Escória** ($\hat{\beta}_2 = 0,0099$): aumento de 0,0099 na raiz da resistência por kg/m^3 de escória.
- **Cinza Volante** ($\hat{\beta}_3 = 0,0089$): aumento de 0,0089 na raiz da resistência por kg/m^3 de cinza.
- **Água** ($\hat{\beta}_4 = -0,0103$): cada kg/m^3 adicional de água reduz a raiz da resistência em 0,0103 unidades.
- **Idade** ($\hat{\beta}_6 = 0,0025$): efeito positivo pequeno, razoavelmente significativo ($p=0,052$).
- **Agregado Graúdo** ($\hat{\beta}_7 = 0,0029$) e **Agregado Miúdo** ($\hat{\beta}_8 = 0,0026$): ambos contribuem positivamente para a resistência.

- **log(Idade)** ($\hat{\beta}_9 = 0,9325$): um acréscimo de 1% na idade eleva a raiz da resistência em aproximadamente 0,0093 unidades; duplicar a idade eleva em 0,646 unidades.
- **Interação Cimento×Idade** ($\hat{\beta}_{10} = -0,0000197$): o efeito benéfico do cimento diminui com a idade do concreto.
- **Intercepto:** β_0 : Não tem interpretação para β_0 pois aparentemente 0 não está no range das covariáveis (se não tem componentes, não tem concreto, consequentemente não tem resistência à compressão).

Teste F parcial (Tipo III)

A tabela ANOVA a seguir apresenta a contribuição individual de cada covariável controlando pelas demais:

Anova Table (Type III tests)

Response: sqrtResist

	Sum Sq	Df	F value	Pr(>F)	
(Intercept)	2.55	1	7.7696	0.005455	**
Cimento	157.24	1	478.1913	< 2.2e-16	***
Escoria	70.19	1	213.4475	< 2.2e-16	***
CinzaVolante	36.64	1	111.4254	< 2.2e-16	***
Agua	6.35	1	19.3203	1.274e-05	***
Idade	1.24	1	3.7841	0.052136	.
AgregadoGraudo	6.23	1	18.9523	1.537e-05	***
AgregadoMiudo	5.37	1	16.3161	5.944e-05	***
logIdade	332.64	1	1011.5843	< 2.2e-16	***
CimXIdade	9.51	1	28.9065	1.031e-07	***
Residuals	233.80	711			

5.5 Significância dos coeficientes

As covariáveis são globalmente significativas: o valor-p do teste F global é menor que $2,2 \times 10^{-16}$, rejeitando $H_0 : \beta_1 = \dots = \beta_4 = \beta_6 = \beta_{10} = 0$. Individualmente, todas as variáveis são significativas ao nível de 5%, menos para a covariável "Idade". As variáveis com maior estatística F são Cimento ($F = 478,1913$), log(Idade) ($F = 1011,5843$) e Escória ($F = 213,4475$).

6 Validação

O modelo ajustado foi aplicado ao conjunto de teste (309 observações). As métricas (calculadas com escala original da resposta) obtidas foram:

Tabela 4: Métricas de ajuste e predição

Métrica	Treino	Teste
RMSE	6,8803	6,87
MAE	5,1922	5,16
MAPE (%)	–	16,01
R^2 preditivo	–	0.8213

Pode-se dizer que o modelo tem capacidade de generalização razoável, mas o poder de predição não é o ideal.

A Tabela 5 exibe as primeiras previsões no conjunto de teste.

Tabela 5: Valores observados e previstos (primeiras linhas do conjunto de teste)

Índice	Resistência real	Predição
1	41,1	46,0
2	44,3	50,1
3	47,0	33,3
4	45,9	23,5
5	43,0	44,3

7 Modelo final

Reajustando o modelo com a base completa de dados (1030 observações):

$$\begin{aligned} \widehat{\sqrt{\text{Resistencia}}} = & \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{Cimento} + \hat{\beta}_2 \cdot \text{Escória} + \hat{\beta}_3 \cdot \text{CinzaVolante} \\ & + \hat{\beta}_4 \cdot \text{Água} + \hat{\beta}_6 \cdot \text{Agregado Graúdo} + \hat{\beta}_7 \cdot \text{Agregado Miúdo} \\ & + \hat{\beta}_8 \cdot \text{Idade} + \hat{\beta}_9 \cdot \log(\text{Idade}) + \hat{\beta}_{10} \cdot (\text{Cimento} \times \text{Idade}) \end{aligned}$$

A Tabela 6 a seguir mostra as estimativas dos parâmetros

Tabela 6: Estimativas dos parâmetros – parte 1 ($\hat{\beta}_0$ a $\hat{\beta}_4$)

Modelo	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$	$\hat{\beta}_4$
Treino	–4,7719	0,01291	0,009906	0,008940	–0,01026
Final (completo)	–3,2993	0,01230	0,009285	0,008145	–0,01127

Tabela 7: Estimativas dos parâmetros – parte 2 ($\hat{\beta}_6$ a $\hat{\beta}_{10}$)

Modelo	$\hat{\beta}_6$	$\hat{\beta}_7$	$\hat{\beta}_8$	$\hat{\beta}_9$	$\hat{\beta}_{10}$
Treino	0,002572	0,002941	0,002548	0,9325	$-1,968 \times 10^{-5}$
Final (completo)	0,002074	0,002257	0,002455	0,9339	$-1,990 \times 10^{-5}$

8 Conclusão

Foram feitas as etapas devidas :

- Familiarização dos dados; Inconsistências não encontradas; Transformações feitas e documentadas.
- Seleção de variáveis (via método StepWise com critério AIC)
- Ajuste do modelo; Diagnóstico de resíduos (Passou pelo crivo); Há presença de outliers mas não tem pontos influentes; Testes indicam significância
- Validação do modelo feita com base de teste. MAPE = 0,16
- Reajuste do modelo com a base completa (as 1030 observações)

Discussão sobre o modelo: O modelo possui uma capacidade boa de generalização, já que as métricas $RMSE_{Treino}$ e $RMSE_{Teste}$ são próximas. Entretanto, o seu poder preditivo não é tão ideal, pois na validação o modelo obteve um MAPE = 0,16, indicando que erra em média 16% nas previsões. Para esse conjunto de dados, o modelo de regressão linear múltipla pode não ser a melhor escolha.

Referências

- [1] I-Cheng Yeh. *Concrete Compressive Strength Data Set*. UCI Machine Learning Repository, 2007. Disponível em: <https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength>.

Apêndice - Código em R

```
1 library(readxl)
2 library(GGally)
3 library(car)
4 library(lmtest)
5 library(nortest)
6 library(MASS)
7 library(leaps)
8 library(glmnet)
9 library(corrplot)
10 library(caret)
11 install.packages("caret")
12
13
14 dados_brutos <- read_excel("C:\\Users\\Marcella Cobra\\Documents
    \\Concrete_Data.xls")
15 colnames(dados_brutos) <- c("Cimento", "Escoria", "CinzaVolante", "
    Agua",
16                             "Superplastificante", "AgregadoGraudo
    ",
17                             "AgregadoMiudo", "Idade", "Resistencia
    ")
18
19 set.seed(20260521)
20
21 n_total <- nrow(dados_brutos)
22 n_treino <- round(0.70 * n_total)
23 idx_treino <- sample(1:n_total, size = n_treino)
24 dados_treino <- dados_brutos[ idx_treino, ]
25 dados_validacao <- dados_brutos[-idx_treino, ]
26 cat("\nTreino:", nrow(dados_treino), "| Valida o:", nrow(
    dados_validacao), "\n")
27
28 treino <- preparar(dados_treino)
29 validacao <- preparar(dados_validacao)
30
31
32 ### fun o que automatiza os testes
33 diagnostico <- function(mod, nome = "Modelo", dados_val, resp_
    val_orig,
```

```
34         transf = c("log", "sqrt", "nenhuma")) {
35     transf <- match.arg(transf)
36     cat("\n", rep("=", 60), "\n", sep = "")
37     cat("  DIAGNOSTICO:", nome, "\n")
38     cat(rep("=", 60), "\n", sep = "")
39
40     res <- residuals(mod)
41     ajus <- fitted(mod)
42     n <- length(res)
43     p <- length(coef(mod))
44
45     # 6a. Normalidade
46     sw <- shapiro.test(res)
47     ad <- ad.test(res)
48     cat("\n[Normalidade]\n")
49     cat("  Shapiro-Wilk   p =", round(sw$p.value, 4),
50         ifelse(sw$p.value > 0.05, "    OK", "    FALHA"), "\n")
51     cat("  Anderson-Darling p =", round(ad$p.value, 4),
52         ifelse(ad$p.value > 0.05, "    OK", "    FALHA"), "\n")
53
54     # 6b. Homocedasticidade
55     bp <- bptest(mod)
56     ncv <- ncvTest(mod)
57     cat("\n[Homocedasticidade]\n")
58     cat("  Breusch-Pagan   p =", round(bp$p.value, 4),
59         ifelse(bp$p.value > 0.05, "    OK", "    FALHA"), "\n")
60     cat("  NCV Test       p =", round(ncv$p, 4),
61         ifelse(ncv$p > 0.05, "    OK", "    FALHA"), "\n")
62
63     # 6c. Autocorrelação
64     dw <- dwtest(mod)
65     cat("\n[Autocorrelação]\n")
66     cat("  Durbin-Watson   p =", round(dw$p.value, 4),
67         ifelse(dw$p.value > 0.05, "    OK", "    FALHA"), "\n")
68
69     # 6d. Multicolinearidade
70     vifs <- vif(mod)
71     cat("\n[VIF      Multicolinearidade]\n")
72     print(round(vifs, 2))
73     if (any(vifs > 10)) cat("      VIF > 10 em algum preditor\n")
74     else cat("      Todos VIF      10\n")
```

```
75
76 # 6e. R ajustado
77 s <- summary(mod)
78 cat("\n[Ajuste no treino]\n")
79 cat(" R ajustado =", round(s$adj.r.squared, 4), "\n")
80
81 # 6f. MAPE na valida o
82 pred_transf <- predict(mod, newdata = dados_val)
83 if (transf == "log") {
84   pred_orig <- exp(pred_transf)
85 } else if (transf == "sqrt") {
86   pred_orig <- pred_transf^2
87 } else {
88   pred_orig <- pred_transf
89 }
90 mape <- mean(abs((resp_val_orig - pred_orig) / resp_val_orig))
91   * 100
92 cat("\n[Valida o MAPE]\n")
93 cat(" MAPE =", round(mape, 2), "%",
94     ifelse(mape < 15, " META ATINGIDA (<15%)", " Acima
95       de 15%"), "\n")
96
97 invisible(list(shapiro = sw, ad = ad, bp = bp, dw = dw,
98               vif = vifs, mape = mape, r2adj = s$adj.r.
99               squared))
100 }
101
102 preparar <- function(df) {
103   df$sqrtIdade <- sqrt(df$Idade)
104   df$logIdade <- log(df$Idade)
105   df$logCimento <- log(df$Cimento + 1)
106   df$logCinza <- log(df$CinzaVolante + 1) # zeros
107   poss veis +1
108   df$logSP <- log(df$Superplastificante + 1)
109   df$razaoAC <- df$Agua / df$Cimento
110   df$CimXIdade <- df$Cimento * df$Idade # intera o
111   df$CimXIdade2 <- (df$Cimento * df$Idade)^2 # intera o
112   df$sqrtResist <- sqrt(df$Resistencia) # alternativa
113   df
114 }
```

```
112
113 modL <- lm(sqrtResist ~ Cimento + Escoria + CinzaVolante + Agua
      +
114         Superplastificante + Idade + AgregadoGraudo +
          AgregadoMiudo +
115         logIdade + CimXIdade,
116         data = treino )
117
118 # Matriz de correla o (dados brutos)
119 library(corrplot)
120 vars_explicativas <- treino[, c("Cimento", "Escoria", "
      CinzaVolante", "Agua",
121                                "Superplastificante", "
                                AgregadoGraudo",
122                                "AgregadoMiudo", "Idade",
                                "logIdade", "CimXIdade")
                                ]
123
124 cor_matrix <- cor(vars_explicativas)
125 print("Matriz de Correla o:")
126 round(cor_matrix, 2)
127
128 # Visualizar matriz de correla o
129 corrplot(cor_matrix,
130         method = "color",
131         type = "upper",
132         addCoef.col = "white",
133         col = colorRampPalette(c("#2166AC", "white", "#B2182B")
                                )(200))
134
135 par(mfrow = c(4, 3))
136 plot(dados_treino$Cimento, dados_treino$Resistencia,
137     main = "Cimento", xlab = "Cimento (kg/m )", ylab = "
      Resist ncia (MPa)",
138     pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
139
140 plot(dados_treino$Escoria, dados_treino$Resistencia,
141     main = "Esc ria", xlab = "Esc ria (kg/m )", ylab = "",
142     pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
143
144 plot(dados_treino$CinzaVolante, dados_treino$Resistencia,
```



```
145     main = "Cinza Volante", xlab = "Cinza Volante (kg/m )",
146         ylab = "",
147         pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
148 plot(dados_treino$Agua, dados_treino$Resistencia,
149     main = " gua ", xlab = " gua (kg/m )", ylab = "
150         Resist ncia (MPa)",
151         pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
152 plot(dados_treino$Superplastificante, dados_treino$Resistencia,
153     main = "Superplastificante", xlab = "Superplast. (kg/m )",
154         ylab = "",
155         pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
156 plot(dados_treino$AgregadoGraudo, dados_treino$Resistencia,
157     main = "Agregado Gra do", xlab = "Ag. Gra do (kg/m )",
158         ylab = "",
159         pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
160 plot(dados_treino$AgregadoMiudo, dados_treino$Resistencia,
161     main = "Agregado Mi do", xlab = "Ag. Mi do (kg/m )",
162         ylab = "Resist ncia (MPa)",
163         pch = 16, col = rgb(0.2, 0.4, 0.8, 0.5), cex = 0.7)
164 plot(dados_treino$Idade, dados_treino$Resistencia,
165     main = "Idade (sem transforma o)", xlab = "Idade (dias)"
166         , ylab = "",
167         pch = 16, col = rgb(0.8, 0.2, 0.2, 0.5), cex = 0.7)
168 # curva completamente n o linear
169 plot(log(dados_treino$Idade), dados_treino$Resistencia,
170     main = "Idade (log)", xlab = "log(Idade)", ylab = "",
171         pch = 16, col = rgb(0.2, 0.8, 0.2, 0.5), cex = 0.7)
172 # Nota: Muito mais linear!
173
174 plot((treino$CimXIdade2), dados_treino$Resistencia,
175     main = "Cimento*Idade", xlab = "cimento * idade", ylab = ""
176         ,
177         pch = 16, col = rgb(0.2, 0.8, 0.2, 0.5), cex = 0.7)
178 par(mfrow = c(1, 1))
```

```
179
180 modL_step <- stepAIC(modL, direction = "both", trace = FALSE)
181 diag_L_step <- diagnostico(modL_step, "Modelo L",
182                             validacao, validacao$Resistencia, transf =
183                                 "sqrt")
184
185 library(lmtest)
186 residuos <- residuals(modL_step)
187 ajustados <- fitted(modL_step)
188
189 par(mfrow = c(2, 1))
190 plot(modL_step, which = 2)
191 plot(ajustados, residuos,
192      xlab = "Valores Ajustados", ylab = "Res duos",
193      main = "Res duos vs Ajustados")
194 abline(h = 0, col = "red")
195
196 par(mfrow = c(1, 1))
197 res_std <- rstandard(modL_step)
198 outliers_idx <- which(abs(res_std) > 3)
199 length(outliers_idx)
200 # ndices dos outliers:
201 outliers_idx
202
203 outliers_idx <- which(abs(res_std) > 3)
204 if(length(outliers_idx) > 0) {
205   cat("Poss veis outliers (res duo studentizado > |3|):",
206       outliers_idx, "\n")
207   print(dados_treino[outliers_idx, ])
208 } else {
209   cat("Nenhum outlier grave detectado.\n")
210 }
211
212 plot(fitted(modL_step), res_std,
213      xlab = "Valores ajustados", ylab = "Res duos studentizados",
214      main = "Res duos studentizados vs Ajustados")
215 abline(h = c(-3, 0, 3), lty = c(2,1,2), col = c("red","gray","red"))
```

```
216 h <- hatvalues(modL_step)
217 limiar_h <- 2 * length(coef(modL_step)) / nrow(treino) # 2p/n
218 plot(h, type = "h", col = ifelse(h > limiar_h, "red", "black"),
219      main = "Alavancagem (os Hii)", ylab = "h_ii")
220 abline(h = limiar_h, lty = 2, col = "blue")
221
222 sum(h > limiar_h)
223
224 n <- nrow(treino)
225 p <- length(coef(modL_step))
226
227 #D-COOK
228
229 #se eu remover essa observa o , o modelo inteiro muda muito?
230 # mede influencia global.
231 cooks_d <- cooks.distance(modL_step)
232 cook_limite_formal <- qf(0.5, df1 = p, df2 = n - p)
233 cook_influentes_formais <- which(cooks_d > cook_limite_formal)
234
235 # Limite de Cook Formal
236 round(cook_limite_formal, 6)
237
238 # N mero de pontos influentes
239 length(cook_influentes_formais)
240
241 # Nenhuma observa o apresentou distancia de Cook acima do
242 # limite formal,
243 # sugerindo ausencia de pontos altamente influentes no ajuste
244 # global
245 # da regress o.
246
247 # grafico
248 plot(cooks_d, type = "h", col = ifelse(cooks_d > cook_limite_
249      formal, "red", "black"),
250      main = "Dist ncia de Cook", ylab = "Cook's D")
251 abline(h = cook_limite_formal, lty = 2, col = "blue")
252
253 #mede impacto no fitted
254 dffits_vals <- dffits(modL_step)
255 dffits_limite <- 2 # amostras grandes
```

```
254 abs_dffits <- abs(dffits_vals)
255 n_dffits <- sum(abs_dffits > dffits_limite)
256 round(dffits_limite, 4)
257 n_dffits
258
259 plot(dffits_vals, type = "h", col = ifelse(abs(dffits_vals) >
      dffits_limite, "red", "black"),
260       main = "DFFITS")
261 abline(h = c(-dffits_limite, dffits_limite), lty = 2, col = "
      blue")
262 # Nenhuma observa o apresentou DFFITS acima do limite adotado
      ,
263 # indicando aus ncia de pontos com forte impacto nas
      predi es do modelo.
264
265 # DETEC O DE PONTOS INFLUENTES
266
267 #DFBETAS
268 #essa observa o altera muito algum coeficiente ?
269 dfbetas_vals <- dfbetas(modL_step)
270 dfbetas_limite <- 2/sqrt(n)
271
272 n_dfbetas_total <- sum(rowSums(abs(dfbetas_vals) > dfbetas_
      limite) > 0)
273 round(dfbetas_limite, 4)
274 n_dfbetas_total
275
276 # O crit rio DFBETAS identificou 128 observa es
      potencialmente
277 # influentes nos coeficientes.
278 #o limite 2/sqrt(n) torna-se bastante sens vel em
279 # amostras grandes, resultando na detec o de pequenas
      altera es
280 # locais nos coeficientes.
281 #o limite ficou 0.0745, qualquer observa o que altere um
      coeficiente em mais de
282 #0.074 desvios padr o ser marcada, muito sensivel.
283
284
285 # Testando com o crit rio alternativo DFBETAS >1
```

```
286 # essa observa o altera o coeficiente em mais de 1 erro
    padr o?
287 # crit rio complementar mais conservador.
288 dfbetas_limite2 <- 1
289 n_dfbetas_total2 <- sum(rowSums(abs(dfbetas_vals) > dfbetas_
    limite2) > 0)
290 round(dfbetas_limite2, 4)
291 n_dfbetas_total2
292 # Nenhuma observa o apresentou DFBETAS acima do limite
    adotado, nenhuma
293 #altera o coeficiente em mais de 1 erro padrao
294 summary(modL_step)
295 anova_tipo3 <- Anova(modL_step, type = "III")
296 print(anova_tipo3)
297
298 predicoes_trans<- predict(modL_step, newdata = validacao)
299 predicoes <- predicoes_trans^2
300 validacao$Pred_Resistencia <- predicoes
301
302 print(validacao[,c("Resistencia","Pred_Resistencia")], n = 15)
303
304 # erros
305 erro_teste <- validacao$Resistencia - validacao$Pred_Resistencia
306
307 # RMSE
308 RMSE_teste <- sqrt(mean(erro_teste^2))
309
310 # MAE
311 mae_teste <- mean(abs(erro_teste))
312
313 #MAPE
314 mape <- mean(abs(erro_teste) / validacao$Resistencia)
315
316 # R preditivo (correla o ao quadrado)
317 r2_pred <- cor(validacao$Resistencia, validacao$Pred_Resistencia
    )^2
318
319 # Exibir resultados
320 cat("RMSE_teste:", round(RMSE_teste, 4), "\n",
    "MAE_teste:", round(mae_teste, 4), "\n",
321 "MAPE:", round(mape,4), "\n",
```

```
323     "R    preditivo:", round(r2_pred, 4), "\n")
324
325 predicoes_treino_trans <- predict(modL_step, newdata = treino)
326
327 predicoes_treino <- predicoes_treino_trans^2
328
329 treino$Pred_Resistencia <- predicoes_treino
330 # erros
331 erro_treino <- treino$Resistencia - treino$Pred_Resistencia
332
333 # RMSE
334 rmse_treino <- sqrt(mean(erro_treino^2))
335
336 # MAE
337 mae_treino <- mean(abs(erro_treino))
338
339 # Exibir resultados
340 cat("RMSE_treino:", round(rmse_treino, 4), "\n",
341     "MAE_treino:", round(mae_treino, 4), "\n")
342 coef(modL_step)
343 dados_brutos <- preparar(dados_brutos)
344 modelo_final <- lm(sqrtResist ~ Cimento + Escoria + CinzaVolante
345     + Agua +
346         + Idade + AgregadoGraudo + AgregadoMiudo +
347         logIdade + CimXIdade,
348         data = dados_brutos )
349 coef(modelo_final)
```