

Trabalho/Atividade 5 em grupo de Regressão

Integrantes do Grupo:

- Matheus Brito
 - Marcella Cobra
 - Marcelo Huang
-

Enunciado: "Encontre um conjunto de dados com, no mínimo, 8 covariáveis. Ajuste um modelo de regressão nos seus dados. Use todas as etapas de análise. Escreva os resultados em um Relatório em PDF. Prepare uma apresentação do seu Relatório."

Conjunto de dados escolhido:

Resistência à compressão do Concreto vs. Idade + Componentes (disponível em [UC Irvine: Concrete Compressive Strength](#))

Etapa 0: Contextualizando

Nesta atividade, será realizada uma análise de um conjunto de dados dito na sala de aula, usando um modelo de regressão linear $Y = X\beta + \varepsilon$.

A partir desses dados, serão conduzidos: Diagnóstico/Análise de resíduos; Detecção de outliers e pontos influentes; Testes estatísticos; e validação do modelo.

Estamos interessados em como os componentes e a idade impacta na resistência à compressão do concreto

O conjunto de dados original é composto por 8 covariáveis e 1 variável resposta:

- X_1 : Cimento (quantitativa - kg/m^3)
 - X_2 : Escória (quantitativa - kg/m^3)
 - X_3 : Cinza Volante (quantitativa - kg/m^3)
 - X_4 : Água (quantitativa - kg/m^3)
 - X_5 : Superplastificante (quantitativa - kg/m^3)
 - X_6 : Agregado Graúdo (quantitativa - kg/m^3)
 - X_7 : Agregado Miúdo (quantitativa - kg/m^3)
 - X_8 : Idade = o tempo decorrido desde o momento em que a água entra em contato com o cimento (quantitativa - dia)
 - Y : Resistência a compressão (quantitativa - MPa)
-

Para validação do modelo, o conjunto de dados (total de 1030 observações) foi dividido aleatoriamente com semente 42 para reprodutibilidade em duas partes: teste (309 observações), treino (721 observações)

Nessa atividade, as análises serão realizadas no software **R**, utilizando funções da linguagem, nativas e/ou de pacotes externos

Etapa 1:

Pegar os dados brutos e começa a verificar inconveniências.

Nesse contexto seria verificar a consistência entre idade, experiência e escolaridade.

- Corrigir
- Transformar
- Remover

Todas ações feitas devem ser documentadas e justificadas.

1.1 Carregando os dados:

Dados do Experimento do treino

Cimento	Escoria	CinzaVolante	Agua	Superplastificante	AgregadoGraudo	AgregadoMiudo	Idade	Resistencia
220.80	147.20	0.00	185.70	0.00	1055.00	744.30	28	25.745034
249.10	0.00	98.75	158.11	12.80	987.76	889.01	14	28.682202
275.00	0.00	0.00	183.00	0.00	1088.00	808.00	7	14.203206
237.50	237.50	0.00	228.00	0.00	932.00	594.00	7	26.258004
139.60	209.40	0.00	192.00	0.00	1047.00	806.90	180	44.207822
277.19	97.82	24.46	160.70	11.19	1061.70	782.46	14	47.711739
...	...	...	...	...	...	...	...	...


(721 x 9)

1.2 Verificando inconsistências:

Não aparenta ter inconsistências nos dados, uma vez que os componentes de um concreto são manipuláveis/controláveis.

1.3 Análise gráfica para linearidade:

Este passo é um pouco desnecessário pois iríamos usar modelo de regressão linear de qualquer jeito.



1.4 Análise descritiva das covariáveis

Variável	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
Cimento	102.0	192.0	266.0	280.4	350.0	540.0
Escoria	0.00	0.00	42.08	78.34	145.00	359.40
CinzaVolante	0.00	0.00	0.00	52.71	118.27	200.00
Agua	121.8	164.9	185.7	181.8	193.0	246.9

Variável	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
Superplastificante	0.000	0.000	6.470	6.298	10.160	32.200
AgregadoGraudo	801.0	932.0	968.0	972.4	1028.4	1134.3
AgregadoMiudo	594.0	724.3	778.5	771.0	821.0	992.6
Idade	1.00	7.00	28.00	45.83	56.00	365.00
Resistencia	2.332	24.065	34.770	36.090	45.940	82.599

1.5 Conclusão da Etapa 1

- A base de treino tem 721 observações.
- Não aparenta ter inconsistências nos dados

Etapa 2:


Para a base da nossa análise, deve se verificar as seguintes coisas:

- Redução de dimensão das covariáveis (Parcimonia)
- Matriz de correlação
- Multicolinearidade, usando critério de VIF (Variance Inflation Factor) como medida
- Seleção de variáveis

*Qual o ponto dessa etapa? Preparar as covariáveis para o ajuste. *

Covariáveis IMPORTANTES/RELEVANTES

2.1 Corrplot das variáveis



A matriz de correlação não revela correlações muito fortes entre as variáveis preditoras (todas as correlações entre pares de preditores são menores que 0,7 em valor absoluto). Isso sugere **ausência de multicolinearidade** problemática, indicando que as covariáveis são aproximadamente linearmente independentes entre si. Porém, pode haver restrição estrutural nos dados: quando X_1 pode ser "reconstruído" por combinações de $X_2 + X_3 + X_4 \dots$.

2.2 Diagnóstico de multicolinearidade usando VIF (Variance Inflation Factor) como medida

Com o modelo full(completo) $Y = X\beta + \varepsilon$, pode-se calcular os VIF's

	Cimento	Escoria	CinzaVolante	Agua	Superplastificante	AgregadoGraudo	AgregadoMiudo	Idade	Resistencia
VIF	7.733	7.801	6.518	7.073	7.073	2.953	5.102	7.119	1.146

Os Valores do Fator de Inflação da Variância (VIF) são todos inferiores a 2. Esse resultado confirma a **ausência de multicolinearidade**; não há evidência de que alguma preditora seja combinação linear das demais.

2.3 Seleção de variáveis

- Stepwise (BIC): a saída em R fica do jeito abaixo

```
Resistencia ~ Cimento + Escoria + CinzaVolante + Agua + Idade
```

```
(Intercept): 34.5938 Cimento: 0.1113 Escoria: 0.0945 CinzaVolante: 0.0814 Agua: -0.2559 Idade: 0.1119
```

O método stepwise both com critério AIC partiu do modelo nulo e adicionou/removeu termos até encontrar o modelo com menor AIC. O modelo selecionado contém ****Escolaridade, Experiencia****. As variável Setor e Idade foram excluídas.

- Cp de Mallows:

Selection Algorithm: exhaustive

```


Cimento Escoria CinzaVolante Agua Superplastificante AgregadoGraudo
1 ( 1 ) "*" " " " " " " " " " "
2 ( 1 ) "*" " " " " " " "*" " " "
3 ( 1 ) "*" " " " " " " "*" " " "
4 ( 1 ) "*" "*" " " " "*" " " " "
5 ( 1 ) "*" "*" "*" " " "*" " " " "
6 ( 1 ) "*" "*" "*" " " "*" "*" " " "
7 ( 1 ) "*" "*" "*" " " "*" "*" "*" " "
8 ( 1 ) "*" "*" "*" " " "*" "*" "*" "*" "
...
5 ( 1 ) " " " "*"
6 ( 1 ) " " " "*"
7 ( 1 ) " " " "*"
8 ( 1 ) "*" " " "*"
.....

```

# de covariável	1	2	3	4	5	6	7	8
Cp de Mallows	723.826	500.483	271.826	114.138	13.184	9.307	10.798	9.000

O modelo com menor Cp é o de 8 variáveis, mas o de 6 (Resistencia ~ Cimento + Escoria + CinzaVolante + Agua + Superplastificante + Idade) é próximo também.

Seleção por Cp de Mallows (dados brutos)



- LASSO:

```
9 x 1 sparse Matrix of class "dgCMatrix"
      lambda.min
(Intercept) -26.91760181
Cimento      0.12112049
Escoria      0.10713827
CinzaVolante 0.09109392
Agua         -0.14727340
Superplastificante 0.29303701
AgregadoGraudo 0.01968407
AgregadoMiudo 0.02137302
Idade        0.11263026
```

O LASSO reteve todas as covariáveis, e atribui valores baixos de λ para AgregadoGraudo e AgregadoMiudo.

Então pelas resultados de Step(BIC) e Cp de Mallows e parcimônia, o modelo terá 6 covariáveis (Resistencia ~ Cimento + Escoria + CinzaVolante + Agua + Superplastificante + Idade).

2.4 Conclusão da Etapa 2

- A Matriz de Correlação não mostrou correlações elevadas entre preditoras, mas com o modelo full (completo) alguns valores de VIFs são razoavelmente elevados sugere um certo nível de multicolinearidade.
 - Na seleção de variáveis, o método Stepwise(BIC) reteve Cimento, Escoria, CinzaVolante, Agua, e Idade; o Cp de Mallows reteve as mesmas covariáveis mais a covariável Superplastificante .
 - Em respeito aos métodos usados (Stepwise, Cp e LASSO), selecionamos para a etapa seguinte **o modelo com Resistencia ~ Cimento + Escoria + CinzaVolante + Agua + Superplastificante + Idade."**
-