

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Estatística

Relatório - Atividade 4- Análise de Regressão

Matheus Brito 812048
Marcela Cobra Moraes 813147
Marcelo Huang 832111

Maio, 2026

1 Introdução

O concreto é um dos materiais de construção mais utilizados no mundo, e sua resistência à compressão é uma propriedade fundamental para o dimensionamento estrutural. Essa resistência depende de múltiplos fatores, como a proporção dos componentes da mistura e o tempo de cura (idade). Compreender quantitativamente essas relações é essencial tanto para a engenharia prática quanto para o controle de qualidade.

Este trabalho utiliza o conjunto de dados de resistência à compressão do concreto disponibilizado no repositório UCI Machine Learning [1], composto por 1030 observações experimentais. O banco de dados registra a resistência à compressão (em MPa) em função de oito variáveis relacionadas à composição da mistura e à idade do concreto.

2 Objetivo

O objetivo deste trabalho é ajustar um modelo de regressão linear múltipla para explicar e prever a resistência à compressão do concreto a partir das variáveis disponíveis, avaliando a adequação do modelo, a significância dos preditores e sua capacidade preditiva em dados novos.

3 Análise Descritiva

3.1 Dados e variáveis

O modelo considerado é da forma:

$$Y = X\beta + \varepsilon,$$

onde Y é a resistência à compressão (MPa) e as covariáveis são:

- X_1 : Cimento (kg/m^3)
- X_2 : Escória (kg/m^3)
- X_3 : Cinza Volante (kg/m^3)
- X_4 : Água (kg/m^3)
- X_5 : Superplastificante (kg/m^3)
- X_6 : Agregado Graúdo (kg/m^3)
- X_7 : Agregado Miúdo (kg/m^3)

- X_8 : Idade (dias)

Para validação, realizou-se uma divisão aleatória (semente 42) em conjunto de treino (721 observações, 70%) e teste (309 observações, 30%). Todas as análises foram executadas no software R.

3.2 Estatísticas descritivas

A Tabela 1 resume as principais estatísticas das variáveis no conjunto de treino.

Tabela 1: Estatísticas descritivas das variáveis (treino)

Variável	Mín.	1º Quart.	Mediana	Média	3º Quart.	Máx.
Cimento	102.0	192.0	266.0	280.4	350.0	540.0
Escória	0.00	0.00	42.08	78.34	145.00	359.40
Cinza Volante	0.00	0.00	0.00	52.71	118.27	200.00
Água	121.8	164.9	185.7	181.8	193.0	246.9
Superplastificante	0.000	0.000	6.470	6.298	10.160	32.200
Agr. Graúdo	801.0	932.0	968.0	972.4	1028.4	1134.3
Agr. Miúdo	594.0	724.3	778.5	771.0	821.0	992.6
Idade	1.00	7.00	28.00	45.83	56.00	365.00
Resistência	2.332	24.065	34.770	36.090	45.940	82.599

3.3 Gráfico de dispersão

A Figura 1 mostra a relação entre cada covariável e a variável resposta. Não há evidências graves de não linearidade.




Figura 1: Gráfico de dispersão das covariáveis versus resistência à compressão

3.4 Matriz de correlação e multicolinearidade

A Figura 2 apresenta o *corrplot* das variáveis. As correlações entre preditoras são geralmente baixas ($|\rho| < 0,7$), sugerindo ausência de multicolinearidade severa.




Figura 2: Corrplot das variáveis numéricas

Os valores do Fator de Inflação da Variância (VIF) para o modelo completo são apresentados na Tabela 2. Todos são inferiores a 10, indicando ausência de multicolinearidade problemática, mas alguns são superiores a 5, iremos investigar.

Tabela 2: VIF do modelo completo (8 variáveis)

Cimento	Escória	CinzaVol.	Água	Superplast.	Agr.Graúdo	Agr.Miúdo	Idade
7.733	7.801	6.518	7.073	7.073	2.953	5.102	7.119

4 Modelo

4.1 Seleção de variáveis

Foram aplicados três métodos de seleção de variáveis:

- **Stepwise (BIC)**: selecionou o modelo com $\text{Resistencia} \sim \text{Cimento} + \text{Escoria} + \text{CinzaVolante} + \text{Agua} + \text{Idade}$.
- **Cp de Mallows**: Como podemos ver na Tabela 3 o modelo com menor Cp é o completo (8 variáveis), porém o modelo com 6 variáveis (incluiu Superplastificante, comparando com Stepwise) apresentou Cp próximo (9,307).

Tabela 3: Cp de Mallows

# de covariável	1	2	3	4	5	6	7	8
Cp de Mallows	723.826	500.483	271.826	114.138	13.184	9.307	10.798	9.000

- **LASSO**: reteve todas as variáveis, com coeficientes muito pequenos para os agregados.

Considerando parcimônia e consistência entre os métodos, optou-se pelo modelo com 6 covariáveis:

$\text{Resistencia} \sim \text{Cimento} + \text{Escoria} + \text{CinzaVolante} + \text{Agua} + \text{Superplastificante} + \text{Idade}$.

4.2 Ajuste do modelo

O modelo foi ajustado (por mínimos quadrados) conforme a seleção realizada na Etapa 2:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \varepsilon.$$

Resumo do modelo ajustado será apresentado posteriormente.

Call:

```
lm(formula = Resistencia ~ Cimento + Escoria + CinzaVolante +
    Agua + Superplastificante + Idade, data = dados_treino)
```

Residuals:

Min	1Q	Median	3Q	Max
-29.277	-6.316	0.273	6.450	34.538

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	28.885497	4.935315	5.853	7.37e-09 ***

Cimento	0.106108	0.005244	20.232	< 2e-16	***
Escoria	0.088490	0.005836	15.163	< 2e-16	***
CinzaVolante	0.070523	0.009198	7.667	5.76e-14	***
Agua	-0.218949	0.024562	-8.914	< 2e-16	***
Superplastificante	0.238821	0.098670	2.420	0.0158	*
Idade	0.111404	0.006350	17.544	< 2e-16	***

Residual standard error: 10.3 on 714 degrees of freedom

Multiple R-squared: 0.6294, Adjusted R-squared: 0.6263

F-statistic: 202.1 on 6 and 714 DF, p-value: < 2.2e-16

4.3 Diagnóstico de resíduos

4.3.1 Independência

Como não temos a ordem da coleta, assume-se a independência.

(Claro, supondo que o índice dos dados sejam a ordem, podemos fazer um teste de Durbin-Watson. O teste de Durbin-Watson resultou em $DW = 2,0125$ ($p = 0,5691$), indicando independência dos resíduos.)

4.3.2 Normalidade

O teste de Shapiro-Wilk ($W = 0,99671$, $p = 0,1453$) não rejeita a hipótese de normalidade dos resíduos.

4.3.3 Homocedasticidade

O teste de Breusch-Pagan ($BP = 104,01$, $p < 2,2 \times 10^{-16}$) rejeita a homocedasticidade. A Figura 9 mostra o QQ-plot e o gráfico de resíduos versus valores ajustados, onde se observa um leve padrão de funil.




Figura 3: QQ-plot e resíduos vs valores ajustados

Tentativas de transformação (log, raiz, quadrado, inverso) não resolveram a heterocedasticidade. Um modelo mais complexo com $\sqrt{Y} \sim \text{Cimento} + \text{Escoria} + \text{CinzaVolante} + \frac{\text{Agua}}{\text{Cimento}} + \text{Superplastificante} + \log(\text{Idade}) + (\log(\text{Idade}))^2 + \frac{\text{Cimento}}{\text{Idade}}$ atendeu aos pressupostos, mas por parcimônia manteve-se o modelo linear original.

4.4 Pontos influentes

- **Resíduo studentizado:** apenas uma observação com $|r_i| > 3$ (observação 219).
- **Alavancagem (h_{ii}):** 57 pontos acima de $2p/n$, mas nenhum acima do critério alternativo $(1/2)$.
- **Distância de Cook:** nenhum ponto acima do limiar $F_{p, n-p, 0.5}$.
- **DFFITS:** nenhum ponto acima do limite.
- **DFBETAS:** com critério $2/\sqrt{n}$ detectaram-se 143 pontos; com critério $|\text{DFBETAS}| > 1$ nenhum ponto influente.

As Figuras 4–7 ilustram essas medidas.





Figura 4: Resíduos studentizados

Figura 5: Alavancagem (h_{ii}) ordenada




Figura 6: Distância de Cook




Figura 7: DFFITS

4.5 Estimativas dos parâmetros e Testes de significância formais

Sumário do modelo

A seguir, o resumo do modelo ajustado no R:

Call:

```
lm(formula = Resistencia ~ Cimento + Escoria + CinzaVolante +  
    Agua + Superplastificante + Idade, data = dados_treino)
```

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

-29.277 -6.316 0.273 6.450 34.538

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	28.885497	4.935315	5.853	7.37e-09 ***
Cimento	0.106108	0.005244	20.232	< 2e-16 ***
Escoria	0.088490	0.005836	15.163	< 2e-16 ***
CinzaVolante	0.070523	0.009198	7.667	5.76e-14 ***
Agua	-0.218949	0.024562	-8.914	< 2e-16 ***
Superplastificante	0.238821	0.098670	2.420	0.0158 *
Idade	0.111404	0.006350	17.544	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.3 on 714 degrees of freedom

Multiple R-squared: 0.6294, Adjusted R-squared: 0.6263

F-statistic: 202.1 on 6 and 714 DF, p-value: < 2.2e-16

- Coeficientes estimados: $\hat{\beta}_0 = 28.88$, $\hat{\beta}_1 = 0.10$, $\hat{\beta}_2 = 0.09$, $\hat{\beta}_3 = 0.07$, $\hat{\beta}_4 = -0.21$, $\hat{\beta}_5 = 0.24$, $\hat{\beta}_6 = 0.11$.

Interpretação:

β_0 : Não tem interpretação para β_0 pois aparentemente 0 não está no range das covariáveis (se não tem componentes, não tem concreto, consequentemente não tem resistência à compressão).

$\hat{\beta}_1$: Para cada kg de Cimento adicional em 1 m^3 de concreto, estima-se um aumento de 4% em média na resistência do concreto, mantendo as outras covariáveis fixas;

A mesma interpretação pode ser feita com $\hat{\beta}_2$, $\hat{\beta}_3$, $\hat{\beta}_4$, $\hat{\beta}_5$, uma vez que são componentes do concreto também.

$\hat{\beta}_6$: Para cada dia adicional na Idade do concreto (range = [1, 180]), estima-se um aumento de 11% em média na resistência do concreto, mantendo as outras covariáveis fixas;

Teste F parcial (Tipo III)

A tabela ANOVA a seguir apresenta a contribuição individual de cada covariável controlando pelas demais:

Anova Table (Type III tests)

Response: Resistencia

	Sum Sq	Df	F value	Pr(>F)	
(Intercept)	3634	1	34.2555	7.366e-09	***
Cimento	43427	1	409.3525	< 2.2e-16	***
Escoria	24392	1	229.9290	< 2.2e-16	***
CinzaVolante	6236	1	58.7851	5.762e-14	***
Agua	8430	1	79.4597	< 2.2e-16	***
Superplastificante	621	1	5.8584	0.01575	*
Idade	32653	1	307.7967	< 2.2e-16	***
Residuals	75746	714			

4.6 Significância dos coeficientes

As covariáveis são globalmente significativas: o valor-p do teste F global é menor que $2,2 \times 10^{-16}$, rejeitando $H_0 : \beta_1 = \dots = \beta_6 = 0$. Individualmente, todas as variáveis são significativas ao nível de 5%. As variáveis com maior estatística F são Cimento ($F = 409,35$), Idade ($F = 307,80$) e Escória ($F = 229,93$). O Superplastificante apresenta significância marginal ($F = 5,86$, $p = 0,0158$), indicando contribuição menor, porém ainda relevante.

5 Discussão dos Resultados

5.1 Validação preditiva

O modelo ajustado foi aplicado ao conjunto de teste (309 observações). As métricas obtidas foram:

- RMSE = 10,6676
- MAE = 8,6598
- MAPE = 0,3324 (33,24%)
- R^2 preditivo = 0,5745

A Tabela 4 exibe as primeiras previsões no conjunto de teste.

Tabela 4: Valores observados e previstos (primeiras linhas do conjunto de teste)

Índice	Resistência real	Predição
1	44,3	59,7
2	47,0	27,3
3	47,8	21,1
4	39,4	30,2
5	37,4	31,6

A validação cruzada com 5 partições, aplicada aos 1030 dados originais, resultou em:

- RMSE médio = 10,4689
- R^2 médio = 0,6070
- MAE médio = 8,3318

Os resultados da validação cruzada são consistentes com os do conjunto de teste, indicando ausência de *overfitting*.

6 Transformações

Por tentativa e erro, temos as seguintes transformações notáveis:

- **1:** Resistencia = $\beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \text{Agua} + \beta_5 \log(\text{Superplastificante} + 1) + \beta_6 \log(\text{Idade}) + \varepsilon$. Métricas:

MAPE: 0.1862 e R^2 preditivo: 0.8287

- **2(que satisfaz os pressupostos):** $\sqrt{\text{Resistencia}} = \beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \text{Agua} + \beta_5 \frac{\text{Agua}}{\text{Cimento}} + \beta_6 \text{Superplastificante} + \beta_7 \text{AgregadoGraudo} + \beta_8 \text{AgregadoMiudo} + \beta_9 (\text{Idade}) + \beta_{10} (\log \text{Idade}) + \beta_{11} (\log \text{Idade})^2 + \beta_{12} \frac{\text{Cimento}}{\text{Idade}} + \varepsilon$

Métricas: MAPE: 0.1687 e R^2 preditivo: 0.843

- **3:** $\log(\text{Resistência}) = \beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \frac{\text{Agua}}{\text{Cimento}} + \beta_5 \text{Superplastificante} + \beta_6 \text{Superplastificante}^2 + \beta_7 \text{AgregadoGraudo} + \beta_8 \text{AgregadoMiudo} + \beta_9 \log(\text{Idade}) + \beta_{10} (\log \text{Idade}) * \text{Cimento} + \varepsilon$

Métricas: MAPE: 0.1781 e R^2 preditivo: 0.7912

6.1 Investigando o modelo melhor(2):

O modelo transformado $\sqrt{\text{Resistencia}} = \beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \text{Agua} + \beta_5 \frac{\text{Agua}}{\text{Cimento}} + \beta_6 \text{Superplastificante} + \beta_7 \text{AgregadoGraudo} + \beta_8 \text{AgregadoMiudo} + \beta_9 (\text{Idade}) + \beta_{10} (\log \text{Idade}) + \beta_{11} (\log \text{Idade})^2 + \beta_{12} \frac{\text{Cimento}}{\text{Idade}} + \varepsilon$

apresenta os seguintes pontos notáveis:

Atende os pressupostos; Não apresenta pontos influentes (DCook e DFFits); Rejeitou a hipótese nula do teste F global; Rejeitou H_0 nos teste t e testes F-Parcial(type III), menos para as covariáveis Agua, Superplastificante e $\log(\text{Idade})^2$




Figura 8: Q-Q-plot e resíduos vs valores ajustados




Figura 9: Distancia de Cook e DFFits

- Coeficientes estimados:

$$\begin{aligned}\hat{\beta}_0 &= -2.9512513, \hat{\beta}_1 = 0.0114770, \hat{\beta}_2 = 0.0094468, \hat{\beta}_3 = 0.0075879, \hat{\beta}_4 = -0.0062324, \\ \hat{\beta}_5 &= -1.0606740, \hat{\beta}_6 = 0.0090825, \hat{\beta}_7 = 0.0018889, \hat{\beta}_8 = 0.0021576, \hat{\beta}_9 = -0.0030991, \\ \hat{\beta}_{10} &= 1.2055903, \hat{\beta}_{11} = -0.0039348, \hat{\beta}_{12} = -0.0009444\end{aligned}$$

Como o modelo utiliza transformações e termos não lineares, a interpretação dos coeficientes não é mais a mesma, e deve ser feita com cautela, principalmente para os termos envolvendo logaritmos, razões e interações.

7 Conclusão

O modelo de regressão linear múltipla ajustado com seis covariáveis (Cimento, Escória, Cinza Volante, Água, Superplastificante e Idade) mostrou-se estatisticamente mediano para explicar a resistência à compressão do concreto, com R^2 ajustado de 62,63% no conjunto de treino. Todas as covariáveis selecionadas são significativas ao nível de 5%, com destaque para Cimento e Idade como os preditores de maior influência.

O pressuposto de homocedasticidade foi violado, indicando limitação do modelo linear simples para capturar a variabilidade dos dados, estamos cientes disso e temos uma transformação que atende os pressupostos. Pelo objetivo pedagógico, o modelo original é mantido. Não foram identificados pontos influentes que comprometam o ajuste. O modelo não apresenta capacidade preditiva promissora (RMSE $\approx$ 10,5 MPa, MAPE = 0,3324 (33,24%), R^2 preditivo $\approx$ 0,57), já que em média as previsões se desviam aproximadamente 33% do valor real.

O modelo com transformação apresenta um desempenho melhor, porém ainda possui um MAPE alto de 17%.

Para trabalhos futuros, recomenda-se explorar mais transformações da variável resposta, inclusão de termos quadráticos ou de interação, e modelos alternativos como regressão não linear ou métodos de aprendizado de máquina, conforme sugerido pelos autores originais do conjunto de dados.

Referências

- [1] I-Cheng Yeh. *Concrete Compressive Strength Data Set*. UCI Machine Learning Repository, 2007. Disponível em: <https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength>.

Apêndice - Código em R

```
1 library(readxl)
2 library(GGally)
3 library(car)
4 library(lmtest)
5 library(nortest)
6 library(MASS)
7 library(leaps)
8 library(glmnet)
9 library(corrplot)
10 library(caret)
11 install.packages("caret")
12
13
14 dados_brutos <- read_excel("C:\\Users\\Marcella Cobra\\Documents
    \\Concrete_Data.xls")
15 colnames(dados_brutos) <- c("Cimento", "Escoria", "CinzaVolante", "
    Agua",
16                             "Superplastificante", "AgregadoGraudo
    ",
17                             "AgregadoMiudo", "Idade", "Resistencia
    ")
18
19 # Dividindo os dados em 70/30 para valida o
20 set.seed(42)
21 n_total <- nrow(dados_brutos)
22 n_treino <- round(0.70 * n_total)
23
24 idx_treino <- sample(1:n_total, size = n_treino)
25 dados_treino <- dados_brutos[idx_treino, ]
26 dados_validacao <- dados_brutos[-idx_treino, ]
27
28 n_total
29 nrow(dados_treino)
30 nrow(dados_validacao)
31
32
33 # ETAPA 1 resumida
34
35 str(dados_treino)
```

```
36
37 #Dados faltantes por coluna:
38 colSums(is.na(dados_treino))
39
40 summary(dados_treino)
41
42 #
43     #####
44
45 # ETAPA 2: Seleção de variáveis
46
47 # Matriz de correlação (dados brutos)
48 vars_explicativas <- dados_treino[, c("Cimento", "Escoria", "
49     CinzaVolante", "Agua",
50     "Superplastificante", "
51     AgregadoGraudo",
52     "AgregadoMiudo", "Idade",
53     "Resistencia")]
54
55 cor_matrix <- cor(vars_explicativas)
56 print("Matriz de Correlação:")
57 round(cor_matrix, 2)
58
59 # Visualizar matriz de correlação
60 corplot(cor_matrix,
61     method = "color",
62     type = "upper",
63     addCoef.col = "white",
64     col = colorRampPalette(c("#2166AC", "white", "#B2182B")
65     )(200))
66
67 # Nenhuma correlação > 0.7 entre preditores, não indica
68     multicolinearidade, por m
69 # pode haver restrição estrutural nos dados:
70 # quando X1 pode ser "reconstruído" por combinações de X2 +
71     X3 + X4...
72
73 # Modelo completo (base com dados brutos)
74 modelo_completo <- lm(Resistencia ~ Cimento + Escoria +
75     CinzaVolante +
```



```
68         Agua + Superplastificante +
69         AgregadoGraudo +
70         AgregadoMiudo + Idade,
71         data = dados_treino)
72 round(coef(modelo_completo), 4)
73
74
75 # Seleção por Cp de mallows
76 reg_sub <- regsubsets(Resistencia ~ Cimento + Escoria +
77     CinzaVolante +
78     Agua + Superplastificante +
79     AgregadoGraudo +
80     AgregadoMiudo + Idade,
81     data = dados_treino, nbest = 1, nvmax = 8)
82
83 resumo_sub <- summary(reg_sub)
84
85 tabela_mallows <- data.frame(
86     "n_vars" = 1:8,
87     "Cp" = round(resumo_sub$cp, 3),
88     "R2" = round(resumo_sub$rsq, 4),
89     "R2_adj" = round(resumo_sub$adjr2, 4),
90     "BIC" = round(resumo_sub$bic, 2)
91 )
92
93 # Seleção por Cp de Mallows
94 tabela_mallows
95
96 # Gráfico Cp
97 par(mar = c(4, 4, 3, 1))
98 plot(1:8, resumo_sub$cp, type = "b", pch = 16, cex = 1.2,
99     xlab = "Número de variáveis", ylab = "Cp de Mallows",
100     main = "Seleção por Cp de Mallows (dados brutos)", col =
101         "steelblue", lwd = 2)
102 abline(a = 1, b = 1, col = "red", lty = 2, lwd = 2)
103 abline(h = 9, col = "orange", lty = 3, lwd = 1.5)
104 legend("topright", c("Cp observado", "Reta ideal (Cp = p+1)"),
105     col = c("steelblue", "red"), lty = c(1, 2), pch = c(16,
106         NA))
```

```
104
105 # Sele o por AIC (Stepwise)
106 modelo_step_AIC <- stepAIC(modelo_completo, direction = "both",
107   trace = FALSE)
108 #Modelo selecionado por AIC:
109 formula(modelo_step_AIC)
110 round(coef(modelo_step_AIC), 4)
111
112 # Sele o por BIC (Stepwise)
113 modelo_step_BIC <- stepAIC(modelo_completo, direction = "both",
114   k = log(nrow(dados_treino)), trace =
115     FALSE)
116 # Modelo selecionado por BIC:")
117 formula(modelo_step_BIC)
118 round(coef(modelo_step_BIC), 4)
119
120 # Sele o por Lasso
121 X_mat <- model.matrix(Resistencia ~ Cimento + Escoria +
122   CinzaVolante +
123     Agua + Superplastificante +
124     AgregadoGraudo +
125     AgregadoMiudo + Idade,
126   data = dados_treino)[, -1]
127
128 y_vec <- dados_treino$Resistencia
129 set.seed(42)
130 cv_lasso <- cv.glmnet(X_mat, y_vec, alpha = 1)
131
132 plot(cv_lasso, main = "Lasso: Valida o Cruzada para sele o
133   de (dados brutos)")
134
135 coef_lasso_min <- coef(cv_lasso, s = "lambda.min")
136 vars_lasso <- names(which(coef_lasso_min[-1, 1] != 0))
137 # Vari veis selecionadas por Lasso:
138 vars_lasso
139
140 # Vemos que, com base no m todo do CP-Mallows e Stepwise BIC eu
141   deveria escolher
```

```
138 # entre 5 a 6 variaveis, o ganho em R^2 n o justifica adicionar
      2 ou 3 vari veis
139 # (de 0.626 para 0.631) como mostra no teste Lasso e AIC
140 # Para seguir com um meio termo, continuaremos com o modelo
      usando 6 variaveis
141
142 resumo_sub$which[6, ]
143
144
145
146 #
      #####
147 # ETAPA 3: Ajuste, diagnosticos e Teste
148
149
150
151 modelo_final <- lm(Resistencia ~ Cimento + Escoria +
      CinzaVolante +
152                      Agua + Superplastificante + Idade,
153                      data = dados_treino)
154
155 summary(modelo_final)
156
157 coef_modelo <- coef(modelo_final)
158
159 round(coef_modelo, 4)
160
161 # Interpreta o do R2
162 r2_modelo <- summary(modelo_final)$r.squared
163 r2_adj_modelo <- summary(modelo_final)$adj.r.squared
164 r2 <- round(r2_modelo, 4)
165 r2_ajus <- round(r2_adj_modelo, 4)
166 r2
167 r2_ajus
168
169
170 # Diagn stico gr fico
171 par(mfrow = c(2, 2))
172 plot(modelo_final)
173 par(mfrow = c(1, 1))
```

```
174 # indicativo de heterocedasticidade com afunilamento no grafico
    Residuals vs Fitted
175 # Indicio de normalidade atrav s do QQplot, respeitando bem a
    linha
176
177 # Testes formais:
178 # Normalidade: Anderson-Darling
179 ad_test <- ad.test(residuals(modelo_final))
180 ad_test
181
182
183 # Homocedasticidade: Breusch-Pagan
184 bp_test <- bptest(modelo_final)
185 bp_test
186 #nao aceitou hipotese nula de homocedasticidade
187
188
189 # Independ ncia: Durbin-Watson
190 dw_test <- dwtest(modelo_final)
191 dw_test
192 # sem autoceorrela o aparente
193
194
195 # Multicolinearidade: VIF
196 vif_values <- vif(modelo_final)
197 # Todos abaixo de 5, nao indicando multicolinearidade
198
199 round(vif_values, 3)
200
201 # Res duos n o s o perfeitamente normais
202 # heterocedasticidade detectada
203 # Sem autocorrela o detectada
204 # Sem multicolinearidade problem tica
205
206
207 #
    #####
208 #Teste F Global
209
210 sumario <- summary(modelo_final)
```

```

211 f_stat_global <- sumario$fstatistic[1]
212 f_pvalue_global <- pf(f_stat_global, sumario$fstatistic[2],
    sumario$fstatistic[3], lower.tail = FALSE)
213
214 #F-statistic:
215 round(f_stat_global, 4)
216 #gl numerador:
217 sumario$fstatistic[2]
218 #gl denominador:
219 sumario$fstatistic[3]
220 #p-value:
221 format(f_pvalue_global, scientific = TRUE)
222 # Interpreta o: Modelo significativo globalmente (rejeita
    H0: todos =0)")
223
224 #
    #####
225 # Teste F Parcial
226 anova_tipo3 <- Anova(modelo_final, type = "III")
227 print(anova_tipo3)
228
229 #Cada linha testa a contribui o de UMA vari vel controlando
    por TODAS as outras
230 #Todos os coeficientes s o estatisticamente significativos ao
    n vel de 5%
231 #s o as vari veis mais importantes, seguidas por Esc ria
232 #(F = 229.93) e gua (F = 79.46). Superplastificante apresenta
233 #signific ncia marginal (F = 5.86, p = 0.0158), indicando
234 #contribui o menor mas ainda relevante ao modelo.
235
236 #
    #####
237 # Detec o de outliers
238 res_std <- rstandard(modelo_final)
239 outliers_idx <- which(abs(res_std) > 3)
240 length(outliers_idx)
241 # ndices dos outliers:
242 outliers_idx
243

```

```
244
245
246
247
248 #
      #####
249 # Hii (Hat Values)
250 n <- nrow(dados_treino)
251 p <- length(coef(modelo_final))
252
253 leverage <- hatvalues(modelo_final)
254 limiar_leverage <- 2 * p / n #existe tambem o limiar de hii
      >0.5, com ele mostra 0 outliers
255
256 high_leverage <- which(leverage > limiar_leverage)
257
258 # Limiar usado:
259 round(limiar_leverage, 4)
260 # N mero de pontos com alto leverage:
261 length(high_leverage)
262
263 #
      #####
264 #DFBETAS
265 dfbetas_vals <- dfbetas(modelo_final)
266 dfbetas_limite <- 2/sqrt(n) # geral, se for amostra pequena/
      moderada = 1
267
268 n_dfbetas_total <- sum(rowSums(abs(dfbetas_vals) > dfbetas_
      limite) > 0)
269 round(dfbetas_limite, 4)
270 n_dfbetas_total
271
272 #
      #####
273 # DFFITS
274 dffits_vals <- dffits(modelo_final)
```

```
275 dffits_limite <- 2 # amostras grandes, seria 1 se fosse
    moderada ou pequena
276
277 abs_dffits <- abs(dffits_vals)
278 n_dffits <- sum(abs_dffits > dffits_limite)
279 round(dffits_limite, 4)
280 n_dffits
281
282
283
284 #####
285 cooks_d <- cooks.distance(modelo_final)
286
287
288 cook_limite_formal <- qf(0.5, df1 = p, df2 = n - p)
289
290 cook_influentes_formais <- which(cooks_d > cook_limite_formal)
291
292 # Limite de Cook Formal
293 round(cook_limite_formal, 6)
294
295 # N mero de pontos influentes
296 length(cook_influentes_formais)
297
298 #
    #####
299 # ETAPA 4: Valida o do Modelo - LOOCV, K-Fold e Treino/Teste
300 #
    #####
301
302
303
304 # Função auxiliar para calcular as métricas
305 calcular_metricas <- function(real, predito, metodo = "") {
306   rmse <- sqrt(mean((real - predito)^2))
307   mae <- mean(abs(real - predito))
308   mape <- mean(abs((real - predito) / real)) * 100
309
310   cat(sprintf("\n--- %s ---\n", metodo))
```

```
311   cat(sprintf("  RMSE : %.4f\n", rmse))
312   cat(sprintf("  MAE  : %.4f\n", mae))
313   cat(sprintf("  MAPE : %.2f%%\n", mape))
314
315   return(data.frame(Metodo = metodo, RMSE = round(rmse, 4),
316                   MAE = round(mae, 4), MAPE = round(mape, 4)))
317 }
318
319 resultados <- list()
320
321 #
322   -----
323 # 1. LOOCV (Leave-One-Out Cross-Validation)
324 #
325   -----
326 ctrl_loocv <- trainControl(method = "LOOCV")
327
328 modelo_loocv <- train(
329   Resistencia ~ Cimento + Escoria + CinzaVolante + Agua +
330     Superplastificante + Idade,
331   data      = dados_treino,
332   method    = "lm",
333   trControl = ctrl_loocv
334 )
335
336 pred_loocv <- modelo_loocv$pred # predi es fora da amostra
337
338 resultados$loocv <- calcular_metricas(
339   real      = pred_loocv$obs,
340   predito   = pred_loocv$pred,
341   metodo    = "LOOCV"
342 )
343 #
344   -----
345 # 2. K-Fold Cross-Validation (k = 5)
346 #
347   -----
```



```
344 set.seed(42)
345 ctrl_kfold <- trainControl(method = "cv", number = 5,
    savePredictions = "final")
346
347 modelo_kfold <- train(
348   Resistencia ~ Cimento + Escoria + CinzaVolante + Agua +
    Superplastificante + Idade,
349   data      = dados_treino,
350   method    = "lm",
351   trControl = ctrl_kfold
352 )
353
354 pred_kfold <- modelo_kfold$pred
355
356 resultados$kfold <- calcular_metricas(
357   real      = pred_kfold$obs,
358   predito   = pred_kfold$pred,
359   metodo    = "K-Fold (k=5)"
360 )
361
362 #
    -----
363 # 3. Valida o Treino/Teste (70%/30%) usando dados_
    validacao j separado
364 #
    -----
365 pred_teste <- predict(modelo_final, newdata = dados_validacao)
366
367 resultados$treino_teste <- calcular_metricas(
368   real      = dados_validacao$Resistencia,
369   predito   = pred_teste,
370   metodo    = "Treino/Teste (70/30)"
371 )
372
373 #
    -----
374 # Tabela comparativa final
```

```
375 #
376
377
378
379
380
381
382
383
384
385
386
387
388
389
390
391
392
393
394
395
396
397
398
399
400
401
402
403
404
405
406
407
```

```
-----

tabela_final <- do.call(rbind, resultados)
rownames(tabela_final) <- NULL

cat("\n===== \n")
cat("      TABELA COMPARATIVA DE METRICAS      \n")
cat("===== \n")
print(tabela_final)

# transforma es ao conjunto de treino
dados_treino$log_Idade <- log(dados_treino$Idade)
dados_treino$log1p_Superplast <- log1p(dados_treino$
  Superplastificante)
# transforma es ao conjunto de valida o
dados_validacao$log_Idade <- log(dados_validacao$Idade)
dados_validacao$log1p_Superplast <- log1p(dados_validacao$
  Superplastificante)

modelo_t1 <- lm(Resistencia ~ Cimento + Escoria + CinzaVolante +
  Agua + log1p_Superplast + AgregadoGraudo
  +
  AgregadoMiudo + log_Idade,
  data = dados_treino)
predicoes_t1 <- predict(modelo_t1, newdata = dados_validacao)
dados_validacao$Pred_Resistencia_t1 <- predicoes_t1
print(dados_validacao[,c("Resistencia", "Pred_Resistencia_t1")])
# erros
erro_teste_t1 <- dados_validacao$Resistencia - dados_validacao$
  Pred_Resistencia_t1
#MAPE
mape_t1 <- mean(abs(erro_teste_t1) / dados_validacao$Resistencia
  )
# R preditivo (correla o ao quadrado)
r2_pred_t1 <- cor(dados_validacao$Resistencia, dados_validacao$
  Pred_Resistencia_t1)^2
# Exibir resultados
cat("MAPE:", round(mape_t1,4), "\n",
  " R preditivo:", round(r2_pred_t1, 4), "\n")
```

```
408 dados_treino$Idade_log <- log(dados_treino$Idade)
409 dados_treino$Agua_Cimento <- dados_treino$Agua / dados_treino$
    Cimento
410 dados_treino$Cimento_Idade <- dados_treino$Cimento * dados_
    treino$Idade_log
411 dados_treino$Idade_log2 <- dados_treino$Idade_log^2
412 dados_treino$Y_sqrt <- sqrt(dados_treino$Resistencia)
413
414 modelo_t3 <- lm(Y_sqrt ~ Cimento + Escoria + CinzaVolante +
415                Agua_Cimento + Superplastificante +
416                AgregadoGraudo +
417                AgregadoMiudo + Idade_log + Idade_log2 +
418                Cimento_Idade,
419                data = dados_treino)
420
421 dados_validacao$Idade_log <- log(dados_validacao$Idade)
422 dados_validacao$Agua_Cimento <- dados_validacao$Agua / dados_
    validacao$Cimento
423 dados_validacao$Cimento_Idade <- dados_validacao$Cimento * dados
    _validacao$Idade_log
424 dados_validacao$Idade_log2 <- dados_validacao$Idade_log^2
425 dados_validacao$Y_sqrt <- sqrt(dados_validacao$Resistencia)
426
427 shapiro.test(residuals(modelo_t3))
428 bptest(modelo_t3)
429
430 predicoes_t3 <- predict(modelo_t3, newdata = dados_validacao)
431
432 # voltar para escala original
433 predicoes_t3_original <- predicoes_t3^2
434 dados_validacao$Pred_Resistencia_t3 <- predicoes_t3_original
435
436 erro_teste_t3 <- dados_validacao$Resistencia -
437                dados_validacao$Pred_Resistencia_t3
438
439 mape_t3 <- mean(abs(erro_teste_t3) /
440                dados_validacao$Resistencia)
441
442 r2_pred_t3 <- cor(dados_validacao$Resistencia,
443                dados_validacao$Pred_Resistencia_t3)^2
444 # Exibir resultados
```

```
443 cat("MAPE:", round(mape_t3,4), "\n",
444      "R    preditivo:", round(r2_pred_t3, 4), "\n")
445
446 summary(modelo_t3)
447 residuos <- residuals(modelo_t3)
448 ajustados <- fitted(modelo_t3)
449
450 par(mfrow = c(2, 1))
451
452 plot(modelo_t3, which = 2)
453 plot(ajustados, residuos,
454      xlab = "Valores Ajustados", ylab = "Res duos",
455      main = "Res duos vs Ajustados")
456 abline(h = 0, col = "red")
457
458 par(mfrow = c(1, 1))
459 # indicativo de heterocedasticidade com afunilamento no grafico
    Residuals vs Fitted
460 # Indicio de normalidade atrav s do QQplot, respeitando bem a
    linha
461
462 n <- nrow(dados_treino)
463 p <- length(coef(modelo_t3))
464
465 #D-COOK
466
467 #se eu remover essa observa o , o modelo inteiro muda muito?
468 # mede influ ncia global.
469 cooks_d <- cooks.distance(modelo_t3)
470 cook_limite_formal <- qf(0.5, df1 = p, df2 = n - p)
471 cook_influentes_formais <- which(cooks_d > cook_limite_formal)
472
473 # Limite de Cook Formal
474 round(cook_limite_formal, 6)
475
476 # N mero de pontos influentes
477 length(cook_influentes_formais)
478
479 # Nenhuma observa o apresentou dist ncia de Cook acima do
    limite formal,
```

```
480 # sugerindo ausência de pontos altamente influentes no ajuste
      global
481 # da regressão.
482
483
484
485 #mede impacto no fitted
486 dffits_vals <- dffits(modelo_t3)
487 dffits_limite <- 2 # amostras grandes
488
489 abs_dffits <- abs(dffits_vals)
490 n_dffits <- sum(abs_dffits > dffits_limite)
491 round(dffits_limite, 4)
492 n_dffits
493 par(mfrow = c(2, 1))
494 # grafico
495 plot(cooks_d, type = "h", col = ifelse(cooks_d > cook_limite_
      formal, "red", "black"),
496       main = "Distância de Cook", ylab = "Cook's D")
497 abline(h = cook_limite_formal, lty = 2, col = "blue")
498
499 plot(dffits_vals, type = "h", col = ifelse(abs(dffits_vals) >
      dffits_limite, "red", "black"),
500       main = "DFFITS")
501 abline(h = c(-dffits_limite, dffits_limite), lty = 2, col = "
      blue")
502
503 par(mfrow = c(1, 1))
```