

Análise de Regressão Linear Múltipla: Resistência à Compressão do Concreto

Matheus Brito Marcella Cobra Marcelo Huang

Universidade Federal de São Carlos – Centro de Ciências Exatas e de Tecnologia – Departamento de Estatística

Maio, 2026

- O concreto é um dos materiais de construção mais utilizados no mundo.
- A resistência à compressão é propriedade fundamental para dimensionamento estrutural.
- Depende de múltiplos fatores: proporção dos componentes da mistura e idade.
- Utilizamos o conjunto de dados do repositório UCI Machine Learning [1] (1030 observações experimentais).
- O banco de dados registra a resistência (MPa) em função de oito variáveis relacionadas à composição e à idade.

Objetivo do trabalho

Ajustar um modelo de regressão linear múltipla para explicar e prever a resistência à compressão do concreto a partir das variáveis disponíveis, avaliando:

- adequação do modelo,
- significância dos preditores,
- capacidade preditiva em dados novos.

Modelo considerado:

$$Y = X\beta + \varepsilon,$$

onde Y é a resistência à compressão (MPa) e as covariáveis são:

- X_1 : Cimento (kg/m^3)
- X_2 : Escória (kg/m^3)
- X_3 : Cinza Volante (kg/m^3)
- X_4 : Água (kg/m^3)
- X_5 : Superplastificante (kg/m^3)
- X_6 : Agregado Graúdo (kg/m^3)
- X_7 : Agregado Miúdo (kg/m^3)
- X_8 : Idade (dias)

Divisão aleatória (semente 42): treino 70% (721 obs.), teste 30% (309 obs.).

Tabela 1: Estatísticas descritivas das variáveis (treino)

Variável	Mín.	1º Quart.	Mediana	Média	3º Quart.	Máx.
Cimento	102.0	192.0	266.0	280.4	350.0	540.0
Escória	0.00	0.00	42.08	78.34	145.00	359.40
Cinza Volante	0.00	0.00	0.00	52.71	118.27	200.00
Água	121.8	164.9	185.7	181.8	193.0	246.9
Superplastificante	0.000	0.000	6.470	6.298	10.160	32.200
Agr. Graúdo	801.0	932.0	968.0	972.4	1028.4	1134.3
Agr. Miúdo	594.0	724.3	778.5	771.0	821.0	992.6
Idade	1.00	7.00	28.00	45.83	56.00	365.00
Resistência	2.332	24.065	34.770	36.090	45.940	82.599

Gráfico de dispersão




Figura 1: Gráfico de dispersão das covariáveis versus resistência à compressão

Não há evidências graves de não linearidade.

Matriz de correlação e multicolinearidade




Figura 2: Corrplot das variáveis numéricas

Tabela 2: VIF do modelo completo (8 variáveis)

Cimento	Escória	CinzaVol.	Água	Superplast.	Agr.Graúdo	Agr.Miúdo	Idade
7.733	7.801	6.518	7.073	7.073	2.953	5.102	7.119

- **Stepwise (BIC):** selecionou o modelo com Resistencia $\sim$ Cimento + Escoria + CinzaVolante + Agua + Idade.
- **Cp de Mallows:** modelo completo (8 var.) tem menor Cp; modelo com 6 var. (inclui Superplast.) tem Cp próximo (9,307).
- **LASSO:** reteve todas as variáveis, coeficientes muito pequenos para agregados.

Tabela 3: Cp de Mallows

#cov	1	2	3	4	5	6	7	8
Cp	723.82	500.48	271.82	114.13	13.18	9.30	10.79	9.00

Modelo escolhido

Considerando parcimônia e consistência entre os métodos, optou-se pelo modelo com 6 covariáveis:

Resistencia $\sim$ Cimento + Escoria + Cinza Volante + Água + Superplastificante + Idade.

- **Independência:** Como não temos a ordem da coleta, assume-se a independência. Porém: Teste de Durbin-Watson $DW = 2,0125$ ($p = 0,5691$) → resíduos independentes.
- **Normalidade:** Teste de Shapiro-Wilk $W = 0,99671$, $p = 0,1453$ → não rejeita normalidade.

Homocedasticidade e diagnóstico gráfico

- **Homocedasticidade:** Teste de Breusch-Pagan $BP = 104,01$, $p < 2,2 \times 10^{-16} \rightarrow$ rejeita homocedasticidade.
- A Figura abaixo mostra QQ-plot e resíduos vs valores ajustados, com leve padrão de funil.
- Transformações foram feitas para melhorar, iremos mostrar isso mais para frente




Figura 3: QQ-plot e resíduos vs valores ajustados

- **Resíduo studentizado**: apenas uma obs. com $|r_i| > 3$ (obs. 219).
- **Alavancagem** (h_{ii}): 57 pontos acima de $2p/n$, nenhum acima de $1/2$.
- **Distância de Cook**: nenhum ponto acima do limiar.
- **DFFITS**: nenhum ponto acima do limite.
- **DFBETAS**: com critério $2/\sqrt{n}$ detectaram-se 143 pontos; com $|\text{DFBETAS}| > 1$ nenhum influente.

Gráficos de diagnóstico de influência




Figura 4: Resíduos studentizados (esq.) e alavancagem ordenada (dir.)

Mais gráficos de influência




Figura 5: Distância de Cook (esq.) e DFFITS (dir.)

Sumário do modelo ajustado

```
1 Call:
2 lm(formula = Resistencia ~ Cimento + Escoria + CinzaVolante
   +
3   Agua + Superplastificante + Idade, data = dados_treino)
4
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	28.885497	4.935315	5.853	7.37e-09	***
Cimento	0.106108	0.005244	20.232	< 2e-16	***
Escoria	0.088490	0.005836	15.163	< 2e-16	***
CinzaVolante	0.070523	0.009198	7.667	5.76e-14	***
Agua	-0.218949	0.024562	-8.914	< 2e-16	***
Superplastificante	0.238821	0.098670	2.420	0.0158	*
Idade	0.111404	0.006350	17.544	< 2e-16	***

Residual standard error: 10.3 on 714 df

Multiple R-squared: 0.6294, Adjusted R-squared: 0.6263

F-statistic: 202.1 on 6 and 714 DF, p-value: < 2.2e-16

Interpretação dos coeficientes

- $\hat{\beta}_0 = 28.88$: sem interpretação prática (componentes zero não produzem concreto).
- $\hat{\beta}_1 = 0.106$: cada kg adicional de cimento/ $\text{m}^3 \rightarrow$ aumento estimado de ≈ 0.11 MPa na resistência (mantendo fixas as demais).
- $\hat{\beta}_2 = 0.088$, $\hat{\beta}_3 = 0.071$, $\hat{\beta}_5 = 0.239$: efeitos positivos de escória, cinza volante e superplastificante.
- $\hat{\beta}_4 = -0.219$: aumento da água reduz a resistência.
- $\hat{\beta}_6 = 0.111$: cada dia adicional na idade $\rightarrow$ aumento médio de 0.11 MPa.

Teste F parcial (Tipo III)

Tabela 4: ANOVA Tipo III

Variável	Sum Sq	Df	F value	Pr(>F)
Cimento	43427	1	409.35	<2.2e-16 ***
Escória	24392	1	229.93	<2.2e-16 ***
CinzaVolante	6236	1	58.79	5.76e-14 ***
Água	8430	1	79.46	<2.2e-16 ***
Superplast.	621	1	5.86	0.01575 *
Idade	32653	1	307.80	<2.2e-16 ***

Todas as variáveis são significativas ao nível de 5%; destaque para Cimento e Idade.

Desempenho no conjunto de teste

Métricas obtidas no conjunto de teste (309 observações):

- $RMSE = 10,6676$
- $MAE = 8,6598$
- $MAPE = 0,3324$ (33,24%)
- R^2 preditivo = 0,5745
- $RMSE(\text{treino}) = 10,2497$
- $MAE(\text{treino}) = 8,105$

Tabela 5: Primeiras previsões (teste)

Índice	Resistência real	Predição
1	44,3	59,7
2	47,0	27,3
3	47,8	21,1
4	39,4	30,2
5	37,4	31,6

Validação cruzada (5 partições, 1030 dados)

Resultados médios:

- RMSE médio = 10,4689
- R^2 médio = 0,6070
- MAE médio = 8,3318

Discussão dos Resultados

- O modelo com seis covariáveis apresenta R^2 ajustado de 62,63%.
- Pressuposto de homocedasticidade violado → limitação do modelo linear simples.
- Transformações (log, raiz, etc.) poderiam atender aos pressupostos, mas mantivemos o modelo linear por objetivos pedagógicos.
- Nenhum ponto influente compromete o ajuste.
- Capacidade preditiva: MAPE de 33,24%.
- Iremos ver transformações em seguida

Transformações Investigadas

Por tentativa e erro, foram avaliadas diferentes transformações da variável resposta e das covariáveis.

Modelo 1

$$\text{Resistencia} = \beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \text{Agua} \\ + \beta_5 \log(\text{Superplastificante} + 1) + \beta_6 \log(\text{Idade}) + \varepsilon$$

Métricas:

$$MAPE = 0.1862 \quad R^2_{\text{pred}} = 0.8287$$

Modelo 2 — que atendeu os pressupostos

$$\sqrt{\text{Resistencia}} = \beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \text{Agua} \\ + \beta_5 \frac{\text{Agua}}{\text{Cimento}} + \beta_6 \text{Superplastificante} + \beta_7 \text{AgregadoGraudo} + \beta_8 \text{AgregadoMiudo} \\ + \beta_9 (\text{Idade}) + \beta_{10} (\log \text{Idade}) + \beta_{11} (\log \text{Idade})^2 + \beta_{12} \frac{\text{Cimento}}{\text{Idade}} + \varepsilon$$

Métricas:

$$MAPE = 0.1687 \quad R^2_{\text{pred}} = 0.843$$

Modelo 3

$$\log(\text{Resistencia}) = \beta_0 + \beta_1 \text{Cimento} + \beta_2 \text{Escoria} + \beta_3 \text{CinzaVolante} + \beta_4 \frac{\text{Agua}}{\text{Cimento}}$$

$$\begin{aligned} &+ \beta_5 \text{Superplastificante} + \beta_6 \text{Superplastificante}^2 + \beta_7 \text{AgregadoGraudo} \\ &+ \beta_8 \text{AgregadoMiudo} + \beta_9 \log(\text{Idade}) \\ &+ \beta_{10} (\log(\text{Idade}) \cdot \text{Cimento}) + \varepsilon \end{aligned}$$

Métricas:

$$MAPE = 0.1781 \quad R_{\text{pred}}^2 = 0.7912$$

Modelo Escolhido


O modelo selecionado foi o **Modelo 2**, pois:

- Apresentou o maior R^2 preditivo;
- Obteve o menor MAPE;
- Satisfez adequadamente os pressupostos da regressão linear (Shapiro-Wilk com resíduos studentizados: valor-p = 0.52, Breusch-Pagan: valor-p = 0.058);
- Não apresentou observações altamente influentes;
- Os testes estatísticos indicaram significância global e parcial.

Conclusões estatísticas



- Rejeição de H_0 no teste F-global;
- Rejeição de H_0 nos testes t individuais menos menos para as covariáveis Água, Superplastificante e $\log(\text{Idade})^2$;
- Rejeição de H_0 nos testes F-parciais (Type III), menos para as covariáveis Água, Superplastificante e $\log(\text{Idade})^2$.

Diagnóstico do Modelo Escolhido




QQ-plot e gráfico de resíduos versus valores ajustados.

Resíduos studentizados e Alavancagem



Distância de Cook e estatística DFFITS.

Influência e Observações Influentes



Distância de Cook e estatística DFFITS.

Coeficientes Estimados

$$\hat{\beta}_0 = -2.9512513 \quad \hat{\beta}_1 = 0.0114770 \quad \hat{\beta}_2 = 0.0094468$$

$$\hat{\beta}_3 = 0.0075879 \quad \hat{\beta}_4 = -0.0062324 \quad \hat{\beta}_5 = -1.0606740$$

$$\hat{\beta}_6 = 0.0090825 \quad \hat{\beta}_7 = 0.0018889 \quad \hat{\beta}_8 = 0.0021576$$

$$\hat{\beta}_9 = -0.0030991 \quad \hat{\beta}_{10} = 1.2055903 \quad \hat{\beta}_{11} = -0.0039348$$

$$\hat{\beta}_{12} = -0.0009444$$

Observação

Como o modelo utiliza transformações e termos não lineares, a interpretação dos coeficientes deve ser feita com cautela, principalmente para os termos envolvendo logaritmos, razões e interações.

Principais conclusões

- O modelo de regressão linear múltipla sem transformação é estatisticamente mediano para explicar a resistência à compressão.
- A violação da homocedasticidade indica que modelos mais flexíveis (termos quadráticos, interações, aprendizado de máquina) podem ser explorados em trabalhos futuros.
- O modelo não apresenta capacidade preditiva promissora ($RMSE \approx 10,5$ MPa, $MAPE 33,24\%$).
- O modelo com transformação tem desempenho melhor. Porém seu MAPE é de 17% que é superior a 15%

- [1] I-Cheng Yeh. *Concrete Compressive Strength Data Set*. UCI Machine Learning Repository, 2007. Disponível em: <https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength>.

Bom dia pra vocês

Relatório completo disponível em PDF.