

Análise de Regressão Linear Múltipla: Resistência à Compressão do Concreto

Matheus Brito

Marcella Cobra

Marcelo Huang

17 de maio de 2026

Sumário

1	Etapa 1: Preparação e Análise Descritiva	3
1.1	Carregamento e verificação dos dados	3
1.2	Análise descritiva	4
1.3	Gráfico de dispersão	4
2	Etapa 2: Redução de Dimensionalidade e Seleção de Variáveis	5
2.1	Matriz de correlação	5
2.2	Diagnóstico de multicolinearidade (VIF)	5
2.3	Seleção de variáveis	6
3	Etapa 3: Ajuste, Diagnóstico e Pontos Influentes	6
3.1	Ajuste do modelo final	6
3.2	Diagnóstico de resíduos	6
3.2.1	Independência	6
3.2.2	Normalidade	6
3.2.3	Homocedasticidade	7
3.3	Análise de pontos influentes	7
3.4	Testes de significância formais	9
4	Etapa 4: Validação do Modelo	11
4.1	Divisão treino-teste	11
4.2	Validação cruzada (5-fold)	11
5	Conclusões	12

Etapa 0: Introdução

Este relatório apresenta a análise de um conjunto de dados sobre resistência à compressão do concreto, disponível no repositório UC Irvine [1]. O objetivo é ajustar um modelo de regressão linear múltipla para avaliar como os componentes da mistura e a idade influenciam a resistência do material.

O modelo considerado é da forma:

$$Y = X\beta + \varepsilon,$$

onde Y é a resistência à compressão (MPa) e as covariáveis são:

- X_1 : Cimento (kg/m^3)
- X_2 : Escória (kg/m^3)
- X_3 : Cinza Volante (kg/m^3)
- X_4 : Água (kg/m^3)
- X_5 : Superplastificante (kg/m^3)
- X_6 : Agregado Graúdo (kg/m^3)
- X_7 : Agregado Miúdo (kg/m^3)
- X_8 : Idade (dias)

O banco de dados original contém 1030 observações. Para validação, foi realizada uma divisão aleatória (semente 42) em conjunto de treino (721 observações, 70%) e teste (309 observações, 30%). Todas as análises foram executadas no software R.

1 Etapa 1: Preparação e Análise Descritiva

1.1 Carregamento e verificação dos dados

Os dados de treino foram carregados e inspecionados. A Tabela 1 apresenta as primeiras linhas.

Tabela 1: Primeiras observações do conjunto de treino

Cimento	Escória	CinVol	Água	Sup.plast.	Ag.Gr	Ag.Mi	Idade	Resistência
220.80	147.20	0.00	185.70	0.00	1055.00	744.30	28	25.745
249.10	0.00	98.75	158.11	12.80	987.76	889.01	14	28.682
275.00	0.00	0.00	183.00	0.00	1088.00	808.00	7	14.203

Não foram encontradas inconsistências óbvias, uma vez que os componentes do concreto são controlados.

1.2 Análise descritiva

A Tabela 2 resume as principais estatísticas das variáveis.

Tabela 2: Estatísticas descritivas das variáveis (treino)

Variável	Mín.	1º Quart.	Mediana	Média	3º Quart.	Máx.
Cimento	102.0	192.0	266.0	280.4	350.0	540.0
Escória	0.00	0.00	42.08	78.34	145.00	359.40
Cinza Volante	0.00	0.00	0.00	52.71	118.27	200.00
Água	121.8	164.9	185.7	181.8	193.0	246.9
Superplastificante	0.000	0.000	6.470	6.298	10.160	32.200
Agregado Graúdo	801.0	932.0	968.0	972.4	1028.4	1134.3
Agregado Miúdo	594.0	724.3	778.5	771.0	821.0	992.6
Idade	1.00	7.00	28.00	45.83	56.00	365.00
Resistência	2.332	24.065	34.770	36.090	45.940	82.599

1.3 Gráfico de dispersão

A Figura 1 mostra a relação entre cada covariável e a resposta. Não há evidências graves de não linearidade.




Figura 1: Gráfico de dispersão das covariáveis versus resistência à compressão

2 Etapa 2: Redução de Dimensionalidade e Seleção de Variáveis

2.1 Matriz de correlação

A Figura 2 apresenta o *corrplot* das variáveis. As correlações entre preditoras são geralmente baixas ($|<0,7|$), sugerindo ausência de multicolinearidade severa.




Figura 2: Corrplot das variáveis numéricas

2.2 Diagnóstico de multicolinearidade (VIF)

Para o modelo completo (8 variáveis), os valores do Fator de Inflação da Variância (VIF) são apresentados na Tabela 3.

Tabela 3: VIF do modelo completo

Cimento	Escória	CinzaVolante	Água	Superplast.	Agr.Graúdo	Agr.Miúdo	Idade
7.733	7.801	6.518	7.073	7.073	2.953	5.102	7.119

Todos os VIFs são inferiores a 10, indicando ausência de multicolinearidade problemática.

2.3 Seleção de variáveis

Foram aplicados três métodos:

- **Stepwise (BIC)**: selecionou o modelo com Resistencia Cimento + Escoria + CinzaVolante + Agua + Idade.
- **Cp de Mallows**: o modelo com menor Cp é o completo (8 variáveis), porém o modelo com 6 variáveis (+ Superplastificante) apresentou Cp próximo (9,307).
- **LASSO**: reteve todas as variáveis, mas com coeficientes muito pequenos para os agregados.

Considerando a parcimônia e os resultados, optou-se pelo modelo com 6 covariáveis:

Resistencia $\sim$ Cimento + Escoria + CinzaVolante + Agua + Superplastificante + Idade.

3 Etapa 3: Ajuste, Diagnóstico e Pontos Influentes

3.1 Ajuste do modelo final

O modelo foi ajustado (por mínimos quadrados) conforme a seleção realizada na Etapa 2:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \varepsilon,$$

Resumo do modelo ajustado será apresentado posteriormente em 3.4.

3.2 Diagnóstico de resíduos

3.2.1 Independência

O teste de Durbin-Watson resultou em $DW = 2,0125$ ($p = 0,5691$), indicando independência dos resíduos.

3.2.2 Normalidade

O teste de Shapiro-Wilk ($W = 0,99671$, $p = 0,1453$) não rejeita a hipótese de normalidade.

3.2.3 Homocedasticidade

O teste de Breusch-Pagan ($BP = 104,01$, $p < 2,2e-16$) rejeita a homocedasticidade. A Figura 3 mostra o QQ-plot e o gráfico de resíduos versus ajustados, onde se observa um leve padrão de funil.




Figura 3: QQ-plot e resíduos vs valores ajustados

Tentativas de transformação (log, raiz, quadrado, inverso) não resolveram a heterocedasticidade. Apenas um modelo mais complexo com $\sqrt{Y} \sim \text{Cimento} + \dots + \log(\text{Idade}) + (\log(\text{Idade}))^2$ atendeu aos pressupostos, mas por parcimônia manteve-se o modelo original.

3.3 Análise de pontos influentes

O R^2 ajustado é 0,6263 e o teste F global é significativo ($p < 2,2e-16$).

- **Resíduo studentizado:** apenas uma observação com $|\text{res}| > 3$ (observação 219).
- **Alavancagem (h_{ii}):** 57 pontos acima de $2p/n$, mas nenhum acima do critério alternativo $(1/2)$.
- **Distância de Cook:** nenhum ponto acima do limiar $F_{n,n-p,0.5}$.

- **DFFITS**: nenhum ponto acima do limite.
- **DFBETAS**: com critério $2/\sqrt{n}$ detectaram-se 143 pontos, mas com critério $|DFBETAS| > 1$ nenhum ponto influente.

As Figuras 4, 5, 6 e 7 ilustram essas medidas.




Figura 4: Resíduos studentizados




Figura 5: Alavancagem (h_{ii}) ordenada




Figura 6: Distância de Cook




Figura 7: DFFITS

3.4 Testes de significância formais

Sumário do modelo

A seguir, o resumo do modelo ajustado no R:

Call:

```
lm(formula = Resistencia ~ Cimento + Escoria + CinzaVolante +  
    Agua + Superplastificante + Idade, data = dados_treino)
```

Residuals:

Min	1Q	Median	3Q	Max
-29.277	-6.316	0.273	6.450	34.538

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	28.885497	4.935315	5.853	7.37e-09	***
Cimento	0.106108	0.005244	20.232	< 2e-16	***
Escoria	0.088490	0.005836	15.163	< 2e-16	***
CinzaVolante	0.070523	0.009198	7.667	5.76e-14	***
Agua	-0.218949	0.024562	-8.914	< 2e-16	***
Superplastificante	0.238821	0.098670	2.420	0.0158	*
Idade	0.111404	0.006350	17.544	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.3 on 714 degrees of freedom

Multiple R-squared: 0.6294, Adjusted R-squared: 0.6263

F-statistic: 202.1 on 6 and 714 DF, p-value: < 2.2e-16

Interpretação: As covariáveis são globalmente significativas, pois o valor-p do teste F global é menor que $2,2 \times 10^{-16}$, rejeitando $H_0 : \beta_1 = \beta_2 = \dots = \beta_6 = 0$.

Teste F parcial (Tipo III)

A tabela ANOVA a seguir apresenta a contribuição individual de cada covariável controlando pelas demais:

Anova Table (Type III tests)

Response: Resistencia

	Sum Sq	Df	F value	Pr(>F)	
(Intercept)	3634	1	34.2555	7.366e-09	***
Cimento	43427	1	409.3525	< 2.2e-16	***
Escoria	24392	1	229.9290	< 2.2e-16	***
CinzaVolante	6236	1	58.7851	5.762e-14	***
Agua	8430	1	79.4597	< 2.2e-16	***
Superplastificante	621	1	5.8584	0.01575	*
Idade	32653	1	307.7967	< 2.2e-16	***
Residuals	75746	714			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interpretação: Cada linha testa a contribuição de uma covariável ajustada para todas as outras. Todos os coeficientes são estatisticamente significativos ao nível de 5%. As variáveis com maior estatística F são Cimento ($F = 409,35$), Idade ($F = 307,80$) e Escória ($F = 229,93$). O superplastificante apresenta significância marginal ($F = 5,86$, $p = 0,0158$), indicando contribuição menor porém ainda relevante.

4 Etapa 4: Validação do Modelo

4.1 Divisão treino-teste

O modelo ajustado foi aplicado ao conjunto de teste (309 observações). As principais métricas preditivas são:

- RMSE = 10,6676
- MAE = 8,6598
- MAPE = 0,3324 (33,24%)
- R^2 preditivo = 0,5745

A Tabela 4 exibe as primeiras previsões.

Tabela 4: Valores observados e previstos para o conjunto de teste (primeiras linhas)

Índice	Resistência real	Predição
1	44,3	59,7
2	47,0	27,3
3	47,8	21,1
4	39,4	30,2
5	37,4	31,6

4.2 Validação cruzada (5-fold)

A validação cruzada com 5 partições, aplicada aos 1030 dados originais, resultou em:

- RMSE médio = 10,4689
- R^2 médio = 0,6070
- MAE médio = 8,3318

Os resultados da validação cruzada são consistentes com os do teste, indicando ausência de *overfitting*.

5 Conclusões

- O modelo final com 6 variáveis explica cerca de 62,6% da variabilidade da resistência à compressão no conjunto de treino.
- Todas as covariáveis selecionadas são estatisticamente significativas ($p < 0,05$), com destaque para Cimento e Idade.
- O pressuposto de homocedasticidade foi violado, sugerindo a necessidade de transformações ou modelos mais flexíveis. Mantemos o modelo pelo princípio da parcimônia e pelo valor pedagógico desse trabalho.
- Não foram identificados pontos influentes que comprometam o ajuste.
- A validação cruzada e a aplicação em teste indicam capacidade preditiva moderada (RMSE 10,5 MPa, R^2 preditivo 0,57).
- O modelo não apresenta capacidade preditiva promissora, já que em média as previsões se desviam aproximadamente 33% do valor real.
- Recomenda-se, em trabalhos futuros, explorar transformações da resposta, inclusão de termos quadráticos ou interações, e modelos alternativos (por exemplo, regressão exponencial que a fonte dos dados recomendou).

Referências

- [1] I-Cheng Yeh. *Concrete Compressive Strength Data Set*. UCI Machine Learning Repository, 2007. Disponível em: <https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength>.