

Análise do artigo "Previsão de matrículas na educação especial do Tocantins: Uma abordagem de aprendizado de máquina com o modelo ARIMA"

Letícia Yumi Ichibara - RA: 834396

Marcelo Xinhong Huang - RA: 832111

Pedro Henrique de Araujo - RA: 831235

Universidade Federal de São Carlos

8 de junho de 2026

- 1 Introdução
- 2 Revisão da Literatura
- 3 Metodologia
 - Pré-processamento de dados
 - Séries temporais
 - Estacionariedade
 - Parâmetros ARIMA
 - Resultados SARIMAX
 - Previsões
- 4 Conclusão
- 5 Críticas

- O Plano Estadual de Educação do Tocantins (PEE/TO 2015–2025) busca ampliar a qualidade e a acessibilidade da educação especial.
- Para uma gestão eficaz, é crucial prever o número de matrículas com precisão
- Previsões precisas permitem:
 - ▶ Garantir recursos adequados (pessoal qualificado, instalações acessíveis)
 - ▶ Alocar recursos financeiros de forma eficiente

- A transição do Ensino Fundamental para o Ensino Médio representou um desafio para alunos com deficiência, devido à falta de infraestrutura e pessoal treinado.
- O uso de técnicas de aprendizado de máquina e o modelo ARIMA foram citados como meios de melhorar a precisão das previsões de matrícula
- Objetivo principal: projetar o volume de matrículas na educação especial para os próximos cinco anos no estado do Tocantins
- Dados utilizados: Censo Escolar do INEP, período de 2007 a 2022

Modelo ARIMA e Séries Temporais

- O modelo ARIMA (*Autoregressive Integrated Moving Average*) é um dos métodos mais utilizados para análise de séries temporais
- Aplicado com sucesso em diversas áreas.
- Capaz de lidar com sazonalidade e autocorrelação nos dados.

Equação Geral do ARIMA

- A equação geral do modelo $\text{ARIMA}(p, d, q)$ é:

$$\Phi(B)(1 - B)^d X_t = \Theta(B)Z_t$$

- $\Phi(B)$: operador autorregressivo de ordem p
- $(1 - B)^d$: operador de diferenciação de ordem d
- $\Theta(B)$: operador de médias móveis de ordem q
- Z_t : ruído branco (erros i.i.d.)
- Os parâmetros p , d e q foram escolhidos com base nos critérios AIC e BIC e nos gráficos ACF e PACF

- O ARIMA passou a ser combinado com redes neurais artificiais (ANN), formando os modelos híbridos ARIMA-ANN, que apresentaram desempenho superior ao ARIMA tradicional.
- Na área educacional, a previsão de matrículas com esses modelos ainda se configurou como um campo emergente, mas com grande potencial para o planejamento educacional

Conjunto de dados

- O conjunto de dados utilizado foi carregado usando a biblioteca Pandas do Python e contém informações sobre a matrícula no ensino fundamental e médio de 2007 a 2022
- Não foram encontrados valores ausentes

	Ano	Mat_FundAnosFinais	Mat_EnsinoMedio
11	2018	4478	1407
12	2019	4664	1608
13	2020	5046	1923
14	2021	5224	2286
15	2022	5507	2518

Figura: Últimas linhas do conjunto de dados de matrículas da educação básica, classes especiais no estado do Tocantins

Séries temporais

- Séries temporais apresentam tendência ascendente nas matrículas ao longo do tempo




Figura: Gráfico de séries temporais das matrículas

- Teste de estacionariedade usado: teste ADF - H_0 : série tem raiz unitária (não é estacionária)
- P-valor encontrado $\approx 0,999$ - indicativos de série não-estacionária
- Após uma diferenciação para tentar retirar a tendência, p-valor encontrado foi aproximadamente 0,998 - série continua tendenciosa
- Após uma segunda diferenciação, o p-valor foi de 0,026322 - série se tornou estacionária para $y''_t = y'_t - y'_{t-1}$

Parâmetros ARIMA

- Parâmetro p : Autor escolheu o componente autorregressivo $p = 1$ baseado no gráfico PACF e com base em critérios AIC e BIC
- Parâmetro d : Como o teste ADF indicou estacionariedade após duas diferenciações, escolheu-se $d = 2$
- Parâmetro q : O decrescimento a partir do pico 1 no gráfico ACF indicou um componente de médias móveis $q = 1$




Figura: Gráfico de autocorrelação (ACF) e autocorrelação parcial (PACF)

- Apesar de usar um modelo ARIMA(1,2,1), o autor optou pelos resultados de um modelo SARIMAX pelos motivos:
 - ▶ Acomoda sazonalidade e as variáveis exógenas - modelagem mais complexa
 - ▶ Maior número de estatísticas de diagnóstico (testes Ljung-Box e Jarque-Bera)
 - ▶ Fornece intervalos de confiança - modelo mais rigoroso

Resultados SARIMAX

```
SARIMAX Results
=====
Dep. Variable:      Mat_EnsinoMedio    No. Observations:      16
Model:              ARIMA(1, 2, 1)     Log Likelihood         -80.897
Date:               Thu, 24 Aug 2023   AIC                    167.795
Time:               21:49:58           BIC                    169.712
Sample:             0                  HQIC                   167.617
Covariance Type:    opg
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ar.L1         -0.1104      1.009      -0.109    0.913     -2.089     1.868
ma.L1         -0.4003      0.814     -0.492    0.623     -1.996     1.196
sigma2        6000.8838    2977.739     2.015    0.044     164.622    1.18e+04
=====
Ljung-Box (L1) (Q):                1.23    Jarque-Bera (JB):                0.79
Prob(Q):                           0.27    Prob(JB):                  0.67
Heteroskedasticity (H):              1.73    Skew:                      0.08
Prob(H) (two-sided):                0.56    Kurtosis:                  1.85
=====
```

Figura: Resultados da aplicação do SARIMAX

- Log-verossimilhança indica ajuste razoável aos dados
- Coeficientes AR e MA são, respectivamente, $-0,1104$ e $-0,4003$, porém ambos são estatisticamente não-significativos
- O teste Ljung-Box indica que os resíduos são independentes
- O teste Jarque-Bera indica que os resíduos seguem distribuição aproximadamente normal

- Embora visto que os coeficientes AR e MA não são estatisticamente significativos, os valores da log-verossimilhança e dos critérios BIC e AIC indicam que o modelo faz um ajuste razoável aos dados
- Os testes Ljung-Box e Jarque-Bera sugerem um bom indicativo de adequação do modelo
- σ^2 grande - incerteza associada à previsões
- O autor concluiu que os resultados SARIMAX validam a escolha do modelo ARIMA(1,2,1) para prever as matrículas no ensino médio

Previsões




Figura: Gráfico de previsão de matrículas para os próximos 5 anos no Ensino Médio

Conclusão e perspectivas futuras

- Os resultados mostram um aumento contínuo nas matrículas - necessidade de acomodar mais alunos
- Modelo ARIMA se baseia no pressuposto de que as observações futuras dependem do passado - pode não ser verdade em casos de mudanças mais bruscas ou fatores externos
- Modelos mais complexos como SARIMA ou SARIMAX poderiam ser mais adequados no tocante à melhoria da precisão das previsões

- 1 Artigo bem didático quanto ao uso do modelo ARIMA na previsão das matrículas
- 2 Falta de clareza na escolha do parâmetro de médias móveis - mencionou o apoio dos critérios de informação porém não mostrou como os utilizou
- 3 Menção ao aprendizado de máquina no título do artigo, porém quase nenhuma menção ao seu uso no conteúdo da pesquisa
- 4 Coeficientes do modelo ARIMA não são estatisticamente significativos - troca de modelo talvez seria um caminho mais adequado
- 5 É mencionado que tem duas séries temporais: n^o de matrículas do ensino fundamental e do ensino médio, mas no artigo apenas a série referente ao ensino médio é ajustado com modelo ARIMA.
- 6 Erros de digitação são encontrados no artigo.