



Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Estatística

Lista 3

Séries Temporais

Componentes do Grupo:

Letícia Yumi Ichibara - 834396

Marcelo Xinhong Huang - 832111

Pedro Henrique de Araújo - 831235

Docente:

Profa. Maria Silvia de Assis Moura

Maio, 2026

Sumário

Enunciado	2
Introdução	2
1 Série 1 — Taxa de Desemprego nos EUA (1890–1988)	3
1.1 Carregamento e visualização inicial	3
1.2 Decomposição da série	6
1.3 Teste de estacionariedade	6
1.4 Transformações para estacionarizar	6
1.5 Identificação do modelo — ACF e PACF	6
1.6 Ajuste do modelo ARIMA	7
1.7 Diagnóstico dos resíduos	8
1.8 Previsão	9
2 Série 2 — Preço das Ações da Microsoft (MSFT, 2020–2026)	11
2.1 Carregamento e visualização inicial	11
2.2 Decomposição da série	14
2.3 Teste de estacionariedade	14
2.4 Transformações para estacionarizar	15
2.5 Identificação do modelo — ACF e PACF	16
2.6 Ajuste do modelo ARIMA	17
2.7 Diagnóstico dos resíduos	18
2.8 Previsão	19
Conclusão	21

Enunciado

Ajustar um modelo para duas séries.

Se quiserem, tentem ajustar modelo para alguma série de <https://finance.yahoo.com/>. Fiquem à vontade.

Introdução

Este relatório apresenta o **procedimento completo** para análise de séries temporais, seguindo a metodologia:

1. Carregamento e visualização dos dados
2. Decomposição da série
3. Teste de estacionariedade
4. Transformações (se necessário)
5. Identificação do modelo via ACF/PACF
6. Ajuste do modelo ARIMA
7. Diagnóstico dos resíduos
8. Previsão

1 Série 1 — Taxa de Desemprego nos EUA (1890–1988)

Utilizamos a série `unemp` do pacote `tseries` (conjunto de dados `NelPlo`), que contém a **taxa de desemprego anual** dos Estados Unidos de 1890 a 1988.

1.1 Carregamento e visualização inicial

O primeiro passo é **observar os dados** para entender:

- Existe **tendência** (crescimento ou queda ao longo do tempo)?
- Existe **sazonalidade** (padrões que se repetem periodicamente)?
- Há anormalidades ou *outliers*?
- A variância é **constante** ou cresce com o tempo?

```
1 Início: 1890 1
2 Fim: 1988 1
3 Frequencia: 1 observacoes/ano
4 Comprimento: 99
5
6 Resumo estatístico:
7   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
8 0.1823  1.3736  1.7047  1.7514  2.0540  3.2149
```

Listing 1: Saída — informações básicas da Série 1




Figura 1: Série original — taxa de desemprego (1890–1988).




Figura 2: Série original com média móvel sobreposta.

Observações da visualização:

- Não há uma tendência decrescente clara ao longo de todo o período. A série oscila bastante e apresenta diferentes fases de crescimento e queda.
- Existem períodos de forte variação: picos acentuados entre 1930 e 1940, e vales em torno de 1915–1920 e 1940–1945.
- A homocedasticidade não é muito evidente, já que a amplitude das oscilações parece variar ao longo do tempo, especialmente entre as décadas de 1920 e 1940.
- A série parece ter comportamento com certa periodicidade, embora não seja claramente identificável (o que é esperado para dados anuais).
- O gráfico de média móvel confirma as mesmas características.

1.2 Decomposição da série

Não é realizada a decomposição da série, pois a frequência dos dados é 1 (dados anuais) — não há sazonalidade a ser isolada.

1.3 Teste de estacionariedade

Queremos ajustar um modelo ARIMA (e não SARIMA, pois não há sazonalidade). Modelos ARIMA exigem série **estacionária** (média e variância constantes no tempo).

Para verificar a estacionariedade, aplicamos o **Teste de Dickey-Fuller Aumentado (ADF)**:

- H_0 : a série tem raiz unitária (não estacionária).
- $p < 0,05 \Rightarrow$ rejeita-se H_0 , a série é estacionária.

```
1      Augmented Dickey-Fuller Test
2
3 data:    ts_data
4 Dickey-Fuller = -3.4183, Lag order = 4, p-value = 0.0556
5 alternative hypothesis: stationary
```

Listing 2: Resultado do teste ADF — Série 1

O valor-p obtido foi 0,0556, portanto **não rejeitamos** H_0 ao nível de 5%.

1.4 Transformações para estacionarizar

O número de diferenças sugeridas pela função `ndiffs()` foi 0, indicando que os demais testes internos classificam a série como estacionária. Com o valor-p de 0,0556, e pelo **princípio da parcimônia**, optamos por considerar a série como estacionária ao nível de 10%, sem aplicar diferenciação.

1.5 Identificação do modelo — ACF e PACF

Com a série estacionária, utilizamos os correlogramas para identificar as ordens p e q :

Tabela 1: Regras de identificação por ACF e PACF.

Padrão observado	Interpretação
ACF corta no lag q , PACF decai	Processo MA(q)
PACF corta no lag p , ACF decai	Processo AR(p)
Ambos decaem gradualmente	Processo ARMA(p,q)




Figura 3: ACF e PACF da Série 1 (taxa de desemprego).

Observações da visualização:

- **ACF**: lag 1 bem alto, lags 2 e 3 ainda significativos; a partir do lag 4 entra no intervalo de confiança.
- **PACF**: lag 1 alto, lag 2 negativo e significativo; após o lag 2 fica dentro do intervalo.

Isso pode indicar que talvez o modelo seja um **ARIMA(3,0,0)**.

Contudo, no próximo passo vamos usar o `auto.arima()` para confirmação via critério de informação.

1.6 Ajuste do modelo ARIMA

```

1 Series: ts_data
2 ARIMA(1,0,1) with non-zero mean
3

```



```

4 Coefficients:
5           ar1           ma1           mean
6           0.5269      0.5546      1.7374
7 s.e.      0.1098      0.1311      0.1274
8
9 sigma^2 = 0.158:  log likelihood = -48.22
10 AIC=104.43      AICc=104.86      BIC=114.81
11
12 Training set error measures:
13
14           MASE           ME           RMSE           MAE           MPE           MAPE
15 Training set 0.004466967 0.3914123 0.2898267 -10.81206 25.33637
16           0.9151758
17
18           ACF1
19 Training set -0.04648874

```

Listing 3: Saída do auto.arima — Série 1

O `auto.arima()` selecionou o modelo **ARIMA(1,0,1)**, equivalente a um ARMA(1,1), com menor AIC em relação ao candidato ARIMA(3,0,0) levantado pelos correlogramas.

Iremos ajustar um modelo de séries temporais ARIMA(1,0,1), ou seja, um modelo ARMA (1,1) da forma

$$\Phi(B)X_t = \Theta(B)\epsilon_t,$$

com $\Phi(B) = 1 - \phi B$ e $\Theta(B) = 1 - \theta B$.

R nos diz que $\hat{\phi} = 0,5269$ e $\hat{\theta} = 0,5546$

1.7 Diagnóstico dos resíduos

Um bom modelo deve ter resíduos que se comportem como **ruído branco**: média ≈ 0 , variância constante, sem autocorrelação e distribuição aproximadamente normal.

O **Teste de Ljung-Box** verifica a ausência de autocorrelação: H_0 = resíduos sem autocorrelação; $p > 0,05$ indica modelo adequado.




Figura 4: Diagnóstico dos resíduos do modelo ARIMA(1,0,1) — Série 1 (função `sarima` do pacote `astsa`).

Conclusões do diagnóstico:

- A média dos resíduos está em torno de zero.
- Os resíduos parecem homocedásticos e aproximadamente normais.
- O Teste de Ljung-Box, aplicado para vários lags, não rejeita H_0 : os resíduos são aleatórios e independentes.

1.8 Previsão

Com o modelo validado, geramos previsões para os próximos 5 anos ($h = 5$).

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
1989	1.687894	1.178501	2.197286	0.9088450	2.466942
1990	1.711332	0.961015	2.461650	0.5638202	2.858845
1991	1.723682	0.919174	2.528191	0.4932923	2.954072

5	1992	1.730190	0.911272	2.549107	0.4777630	2.982616
6	1993	1.733618	0.910745	2.556491	0.4751422	2.992094

Listing 4: Previsões para 1989–1993 — Série 1




Figura 5: Previsão para 1989–1993 com intervalos de confiança de 80% e 95% — Série 1.

2 Série 2 — Preço das Ações da Microsoft (MSFT, 2020–2026)

Utilizamos a série `MSFT` obtida via pacote `quantmod` diretamente do Yahoo Finance, contendo o **preço ajustado de fechamento** diário da Microsoft de janeiro de 2020 a maio de 2026.

2.1 Carregamento e visualização inicial

A coluna `MSFT.Adjusted` desconta dividendos e *splits*, sendo a mais adequada para análise de série temporal financeira.

Sobre a frequência

Os dados de ações são **diários** (sem registros em fins de semana), com aproximadamente 252 pregões por ano. Utilizamos `frequency = 252` para permitir a decomposição com perspectiva anual. Para a modelagem ARIMA, o valor de `frequency` não influencia o resultado.




Figura 6: Preço ajustado de fechamento — Microsoft (2020–2026).




Figura 7: Série MSFT com média móvel sobreposta.

Observações da visualização:

- Há uma **tendência crescente** ao longo do período, com forte aceleração entre 2020–2021 e novamente a partir de 2023.
- A **variância não é constante**: a amplitude das oscilações cresce com o nível da série — comportamento típico de série **heterocedástica**, sugerindo transformação logarítmica.
- Não há evidências visuais claras de **sazonalidade**.
- Observa-se queda acentuada em 2022, possivelmente relacionada ao ciclo de alta de juros nos EUA.
- Visualmente, a série **não é estacionária**.

2.2 Decomposição da série

Com `frequency = 252`, utilizamos a decomposição **STL** (*Seasonal and Trend decomposition using Loess*) para tentar isolar um padrão sazonal anual. Para séries de preços de ações, esse componente tende a ser **fraco**, com a maior parte da variação concentrada na tendência e no resíduo.




Figura 8: Decomposição STL da série MSFT (`frequency = 252`).

2.3 Teste de estacionariedade

```
1 Augmented Dickey-Fuller Test
2
3 data: ts_msft
4 Dickey-Fuller = -2.3745, Lag order = 11, p-value = 0.4198
5 alternative hypothesis: stationary
```

Listing 5: Resultado do teste ADF — Série 2 (original)

Com valor-p de 0,4198, **não rejeitamos** H_0 : a série original não é estacionária, confirmando a necessidade de transformações.

2.4 Transformações para estacionarizar

Para séries financeiras com variância crescente, aplicamos:

1. **Transformação log** — estabiliza a variância, convertendo a série em *log-preços*.
2. **Diferenciação simples** — remove a tendência, convertendo log-preços em **log-retornos**: $r_t = \log(P_t) - \log(P_{t-1})$.

```
1 Diferencas simples sugeridas (ndiffs) : 1
2 Diferencas sazonais sugeridas (nsdiffs): 0
```

Listing 6: Número de diferenças sugeridas




Figura 9: Log-retornos diários — Microsoft (série estacionarizada).

```
1 Augmented Dickey-Fuller Test
```



```

2
3 data:  ts_logret
4 Dickey-Fuller = -11.655, Lag order = 11, p-value = 0.01
5 alternative hypothesis: stationary

```

Listing 7: Teste ADF após transformação

Com valor-p < 0,01, **rejeitamos** H_0 : a série transformada (log-retornos) é estacionária.

2.5 Identificação do modelo — ACF e PACF




Figura 10: ACF e PACF dos log-retornos diários — Microsoft.

Observações:

- A ACF apresenta autocorrelações muito próximas de zero na maior parte das defasagens, indicando baixa dependência linear.
- Apenas alguns lags isolados ultrapassam os limites de significância, sem formar um padrão persistente.

- A PACF também mostra poucos coeficientes significativos, sem corte claro que sugira um $AR(p)$ específico.
- A ausência de padrão sistemático sugere que os log-retornos podem ser aproximados por **ruído branco** — o que levaria a um $ARIMA(0,1,0)$ nos log-preços, equivalente a um *random walk*. Esse comportamento é comum em séries financeiras e é consistente com a **Hipótese do Mercado Eficiente**.

2.6 Ajuste do modelo ARIMA

O `auto.arima()` é aplicado na série de **log-preços** (não nos log-retornos), pois determina internamente o valor de d e o modelo resultante fica na escala dos log-preços, facilitando a previsão.

```
1 modelo_auto <- auto.arima(ts_log, stepwise = FALSE,
  approximation = FALSE)
2 summary(modelo_auto)
```

Listing 8: Ajuste com `auto.arima` — Série 2

```
1 Series: ts_log
2 ARIMA(1,1,0) with drift
3
4 Coefficients:
5           ar1      drift
6       -0.1445    6e-04
7 s.e.    0.0247    4e-04
8
9 sigma^2 = 0.0003431:  log likelihood = 4133.36
10 AIC=-8260.71   AICc=-8260.7   BIC=-8244.56
11
12 Training set error measures:
13
14           MAPE
15           ME      RMSE      MAE      MPE
16 Training set -5.465093e-07 0.01850475 0.01300781 -0.000224974
           0.2315613
17
18           MASE      ACF1
19 Training set 0.05616329 0.0006359506
```

Listing 9: Saída do `auto.arima` — Série 2

O `auto.arima()` selecionou o modelo **ARIMA(1,1,0) com drift**, ligeiramente diferente do random walk puro ($ARIMA(0,1,0)$) por incluir um componente $AR(1)$ e uma deriva (*drift*) positiva, capturando a tendência crescente de longo prazo.

Iremos ajustar um modelo de séries temporais ARIMA(1,1,0), da forma

$$\Phi(B)X_t = c + \epsilon_t,$$

com $\Phi(B) = 1 - \phi B$

R nos diz que $\hat{\phi} = 0.1445$ e $\hat{c} = 6e - 4$

2.7 Diagnóstico dos resíduos

Tendo um modelo ajustado ARIMA(1,1,0). Verificamos se os resíduos do modelo se comportam como **ruído branco**:




Figura 11: Diagnóstico dos resíduos do modelo ARIMA(1,1,0) — Série 2 (função sarima do pacote astsa)

Conclusões do diagnóstico:

- A média dos resíduos está em torno de zero.

- A normalidade não é perfeitamente atendida pelo QQ-plot (pontos desviados nas caudas), o que é típico de séries financeiras (caudas pesadas). O modelo ARIMA é, contudo, robusto a desvios leves de normalidade.
- O gráfico de resíduos apresenta uma estrutura diferente no final da série, indicando possível leve violação da homocedasticidade.
- O Teste de Ljung-Box, aplicado para vários lags, não rejeita H_0 : os resíduos são aleatórios e independentes.

2.8 Previsão

Geramos previsões para os próximos **30 pregões** (≈ 6 semanas) na escala de log-preços. Os valores são revertidos com $\exp(\cdot)$ para a escala original em USD.

1	<code>pred_log</code>	<code>Forecast</code>	<code>Lo 80</code>	<code>Hi 80</code>	<code>Lo 95</code>	<code>Hi 95</code>
2	7.384921	427.3352	417.2081	437.7082	411.9446	443.3008
3	7.388889	427.5890	413.3293	442.3408	405.9741	450.3548
4	7.392857	427.8360	410.4274	445.9830	401.5004	455.8990
5	7.396825	428.0846	408.0352	449.1191	397.8047	460.6694
6	7.400794	428.3454	405.9787	451.9443	394.6152	464.9587
7	...					

Listing 10: Primeiras previsões — Série 2 (USD)




Figura 12: Previsão para os próximos 30 pregões com intervalos de confiança de 80% e 95% — Microsoft (MSFT).

Conclusão

Este trabalho apresentou a análise de duas séries temporais distintas seguindo a metodologia clássica de Box-Jenkins.

A **Série 1** (taxa de desemprego anual dos EUA, 1890–1988) resultou em um modelo **ARIMA(1,0,1)**, com resíduos sem autocorrelação significativa e previsões dentro de intervalos razoáveis.

A **Série 2** (preço ajustado diário das ações da Microsoft, 2020–2026) resultou em um modelo **ARIMA(1,1,0) com drift** nos log-preços, o que é consistente com o comportamento típico de séries financeiras. Os log-retornos se comportaram próximos de ruído branco.

Referências

1. Material disponibilizado pela professora Maria Silvia de Assis Moura no classroom "Séries Temporais - 2026".
2. Conjunto de dados "NelPlo" do pacote tseries.
3. A série MSFT sobre preço ajustado de fechamento diário da Microsoft de janeiro 2020 a maio 2026, via Yahoo Finance.