

2. Analise a série `UnempRate` do pacote `astsa` do R, também disponível aqui. Aplique teste de raiz unitária, e verifique a existência ou não de outliers. Por fim, faça previsões. Essa série apresenta valores mensais de desempregados.
3. Para a série `UnempRate` Faça previsões usando algum modelo de alisamento exponencial.
4. Compare as previsões dos dois ajustes anteriores.

2. Questão 2 — Raiz Unitária, *Outliers* e ARIMA

2.1 Testes de raiz unitária

Teste	H_0	Sinal de raiz unitária
ADF	Raiz unitária	p-valor grande (não rejeita)
KPSS	Estacionária	p-valor pequeno (rejeita)

Usando R temos o seguinte resultado:

```
=== Teste ADF ===

Augmented Dickey-Fuller Test

data:  serie
Dickey-Fuller = -2.5923, Lag order = 9, p-value = 0.3276
alternative hypothesis: stationary

Interpretação ADF: p = 0.3276 → NÃO rejeita  $H_0$  → evidência de raiz unitária.

=== Teste KPSS ===

KPSS Test for Level Stationarity

data:  serie
KPSS Level = 1.8274, Truncation lag parameter = 6, p-value = 0.01

Interpretação KPSS: p = 0.01 → Rejeita  $H_0$  → evidência de raiz unitária.
```

Note que há evidências de que a série não é estacionária, possui raiz unitária.

Usando R nós descobrimos que:

```
Diferenciações sugeridas: 1

Após diferenciar (d = 1 ):
```

```
ADF  p = 0.01
KPSS p = 0.1
```

Ou seja, fizemos uma diferenciação e a série ficou estacionária.

2.2 Detecção de *Outliers*

Usamos a função `tso` do pacote "tsoutliers" do R

`tso()` testa quatro tipos de anomalia:

- **AO** (*Additive Outlier*) — pico/vale pontual isolado
- **IO** (*Innovational Outlier*) — choque que se propaga
- **LS** (*Level Shift*) — mudança permanente no nível
- **TC** (*Temporary Change*) — mudança que decai gradualmente

Resultado usando R:


```
Detectando outliers...
Series: serie
Regression with ARIMA(4,0,0)(2,1,1)[12] errors

Coefficients:
      ar1      ar2      ar3      ar4      sar1      sar2      sma1      IO325
      1.0861  0.0924 -0.0873 -0.1154  0.0408  0.0456 -0.7929  1.2694
s.e.  0.0354  0.0525  0.0519  0.0350  0.0615  0.0528  0.0481  0.2312

sigma^2 = 0.05328:  log likelihood = 35.92
AIC=-53.85  AICc=-53.62  BIC=-11.52

Outliers:
  type ind  time coefhat tstat
1  IO 325 28:01   1.269  5.49
```

Note que temos um outlier do tipo IO (Innovational Outlier). Nós vamos prosseguir com `auto.arima()` na série original, isso pode dar certo, mas ao mesmo tempo estamos deixando o outlier influenciar a escolha do modelo.



2.3 Ajuste ARIMA e Previsões

`auto.arima()` busca a ordem $(p, d, q)(P, D, Q)_s$ que minimiza o AIC.

Usando R temos:

```
Ajustando ARIMA...
Series: serie
ARIMA(3,0,1)(0,1,1)[12]

Coefficients:
      ar1      ar2      ar3      ma1      sma1
      1.6979 -0.5957 -0.1132 -0.6197 -0.7538
s.e.  0.0908  0.1312  0.0469  0.0872  0.0268

sigma^2 = 0.05448:  log likelihood = 25.3
```

```
AIC=-38.59   AICc=-38.49   BIC=-10.37
```

```
Training set error measures:
```

```
           ME      RMSE      MAE      MPE      MAPE      MASE
Training set 0.003227908 0.231003 0.1753853 -0.003109258 3.289598 0.1996076
           ACF1
Training set 0.003210108
```

Como esse modelo ARIMA(3,0,1)(0,1,1)[12] vamos ver os residuos.


Teste de Ljung-Box de lag1 a 24:

```
Ljung-Box test
```

```
data:  Residuals from ARIMA(3,0,1)(0,1,1)[12]
Q* = 21.097, df = 19, p-value = 0.3315
```

```
Model df: 5.    Total lags used: 24
```

Residuals from ARIMA(3,0,1)(0,1,1)[12]




Previsões feitas com o modelo:

=== Previsões ARIMA ===

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Dec 69	4.481716	4.182584	4.780849	4.024232	4.939200
Jan 70	5.176881	4.737010	5.616753	4.504156	5.849606
Feb 70	5.071831	4.497445	5.646218	4.193383	5.950279
Mar 70	4.920573	4.219967	5.621179	3.849089	5.992057
Apr 70	4.445259	3.626045	5.264472	3.192380	5.698137
May 70	4.583398	3.653461	5.513334	3.161183	6.005613
Jun 70	5.079853	4.047253	6.112452	3.500628	6.659078
Jul 70	5.224775	4.097624	6.351925	3.500947	6.948602
Aug 70	5.057826	3.844151	6.271500	3.201671	6.913980
Sep 70	4.816624	3.524250	6.108999	2.840108	6.793141
Oct 70	4.779136	3.415588	6.142685	2.693769	6.864504

Nov 704.7444493.3168866.1720122.5611796.927718

ARIMA — Previsão 12 meses à frente (zoom)



3. Questão 3 — Holt-Winters

Uma das opções é O método de **Holt-Winters**:

Há duas variantes:

Variante	Quando usar	Equação sazonal
Aditivo	Amplitude sazonal constante	$\hat{y} = (\ell + bh) + s$
Multiplicativo	Amplitude cresce com o nível	$\hat{y} = (\ell + bh) \times s$

Vamos ajustar **ambos** e comparar pelo AIC.

Usando R:

```

=== Holt-Winters Aditivo ===
Holt-Winters' additive method

Call:
hw(y = serie, h = h_prev, seasonal = "additive", level = c(80,
  95))

Smoothing parameters:
  alpha = 0.8539
  beta  = 0.0014
  gamma = 0.1458

Initial states:
  l = 2.5948
  b = -0.0096
  s = -0.6752 -0.3594 -0.6546 -0.2958 -0.3413 0.1712
      0.2713 -0.3058 0.2478 0.483 0.8937 0.5652

sigma: 0.2655

      AIC      AICc      BIC
3380.334 3381.090 3460.536

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE
...
AIC Aditivo      : 3380.33
AIC Multiplicativo : 3683.65

→ Modelo selecionado: Holt-Winters Aditivo

```


Pelo AIC vamos escolhero HoltWinters Aditivo.

```

Parâmetros Holt-Winters Aditivo :
  alpha (nível)      = 0.8539
  beta  (tendência) = 0.0014
  gamma (sazonal)   = 0.1458

```

Residuals from Holt-Winters' additive method



Previsões:


=== Previsões Holt-Winters Aditivo ===					
	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Dec 69	4.547868	4.207554	4.888182	4.027402	5.068334
Jan 70	5.269040	4.821238	5.716842	4.584186	5.953894
Feb 70	5.159907	4.625571	5.694243	4.342711	5.977103
Mar 70	4.968898	4.359982	5.577814	4.037642	5.900155
Apr 70	4.458090	3.782576	5.133604	3.424981	5.491200
May 70	4.576234	3.839935	5.312532	3.450162	5.702305
Jun 70	5.017027	4.224418	5.809636	3.804836	6.229218
Jul 70	5.062682	4.217342	5.908023	3.769846	6.355519
Aug 70	4.781447	3.886322	5.676572	3.412471	6.150423
Sep 70	4.458563	3.516132	5.400995	3.017239	5.899888
Oct 70	4.383499	3.395884	5.371114	2.873072	5.893926

Nov 70	4.363174	3.332219	5.394129	2.786464	5.939884
--------	----------	----------	----------	----------	----------

Previsões feitas com o modelo:

=== Previsões ARIMA ===					
	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Dec 69	4.481716	4.182584	4.780849	4.024232	4.939200
Jan 70	5.176881	4.737010	5.616753	4.504156	5.849606
Feb 70	5.071831	4.497445	5.646218	4.193383	5.950279
Mar 70	4.920573	4.219967	5.621179	3.849089	5.992057
Apr 70	4.445259	3.626045	5.264472	3.192380	5.698137
May 70	4.583398	3.653461	5.513334	3.161183	6.005613
Jun 70	5.079853	4.047253	6.112452	3.500628	6.659078
Jul 70	5.224775	4.097624	6.351925	3.500947	6.948602
Aug 70	5.057826	3.844151	6.271500	3.201671	6.913980
Sep 70	4.816624	3.524250	6.108999	2.840108	6.793141
Oct 70	4.779136	3.415588	6.142685	2.693769	6.864504
Nov 70	4.744449	3.316886	6.172012	2.561179	6.927718

Holt-Winters Aditivo — Previsão 12 meses à frente (zoom)



4. Questão 4 — Comparação: ARIMA vs Holt-Winters

Usamos **hold-out simples**: reservamos os últimos 12 meses como teste, ajustamos ambos os modelos no restante (treino) e comparamos o erro nas observações retidas.

Usando R temos as seguintes métricas:

```
Observações no treino: 815
```

```
Observações no teste : 12
```

```
Ajustando ARIMA no treino...
```


```
=== Hold-out: erros no teste (últimos 12 meses) ===
```

```
Modelo    RMSE    MAE    MAPE
```

```
1 ARIMA(3,0,1)(0,1,1)[12] 0.5466 0.5004 10.3645
2 Holt-Winters 0.2226 0.1801 3.7036
```

→ Menor RMSE no teste: Holt-Winters

Hold-out: ARIMA vs Holt-Winters — Previsão vs Realizado (zoom)



Dá pra perceber que o método de HoltWinters possui uma precisão melhor na previsão das observações.

Apêndice (códigos usados):

```
library(astsa)
library(tseries)
library(ggplot2)
library(ggfortify)
```

```
library(tsoutliers)
library(forecast)

data(UnempRate)
#library(readxl)
#dados <- read_excel("lista4.xlsx")
#serie <- ts(dados$X)
serie <- UnempRate
# Série completa
autoplot(serie) +
  ggtitle("UnempRate – Taxa Mensal de Desemprego") +
  xlab("Tempo") + ylab("Taxa de Desemprego") +
  theme_bw()

# ACF e PACF – decaimento lento da ACF indica não-estacionariedade
par(mfrow = c(1, 2))
acf(serie, lag.max = 48, main = "ACF – Série Original")
pacf(serie, lag.max = 48, main = "PACF – Série Original")
par(mfrow = c(1, 1))

adf_orig <- adf.test(serie, alternative = "stationary")
kpss_orig <- kpss.test(serie, null = "Level")

cat("=== Teste ADF ===\n")
print(adf_orig)
cat("\nInterpretação ADF: ")
if (adf_orig$p.value > 0.05) {
  cat("p =", round(adf_orig$p.value, 4), "→ NÃO rejeita H0 → evidência de raiz
unitária.\n")
} else {
  cat("p =", round(adf_orig$p.value, 4), "→ Rejeita H0 → série provavelmente
estacionária.\n")
}

cat("\n=== Teste KPSS ===\n")
print(kpss_orig)
cat("\nInterpretação KPSS: ")
if (kpss_orig$p.value < 0.05) {
  cat("p =", round(kpss_orig$p.value, 4), "→ Rejeita H0 → evidência de raiz
unitária.\n")
} else {
  cat("p =", round(kpss_orig$p.value, 4), "→ NÃO rejeita H0 → consistente com
estacionariedade.\n")
}

# ndiffs() sugere quantas diferenciações são necessárias
nd <- ndiffs(serie)
cat("Diferenciações sugeridas:", nd, "\n")

if (nd > 0) {
  serie_diff <- diff(serie, differences = nd)

  adf_d <- adf.test(serie_diff, alternative = "stationary")
```

```

kpss_d <- kpss.test(serie_diff, null = "Level")
cat("\nApós diferenciar (d = ", nd, "):")
cat("\n ADF p =", round(adf_d$p.value, 4))
cat("\n KPSS p =", round(kpss_d$p.value, 4), "\n")

autoplot(serie_diff) +
  ggtitle(paste0("Série Diferenciada (d = ", nd, ")")) +
  xlab("Tempo") + ylab("Δ UnempRate") + theme_bw()
} else {
  cat("Série já estacionária – sem diferenciação necessária.\n")
}

cat("Detectando outliers...\n")
out_res <- tso(
  serie,
  types = c("AO", "IO", "LS", "TC"),
  maxit = 10,
  delta = 0.7
)
print(out_res)

plot(out_res)

if (!is.null(out_res$outliers) && nrow(out_res$outliers) > 0) {
  cat("Outliers detectados:\n")
  print(out_res$outliers)
} else {
  cat("Nenhum outlier significativo detectado.\n")
}

cat("Ajustando ARIMA...\n")
modelo_arima <- auto.arima(
  serie,
  stepwise = FALSE,
  approximation = FALSE,
  trace = FALSE
)
print(summary(modelo_arima))

# Diagnóstico: resíduos devem ser ruído branco (Ljung-Box p > 0.05)
checkresiduals(modelo_arima)

h_prev <- 12 # horizonte: 12 meses à frente
prev_arima <- forecast(modelo_arima, h = h_prev, level = c(80, 95))

cat("=== Previsões ARIMA ===\n")
print(prev_arima)

# — Gráfico focado na previsão —————
# Mostramos apenas os últimos 36 pontos históricos + 12 de previsão
n_hist_graf <- 36
serie_zoom <- tail(serie, n_hist_graf)

```

```

df_hist_z <- data.frame(
  t = as.numeric(time(serie_zoom)),
  y = as.numeric(serie_zoom)
)
df_prev_a <- data.frame(
  t = as.numeric(time(prev_arima$mean)),
  mean = as.numeric(prev_arima$mean),
  lo80 = as.numeric(prev_arima$lower[, "80%"]),
  hi80 = as.numeric(prev_arima$upper[, "80%"]),
  lo95 = as.numeric(prev_arima$lower[, "95%"]),
  hi95 = as.numeric(prev_arima$upper[, "95%"])
)

y_min <- min(df_hist_z$y, df_prev_a$lo95) * 0.98
y_max <- max(df_hist_z$y, df_prev_a$hi95) * 1.02

ggplot() +
  geom_line(data = df_hist_z, aes(x = t, y = y),
    colour = "gray30", size = 0.9) +
  geom_ribbon(data = df_prev_a,
    aes(x = t, ymin = lo95, ymax = hi95),
    fill = "steelblue", alpha = 0.20) +
  geom_ribbon(data = df_prev_a,
    aes(x = t, ymin = lo80, ymax = hi80),
    fill = "steelblue", alpha = 0.35) +
  geom_line(data = df_prev_a, aes(x = t, y = mean),
    colour = "steelblue", size = 1.2) +
  geom_point(data = df_prev_a, aes(x = t, y = mean),
    colour = "steelblue", size = 2) +
  coord_cartesian(ylim = c(y_min, y_max)) +
  ggtitle("ARIMA – Previsão 12 meses à frente (zoom)") +
  xlab("Tempo") + ylab("Taxa de Desemprego") +
  theme_bw(base_size = 13)

# Holt-Winters aditivo
hw_add <- hw(serie, seasonal = "additive", h = h_prev, level = c(80, 95))
# Holt-Winters multiplicativo
hw_mult <- hw(serie, seasonal = "multiplicative", h = h_prev, level = c(80, 95))

cat("=== Holt-Winters Aditivo ===\n")
print(summary(hw_add$model))

cat("\n=== Holt-Winters Multiplicativo ===\n")
print(summary(hw_mult$model))

cat("\nAIC Aditivo :", round(hw_add$model$aic, 2), "\n")
cat("AIC Multiplicativo :", round(hw_mult$model$aic, 2), "\n")

# Seleciona o melhor
if (hw_add$model$aic <= hw_mult$model$aic) {
  modelo_hw <- hw_add
  tipo_hw <- "Aditivo"
} else {

```

```

modelo_hw <- hw_mult
tipo_hw    <- "Multiplicativo"
}
cat("\n→ Modelo selecionado: Holt-Winters", tipo_hw, "\n")

# Parâmetros estimados do modelo selecionado
par_hw <- modelo_hw$model$par
cat("Parâmetros Holt-Winters", tipo_hw, ":\n")
cat("  alpha (nível)      =", round(par_hw["alpha"], 4), "\n")
cat("  beta  (tendência) =", round(par_hw["beta"], 4), "\n")
cat("  gamma (sazonal)   =", round(par_hw["gamma"], 4), "\n")

# Diagnóstico dos resíduos
checkresiduals(modelo_hw)

cat("=== Previsões Holt-Winters", tipo_hw, "===\n")
print(modelo_hw)

# — Gráfico focado na previsão —————
df_prev_hw <- data.frame(
  t      = as.numeric(time(modelo_hw$mean)),
  mean   = as.numeric(modelo_hw$mean),
  lo80   = as.numeric(modelo_hw$lower[, "80%"]),
  hi80   = as.numeric(modelo_hw$upper[, "80%"]),
  lo95   = as.numeric(modelo_hw$lower[, "95%"]),
  hi95   = as.numeric(modelo_hw$upper[, "95%"])
)

y_min_hw <- min(df_hist_z$y, df_prev_hw$lo95) * 0.98
y_max_hw <- max(df_hist_z$y, df_prev_hw$hi95) * 1.02

ggplot() +
  geom_line(data = df_hist_z, aes(x = t, y = y),
    colour = "gray30", size = 0.9) +
  geom_ribbon(data = df_prev_hw,
    aes(x = t, ymin = lo95, ymax = hi95),
    fill = "darkorange", alpha = 0.20) +
  geom_ribbon(data = df_prev_hw,
    aes(x = t, ymin = lo80, ymax = hi80),
    fill = "darkorange", alpha = 0.35) +
  geom_line(data = df_prev_hw, aes(x = t, y = mean),
    colour = "darkorange", size = 1.2) +
  geom_point(data = df_prev_hw, aes(x = t, y = mean),
    colour = "darkorange", size = 2) +
  coord_cartesian(ylim = c(y_min_hw, y_max_hw)) +
  ggtitle(paste0("Holt-Winters ", tipo_hw, " – Previsão 12 meses à frente
(zoom)")) +
  xlab("Tempo") + ylab("Taxa de Desemprego") +
  theme_bw(base_size = 13)

```