

lista 4 séries

2026-06-24


Exercício 2

Teste da raiz unitária A série que iremos ajustar é a série *UnempRate*, presente no pacote *astsa* do R. Essa série representa o número de desempregados nos EUA, por mês, dos anos de 1948 até 2016.

Em primeiro lugar, iremos realizar uma breve análise da série. Para realizar futuras validações do modelo, dividiremos a base em treino-tese, sendo a base de teste os últimos 12 meses de observações.

```
## Warning: pacote 'astsa' foi compilado no R versão 4.4.3
```


Série da taxa de desempregados mensal (1948–2016)



```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    2.400  4.700   5.600   5.826  6.900   11.400
```

Agora, vamos aplicar o teste da raiz unitária para analisar a estacionariedade da série. Para isso, vamos usar o teste ADF, que analisa as hipóteses


$$\begin{cases} H_0 : \text{a s\u00e9rie possui raiz unit\u00e1ria (s\u00e9rie n\u00e3o-estacion\u00e1ria)} \\ H_1 : \text{a s\u00e9rie n\u00e3o possui raiz unit\u00e1ria (s\u00e9rie estacion\u00e1ria)} \end{cases}$$




Como $p\text{-valor} = 0,29 > 0,05$, a um n\u00edvel de signific\u00e2ncia de 5%, n\u00e3o rejeitamos H_0 e temos evid\u00eancias de que a s\u00e9rie n\u00e3o \u00e9 estacion\u00e1ria. Al\u00e9m disso, os gr\u00e1ficos de autocorrela\u00e7\u00e3o indicam que os valores demoram muito a decair, indicativo claro de tend\u00eancia.

Para resolver o problema, iremos realizar uma diferencia\u00e7\u00e3o de ordem 1 para retirar a tend\u00eancia.

Série diferenciada da taxa de desempregados mensal (1948–2016)






Feita a diferenciação, o teste ADF nos dá um $p\text{-valor} = 0,01 < 0,05$, rejeitamos H_0 e temos evidências de que a série se tornou estacionária.

Porém, analisando o gráfico de autocorrelação, se percebe um padrão sazonal nos valores a cada lag de 10-12 meses.

Desse modo, iremos realizar uma diferenciação sazonal de ordem 12 para retirar a sazonalidade da série já diferenciada.



Realizada a diferenciação sazonal, temos que o padrão temporal na autocorrelação não se torna mais tão evidente.

Verificação de outliers Nessa etapa, verificaremos se há existência de outliers na série que possam afetar o desempenho do modelo.

Usaremos a função `tsoutliers` presente no pacote `forecast`.

Verificando outliers na série, vemos pela função `tsoutliers` que não há outliers.

Ajuste do modelo Feita a detecção de outliers, ajustaremos o modelo. Como já fizemos as diferenciações, o parâmetro d será 0. Usando a função `auto.arima` para encontrar o melhor modelo, encontramos que o melhor modelo para a série diferenciada será o $ARIMA(1, 0, 2)$.

Desse modo, a série ajustada é

$$\Delta^{12}X_t = \phi_1 X_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2},$$


substituindo com os coeficientes encontrados pela função:

$$\Delta^{12}X_t = 0,7226X_{t-1} + \epsilon_t - 0,6257\epsilon_{t-1} + 0,1621\epsilon_{t-2}$$

Análise de resíduos Agora, iremos realizar o diagnóstico dos resíduos para verificar se atendem aos pressupostos desejados, que são:

- Resíduos com média próximas de zero;
- Independentes, ou seja, sem autocorrelação;
- Teste de Ljung-Box não-significativo, isto é, não-rejeição da hipótese nula $H_0 : \rho_1 = \rho_2 = \dots = 0$.

```
## initial value -1.153069
## iter 2 value -1.163679
## iter 3 value -1.193788
## iter 4 value -1.194993
## iter 5 value -1.195403
## iter 6 value -1.196573
## iter 7 value -1.198640
## iter 8 value -1.204046
## iter 9 value -1.208708
## iter 10 value -1.210072
## iter 11 value -1.210492
## iter 12 value -1.210991
## iter 13 value -1.211032
## iter 14 value -1.211032
## iter 15 value -1.211033
## iter 16 value -1.211033
## iter 17 value -1.211033
## iter 17 value -1.211033
## iter 17 value -1.211033
## final value -1.211033
## converged
## initial value -1.211400
## iter 2 value -1.211400
## iter 3 value -1.211401
## iter 4 value -1.211402
## iter 5 value -1.211403
## iter 6 value -1.211404
## iter 7 value -1.211404
## iter 7 value -1.211404
## iter 7 value -1.211404
## final value -1.211404
## converged
## <><><><><><><><><><><><><><>
##
## Coefficients:
##      Estimate      SE t.value p.value
## ar1      0.7223 0.0590 12.2415 0.0000
## ma1     -0.6253 0.0668 -9.3673 0.0000
## ma2      0.1622 0.0354  4.5799 0.0000
## xmean   -0.0019 0.0203 -0.0914 0.9272
##
## sigma^2 estimated as 0.08864817 on 798 degrees of freedom
##
## AIC = 0.4275377  AICc = 0.4276002  BIC = 0.456759
##
```



Na saída da função `sarima`, vemos que:

- Os coeficientes ϕ_1, θ_1 e θ_2 são estatisticamente significativo, pois seus p-valores são menores do que 0,05;
- A média dos resíduos padronizados é próxima de zero;
- A autocorrelação de quase todos os lags se mantém dentro dos intervalos de confiança no gráfico ACF, indicando independência dos resíduos;
- Os p-valores do teste Ljung-Box se mantêm maiores do que o nível de significância de 0,05 nos primeiros lags

Portanto, todos os pressupostos do modelo de séries temporais foram validados.

Previsões Ajustado o nosso modelo, o passo final é fazer previsões para o nosso modelo.

Usando a função `autoplot`, iremos prever os próximos 12 meses da nossa série. Observando apenas as últimas 60 observações para uma melhor visualização, temos que a previsão do próximo ano será:

Forecasts from ARIMA(1,0,2) with zero mean

