



Lista 5 Ex 2 - Análise e ajuste com modelo de alisamento exponencial da série CO2

Letícia Yumi Ichibara - RA: 834396

Marcelo Xinhong Huang - RA: 832111

Pedro Henrique de Araujo - RA: 831235

Universidade Federal de São Carlos - Departamento de Estatística

Julho de 2026

Enunciado: “Considere a série temporal ‘co2’, que registra concentrações atmosféricas mensais de dióxido de carbono. A série fornecida contém uma observação atípica inserida artificialmente. $y[250] < y[250] + 20$ ”

Sumário

1	Gráfico da série temporal e seus componentes	3
2	Verificando tendência e sazonalidade	4

3	Ajuste de um modelo de Alisamento Exponencial de Holt-Winters	5
4	Ajuste de um modelo ETS	6
5	Comparando os modelos ajustados	8
6	Análise dos resíduos dos modelos obtidos	8
7	Previsões para os próximos 24 meses	10
8	Investigando a presença de observações atípicas	11
9	Tratamento da observação atípica e reajuste dos modelos	13
10	Comparando as previsões antes e depois do tratamento	16

A série ‘co2’ (dataset nativo do R) contém as concentrações atmosféricas mensais de CO2 medidas no observatório de Mauna Loa, no Havaí, entre 1959 e 1997 – uma das séries mais conhecidas em ciência do clima, usada para ilustrar tanto tendência de longo prazo quanto sazonalidade bem definida.

Assim como no Exercício 1, um outlier artificial foi inserido na observação de índice 250, somando **20** ao valor original, um salto grande para a escala típica de variação mensal do CO2 (que costuma variar poucas unidades de ppm entre meses).

1 Gráfico da série temporal e seus componentes

O primeiro passo é sempre olhar para a série. Vamos plotar ‘y’ e, para deixar claro onde está a observação atípica, marcar o ponto correspondente ao índice 250.




Figura 1: Série temporal


Com o gráfico podemos perceber que:

- A série apresenta uma **tendência de crescimento forte, suave e aproximadamente linear** ao longo dos quase 40 anos – reflexo do aumento contínuo da concentração de CO2 na atmosfera.
- Há uma **sazonalidade anual muito regular**, associada ao ciclo de fotossíntese das plantas no hemisfério norte (concentração cai na primavera/verão, quando a vegetação absorve mais CO2, e sobe no outono/inverno).

- Diferente da série **AirPassengers**, aqui a **amplitude da sazonalidade parece bastante estável** ao longo do tempo, não crescendo proporcionalmente ao nível – um indício de que a série tem estrutura **aditiva**, sem necessidade de transformação logarítmica.
- O ponto vermelho evidencia o **outlier artificial**: um salto isolado, bem maior do que a variação mês a mês típica da série, destoando do padrão suave de tendência e sazonalidade.

2 Verificando tendência e sazonalidade

Vamos confirmar formalmente com a decomposição da série e com o ‘monthplot’, que evidencia o padrão sazonal mês a mês.



(a) Decomposição da série

(b) Gráfico de sazonalidade por mês (usando monthplot)

Figura 2: Gráficos de Decomposição e Sazonalidade

Com esses dois gráficos podemos perceber que:

- A parte de **tendência** da decomposição confirma um crescimento suave e consistente ao longo do tempo.
- A parte de **sazonalidade** mostra um ciclo anual bem definido e recorrente.
- O ‘monthplot’ reforça que cada mês tem um nível sazonal característico e consistente ao longo dos anos, sem grandes distorções.

- O componente de resíduo da decomposição fica próximo de zero na maior parte da série, exceto por um desvio isolado na posição do outlier artificial.

Em resumo, a série apresenta **tendência** e **sazonalidade** claras, e não temos a necessidade de estabilizar a variância aparentemente.

3 Ajuste de um modelo de Alisamento Exponencial de Holt-Winters

Como a série tem tendência e sazonalidade com amplitude aproximadamente constante, o modelo apropriado é o **Holt-Winters aditivo**, que estima simultaneamente nível, tendência e sazonalidade por meio de alisamento exponencial, com os parâmetros α (nível), β (tendência) e γ (sazonalidade) escolhidos para minimizar a soma dos quadrados dos erros de um passo à frente (SSE).

alpha: 0.144361999075436
 beta: 0.0103297562155283
 gamma: 0.0712100493356542
 SSE: 510.188969417399




Figura 3: Alisamento com Holt-Winters

Sobre os parâmetros, podemos dizer que:

- O parâmetro de suavização do nível ($\alpha = 0.1444$) é relativamente baixo, indicando que o nível da série é atualizado de forma gradual. Assim, o modelo atribui maior peso ao histórico do que às observações mais recentes, produzindo estimativas mais estáveis.
- O parâmetro de tendência ($\beta = 0.0103$) é bastante pequeno, sugerindo que a tendência evolui lentamente ao longo do tempo. Isso indica que o modelo considera a inclinação da série relativamente estável, realizando apenas pequenos ajustes a cada nova observação.
- O parâmetro sazonal ($\gamma = 0.0712$) também é baixo, mostrando que o padrão sazonal é consistente ao longo dos ciclos e necessita apenas de pequenas atualizações conforme novos dados são incorporados.

Além disso, o gráfico mostra que os valores ajustados acompanham de forma satisfatória a evolução da série observada, capturando seu comportamento geral, embora eventos atípicos (outliers) possam gerar desvios pontuais que não são reproduzidos pelo modelo.

4 Ajuste de um modelo ETS

O modelo **ETS** generaliza o alisamento exponencial, permitindo escolher automaticamente (por AICc) a melhor combinação de componentes de **Erro** (aditivo/multiplicativo), **Tendência** (nenhuma/aditiva/amortecida) e **Sazonalidade** (nenhuma/aditiva/multiplicativa). Usamos `ets()` do pacote `forecast`, deixando a função escolher as especificações automaticamente.

Resultado:

```
ETS(A,A,A)
```

Call:

```
ets(y = y)
```

Smoothing parameters:

```
alpha = 0.1431
```

```
beta  = 0.0019
```

```
gamma = 1e-04
```

Initial states:

```
l = 315.5741
```

```
b = 0.0701
```

```
s = -1.0294 -2.1237 -2.767 -3.1761 -1.3216 0.7938
      2.3461 2.9633 2.5179 1.3432 0.6069 -0.1534
```

```
sigma: 1.0284
```

```
      AIC      AICc      BIC
2921.420 2922.780 2991.943
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.06113233	1.010672	0.3897751	0.01747329	0.1149603	0.2898996

ACF1

Training set	0.008396864
--------------	-------------




Figura 4: Decomposição do modelo ETS

A notação do modelo escolhido **ETS(A,A,A)** informa a combinação selecionada: erro aditivo, tendência aditiva e sazonalidade aditiva, o que é coerente com o que já havíamos observado no gráfico da série (amplitude sazonal estável e tendência aproximadamente linear). O gráfico dos componentes mostra separadamente o **nível**, a **tendência (slope)** e a **sazonalidade** estimados, permitindo visualizar como cada um evolui ao longo do tempo. Assim como no Holt-Winters, o componente sazonal do ETS está bastante estável ao longo dos ciclos, e o nível segue perto da série observada, exceto no ponto do outlier.

5 Comparando os modelos ajustados

Para comparar Holt-Winters e ETS de forma justa, usamos métricas de qualidade de ajuste sobre os valores ajustados (in-sample): RMSE, MAE, MAPE (com a função ‘accuracy()’).

Tabela 1: Métricas de ajuste do modelo Holt-Winters.

ME	RMSE	MAE	MPE	MAPE (%)
0.0497	1.0578	0.4283	0.0135	0.1262

Tabela 2: Métricas de ajuste do modelo ETS.

ME	RMSE	MAE	MPE	MAPE (%)	MASE	ACF1
0.0611	1.0107	0.3898	0.0175	0.1150	0.2899	0.0084

Observa-se que o modelo ETS apresentou valores ligeiramente menores para RMSE, MAE e MAPE, indicando um ajuste marginalmente superior ao do modelo Holt-Winters. Além disso, o valor de ACF1 próximo de zero sugere que os resíduos do modelo ETS apresentam baixa autocorrelação no primeiro lag, o que constitui um indício favorável quanto à adequação do ajuste. Apesar dessas diferenças, ambos os modelos apresentaram desempenho semelhante, reproduzindo satisfatoriamente o comportamento da série.

6 Análise dos resíduos dos modelos obtidos

Vamos examinar os resíduos de cada modelo: tanto para o HW quanto para o ETS, usamos ‘checkresiduals()’ (que já inclui teste de Ljung-Box);




Figura 5: Enter Caption




Figura 6: Enter Caption

Ljung-Box test

data: Residuals from ETS(A,A,A)
 $Q^* = 2.9653$, $df = 24$, $p\text{-value} = 1$

Model df: 0. Total lags used: 24

Ljung-Box test

```
data: Residuals from HoltWinters
Q* = 2.2491, df = 24, p-value = 1
```

```
Model df: 0.    Total lags used: 24
```

Shapiro-Wilk normality test

```
data: residuals(ets_fit)
W = 0.33206, p-value < 2.2e-16
```

Shapiro-Wilk normality test

```
data: as.numeric(res_hw)
W = 0.35712, p-value < 2.2e-16
```

Em ambos os modelos, o gráfico de resíduos ao longo do tempo mostra comportamento estável em torno de zero, exceto por um pico isolado próximo à observação 250, onde é colocado o outlier artificial. Nenhum dos dois modelos de alisamento exponencial tem como "prever" um salto pontual e não estrutural. O teste de Shapiro-Wilk indicou afastamento da normalidade, novamente por causa do valor discrepante em uma única observação, que infla a assimetria e a curtose da distribuição dos resíduos.

7 Previsões para os próximos 24 meses

Com os dois modelos ajustados (ainda com o outlier presente nos dados), geramos as previsões para os 24 meses seguintes ao fim da série, com intervalos de confiança de 80% e 95%.

Holt-Winters:

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 1998	364.6493	363.2937	366.0048	362.5761	366.7224
...					
Jan 1999	366.1146	364.5639	367.6652	363.7430	368.4861
Dec 1998	365.1285	363.6076	366.6493	362.8025	367.4544
...					
Dec 1999	366.5938	364.8624	368.3251	363.9459	369.2416

EST:

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 1998	364.5142	363.1963	365.8322	362.4986	366.5299
...					
Dec 1998	364.9975	363.5168	366.4781	362.7330	367.2619
Jan 1999	365.9970	364.5004	367.4937	363.7081	368.2860
...					
Dec 1999	366.4803	364.7959	368.1646	363.9043	369.0562




Figura 7: Enter Caption

As previsões pontuais dos dois modelos estão muito próximas entre si, já que ambos capturam a mesma tendência de crescimento praticamente linear e o mesmo ciclo sazonal estável, projetando a continuidade do padrão de alta gradual com oscilação anual. A amplitude de ambos tende a crescer com o horizonte de previsão. Assim como no Exercício 1, a presença do outlier nos dados de ajuste pode inflar a incerteza estimada, alargando os intervalos de previsão além do que seria razoável para uma série tão regular quanto o CO₂.

8 Investigando a presença de observações atípicas

Vamos detectar formalmente a observação atípica, condicional a um modelo ajustado, usando a função 'tso' do pacote 'tsoutliers'. Em seguida, avaliamos o efeito estimado do outlier sobre o ajuste dos modelos.

```

Series: y
Regression with ARIMA(0,1,1)(1,1,2)[12] errors

Coefficients:
          ma1          sar1          sma1          sma2          A0250
        -0.3498      -0.5047      -0.3089      -0.4697      19.8429
s.e.      0.0498      0.5288      0.5156      0.4356      0.2269

sigma^2 = 0.08613:  log likelihood = -85.35
AIC=182.7   AICc=182.89   BIC=207.42

Outliers:
  type ind    time coefhat tstat
1   AO 250 1979:10   19.84 87.44

```




Figura 8: Gráfico que veio da função tso

A função ‘tso()’ apontou uma observação atípica do tipo AO (additive outlier) exatamente da posição 250 da série e estimou que seu efeito é de 19.84, coincidindo com o ponto em que somamos artificialmente ‘+20’. Isso valida a detecção.

Sobre efeito sobre o ajuste dos modelos: tanto o Holt-Winters quanto o ETS "absorvem" parcialmente o outlier ao atualizar o **nível** da série logo após a observação 250 (já que ambos são modelos de alisamento que reagem a cada nova observação), o que pode distorcer temporariamente o nível estimado nos períodos seguintes ao outlier, mesmo a sazonalidade e a tendência sendo pouco afetadas no longo

prazo. Isso é uma diferença importante em relação a um modelo SARIMA, que também sofre com o outlier, mas de forma distinta (via resíduos e possivelmente nas estimativas dos parâmetros MA).

9 Tratamento da observação atípica e reajuste dos modelos

Com o outlier identificado, usamos a série corrigida ('yadj', fornecida por 'tso()') para reajustar ambos os modelos, Holt-Winters e ETS.




Figura 9: Série original e a corrigida

Reajustando os modelos:

Holt-Winters:

```
alpha: 0.144361999075436
beta: 0.0103297562155283
gamma: 0.0712100493356542
SSE: 43.0819607921928
```

Shapiro-Wilk normality test

```
data: residuals(hw_fit_adj)
W = 0.99683, p-value = 0.5177
Ljung-Box test
```

```
data: Residuals from HoltWinters
Q* = 28.845, df = 24, p-value = 0.226
```

```
Model df: 0.    Total lags used: 24
```




Figura 10: Diagnóstico de residuos - HW

ETS:

ETS(M,Ad,M)

Call:

```
ets(y = y_adj)
```

Smoothing parameters:

alpha = 0.6941

beta = 0.0422

gamma = 1e-04

phi = 0.9777

Initial states:

l = 315.2905

b = 0.1221

s = 0.9972 0.9939 0.9904 0.9909 0.9963 1.0024

1.0069 1.0089 1.0074 1.004 1.0018 0.9999

sigma: 8e-04

	AIC	AICc	BIC
	1720.183	1721.706	1794.855

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.04222718	0.2791605	0.2245233	0.01232825	0.06673453	0.1773228

ACF1

Training set -0.02559317

Shapiro-Wilk normality test

data: residuals(ets_fit_adj)
W = 0.99768, p-value = 0.7704

Ljung-Box test

data: Residuals from ETS(M,Ad,M)
Q* = 25.929, df = 24, p-value = 0.3568

Model df: 0. Total lags used: 24




Figura 11: Diagnóstico de resíduos - ETS

Após o tratamento da observação atípica, os gráficos dos resíduos dos modelos Holt-Winters e ETS deixam de apresentar o pico isolado anteriormente observado na posição 250. Os testes de Shapiro-Wilk também deixam de rejeitar a hipótese de normalidade dos resíduos, enquanto os testes de Ljung-Box continuam indicando ausência de autocorrelação residual significativa.

Observa-se ainda que o tratamento do outlier influenciou a seleção automática do modelo ETS. Antes da correção, o modelo selecionado era do tipo $ETS(A,A,A)$, enquanto, após a remoção do efeito da observação atípica, o modelo escolhido passou a ser $ETS(M,Ad,M)$, com erro, tendência amortecida e sazonalidade multiplicativos. Isso sugere que a presença do outlier influenciava não apenas a estimação dos parâmetros, mas também a própria estrutura do modelo selecionado. Em contrapartida, o modelo Holt-Winters manteve essencialmente a mesma interpretação, apresentando apenas pequenas alterações nos parâmetros de suavização.

10 Comparando as previsões antes e depois do tratamento

Por fim, comparamos as previsões dos próximos 24 meses obtidas com os modelos ajustados sobre a série **original (com outlier)** e sobre a série **corrigida (sem outlier, removendo seu efeito)**, tanto para Holt-Winters quanto para ETS.

Tabela 3: Previsões pontuais – Holt-Winters

Período	Com outlier	Sem outlier	Diferença
1998.01	364,649	365,108	-0,459
1998.02	365,425	365,967	-0,542
1998.03	366,273	366,734	-0,462
⋮	⋮	⋮	⋮
1999.10	364,285	364,249	+0,037
1999.11	365,307	365,717	-0,411
1999.12	366,594	367,172	-0,578

Tabela 4: Previsões pontuais – ETS

Período	Com outlier	Sem outlier	Diferença
1998.01	364,514	365,239	-0,724
1998.02	365,398	366,087	-0,689
1998.03	366,258	367,017	-0,759
⋮	⋮	⋮	⋮
1999.10	364,495	363,928	+0,567
1999.11	365,262	365,300	-0,037
1999.12	366,480	366,598	-0,118




Figura 12: Comparação gráfica das previsões

Além de comparar a estimação pontual, vamos ver também a amplitude dos intervalos de confiança:

Tabela 5: Amplitude dos intervalos de confiança (24 meses)

Mês	HW c/out	HW s/out	ETS c/out	ETS s/out
1	4,146	1,204	4,031	1,211
2	4,190	1,356	4,073	1,507
3	4,234	1,494	4,116	1,782
4	4,279	1,623	4,160	2,048
5	4,324	1,745	4,204	2,303
6	4,370	1,861	4,248	2,546
7	4,416	1,971	4,293	2,777
8	4,462	2,078	4,339	2,998
9	4,509	2,182	4,386	3,218
10	4,556	2,282	4,433	3,451
11	4,604	2,380	4,481	3,699
12	4,652	2,475	4,529	3,947
⋮	⋮	⋮	⋮	⋮

As previsões pontuais dos modelos, antes e depois do tratamento, ficaram bastante próximas para os primeiros meses. Assim como no Exercício 1, a diferença mais evidente entre os modelos com e sem tratamento aparece na amplitude dos intervalos de confiança: os modelos ajustados sobre a série com outlier tendem a produzir intervalos **mais largos**, refletindo uma variância do erro superestimada por causa do resíduo atípico na observação 250. Isso reforça, mais uma vez, que outliers pontuais podem ter impacto limitado sobre a previsão central, mas efeito relevante sobre a quantificação da incerteza, daí a importância de sempre investigar e, quando apropriado, tratar observações atípicas antes de reportar previsões finais.

Conclusão geral

A série ‘co2’ (com outlier artificial) apresenta tendência de crescimento aproximadamente linear e sazonalidade aditiva bem definida e estável, sem necessidade de transformação de variância. Tanto o modelo de Holt-Winters aditivo quanto o modelo ETS capturam bem essa estrutura, com medidas de erro de ajuste (RMSE, MAE) muito próximas entre si. O diagnóstico de resíduos revelou a presença de um valor atípico do tipo additive outlier na observação 250; após identificá-lo e tratá-lo, ambos os modelos reajustados apresentam resíduos mais próximos de ruído branco e intervalos de previsão mais estreitos e confiáveis, com as previsões pontuais permanecendo relativamente estáveis.