

seminário séries

2026-06-27

Sumário

1. Introdução: explicação da base, importação e filtro 2016-2026
2. Análise exploratória: gráfico da série, tabela de descritivas, ACF/PACF, série decomposta
3. Estacionariedade: testes & diferenciação
4. Modelagem: verificar pressupostos atendidos, ajustar o modelo SARIMA adequado, comparação de BIC
5. Diagnóstico dos resíduos: ACF, Ljung-Box, normalidade, homocedasticidade
6. Previsão: previsão de h semanas, intervalos de confiança, comparação real
7. Validação: treino/teste, métricas de validação

1. Introdução

A análise de séries temporais é um método estatístico bem eficiente quando tratamos de dados levantados ao longo de um determinado período de tempo.

Por isso, para esse trabalho, iremos realizar uma análise completa de uma série temporal, desde as medidas descritivas, decomposição STL, identificação de outliers até ajuste de modelos ARIMA e previsões.

A série temporal escolhida para análise é a série do **número de jogadores semanais de Counter Strike 2**, um jogo de tiro multiplayer.

Nessa série, foi levantado a quantidade de pessoas que jogaram Counter Strike 2 desde que o jogo foi lançado, no dia 30 de novembro de 2011. Os dados foram obtidos da base de dados da Steam, plataforma na qual Counter Strike 2 se encontra disponível para download.


Porém, para uma análise mais focada nos últimos anos e uma precisão maior, a série foi reduzida entre os dias 1 de janeiro de 2016 e 31 de dezembro de 2025. Além disso, transformamos o número de jogadores diários, o padrão da base em que pegamos, para jogadores semanais.

2. Análise descritiva

Com a série apresentada, começaremos, agora, uma breve análise descritiva da série a fim de entender o comportamento visual da série de jogadores de Counter Strike 2 e caracterizar sua estrutura.

Para isso, iremos primeiramente visualizar a série, no período delimitado anterior.

Número de jogadores semanais de Counter Strike 2 (2016–2025)



```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 382055  599685  849719  916332 1207915 1753420
```


Analisando visualmente a série, percebemos que ela possui uma tendência crescente bem evidente, com poucos picos decrescentes que mudem o crescimento da série. Esse comportamento se dá devido ao jogo ser multijogador, ou seja, não possui fases e mantém as pessoas jogando por mais tempo.

Além disso, há vários picos evidentes ao longo do tempo, provavelmente indicativos de eventos ou atualizações no jogo para aumentar o número de jogadores.

Para verificar melhor a tendência, tanto quanto outros componentes da série, iremos decompô-la por meio da função `stl`, a qual decompõe a série em:

$$X_t = T_t + S_t + R_t,$$

em que T_t é o componente de tendência, S_t é o componente sazonal e R_t é o componente residual.




Com a série decomposta, podemos analisar seus componentes mais detalhadamente.

A tendência já age conforme o esperado, com um claro padrão crescente por todo o tempo analisado. Já a sazonalidade também é bem evidente, apresentando pico de jogadores em todo começo de ano, período de férias ou recesso, o que aumenta o número de jogadores.

Por fim, temos os resíduos, o restante da série após retirarmos a tendência e a sazonalidade. Exceto por picos em 2020 (pandemia) e 2023-2024 (lançamento do CS2), os resíduos não apresentam padrão evidente, oscilando em torno de zero com o passar do tempo.

A última análise a ser feita nessa etapa será avaliar a presença de autocorrelação e autocorrelação parcial, ferramentas para identificar a dependência temporal da série.



Analisando a autocorrelação, há um indicativo forte de tendência, uma vez que os lags decaem de forma lenta, demorando a entrar no intervalo de confiança. Isso é uma evidência para diferenciarmos a série, passo que será feito na próxima etapa.

Já a autocorrelação parcial mostra um pico do lag 1 muito próximo de 1 decaindo rapidamente para dentro do intervalo de confiança logo no próximo lag, evidenciando que a série possa ser modelado futuramente como um modelo autoregressivo de ordem 1.

3. Estacionariedade

Como analisado na última etapa, é claro que a série utilizada não é estacionária, ou seja, sua média não se mantém constante ao longo do tempo.

Além da decomposição e gráfico ACF, uma maneira mais precisa de verificar estacionariedade é por meio de dois testes estatísticos. O teste Dickey-Fuller Aumentado (ADF) e o teste KPSS.

O teste ADF tem como hipóteses:

$$\begin{cases} H_0 : \text{há raiz unitária (série não-estacionária)} \\ H_1 : \text{não há raiz unitária (série estacionária)} \end{cases}$$

enquanto o teste KPSS apresenta:

$$\begin{cases} H_0 : \text{Série estacionária} \\ H_1 : \text{Série não-estacionária} \end{cases}$$

Realizando os teste:

```
library(tseries)
```

```
## Warning: pacote 'tseries' foi compilado no R versão 4.4.3
```

```
## Registered S3 method overwritten by 'quantmod':
```

```
##   method          from
```

```
## as.zoo.data.frame zoo
```

```
adf.test(serie)
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data:  serie
```

```
## Dickey-Fuller = -3.5364, Lag order = 8, p-value = 0.03881
```

```
## alternative hypothesis: stationary
```

```
##
```

```
## KPSS Test for Level Stationarity
```

```
##
```

```
## data:  serie
```

```
## KPSS Level = 6.286, Truncation lag parameter = 6, p-value = 0.01
```

O p-valor do teste resultou em aproximadamente 0,038, ou seja, rejeitamos H_0 e temos evidências que a série é estacionária.

Entretanto, o teste KPSS resultou em um p-valor menor que 0,01, ou seja, esse teste já indica que a série não é estacionária.


Dado a divergência dos testes e o fato dos gráficos anteriores indicarem com clareza a tendência crescente da série, o caminho é diferenciar a série e refazer os testes.

Iremos fazer, então, uma diferenciação de ordem 1 na série, isto é,

$$X_t = X_t - X_{t-1}$$

```
serie_diff <- diff(serie)
```


```
plot(serie_diff, main = "Série dos jogadores de CS diferenciada",  
     xlab="Semanas", ylab="Nº de jogadores", col='darkorange3')
```



Percebemos, analisando o gráfico da série diferenciada, que após uma diferenciação a série se tornou bem mais estacionária do que a anterior, com indícios de que a média se tornou constante.

Para confirmar a suspeita de estacionariedade, realizaremos os teste ADF e KPSS novamente, juntamente com os gráficos de ACF e PACF.

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: serie_diff  
## Dickey-Fuller = -8.6564, Lag order = 8, p-value = 0.01  
## alternative hypothesis: stationary  
  
##  
## KPSS Test for Level Stationarity  
##  
## data: serie_diff  
## KPSS Level = 0.043643, Truncation lag parameter = 6, p-value = 0.1
```



Uma vez que ambos os testes indicam que a série se tornou estacionária e o gráfico ACF mostra uma queda brusca do lag 0 ao lag 1, comportamento esperado em tendência constante, temos evidências suficientes para concluir que a série dos jogadores semanais de CS2 se torna estacionária após uma diferenciação.

4. Detecção de outliers

```
library(forecast)
```

```
## Warning: pacote 'forecast' foi compilado no R versão 4.4.3
```

```
outliers2 <- tsoutliers(serie)
datas <- cs_semanal$semana


data.frame(
  posicao      = outliers2$index,
  data        = datas[outliers2$index],
  valor_orig  = as.vector(serie)[outliers2$index],
  valor_sug   = round(outliers2$replacements)
)
```

```
##   posicao      data valor_orig valor_sug
## 1    224 2020-04-13   1282040   1231996
## 2    384 2023-05-08   1753420   1523203
## 3    385 2023-05-15   1692866   1545855
```

5. Modelagem

Após analisar os componentes da série e detectar os outliers, podemos, enfim, ajustar um modelo apropriado para a nossa série temporal.

Podemos encontrar o modelo de duas maneiras diferentes: manualmente, analisando os gráficos ACF e PACF, ou pela função `auto.arima`, que ajusta o melhor modelo ARIMA encontrando aquele com o menor BIC, critério muito usado em seleção de modelos.



Em primeiro lugar, vale lembrar que esses gráficos ACF e PACF são obtidos após a diferenciação de ordem 1 da série. Logo, teremos $d = 1$ como parâmetro do modelo ARIMA.

Analisando o gráfico PACF, percebe-se que, após o lag 1, o próximo lag decai rapidamente para o intervalo de confiança. Com isso, um valor possível para o parâmetro autoregressivo seria $p = 1$.

Agora, pelo gráfico ACF, percebe-se que o lag 1 apresenta-se para fora do intervalo de confiança e o lag 2 está em cima do tracejado, ou seja, no limiar do IC. Assim, um valor para o parâmetro de médias móveis seria $q = 1$ ou $q = 2$.

Porém, é válido perceber que ambos os gráficos apresentam um comportamento sazonal a cada um ano, de acordo com a escala transformada dos gráficos. Desse modo, uma diferença sazonal de 52 semanas, isto é, um ano, seria ideal para remover a sazonalidade.

```
## Series: serie
## ARIMA(1,1,2)(0,0,1)[52]
##
## Coefficients:
##          ar1      ma1      ma2      sma1
##      -0.6346  0.7723  0.1644  0.2428
```



```

## s.e.    0.1806  0.1804  0.0462  0.0439
##
## sigma^2 = 1.763e+09:  log likelihood = -6285
## AIC=12580   AICc=12580.12   BIC=12601.28
##
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 1186.485 41788.17 28767.38 0.05205191 3.103232 0.1678357
##           ACF1
## Training set -0.004459805

```

Encontrando o melhor modelo ARIMA pelo função `auto.arima`, percebemos que aquele com menor BIC indica que

$$X_t \sim ARIMA(1, 1, 2)(0, 0, 1)[52]$$

é o melhor modelo, confirmando o ajuste manual pelos gráficos.