



Lista 5 Ex 1 - Análise e ajuste com modelo SARIMA da série AirPassengers

Letícia Yumi Ichibara - RA: 834396

Marcelo Xinhong Huang - RA: 832111

Pedro Henrique de Araujo - RA: 831235

Universidade Federal de São Carlos - Departamento de Estatística

Julho de 2026

Enunciado: “Considere a série temporal ‘AirPassengers’, que representa o número mensal de passageiros de companhias aéreas internacionais entre 1949 e 1960. A série fornecida contém uma observação atípica inserida artificialmente. $y[100] <- y[100] + 150$ ”

Sumário

1	Gráfico da série temporal e seus componentes	3
2	Verificando tendência e sazonalidade	4

3	Estabilizando a variância	5
4	ACF e PACF para identificação do modelo SARIMA	6
5	Ajuste do modelo SARIMA e justificativa	7
6	Análise dos resíduos do modelo ajustado	8
7	Previsões para os próximos 12 meses	10
8	Investigando a presença de observações atípicas	10
9	Tratamento da observação atípica e reajuste do modelo	12
10	Comparando as previsões antes e depois do tratamento	15

A série ‘AirPassengers’ é uma série mensal clássica (Box & Jenkins), com 144 observações (12 anos, de janeiro de 1949 a dezembro de 1960), representando o número total de passageiros (em milhares) de companhias aéreas internacionais.

No enunciado, é pedido que um **outlier artificial** seja inserido na observação de índice 100 (correspondente a abril de 1957), somando 150 ao valor original. Isso simula, por exemplo, um evento pontual (greve, feriado atípico, erro de registro) que distorce a série sem alterar sua estrutura temporal de fundo.

1 Gráfico da série temporal e seus componentes

O primeiro passo é sempre olhar para a série. Vamos plotar ‘y’ e, para deixar claro onde está a observação atípica, marcar o ponto correspondente ao índice 100.




Figura 1: Série temporal do número mensal de passageiros


Com o gráfico podemos perceber que:

- A série apresenta uma **tendência de crescimento clara e aproximadamente exponencial** ao longo dos 12 anos, ou seja o número de passageiros aumenta de forma consistente de 1949 a 1960.
- Há uma **sazonalidade anual bem marcada**, com picos recorrentes (tipicamente em julho/agosto, meses de férias no hemisfério norte) e vales também recorrentes.

- A **amplitude da sazonalidade cresce junto com o nível da série**, isso é, os "sobe e desce" anuais ficam maiores conforme o número de passageiros aumenta. Esse é o padrão de uma série multiplicativa, e é um **forte indício** de que a variância não é constante ao longo do tempo.
- O ponto vermelho evidencia o **outlier artificial**: um pico isolado, fora do padrão sazonal esperado para aquele mês, que não corresponde a uma mudança estrutural na série, apenas a um "salto" pontual.

2 Verificando tendência e sazonalidade

Para confirmar formalmente o que já vimos no gráfico, vamos decompor a série em seus componentes (tendência, sazonalidade e resíduo) e também visualizar o padrão sazonal mês a mês com a função 'monthplot' do pacote stats.



(a) Decomposição da série (b) Gráfico de sazonalidade por mês (usando monthplot)

Figura 2: Gráficos de Decomposição e Sazonalidade

Com esses dois gráficos podemos perceber que:

- A parte de **tendência** da decomposição confirma um crescimento suave e consistente ao longo do tempo.
- A parte de **sazonalidade** mostra um padrão que se repete a cada 12 meses, com meses de pico (verão no hemisfério norte) e meses de vale bem definidos.

- O ‘monthplot’ reforça isso: cada mês tem um nível médio distinto e uma leve tendência de alta dentro do próprio mês ao longo dos anos, mas o **ordenamento entre os meses se mantém estável**.
- O componente de resíduo da decomposição multiplicativa fica razoavelmente estável em torno de 1, exceto por um desvio isolado próximo à observação onde inserimos o outlier: isso é o que esperávamos.

Em resumo, a série apresenta **tendência** e **sazonalidade** claras

3 Estabilizando a variância

Como a amplitude da sazonalidade cresce com o nível da série, a variância **não é constante**, o que viola as premissas dos modelos SARIMA (que assumem série estacionária em variância após as diferenciações). A transformação padrão nesse caso é a logarítmica, que tende a converter um padrão multiplicativo em aditivo.

Vamos confirmar isso formalmente com o parâmetro ótimo de Box-Cox.

Nós investigamos qual é o λ usando a função **BoxCox.lambda** do R, e o resultado é $\lambda = -0.3204$ que está próximo de 0. Com esse valor de λ podemos dizer que a transformação logarítmica é apropriada (para atingir resultado ideal vamos).




Figura 3: Série temporal do número mensal de passageiros

No gráfico de ‘log(série)’, a amplitude da sazonalidade fica visivelmente mais estável ao longo do tempo, os "sobe e desce" anuais não crescem mais junto com o nível da série, como aconteciam na escala original.

Além disso, a tendência de crescimento, na escala log, fica aproximadamente linear, o que é coerente com o crescimento exponencial observado na série original.

4 ACF e PACF para identificação do modelo SARIMA

Antes de olhar para ACF/PACF, a série ainda tem tendência e sazonalidade, então não é estacionária. Precisamos diferenciar. Usamos ‘ndiffs’ para o número de diferenças não **sazonais** (d) e ‘nsdiffs’ para o número de diferenças **sazonais** (D).

Essas duas funções fizeram testes e o resultado é que elas sugerem **uma diferença sazonal ($D = 1$)** e **uma diferença não sazonal ($d = 1$)**, o que é o padrão esperado de séries mensais com tendência e sazonalidade forte, como essa do contexto.




Figura 4: Série temporal do número mensal de passageiros

A série diferenciada oscila em torno de zero, sem tendência nem crescimento aparente da variância, um bom indício de **estacionariedade**. Ainda assim, note que temos saltos próximos à posição do outlier, isso nós mostra que a diferenciação




Figura 5: Gráfico de ACF e PACF

não remove o efeito de uma observação atípica pontual, apenas a estrutura de tendência/sazonalidade.

Interpretação do ACF/PACF:

Na parte não sazonal (lags 1, 2, 3, ...), observa-se um corte após o lag 1 na ACF, com decaimento mais suave na PACF, esse padrão sugere um componente MA(1) não sazonal ($q = 1$).

Na parte sazonal (lags 12, 24, 36, ...), há um pico destacado na ACF no lag 12, com decaimento na PACF nos múltiplos de 12, o que sugere um componente MA(1) sazonal ($Q = 1$).

Além disso não temos indícios para incluir algum componente AR, já que o ACF não decai suavemente e temos mais de um pico sinificativo no PACF que seria o efeito do componente MA(1).

Assim o nosso modelo seria:

$$\text{SARIMA}(0, 1, 1)(0, 1, 1)_{12}$$

Vamos usar esse modelo como candidato principal, mas comparando com uma busca automática ('auto.arima') para confirmar a escolha.

5 Ajuste do modelo SARIMA e justificativa

Ajustamos o modelo indicado pela análise de ACF/PACF, SARIMA(0, 1, 1)(0, 1, 1)₁₂, diretamente sobre a série original em escala de passageiros, usando 'lambda' para

que a transformação Box-Cox seja aplicada internamente para obter um resultado ideal em vez de só aproximar com log. Assim descobrimos que o `auto.arima` retornou o mesmo modelo indicado pela análise de ACF/PACF

```
Series: y
ARIMA(0,1,1)(0,1,1)[12]
Box Cox transformation: lambda= -0.3203622
```

```
Coefficients:
          ma1      sma1
      -0.5869  -0.7051
s.e.    0.0755   0.0703
```

```
sigma^2 = 7.578e-05:  log likelihood = 432.76
AIC=-859.52  AICc=-859.33  BIC=-850.9
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.8778165	18.13763	9.955496	-0.3128954	3.298529	0.290222

```
ACF1
Training set -0.05270148
```

Então vamos adotar com o modelo $SARIMA(0, 1, 1)(0, 1, 1)_{12}$ como modelo final.

Justificativa:

O modelo identificado manualmente a partir do ACF/PACF, $SARIMA(0, 1, 1)(0, 1, 1)_{12}$, corresponde exatamente ao modelo escolhido por ‘`auto.arima`’ com base em AICc, o que reforça a validade da leitura visual dos correlogramas. E ambos os componentes $d = 1$ e $D = 1$ eliminam a tendência e a sazonalidade, e os termos $MA(1)$ não sazonal e $MA(1)$ sazonal capturam as autocorrelações residuais de curto prazo e no lag sazonal, respectivamente.

6 Análise dos resíduos do modelo ajustado

Um bom modelo deve deixar resíduos que se comportem como ruído branco (sem autocorrelação, com média zero e, idealmente, aproximadamente normais). Usamos ‘`checkresiduals()`’, que já reúne o gráfico dos resíduos, o ACF dos resíduos, o histograma e o teste de Ljung-Box:

Ljung-Box test

```
data:  Residuals from ARIMA(0,1,1)(0,1,1)[12]
```





Figura 6: Gráfico de diagnóstico

$Q^* = 15.8$, $df = 22$, $p\text{-value} = 0.8257$

Model df : 2. Total lags used: 24

Shapiro-Wilk normality test

```
data: residuals(fit_manual)
W = 0.88813, p-value = 5.134e-09
```

studentized Breusch-Pagan test

```
data: residuals(fit_manual) ~ t_index
BP = 0.26928, df = 1, p-value = 0.6038
```

- O gráfico de resíduos ao longo do tempo mostra comportamento estável em torno de zero, exceto por um pico isolado exatamente na posição correspondente à observação 100, o efeito do outlier artificial "vaza" para os resíduos, já que o modelo SARIMA não tem como prever um salto pontual e não estrutural.
- O ACF dos resíduos fica praticamente dentro das bandas de confiança na maioria dos lags, indicando que o modelo capturou bem a estrutura de autocorrelação. O teste de Ljung-Box (valor- $p = 0.8257$) afirma que não tem evidências de presença da autocorrelação ao nível de 5%.

- O teste de Shapiro-Wilk indicou afastamento da normalidade, novamente influenciado pelo valor discrepante em uma única observação.
- O teste de Breusch-Pagan(valor-p = 0.6038) nos diz que a transformação foi adequada para estabilizar a variância.

7 Previsões para os próximos 12 meses

Com o modelo ajustado (ainda com o outlier presente nos dados), vamos gerar as previsões para os 12 meses seguintes ao fim da série (ano de 1961), com intervalos de confiança de 80% e 95%.

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 1961	453.7456	419.6122	491.6428	402.9091	513.4052
Feb 1961	431.1917	396.7768	469.6600	380.0196	491.8689
Mar 1961	499.1737	454.7705	549.4851	433.3645	578.8465
Apr 1961	523.3605	473.4113	580.5099	449.5030	614.1222
May 1961	518.6376	466.7454	578.4269	442.0335	613.7893
Jun 1961	606.6283	540.1149	684.3975	508.7769	730.9397
Jul 1961	702.3882	618.6317	801.7906	579.5936	862.0000
Aug 1961	700.8300	614.1540	804.4157	573.9575	867.5138
Sep 1961	580.7742	510.4291	664.5059	477.7115	715.3445
Oct 1961	506.2523	445.4471	578.5137	417.1340	622.3314
Nov 1961	432.6924	381.5626	493.2710	357.7024	529.9144
Dec 1961	489.2268	427.5885	563.1598	399.0786	608.3291

Note que :

As previsões pontuais seguem o padrão de tendência crescente e sazonalidade da série, projetando novos picos em torno de julho/agosto de 1961.

Os intervalos de confiança de 80% e 95% ficam relativamente estreitos, mas sua amplitude pode ser inflada pelo outlier: como o modelo estima a variância do erro usando todo o histórico de resíduos, e o resíduo na observação 100 é anormalmente grande, o desvio-padrão do erro fica superestimado, tornando os intervalos mais largos do que seriam com dados "limpos". Voltaremos a este ponto na seção 10.

8 Investigando a presença de observações atípicas

Até aqui, nós identificamos "visualmente" a presença do outlier (que foi inserido por nós). Em uma análise real, isso é feito de forma **formal e automática**, por exemplo com a função 'tso' o pacote 'tsoutliers', que testa a presença de diferentes




Figura 7: Previsão dos 12 meses seguintes

tipos de anomalias (AO:additive outlier, LS: level shift, TC: transient change, entre outras) em cada observação da série, condicional ao modelo ARIMA ajustado.

```
Series: y
Regression with ARIMA(0,1,1)(0,1,0)[12] errors
```

Coefficients:

	ma1	A0100	A0135
	-0.2598	153.4911	-43.9838
s.e.	0.0865	6.0190	8.4762

```
sigma^2 = 116.7: log likelihood = -496.15
AIC=1000.31 AICc=1000.62 BIC=1011.81
```

Outliers:

	type	ind	time	coefhat	tstat
1	AO	100	1957:04	153.49	25.501
2	AO	135	1960:03	-43.98	-5.189

A função ‘tso()’ conseguiu apontar duas observações atípicas do tipo AO (additive outlier), sendo uma delas é da posição 100 da série, o ponto onde inserimos artificialmente ‘+150’.

O tipo AO é o esperado aqui: trata-se de um efeito pontual, que afeta uma única observação e não se propaga para os períodos seguintes, diferente de um level shift




Figura 8: Série Original e a corrigida

(LS, mudança permanente de patamar) ou de uma transient change (TC, efeito que decai aos poucos). Isso é coerente com a forma como o outlier foi construído no enunciado ($y[100] <- y[100] + 150$).

O tamanho estimado do efeito (coeficiente do outlier) ficou próximo de 150, o valor que somamos artificialmente, uma boa validação de que o método de detecção funcionou corretamente.

Além dessa observação atípica artificial, também é detectada outra: da posição 135 que possui um efeito estimado de -43.98. Pode ser que naquele mês tenha acontecido algum evento atípico que diminuiu a quantidade de passageiros.

9 Tratamento da observação atípica e reajuste do modelo

Temos dois outliers: observação da posição 100 e da posição 135. Considerando essas duas observações, o próximo passo poderia ser: remover seu efeito da série (sem descartar a observação, apenas corrigindo o valor distorcido) e reajustar o modelo SARIMA sobre a série tratada. Isso é equivalente colocar o parâmetro 'xreg' no ajuste do modelo já que os dois são do tipo AO.

O objeto retornado por `tso()` já fornece a série ajustada (`yadj`), que substitui o efeito estimado do outlier pelo valor que a série "deveria" ter, mantendo a estrutura temporal intacta.

No gráfico, as duas séries são praticamente idênticas em todos os pontos, exceto




Figura 9: Comparação: série original vs série tratando outliers

exatamente na posição do outlier, onde a série corrigida (azul) volta a acompanhar o padrão sazonal esperado, enquanto a série original (vermelha) mostra o salto artificial e um outro de razões desconhecidas.

Agora reajustamos o mesmo modelo, $SARIMA(0, 1, 1)(0, 1, 1)_{12}$, sobre a série corrigida usando 'xreg'.

Series: y

Regression with $ARIMA(0, 1, 1)(0, 1, 1)_{12}$ errors

Box Cox transformation: $\lambda = -0.3203622$

Coefficients:

	ma1	sma1	A0100	A0135
	-0.4030	-0.5950	0.0523	-0.0156
s.e.	0.0935	0.0733	0.0048	0.0054

$\sigma^2 = 4.291e-05$: log likelihood = 473.08

AIC=-936.15 AICc=-935.67 BIC=-921.78

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.6063763	9.32866	7.057657	-0.150354	2.623412	0.2057444

ACF1

Training set 0.03938314




Figura 10: Gráfico de diagnóstico de resíduo

Ljung-Box test

```
data: Residuals from Regression with ARIMA(0,1,1)(0,1,1)[12] errors
Q* = 27.326, df = 22, p-value = 0.1991
```

Model df: 2. Total lags used: 24

Shapiro-Wilk normality test

```
data: residuals(fit_adj)
W = 0.97921, p-value = 0.02751
```

Após o tratamento do outlier, o gráfico de resíduos ao longo do tempo não apresenta mais o pico isolado que víamos antes, e os resíduos ficam mais homogêneos, sem o salto pontual em torno da observação 100.

O teste de Ljung-Box e o diagnóstico do ACF dos resíduos indicaram comportamento mais próximo de ruído branco, e o teste de Shapiro-Wilk mostrou que temos uma maior aderência à normalidade do que no modelo ajustado sobre a série com outlier. (dá para aceitar normalidade ao nível de 1% agora)

Conclusão essa parte: o tratamento do outlier melhora a qualidade do ajuste e a validade dos pressupostos do modelo, sem alterar a especificação SARIMA escolhida, apenas adicionamos o parâmetro 'xreg'.

10 Comparando as previsões antes e depois do tratamento

Por fim, comparamos as previsões dos próximos 12 meses obtidas com o modelo ajustado sobre a série original (com outlier) e com o modelo ajustado levando em conta os efeitos dos outliers.




Figura 11: Comparação visual das duas previsões, lado a lado

Tabela 1: Comparação entre as previsões com e sem tratamento dos outliers.

Período	Com outlier	Sem outlier	Diferença
1961.1	453.75	451.90	1.84
1961.2	431.19	426.47	4.72
1961.3	499.17	507.03	-7.86
1961.4	523.36	496.87	26.49
1961.5	518.64	514.87	3.77
1961.6	606.63	597.39	9.23
1961.7	702.39	691.89	10.50
1961.8	700.83	689.38	11.45
1961.9	580.77	570.32	10.45
1961.10	506.25	502.25	4.00
1961.11	432.69	430.39	2.30
1961.12	489.23	482.14	7.09

Além disso podemos comparar as amplitudes de intervalos de confiança:

Tabela 2: Comparação da amplitude dos intervalos de previsão com e sem tratamento dos outliers.

Período	Com outlier	Sem outlier
1961.1	110.50	79.10
1961.2	111.85	85.61
1961.3	145.48	120.37
1961.4	164.62	129.03
1961.5	171.76	146.42
1961.6	222.16	190.20
1961.7	282.41	244.50
1961.8	293.56	257.11
1961.9	237.63	211.47
1961.10	205.20	187.73
1961.11	172.21	160.29
1961.12	209.25	192.94

Podemos dizer que:

As previsões **pontuais** (a média prevista) dos dois modelos ficaram próximas, já que um outlier reflete apenas em uma observação isolada, longe do fim da série, e o componente MA(1) tem memória curta, ou seja, seu efeito sobre o nível previsto é pequeno.

A diferença mais importante aparece na **amplitude dos intervalos de confiança**: como o modelo ajustado sobre a série com outlier superestima a variância do erro (por causa do resíduo anormalmente grande na observação 100), seus intervalos de previsão tendem a ser mais largos do que os do modelo ajustado considerando outliers. Isso ilustra um ponto importante em séries temporais: mesmo quando um outlier pontual não desloca muito a previsão central, ele pode **inflar a incerteza estimada** e comprometer a interpretação prática dos intervalos de confiança, daí a importância dos itens anteriores.

Conclusão geral

A série ‘AirPassengers’ (com outlier artificial) apresenta tendência de crescimento e forte sazonalidade multiplicativa, tratadas respectivamente por diferenciação não sazonal ($d = 1$) e sazonal ($D = 1$) após transformação logarítmica. O modelo SARIMA(0, 1, 1)(0, 1, 1)₁₂ se ajusta bem à série, mas o diagnóstico de resíduos revela a presença de um valor atípico do tipo **additive outlier** na observação 100. Após identificar e tratar esse outlier, o modelo reajustado apresenta resíduos

mais próximos de ruído branco e intervalos de previsão mais estreitos e confiáveis, embora as previsões pontuais permaneçam praticamente inalteradas.